



بهار ۱۴۰۵

گزارش تمرین علوم شناختی رفتاری

تمرین: طراحی آزمایش، تحلیل داده‌ها و مدل‌سازی محاسباتی
مرتضی ملکی‌نژاد شوشتری - ۸۱۰۱۰۴۲۵۶

مقدمه

این گزارش سه بخش دارد. در بخش اول قسمت طراحی آزمایش توضیح داده می‌شود. در بخش دوم تحلیل‌های روی داده‌های داده شده توضیح داده می‌شوند و در بخش سوم مدل‌هایی که روی داده آموزش دیده‌اند تا رفتار شرکت کنندگان را تقلید کنند تحلیل می‌شوند.

بخش اول: طراحی آزمایش

روند کلی آزمایش طبق خواسته سوال پیاده‌سازی شد. در اینجا چون سوال فقط پیاده‌سازی خواسته، خیلی توضیحی وجود ندارد. تنها جایی که در نتایج ممکن است تفاوت ایجاد کند، ستون‌های ذخیره شده است.

پارامترهای ذخیره‌شده

داده‌های ذخیره‌شده برای هر آزمودنی در جدول ۱ آمده‌اند.

جدول ۱: پارامترهای ذخیره‌شده در فایل خروجی

نام ستون	توضیح
block	شماره بلوک (۱، ۲ یا ۳)
trial	شماره دور در بلوک
choice	کارت انتخاب شده (۰ تا ۳)
outcome	نتیجه (win/lose)
choice_rt	زمان واکنش انتخاب (ثانیه)
confidence_level	سطح اطمینان (۱ تا ۵)
confidence_rt	زمان واکنش اعلام اطمینان
card_probs	لیست احتمالات کارت‌ها

دلایل انتخاب پارامترها

◇ شماره بلوک و شماره دور مشخص می‌کنند که آزمودنی در کدام مرحله بوده است و می‌توان روند او را با این پارامترها دنبال کرد.

◇ کارت انتخاب شده و نتیجه آن برای تحلیل یادگیری

◇ زمان واکنش برای بررسی اطمینان آزمودنی و بررسی تغییرات آن در دورها

◇ سطح اطمینان از ورودی‌های سوال است.

◇ احتمالات کارت‌ها برای تحلیل رفتار آزمودنی

بخش دوم: تحلیل داده‌های رفتاری

ساختار داده‌ها

داده‌های داده شده شامل داده‌های ۴۰ آزمودنی (۲۰ مرد و ۲۰ زن) در پوشه‌های جداگانه است. تنها تفاوت قابل مشاهده‌ای که در این داده‌ها دیده شد این است که بلوک سوم بجای ۴۵ دور، شامل ۶۰ دور می‌باشد. برای بارگذاری داده، همه داده‌ها در یک Dataframe قرار گرفتند که یک ستون جنسیت نیز دارد. پس از بارگذاری و پردازش، ستون‌های زیر به داده‌ها اضافه شدند:

◇ **block**: شماره بلوک بر اساس شماره‌ی trial

◇ **trial_in_block**: شماره دور در هر بلوک (شروع از ۱)

◇ **chosen_probability**: احتمال پاداش کارت انتخاب شده


◇ **optimal_choice**: آیا انتخاب بهینه بوده است (۱/۰)

◇ **rewarded**: آیا پاداش دریافت شده است (۱/۰)

تحلیل‌های توصیفی

توزیع متغیرها

توزیع پارامترهای توزیع در شکل ۱ آمده است. مشاهده می‌شود که اکثر پارامترهای زمانی شکلی شبیه به توزیع نمایی دارند و در باقی پارامترهای نیز تعادل خوبی برقرار است. البته پارامترهایی که ناشی از انتخاب کاربر هستند، مثل `outcome`, `chosen_probability`, `rewarded` و غیره، یک چولگی به سمت راست داریم. زیرا شرکت‌کنندگان تلاش داشتند تا بهترین گزینه را انتخاب کنند. همچنین یک مورد جالب در توزیع متغیر `choice` است که نشان می‌دهد که تعداد دفعات انتخاب کارت چهارم از باقی کارت‌ها کمی کمتر است. این مورد می‌تواند نشان دهد که تمایل شرکت‌کنندگان به کارت‌های اولی بوده که می‌دیدند.




شکل ۱: توزیع پارامترهای مختلف مجموعه داده

تغییرات در طول دورها

◇ تعداد انتخاب هر احتمال:

در شکل ۲ می‌توان تعداد انتخابات هر احتمال را براساس تعداد دور دید. اگر به دورهای اول نگاه کنیم، مبینیم که تقریباً هر چهار احتمال دفعات مشابهی انتخاب شده‌اند و نظم خاصی مشاهده نمی‌کنیم. ولی در دورهای آخر می‌توان دید که کارتهای با احتمال بیشتر، تعداد بیشتری انتخاب شده‌اند. یعنی شرکت‌کنندگان توانسته‌اند تشخیص بدهند که کدام کارت بهینه‌تر است و آن را بیشتر انتخاب کردند.


یک نکته جالب، ریزش نمودار در دورهای ۱۵ و ۴۵ است. می‌توان دید که علیرغم این‌که انتخاب کارتهای محتمل‌تر در این دورها می‌ریزد (زیرا بلوکهای جدید شروع می‌شوند.) ولی به سرعت دوباره بعد از تعداد کمی دور کارتها مرتب می‌شوند. حتی این سرعت مرتب شدن از سرعت اولیه بیشتر است. که این موضوع نشان می‌دهد که شرکت‌کنندگان با بازی آشنا شده‌اند و راحت‌تر می‌توانند کارتهای بهتر را پیدا کنند.



شکل ۲: توزیع پارامترهای مختلف مجموعه داده

◇ **میزان اطمینان شرکت کنندگان در گذر زمان:** سه مورد می‌تواند نشان دهد که چقدر شرکت کنندگان در انتخاب خود شک داشتند و یا همچنان کارت ایده‌آل را پیدا نکرده‌اند. زمان واکنش انتخاب کارت، زمان واکنش انتخاب اطمینان و میزان اطمینانی که گزارش می‌دهند. هر سه این موارد در شکل ۳ آمده است. می‌توان دید که هرچه جلوتر می‌رویم زمان واکنش کمتر و میزان اطمینان بیشتر می‌شود. البته این روند کلی روی دوره‌های ۱۵ و ۴۵ شکسته می‌شود زیرا بلوک‌های جدید شروع شده‌اند ولی به زودی به روند خود باز می‌گردد.


می‌شود دید حتی بعد از اینکه یک بلوک جدید شروع می‌شود، مقدار زمان واکنش به شکل توزیع قبل بر می‌گردد. یعنی اگر پیک زدن نمودار در خود دور را در نظر بگیریم، انگار آزمودنی پس از دور ۱۵ نیز مشابه قبل از آن رفتار کرده و دوباره مقادیر از پایه شروع نمی‌شوند. البته نمودار اطمینان به این صورت نیست و در نمودار اطمینان می‌توان دید پس از شروع هر بلوک، نمودار تقریباً روند یکسانی را طی می‌کند. این مورد نشان می‌دهد که احتمالاً تغییرات زمان واکنش بیش از آنکه به علت یافتن کارت درست بوده باشد به خاطر آشنایی با بازی است.



شکل ۳: مقدار میانگین اطمینان و زمان واکنش در گذر دورها


◇ **تحلیل برد-بمان باخت-تغییر کن:** در جستجوهای که انجام شد یکی از تحلیل‌هایی که انجام می‌شود تحلیل برد-بمان باخت-تغییر کن است.^۱ این مورد نشان می‌دهد که در بین شرکت کنندگانی که انتخابشان پاداش گرفته چند درصد همچنان گزینه قبلی را انتخاب کرده‌اند و در بین شرکت کنندگانی که کارشان پاداشی نگرفته است، چند درصد اقدام به عوض کردن کارت کرده‌اند. در شکل ۴ این دو مقدار در طول دورها نشان داده شده‌اند. می‌توان دید که بعد از دوره‌های اولیه، دیگر تقریباً نسبت این مقادیر یکی است. این موضوع بعداً در بحث مدلسازی کاربر مهم است زیرا به نوعی یک تعادل از explore-exploit به ما می‌دهد. با ماندن روی کارت درست ما exploit بیشتری داریم و با رفتن از کارت اشتباه explore می‌کنیم. البته حتی در explore اینجا نیز به نوعی exploit مطرح است. زیرا احتمال اینکه کارتی که پاداش نداده کارت خوبی باشد کمتر است.

^۱ Win stay - Lose shift



شکل ۴: نمودار برد-بمان باخت تغییر کن


◇ **پراکندگی انتخاب‌ها:** در شکل ۵ می‌توان آنتروپی ۵ انتخاب اخیر هر آزمودنی را دید. این نمودار درواقع نشان می‌دهد که هر آزمونی چه قدر انتخاب‌های خود را تغییر داده است. مشابه نمودار ۴ می‌توان در اینجا نیز دید پس از یک پیک اولیه دیگر میانگین آنتروپی خیلی تغییری نکرده است. ولی داده جدیدی که این نمودار دارد واریانس آنتروپی است. می‌توان دید که در دوره‌های بالا علیرغم تغییر نه چندان زیاد میانگین ولی واریانس زیاد تغییر می‌کند. (تا دور ۳۰ حدوداً) یعنی افراد در دوره‌های اول برای مثال یک یا دو شیفت داشتند ولی در دوره‌های بالا یا شیفت‌های کمتری داشتند زیرا یا کارت بهینه را پیدا کردند و یا به دنبال آن بوده‌اند.




شکل ۵: نمودار آنتروپی انتخاب‌ها

◇ **نرخ انتخاب بهینه:** همانطور که در شکل ۶ می‌توان دید، نرخ انتخاب کارت ۰.۷ از حدود احتمال تصادفی (۰.۲۵) که در اوایل بوده به حدود ۰.۴ تا ۰.۶ می‌رسد. این نمودار درواقع همان نمودار ۲ است که فقط خط مربوط به کارت ۰.۷ نشان داده شده است و می‌توان نرخ تغییرات آن را دقیق‌تر دید.

یک نمودار دیگر که این موضوع را نشان می‌دهد، نمودار ۷ است. به واضح می‌توان دید که نمودار پاداش تقریباً همان نمودار پاداش بهینه‌است که شیفت خورده. و به میانگینی حدود ۰.۶ می‌رسد. یعنی یادگیری که گفته شد فقط برای این کارت نبوده و در مقدار کلی پاداش اثر دارد.




شکل ۶: نمودار ریت انتخاب کارت 0.7



شکل ۷: نمودار ریت انتخاب کارت 0.7 و تعداد پاداش‌های آزمودنی‌ها

همچنین در ۸ می‌توان دید که احتمالات از حالت برابر در دوره‌های اولیه به این رسیده‌اند که احتمال انتخاب کارت‌های بهتر بیشتر است. این همان موضوعی است که درباره نمودار ۲ گفته شد. منتها در آن نمودار تمرکز بر تغییرات هر کارت بود ولی در اینجا می‌توان نسبت را در هر دور مشاهده کرد.



شکل ۸: نمودار انتخاب هر احتمال در هر دور

آزمون T

در آخر برای اینکه موضوع یادگیری بصورت آماری بررسی شود، به روی میانگین rewarded دو آزمون T پیاده‌سازی شد. فرض بر این است که توزیع پارامتر rewarded یک توزیع برنولی است. اگر کاملاً بصورت تصادفی عمل می‌کنیم، پارامتر این توزیع برنولی برابر با میانگین احتمالات یعنی 0.55 است.

در اولین آزمون فرض صفر این است که هیچ یادگیری رخ نداده و میانگین همان 0.55 است. این موضوع روی داده‌های ۱۵ دور اول و ۱۵ دور آخر تست شد و با $\alpha = 0.05$ این فرض نتوانست برای دوره‌های اول رد شود ولی برای دوره‌های آخر رد شد.

دومین آزمون بررسی می‌کند که میانگین توزیع پارامتر rewarded تغییر کرده است یا خیر. یعنی یک تست paired داریم. با بررسی این موضوع فرض صفر که می‌گویند توزیع تغییر نکرده است رد شد.

نتایج این تست‌ها در جدول ۲ آمده است.

جدول ۲: مقادیر p value در تست‌هایی که انجام شد.

Distribution	H0	H1 P Value	H0 rejected
First 15 rounds $p = 0.55$	$p > 0.55$	0.12	no
First 15 rounds $p = 0.55$	$p > 0.55$	0.00005	yes
First and last 15 rounds paired $p_{first} = p_{last}$	$p_{last} > p_{first}$	0.0159	yes

بخش سوم: مدل‌سازی محاسباتی

معرفی مدل‌ها

مدل‌های Q-Learning با سه تابع سیاست مختلف پیاده‌سازی شدند.

$$Q_{t+1}(a) = Q_t(a) + \alpha \cdot (r_t - Q_t(a)) \quad (1)$$

که در آن:

$Q_t(a)$: ارزش تخمینی برای عمل a در زمان t ◇

α : نرخ یادگیری (Learning Rate) ◇

r_t : پاداش دریافت شده ◇

سیاست‌های انتخاب عمل

۱. Softmax:

$$P(a) = \frac{\exp(\beta \cdot Q(a))}{\sum_i \exp(\beta \cdot Q(i))} \quad (2)$$

که β پارامتر دما (Temperature) است. هرچه قدر این مقدار بیشتر باشد مدل کمتر explore می‌کند و بیشتر حریصانه عمل می‌کند.

۲. Epsilon-greedy: با احتمال ϵ یک عمل تصادفی و با احتمال $1 - \epsilon$ بهترین عمل انتخاب می‌شود.

۳. UCB (Upper Confidence Bound):

$$UCB(a) = Q(a) + \beta \cdot \sqrt{\frac{\ln(N)}{n_a}} \quad (3)$$

که در آن N تعداد کل انتخاب‌ها و n_a تعداد دفعات انتخاب عمل a است. یعنی این مدل علاوه بر اینکه سعی می‌کند تا بهترین کار را انجام بدهد، به عمل‌هایی که کمتر انجام شده وزن بیشتری می‌دهد تا مدل هم explore کند و هم exploit

روش برازش مدل‌ها

برای هر شرکت‌کننده و هر بلوک، سه مدل با توابع سیاست مختلف برازش شدند. فرایند برازش شامل موارد زیر بود:

۱. بهینه‌سازی پارامترها با روش L-BFGS-B


۲. استفاده از ۲۰ شروع تصادفی برای یافتن بهینه‌ی سراسری

۳. محاسبه‌ی معیارهای AIC و BIC برای مقایسه‌ی مدل‌ها

جدول ۳: مقایسه ی معیارهای نیکویی برازش مدل ها


سیاست	NLL میانگین	AIC میانگین	BIC میانگین
Softmax	34.56	75.12	79.33
Epsilon-greedy	226.92	459.85	464.05
UCB	592.15	1190.30	1194.50

نتایج نشان می دهد که مدل Softmax با اختلاف زیادی بهترین عملکرد را دارد. همچنین توزیع این معیارها در شکل ۹ آمده است. می توان دید که مدل softmax هم بهترین میانگین و هم بهترین واریانس را دارد و پس از آن مدل حریصانه و بعد مدل UCB قرار دارد.



شکل ۹: توزیع معیارها در هر مدل

اگر بجای این معیارها، تعداد mismatch های بین مدل و آزمودنی را در نظر بگیریم، به شکل ۱۰ می رسیم. می توان دید که همچنان ترتیب حفظ شده ولی مدل ها بهم نزدیک تر هستند. این مورد نشان می دهد که برای این امتیاز مدل های epsilon-greedy و UCB کمتر شده که احتمالاً در پیش بینی احتمالات کارت های انتخاب نشده ضعیف تر بوده اند. همچنین می توان دید که مدل ها تا حد خوبی توانایی شبیه سازی رفتار انسان را دارند. مثلاً مدل softmax بطور میانگین تنها در حدود ۱۲ مورد نتوانسته حدس را درست پیش بینی کند.



شکل ۱۰: توزیع mismatch ها در هر مدل


توزیع پارامترها

توزیع پارامترها در شکل ۱۱ آمده است. رفتار عجیب مدل UCB را می‌توان مشاهده کرد که برخلاف انتظار که یک مدل شبیه نرمال را انتظار داریم عمدتاً توزیع‌هایی است که در میانگین چگالی کمتری وجود دارد. این موضوع برای نرخ یادگیری softmax هم وجود دارد. در مقابل، مدل egreedy رفتار نرمال‌تری از خود نشان می‌دهد.

◇ می‌توان دید که α در softmax توزیع نسبتاً یکنواختی دارد و تنها در میانگین کمی چگالی کمتری دارد. این موضوع می‌تواند نشان دهد که در هر وضعیت مدل یا نمی‌خواسته چیزی یاد بگیرد و یا نیاز به یادگیری شدید بوده. این موضوع در سیاست UCB نیز با شدت بیشتر مشاهده می‌شود. که توزیع بجای یک توزیع نرمال یک توزیع دو مدی است. این نشان می‌دهد که هر شرکت کننده چقدر از کار خود اثر می‌برد. اگر فرد تنها از وضعیتی که می‌بیند تصمیم خود را عوض کند، به α بالا می‌رسیم ولی اگر فارغ از نتیجه عمل کند α پایین خواهد بود.

در مقابل مدل egreedy نسبتاً توزیع نرمالی دارد. این موضوع می‌تواند به این خاطر باشد که در سیاست egreedy مقدار ϵ می‌تواند روی α اثر بگذارد و برای همین شکل این توزیع فرق کرده است.

◇ β می‌توان دید که برای پارامتر β سیاست softmax یک چولگی به سمت مقادیر کمتر دارد که نشان می‌دهد افراد همواره به دنبال این نیستند که یک انتخاب ثابت (و احتمالاً بهترین انتخابی که فکر می‌کنند) را هی تکرار کنند. نمود دیگری از این موضوع را میشد در نمودار آنتروپی دید. اما در سیاست UCB مجدد می‌بینیم که یک توزیع دومدی داریم. این موضوع در اینجا به نظر من به این علت است که سیاست UCB در این سوال نمی‌تواند به خوبی رفتار افراد را تقلید کند و از همین رو بهینه‌ساز مجبور به کاوش حالات حدی پارامتر شده است.



شکل ۱۱: توزیع پارامترها در هر مدل

معیارهای بررسی

معیارهای aic , nll و bic مورد بررسی قرار گرفتند. همراه با تعداد mismatch ها.

◇ **nll**: این معیار همان negative log likelihood است که نشان می‌دهد که چقدر احتمالات باهم تفاوت داشتند.

◇ **AIC**: این معیار علاوه بر بررسی برازش مدل، پیچیدگی مدل را جریمه می‌کند. زیرا ممکن است یک مدل به علت پیچیدگی بیشتر بتواند احتمال را بهتر تخمین بزند ولی لزوماً الگوی داده را یاد نگرفته باشد. برای همین علاوه بر nll مقدار را با منفی تعداد پارامترها جمع می‌کند.

$$AIC = 2k - 2\ln(\hat{L}) \quad (۴)$$

که k تعداد پارامترها و $\hat{L}$ بیشینه‌ی تابع درستنمایی است.

◇ **BIC**: این مورد مشابه AIC است. با این تفاوت که از انجایی که سایز مدل ثابت است ولی nll با تعداد داده زیاد می‌شود، در داده زیاد AIC به همان nll متمایل می‌شود. پس برای حل این مشکل تعداد پارامترها را در لگاریتم تعداد داده ضرب می‌کند.

$$BIC = k \ln(n) - 2\ln(\hat{L}) \quad (۵)$$

که n تعداد نقاط داده است.

در این مسئله خاص این معیارها خیلی باهم تفاوت ندارند. زیرا پیچیدگی مدل‌ها تقریباً برابر است و حجم داده نیز کم است. برای همین در نمودارها عمدتاً فقط مقیاس فرق می‌کند و ترتیب و نسبت فاصله بین مدل‌ها برابر است.

مدل Softmax در هر معیاری بهترین مدل است. این نشان می‌دهد که شرکت‌کنندگان از یک سیاست انتخاب نرم‌افزاری (Probabilistic) پیروی می‌کنند تا یک سیاست قطعی.

نتیجه‌گیری

با استفاده از مدل‌های محاسباتی می‌شد فهمید که شرکت‌کنندگان بیشتر از یک روش احتمالاتی پیروی کرده‌اند تا یک روش قطعی. باتوجه به نمودار ۵ می‌شد دید که روند به این‌صورت نبوده که $exploit$ و $explore$ جدا صورت گرفته باشد (مثلاً اول همه کارت‌ها را امتحان کنند و بعد از شناسایی کارت بهینه تنها آن را انتخاب کنند). بلکه همواره شرکت‌کنندگان بین انتخاب‌های مختلف سوییچ کرده‌اند. البته با پیروی از مواردی مثل win stay lose shift. همچنین این سوییچ کردن در جهت بهتر کردن میانگین کلی بوده است و بصورت تصادفی نبوده است.