



پاییز ۱۴۰۴

# استنباط آماری

تمرین دوم

مرتضی ملکی نژاد شوشتری - ۸۱۰۱۰۴۲۵۶

## سوال ۱

### A: Pipeline Pressure Monitoring System

a

داریم:

$$p(\bar{x}_n - z_{\frac{\alpha}{2}} \sigma_{\bar{x}_n} < \mu < \bar{x}_n + z_{\frac{\alpha}{2}} \sigma_{\bar{x}_n}) \approx 1 - \alpha$$

$$\sigma_{\bar{x}_n} = \frac{s(n)}{\sqrt{n}} = 2.5 \Rightarrow p(75358 - 2.5 z_{2.5} < \mu < 75358 + 2.5 z_{2.5}) \xrightarrow{z_{2.5}=1.96} p(75353.1 < \mu < 75362.9) \Rightarrow$$

95% confidence interval: [75353.1, 75362.9]

کار بهتر این است که بجای توزیع  $Z$  از توزیع  $T$  استفاده شود، ولی باتوجه به اینکه  $n$  از ۳۰ بزرگتر است و توزیع  $T$  تفاوت کمی با  $Z$  دارد و در درس نیز از توزیع  $Z$  استفاده شده، از توزیع  $Z$  استفاده شد.

b

گزینه ۴. چیزی که بازه اطمینان می گوید این است که احتمال این که این بازه شامل میانگین باشد چقدر است. به بیان ملموس تر، در توزی عهایی که می توانند همچنین نمونه برداری ای داشته باشند، میانگین ۹۵ درصد آن ها در این بازه است.

c

عملا باید حاصل  $\frac{z_{2.5} * s(n)}{\sqrt{n}}$  از یک کوچکتر شود. پس داریم:

$$\sqrt{n} \geq 25 * 1.96 \Rightarrow \sqrt{n} \geq 49.0 \Rightarrow n \geq 2401$$

پس برای اینکه حدود بازه اطمینان از میانگین ۱ واحد اختلاف داشته باشند با فرض این که در تلاش های مجدد نیز واریانس نمونه ۲۵ باشد، باید سائز نمونه حداقل ۲۴۰۱ باشد.

## B: Smart Vending Machine Calorie Monitoring

a

طبق قضیه CLT و باتوجه به اینکه  $n$  از ۳۰ بزرگتر است، توزیع Sample mean یک توزیع نرمال می‌باشد. برای میانگین توزیع، دو گزینه در اختیار است؛ ۱۰۰ و ۱۰۲.۲۵ مقدار ۱۰۲.۲۵ از یک نمونه‌برداری بدست آمده و نمی‌تواند مقدار میانگین را بدرستی تخمین بزند. در اینجا با فرض درست بودن ادعا توزیع بدست می‌آید و سپس در قسمت بعد با بازه اطمینان میزان درستی این فرض چک می‌شود. برای واریانس ولی چون واریانس جامعه موجود است، می‌توان انحراف معیار Sample mean را براحتی بدست آورد:

$$\sigma = 5 \Rightarrow \sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} = \frac{5}{6}$$

پس در نهایت می‌توان گفت توزیع Sample mean یک توزیع از نوع  $Normal(100, \frac{5}{6})$  می‌باشد.

b

باید مقدار  $\sigma_{\bar{x}z}$  را حساب کرد. مقدار انحراف معیار در قسمت قبل محاسبه شد؛ مقدار  $Z$  نیز طبق جدول برابر ۱.۹۶ می‌باشد. پس داریم:

$$\sigma_{\bar{x}z} = \frac{5}{6} * 1.96 = 1.6\bar{3} \Rightarrow P(98.3\bar{3} < \mu < 101.6\bar{3}) \approx 0.95$$

همچنان احتمال دارد که این نمونه از پنج درصد مواردی باشد که در بازه نمی‌گنجد، ولی حداقل می‌توان به آن مشکوک شد. برای نظر دادن با احتمال بالاتر نیاز به نمونه‌های بیشتری می‌باشد.

c

صرفاً ضریب  $Z$  بیشتر می‌شود و بازه بزرگ‌تر می‌شود.

$$\frac{5}{6} * 2.33 \approx 1.94 \Rightarrow P(-1.94 < \mu - 100 < 1.94) \approx 98 \Rightarrow P(98.6 < \mu < 101.94) \approx 98$$

d

چون هدف یافتن بازه میانگین جامعه از روی میانگین estimator می‌باشد، برای این که احتمال قرارگیری میانگین در بازه بیشتر باشد، بازه باید بخش بیشتری از مقادیر ممکن را پوشش دهد.

## C: Smart Health Kiosk Temperature Screening

a

بازه گفته شده یک بازه متقارن حول میانگین است. فاصله دوسر بازه از میانگین برابر  $98.93 - 98.2 = 0.73$  می‌باشد که برابر با انحراف معیار می‌باشد. طبق قاعده  $99.7 - 95 - 68$  احتمال وجود داده در این بازه حدود ۶۸ درصد می‌باشد.

b

داریم:

$$Z\_Score = \frac{x - \mu}{\sigma} = \frac{96.8 - 98.2}{0.73} = \frac{1.4}{0.73} \approx 1.92$$

که نزدیک به  $2\sigma$  می باشد. یعنی احتمال کمتر بودن دمای یک فرد از این مقدار حدود 2.5 درصد می باشد. بدون دانستن توزیع های شرطی افراد برای سالم بودن نمی توان به طور دقیق گفت که فرد سالم است یا خیر، ولی با توجه به احتمال کم این دما، بررسی بیشتر می تواند مفید باشد.

**c**

درواقع باید مقدار  $\alpha$  را در نامساوی  $P(t < \alpha) \leq 0.03$  چون توزیع نرمال است می توان آن را به توزیع نرمال استاندارد تبدیل کرد:

$$P\left(\frac{t - \mu}{\sigma} < \alpha\right) \leq 0.03 \Rightarrow P\left(\frac{t - 98.2}{0.73} < -1.88\right) = 0.3 \Rightarrow \frac{t - 98.2}{0.73} \leq -1.88 \Rightarrow 98.2 - t \geq 1.88 * 0.73 \Rightarrow t \leq 98.2 - 1.88 * 0.73 \Rightarrow \max(t) = 96.8276$$

**d**

**a**

خیر درست نیست. درواقع این می گوید به احتمال ۹۵ درصد، افراد بین ۵.۲ تا ۳.۸ درصد سود خواهند کرد؛ ولی چون این بازه درواقع امید سود را تخمین می زند، اعضای جامعه سرمایه گذاران نیستند، بلکه پروژه می باشد و فقط یک پروژه می باشد، یعنی افراد درصد سود یکسانی خواهند داشت (یا ضرر) و توصیف دقیقتر این بازه این می باشد که «با احتمال ۹۵ درصد سوددهی پروژه بین ۵.۲ تا ۳.۸ درصد خواهد بود».

**b**

این توصیف از توصیف قبلی کمی دقیق تر می باشد ولی کلمه «احتمال» درست معنی نشده. احتمال بودن سود در آن بازه به این معنی نیست که به ازای هر ۱۰۰ تکرار «دقیقا» ۹۵ مورد آن در آن بازه باشد، ممکن است با داده هر ۱۰۰ سال نیز افراد همچنین سودی نکنند. مثل یک سکه که با این که احتمال رو شدن هر طرف برابر است، ممکن است ۱۰ بار پشت سر هم رو بیاید. همچنین ۹۵ درصد موارد این بازه را تولید نخواهند کرد، بلکه هرکدام ممکن است بازه مختلفی را تولید کنند.

**c**

احتمال این که سود بین ۵.۲ تا ۳.۸ درصد باشد ۹۵ درصد می باشد. یعنی از هر ۱۰۰ پروژه به طور میانگین سود ۹۵ پروژه در این بازه خواهد بود.

## E: Smart Waste Management and Recycling Program

**a**

$$\hat{\sigma}^2 = p_{sample}(1 - p_{sample}) = 0.62 * 0.38 = 0.2356$$

**b**

$$SE(\hat{p}) = \sqrt{\frac{\hat{\sigma}}{n}} = \sqrt{\frac{0.2356}{500}} \approx 0.0217$$

طبق CLT می‌توان انتظار داشت که توزیع  $p$  در نمونه‌ها یک توزیع نرمال باشد. در صورت سوال میانگین توزیع (0.62) حساب شده و در قسمت b نیز انحراف معیار توزیع حساب شده. پس داریم:

$$P(\mu_n - \sigma_n z < \mu < \mu_n + \sigma_n z) \Rightarrow P(0.62 - 0.0217 * 1.96 < \mu < \mu + 0.0217 * 1.96) \\ \Rightarrow P(0.5775 < \mu < 0.6625) \approx 0.95$$

(چون انحراف معیار نمونه جایگذاری شده نیازی به تقسیم بر  $\sqrt{n}$  نیست.)

باتوجه به بازه بدست آمده با احتمال خوبی هدف انجام شده (البته نمی‌توان به طور قطعی یا حتی با احتمال ۹۵ درصد این را گفت).

## سوال ۲

### A: Theoretical Foundation


$$\sigma Z = 1.96 * \sqrt{\frac{p(1-p)}{N}} \Rightarrow CI = [p - 1.96\sqrt{\frac{p-p^2}{N}}, p + 1.96\sqrt{\frac{p-p^2}{N}}]$$

### B: Monte Carlo Verification

با شرایط گفته شده، در بین آزمایش‌های انجام شده، 95.727 درصد موارد در بازه محاسبه شده بودند.

### C: Time Series Visualization

برای محاسبه ترند می‌توان از میانگین نمایی استفاده کرد.



شکل ۱: نمودار پراکندگی و میل درصد طرفداران هر نماینده.

در شکل ۱ می‌توان دید که با گذر زمان نرخ تغییرات بیشتر است و علاوه بر این، تاثیر مکمل بودن درصد ها در نمودار مشخص است.

## E: Total Sample Size

درمجموع اطلاعات 1940931 رای دهنده در مجموعه آمده است.

## F: Aggregate Proportions

جدول ۱: تعداد و نسبت طرفداران هر کاندید

|            | Trump      | Clinton    | Total     |
|------------|------------|------------|-----------|
| Count      | 787,694.91 | 885,299.02 | 1,940,931 |
| Proportion | 40.58%     | 45.61%     | 100%      |

## G: Confidence Intervals for Both Candidates

با استفاده از فرمولی که در بخش اول حساب شد می‌توان بازه اطمینان را حساب کرد.

Trump :  $CI \approx [0.405, 0.407]$

Clinton :  $CI \approx [0.455, 0.457]$

## سوال ۳

در هر مورد باید بررسی شود با میل کردن  $n$  به سمت بینهایت، مقدار  $\frac{1}{n}S_n$  به سمت  $1 - p$  میل می‌کند یا خیر. در حالت کلی می‌توان گفت:

$$S_n = \sum x_i(1 - p_i)$$

که در آن  $p_i$  ها از توزیع برنولی با متغیر  $p$  هستند. در هر مورد باید چک کرد تعداد متغیرها به سمت بینهایت میل می‌کند یا خیر و همچنین واریانس  $S_n$  مقدار متناهی باشد.

۱. در اینجا عملاً هدف میانگین گرفتن  $n$  متغیر تصادفی از توزیع برنولی است پس:

$$\frac{1}{n}E(S_n) = \frac{1}{n} \sum (1 - p) = \frac{n(1 - p)}{n} = 1 - p$$

واریانس نیز یک کسر با مخرج  $\sqrt{n}$  و صورت ثابت  $(p(1 - p))$  می‌باشد پس با زیاد شدن  $n$  به صفر میل می‌کند. پس قانون اعداد بزرگ در اینجا صدق می‌کند.

۲. در اینجا نیز با زیاد شدن  $n$  تعداد متغیرهای تصادفی زیاد می‌شوند. همچنین واریانس و امید مشابه قسمت قبل حساب می‌شوند با این تفاوت

که تعداد متغیرهای تصادفی برابر  $\frac{n}{2}$  است.

$$\frac{1}{n}E(S_n) = \frac{1}{n} \sum_{i=1}^{\frac{n}{2}} 2(1-p) = 1-p$$

واریانس اینجا نیز مشابه قسمت قبل است (می‌توان فرض کرد که این توزیع درواقع حاصل دوبرار جمع کردن توزیع قبل است و چون  $n$  به سمت بینهایت می‌رود مسئله‌ای پیش نمی‌آید و دوبرابر صفر، صفر است.) و برابر صفر می‌شود. پس قانون اعداد بزرگ در اینجا صدق می‌کند.

۳. در اینجا با زیاد شدن  $n$  تعداد متغیرهای تصادفی تغییری نمی‌کند، پس قانون اعداد بزرگ در اینجا صدق نمی‌کند زیرا عملاً تعداد متغیرهای تصادفی ثابت و برابر دو می‌باشد. حتی واریانس نیز به سمت صفر میل نمی‌کند.

$$\mu = E(x) = (1-p)^2 n + 2p(1-p)\left(\frac{n}{2}\right) + 0 * p^2 = n(1-p)(1-p+p) = n(1-p)$$

$$Var(S_n) = E((x - \mu)^2) = (1-p)^2(n - \mu)^2 + 2p(1-p)\left(\frac{n}{2} - \mu\right)^2 + p^2\mu^2 = \frac{n^2}{2}p(1-p)$$

$$\text{mean : } Var\left(\frac{S_n}{n}\right) = \frac{Var(S_n)}{n^2} = p(1-p)$$

که یعنی با زیاد شدن  $n$  واریانس میانگین به صفر میل نمی‌کند پس قانون اعداد بزرگ برقرار نیست. (به غیر از حالات خاص  $p = 0$  و  $p = 1$ )

۴. اینجا نیز مشابه قسمت قبل چون تعداد متغیرهای تصادفی ثابت و برابر یک است قانون اعداد بزرگ صدق نمی‌کند. واریانس نیز برابر است با:

$$\mu = E(X) = \sum x f(x) = n(1-p)$$

$$Var(S_n) = E((X - \mu)^2) = (1-p)(n - n(1-p))^2 = (1-p)(pn)^2 = n^2 * p^2 * (1-p)$$

$$\text{mean : } Var\left(\frac{S_n}{n}\right) = \frac{Var(S_n)}{n^2} = p^2(1-p)$$


که در اینجا نیز واریانس به سمت صفر میل نمی‌کند و قانون صدق نمی‌کند (به غیر از حالات خاص  $p = 0$  و  $p = 1$ )

□

## سوال ۴

### بخش ۲

توزیع سود شبیه یک توزیع نرمال به نظر می‌آید. مقدار میانگین با زیاد شدن  $N$  کاهش می‌یابد که مطابق انتظار است زیرا احتمال باخت از احتمال برد بیشتر است (به اندازه  $\frac{2}{38}$ ) و با دفعات بیشتر بازی این ضرر جمع می‌شود. مقدار انحراف معیار نیز افزایش می‌یابد.




شکل ۲: توزیع میزان پول نهایی

جدول ۲: نتایج شبیه‌سازی برای میزان پول نهایی

| $N$  | Average   | Standard Deviation |
|------|-----------|--------------------|
| 10   | -0.52810  | 3.16515            |
| 25   | -1.28590  | 4.98919            |
| 100  | -5.23976  | 10.01691           |
| 1000 | -52.76080 | 31.46681           |

### بخش ۳

میانگین‌ها تقریباً برابر شد و انحراف معیار به سمت صفر میل می‌کند.



شکل ۳: توزیع میزان پول نهایی که با  $N$  نرمال شده است.

جدول ۳: نتایج شبیه‌سازی برای پول نهایی که با  $n$  نرمال شده است.

| $N$  | Average      | Standard Deviation |
|------|--------------|--------------------|
| 10   | -0.053252000 | 0.315180305        |
| 25   | -0.052440800 | 0.199517434        |
| 100  | -0.052237200 | 0.099651046        |
| 1000 | -0.052664400 | 0.031606469        |

### بخش ۴

در هر راند احتمال برد برابر  $\frac{18}{38}$  و احتمال باخت برابر  $\frac{20}{38}$  می‌باشد. چون راندها مستقل از هم هستند، می‌توان امید و واریانس یک راند را بدست آورد و از روی آن امید و واریانس را برای  $N$  راند حساب کرد.

$$E(X) = 1 * \frac{18}{38} + (-1) * \frac{20}{38} = \frac{-2}{38} = \frac{-1}{19}$$

$$E((X - \mu)^2) = (1 - \mu)^2 * \left(\frac{18}{38}\right) + (-1 - \mu)^2 * \left(\frac{20}{38}\right) = \frac{1}{19} \left(9 * \left(\frac{20}{19}\right)^2 + 10 * \left(\frac{18}{19}\right)^2\right) = \frac{1}{19^3} (3600 + 3240) = \frac{6840}{6859} \approx 0.9972$$

پس امید و واریانس برای یک متغیر تصادفی پیدا شد. حال باید امید و واریانس جمع  $N$  متغیر تصادفی پیدا شود که باتوجه به استقلال آن‌ها، صرفاً کافیت جمع شوند.

$$\text{mean of } n \text{ rounds} = n\mu = \frac{-n}{19}$$

$$\text{variance of } n \text{ rounds} = n\sigma = \frac{6840n}{6859} \Rightarrow \text{std of } n \text{ rounds} = \sqrt{\frac{6840n}{6859}}$$

جدول ۴: مقادیر محاسبه شده به طور نظری

| $N$  | Average  | Standard Deviation |
|------|----------|--------------------|
| 10   | -0.5263  | 3.1579             |
| 25   | -1.3158  | 4.9931             |
| 100  | -5.2632  | 9.9861             |
| 1000 | -52.6316 | 31.5789            |

با مقایسه جدول ۴ با ۲ می توان دید اندکی خطا ناشی از نمونه گیری توزیع وجود دارد ولی مقادیر به هم نزدیک هستند.

## بخش ۵

البته معمولاً برای  $n$  های بزرگتر از ۳۰ از قضیه حد مرکزی استفاده می شود، با این حال اگر توزیع پول نهایی را طبق حد مرکزی نرمال بدانیم، در قسمت قبل واریانس و میانگین آن حساب شد. پس با استفاده از جدول ۴ داریم:

$$X \sim Normal(-1.3158, 4.9931) \Rightarrow \frac{X + 1.3158}{4.9931} \sim Normal(0, 1) \Rightarrow P(X > 0) = P(Z > \frac{1.3158}{4.9931}) \approx 1 - Z(0.26) \xrightarrow{Z(0.26)=0.60257} P(X > 0) \approx 0.3974$$

در شبیه سازی انجام شده، احتمال بدست آمده برابر 0.39414 شد که به مقدار محاسبه شده نزدیک است.

## بخش ۶


قبل از شبیه سازی نیز می توان فرم نمودار را حدس زد. حالت کلی سوال قبل برابر است با:

$$X_n \sim Normal(\mu_n, \sigma_n) \Rightarrow P(X_n > 0) = P(Z > \frac{-\mu_n}{\sigma_n}) = 1 - Z(\frac{-\mu_n}{\sigma_n})$$

از طرفی در بخش ۴ مقادیر میانگین و واریانس به طور نظری بدست آمدند پس داریم:

$$P(X_n > 0) = 1 - Z(\frac{\frac{n}{19}}{\sqrt{\frac{6840n}{6859}}}) = 1 - Z(\frac{\sqrt{6859n}}{\sqrt{6840} \cdot 19}) \approx 1 - Z(0.0527\sqrt{n})$$





شکل ۴: نمودار احتمال ضرر کازینو طبق شبیه‌سازی. خط سبز نمایانگر مقدار محاسبه شده توسط فرمول بدست‌آمده است.

## سوال ۵

زده نشده.

## سوال ۶

### A: Multi-Stage Polling Design

$$ME = 1.96 * \frac{\sigma}{\sqrt{n}} \Rightarrow \sqrt{n} = \frac{\sigma}{ME} \Rightarrow n = \frac{\sigma^2}{ME^2} \Rightarrow n = \begin{cases} \text{Urban} & 81 \\ \text{Suburban} & 100 \\ \text{Rural} & 77.4 \xrightarrow{n \in \mathbf{N}} 78 \end{cases}$$

۱

۲

◇ در جدول ۵ تعداد نمونه هر ناحیه آمده. برای هر سطر درصد جمعیت آن در عدد 2000 ضرب شد.

◇ با استفاده از فرمول بازه خطا داریم:

جدول ۵: تعداد پاسخ‌دهنده‌ها به نسبت جمعیت

| Region   | Sample Size |
|----------|-------------|
| Urban    | 900         |
| Suburban | 700         |
| Rural    | 400         |

$$ME = \begin{cases} \text{Urban} & 1.96 * \frac{0.18}{30} = 0.0176 \\ \text{Suburban} & 1.96 * \frac{0.15}{\sqrt{700}} \approx 0.0111 \\ \text{Rural} & 1.96 * \frac{0.22}{20} \approx 0.0215 \end{cases}$$

◇ خیر، مقدار ME برای همه نواحی کمتر از مقدار تعیین شده است. (که مطابق انتظار است زیرا سائز نمونه‌ها از اعداد بیان شده در بخش اول بیشتر است.)

۳

$$ME = 1.96 * \frac{\sigma}{\sqrt{n}} = \frac{constant}{\sqrt{n}} \Rightarrow \frac{ME_1}{ME_2} = \frac{\sqrt{n_2}}{n_1} \xrightarrow{ME_2=kME_1} k = \frac{\sqrt{n_2}}{\sqrt{n_1}} \Rightarrow n_2 = k^2 n_1$$

◇ طبق قضیه اثبات شده، برای نصف کردن مقدار ME باید تعداد نمونه‌ها را چهار برابر کرد.

◇ باتوجه به اینکه تنها مقادیر تغییر پذیر، درصد سائز نمونه برای هر بخش و مقدار ME است، باید بین سائز نمونه بخش‌های مختلف Trade off کرد یا به بیان دیگر روی ME بخش‌های مختلف Trade off کرد.

## سوال ۷

### A: Understanding Stratification

۱

◇ باتوجه به اینکه نمونه‌گیری از نوع SRS است، گروه‌ها هیچ مزیتی نسبت به هم ندارند، پس امید هر گروه، متناسب است با تعداد اعضای آن تقسیم بر تعداد همه خانوارها:

$$E(X_i) = \sum_{i=1}^{N_i} p_i = N_i p = N_i * \frac{1}{N} = \frac{N_i}{N}$$

برای پیدا کردن امید تعداد اعضای هر گروه باید امید هر متغیر را جمع کرد با فرض مستقل بودن نمونه‌برداری، در نمونه‌برداری با سائز n هر عضو نمونه یک متغیر تصادفی مستقل است و می‌توان امید آن‌ها را باهم جمع کرد یعنی عملاً مقدار بدست آمده را در سائز نمونه ضرب کرد.

$$\begin{cases} N_1 = 5,000 \Rightarrow 10\% \Rightarrow 100 \\ N_2 = 25,000 \Rightarrow 50\% \Rightarrow 500 \\ N_3 = 20,000 \Rightarrow 40\% \Rightarrow 400 \end{cases}$$

◇ در SRS می‌توان گفت که امید میانگین نمونه یک تخمین Unbiased از میانگین جامعه می‌باشد؛ ولی در شرایطی که هدف پیدا کردن یک آماره کلی نیست، بلکه بررسی توزیع‌های هر بخش می‌باشد یا دسته‌بندی داده است، چون از گروهی مثل گروه اول داده کمی موجود است، نمی‌توان خیلی بررسی انجام داد یا حتی احتمال از دست دادن یک گروه بالا است.

در واقع، در شرایطی که جامعه همگن نیست و تفاوت زیادی وجود دارد، واریانس نمونه‌برداری SRS بالا خواهد بود.

◇ بله ممکن است. با فرض جایگذاری (برای استقلال) داریم:

$$P(X_i \notin Y_1) = 1 - P(X_i \in Y_1) = 1 - 0.1 = 0.9$$

باتوجه به استقلال، می‌توان مقدار احتمال هر متغیر را ضرب کرد:

$$P(X_j \notin Y_1 \forall j) = \prod_{j=1}^{1000} 0.9 = 0.9^{1000}$$

۲

$$W_1 = \frac{1}{10}$$

$$W_2 = \frac{1}{2}$$

$$W_3 = \frac{2}{5}$$

۳

◇ داریم:

$$n_1 = 100$$

$$n_2 = 500$$

$$n_3 = 400$$

◇ در اینجا نیز همانند SRS امید میانگین نمونه با امید جامعه برابر است، ولی برخلاف SRS که اطلاعات گروه‌ها را به کلی نادیده می‌گیرد، در اینجا اطمینان حاصل می‌شود تا از هر گروه به نسبت اعضای آن در نمونه‌برداری باشد، به این ترتیب احتمال نادید گرفتن یک گروه نیست و واریانس نمونه‌برداری نیز کاهش می‌یابد.

◇ خیر. در حالتی که دو گروه با تعداد یکسان موجود است ولی واریانس یک گروه از گروه دیگر بیشتر است، اگر از هر گروه به تعداد مشابهی نمونه برداشته شود، واریانس Estimator به نسبت زیاد می‌شود؛ زیرا گروهی که واریانس بیشتری دارد، یعنی داده‌های آن پراکندگی بیشتری دارند و نبود تعداد کمی از اعضای آن می‌تواند تخمین را جابجا کند. در شرایطی که واریانس گروه‌ها برابر باشد، این نمونه‌گیری بهینه است ولی اگر واریانس نیز مثل میانگین بطور یکنواخت پخش نشده باشد، نمونه‌گیری واریانس بالایی خواهد داشت.

## B: Optimal Allocation Theory

۱

◇ اگر یک گروه تعداد اعضای بالایی داشته باشد، نمونه‌گیری برای این‌که بتواند نماینده جامعه باشد، باید از گروه اعضای بیشتری داشته باشد وگرنه گروه با تعداد بیشتر اثر کمتری در نمونه دارد.

◇ گروهی که واریانس بیشتری دارد یعنی اعضا در آن باهم خیلی یکدست نیستند و عملاً برای این‌که واریانس نمونه‌برداری کمتر باشد، باید تعداد بیشتری از گروه را انتخاب کرد. در طرف مقابل نیز، اگر گروهی واریانس کمی داشته باشد، نیازی نیست تا خیلی از آن نمونه گرفت، با نمونه‌های کمی می‌توان اطلاعات گروه را داشت. برای مثال یک گروه با واریانس صفر (همه اعضا یکسان باشند) اگر صرفاً یک عضو از آن در نمونه‌برداری باشد، داده گروه بدست آمده است، با اعضای بیشتر صرفاً اعضای نمونه‌برداری هدر می‌روند!

۲

$$n_h^{opt} = n * \frac{W_h \sigma_h}{\sum_k W_h \sigma_h}, \sum_k W_h \sigma_h = 5,000 * 80,000 + 25,000 * 30,000 + 20,000 * 15,000 = 1e6(400 + 750 + 300)$$

$$n_1^{opt} = 1000 * \frac{40}{145}, n_2^{opt} = 1000 * \frac{75}{145}, n_3^{opt} = 1000 * \frac{30}{109}$$

۳

جدول ۶: تعداد اعضای هر گروه در نمونه‌برداری‌های مختلف

| Allocation Method | $n_a$ | $n_b$ | $n_c$ |
|-------------------|-------|-------|-------|
| Proportional      | 100   | 500   | 400   |
| Equal             | 333   | 333   | 333   |
| Optimal (Neyman)  | 276   | 517   | 207   |

برای محاسبه SE داریم:

$$SE = \sqrt{\sum_h W_h^2 \frac{\sigma_h^2}{n_h}}$$

که اگر مقادیر را در فرمول بگذاریم داریم:

جدول ۷: مقدار SE برای نمونه‌برداری‌های مختلف

| Allocation Method | SE         |
|-------------------|------------|
| Proportional      | 49,395,748 |
| Equal             | 54,313,902 |
| Optimal (Neyman)  | 45,853,031 |

طبق جدول ۷ می‌توان دید کمترین میزان SE برای روش Neyman می‌باشد که دور از انتظار نیز نیست، زیرا در روش Neyman مقدار n با مقدار  $W * \sigma$  نسبت مستقیم دارد، ولی در روش Proportional مقدار n به  $\sigma$  ربطی ندارد و برای همین یک کلاس با واریانس بالا می‌تواند مقدار SE را بالا ببرد.

## C: Practical Implications

۱

نمونه‌گیری بر اساس نسبت شاید «عادلانته» باشد، ولی باعث می‌شود تا نمونه‌های مختلف تفاوت زیادی باهم داشته باشند زیرا در یک گروه ممکن است تنوع بیشتری باشد. با نمونه‌گیری به اندازه مساوی از این گروه، نمی‌توان دید خوبی از جامعه داشت. در نمونه‌گیری با نسبت برابر نمی‌توان به نمونه به چشم نماینده جامعه نگاه کرد زیرا اگر نمونه جامعه را نمایندگی می‌کند، نباید خیلی تفاوت بکند. کار منطقی‌تر این است که به شیوه‌ای نمونه‌گیری کرد که نمونه‌ها در آن با هم تفاوت زیادی نداشته باشند. برای این که نمونه‌گیری «عادلانته» باشد، باید امید آن برابر با میانگین جامعه باشد (نه لزوماً سائز نمونه‌ها برابر باشد) برای این که دید خوبی از جامعه داشت، منطقی است که از گروهی که تنوع بیشتری دارد، نمونه‌های بیشتری گرفته شود.

۲

داریم:

$$SE = \sqrt{\sum W_h^2 \frac{\sigma_h^2}{n_h}} \approx 115,012,076$$

(با استفاده از کد ارائه شده در نوت بوک حساب شده است)

در محاسبه خطا، دخیل بودن  $W$  واضح است. اگر دو گروه پراکندگی یکسانی دارند، گروه با تعداد بیشتر باعث می‌شود نمونه‌گیری نادقیق‌تر باشد، به همین علت نمی‌توان فقط بر واریانس تمرکز کرد.

۳

طبق فرمول Neyman نسبت سائز نمونه‌ها ثابت است یعنی سائز نمونه هر گروه نصف می‌شود. با توجه به فرمول  $SE$  می‌توان دید که با نصف شدن همه  $n$  ها، مقدار  $SE \sqrt{2}$  برابر می‌شود. یعنی 64,845,978

◇ همانطور که در قسمت قبل محاسبه شد  $\sqrt{2}$

◇ با نصف کردن نمونه‌گیری، مقدار  $ME$  در  $\sqrt{2}$  ضرب می‌شود. به بیان دیگر، میزان خطا در  $\sqrt{2}$  ضرب می‌شود.

## سوال ۸

### A: The Known Variance Case

۱

داریم:

$$CI : P(\bar{x} - Z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} < \mu < \bar{x} + Z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}) = 1 - \alpha$$

$$Z_{0.975} \frac{\sigma}{\sqrt{n}} = 1.96 * \frac{0.05}{8} = 0.01225 \Rightarrow P(12.06775 < \mu < 12.9225) = 0.95$$

۲

عملا مشابه بخش قبل باید عمل کرد، صرفا مقدار Z بجای 1.96 برابر است با 2.57 پس:

$$Z_{0.995} \frac{\sigma}{\sqrt{n}} = 2.57 * \frac{0.05}{8} = 0.0160625 \Rightarrow P(12.0639375 < \mu < 12.0960625) \approx 0.99$$

۳

\* چون فقط مقدار Z تغییر می کند، نسبت عرض بازه ها برابر است با نسبت Z ها:

$$\frac{Width\ 99}{Width\ 95} = \frac{Z_{0.995}}{Z_{0.975}} \approx \frac{2.57}{1.96} \approx 1.31$$

\* چون هدف داشتن بازه با اطمینان بالاتر است، نیاز است که بازه مقادیر بیشتری را شامل شود. در حالت کلی می توان گفت اگر بازه  $a$  زیرمجموعه بازه  $b$  باشد،  $P(x \in a) \leq P(x \in b)$  زیرا هر حالتی که  $x$  عضو  $a$  باشد، عضو  $b$  نیز هست. یعنی بازه های بزرگتر احتمال بیشتری دارند.

\* مطابق عدد حساب شده، حدودا 1.3 است.

۴

شیوه درست استفاده از واریانس جامعه می باشد. در شرایطی که واریانس جامعه موجود نیست می توان از واریانس نمونه استفاده کرد و در بازه اطمینان بجای توزیع Z از توزیع T Student استفاده کرد که باعث می شود به دلیل ندانستن واریانس جامعه اطمینان کمتر شود و به همین علت بازه اطمینان کمی بزرگتر می شود.

جدول ۸: مقادیر بازه اطمینان برای سیگماهای مختلف

| $\sigma$ | $\alpha$ | CI Width | Left Bound | Right Bound |
|----------|----------|----------|------------|-------------|
| 0.05     | 0.95     | 0.012 25 | 12.067 75  | 12.092 25   |
| 0.05     | 0.99     | 0.016 06 | 12.063 94  | 12.096 06   |
| 0.06     | 0.95     | 0.014 70 | 12.065 30  | 12.094 70   |
| 0.06     | 0.99     | 0.019 27 | 12.060 72  | 12.099 28   |
| 0.07     | 0.95     | 0.017 15 | 12.062 85  | 12.097 15   |
| 0.07     | 0.99     | 0.022 49 | 12.057 51  | 12.102 49   |

## B: Unknown Variance - Comparing Approaches

۱

داریم:

$$Width = 1.96 * \frac{0.08}{5} = 1.96 * \frac{0.08}{5} = 0.03136 \Rightarrow CI : [11.92864, 11.99136]$$

۲

داریم:

$$Width = 2.64 * \frac{0.08}{5} = 0.04224 \Rightarrow CI : [11.91776, 12.00224]$$

۳

\* مورد محاسبه شده با استفاده از توزیع T Student

\* داریم:

$$\frac{Width_T}{Width_Z} = \frac{T_{24, 0.025}}{Z_{0.025}} = \frac{2.64}{1.96} \approx 1.35$$

\* چون مقدار واریانس به طور دقیق در اختیار نیست، ممکن است واریانس از واریانس توزیع بیشتر باشد و میانگین در بازه‌ای که با استفاده از توزیع Z بیان شد نباشد، به بیان دیگر اطمینان کم می‌شود، برای این که همچنان با اطمینان 95 درصد بتوان بازه را گفت، باید بازه را بزرگتر گفت.


۴

\* نسبت عرض بازه‌ها فقط به مقدار t و Z بستگی دارد پس داریم:

$$\frac{Width_T}{Width_Z} = \frac{T_{9, 0.025}}{Z_{0.025}} = \frac{1.984}{1.96} \approx 1.012$$

\* با تعداد بالا، دقت واریانس نیز بیشتر می‌شود و واریانس نمونه‌برداری به واریانس توزیع نزدیک می‌شود پس دقت بیشتر می‌شود (ولی هیچگاه به Z نمی‌رسد. صرفاً در حالت حدی برابر می‌شود. )

\* با گذر از حدود 30 مقدار Z و T به هم به نسبت نزدیک است. با مقدار حدود 240 از 0.01 کمتر می‌شود.



شکل ۵: نمودار مقدار T به ازای زیاد شدن n

## C: Interpretation and Misconceptions

۱

غلط است. میانگین مقداری ثابت است. شیوه درست این است: «این بازه به احتمال 95 درصد شامل میانگین است.»

۲

درست است. این تعریف کاملاً مطابق تعریف ارائه شده در بخش قبل است. (میانگین مقداری ثابت دارد و این بازه است که رفتاری شبیه به متغیر دارد)

۳

اشتباه است. این موضوع کاملاً به شکل توزیع و سائز نمونه بستگی دارد برای مثال، اگر  $n$  در نمونه‌گیری به سمت بینهایت برود، عرض بازه اطمینان به صفر میل می‌کند ولی قاعدتاً 95 درصد داده‌ها دقیقاً برابر میانگین نیستند.

۴

اشتباه است. بعد از نمونه‌گیری مقدار sample mean یک عدد است و کامل معلوم است. اگر منظور از sample mean درواقع امید آن باشد، چون امید آن برابر میانگین است، این گزاره شبیه مورد اول می‌شود که همچنان غلط است.



بلی. با داده بیشتر با اطمینان بیشتری می توان صحبت کرد و باعث می شود بازه اطمینان کوچک تر شود.

## D: Sample Size for Desired Precision

۱

$$ME = Z * \frac{\sigma}{\sqrt{n}} \Rightarrow n = \left(\frac{Z\sigma}{ME}\right)^2$$

باتوجه به فرضیات مسئله داریم:

$$n = \left(\frac{1.96 * 0.08}{0.02}\right)^2 \approx 61.4 \xrightarrow{n \in \mathbb{N}} n \geq 62$$

یعنی حداقل 62 بطری را باید نمونه بگیرند.

۲

\* بازه قبلی درست است. بازه اطمینان برحسب واریانس نمونه گیری سنجیده می شود که خود بر حسب واریانس جامعه بدست می آید. واریانس نمونه ممکن است کمتر و یا بیشتر باشد ولی تاثیری در بازه اطمینان ندارد. در شرایطی که واریانس جامعه در دسترس نیست از واریانس نمونه و توزیع T Student استفاده می شود.

\* همانطور که در بخش قبل بیان شد، نیازی به نمونه گیری اضافه نیست.

۳

می دانیم نسبت سائز نمونه با واریانس یک نسبت مربع است. یعنی اگر در اینجا واریانس یک و نیم برابر شده است، سائز نمونه باید  $1.5^2 = 2.25$  برابر بشود. پس داریم:

$$n \approx 2.25 * 61.4 = 138.15 \xrightarrow{n \in \mathbb{N}} n \geq 139$$

یعنی حداقل 139 بطری باید نمونه گرفته شود.

## سوال ۹

## A: Proving the Central Limit Theorem via MGFs

$$E(X) = 0, Var(X) = 1 \Rightarrow E(X^2) = E(X)^2 + Var(X)^2 = 0 + 1 = 1$$

برای محاسبه MGF متغیر X چون می‌دانیم مشتق i ام تابع MGF برابر ممای i ام است داریم:

$$M_X(t) \approx M_X(0) + tM'_X(0) + t^2M''_X(0) = M_X(0) + tE(X) + \frac{t^2}{2}E(X^2)$$

$$\xrightarrow{E(X)=0, E(X^2)=1} M_X(t) \approx M_X(0) + 0 + \frac{t^2}{2} \xrightarrow{M_X(0)=E(e^0)=E(1)=1} M_X(t) \approx 1 + \frac{t^2}{2}$$

۲

داریم:

$$M_{Z_n}(t) = M_{\sqrt{n}\bar{X}_n} = E(e^{t\sqrt{n}\bar{X}}) = E(\exp(t\sqrt{n}\bar{X})) = E(\exp(t\sqrt{n}(\frac{\sum X_i}{n}))) = E(\prod \exp(t\sqrt{n}(\frac{X_i}{n}))) =$$

$$E(\prod \exp(t(\frac{X_i}{\sqrt{n}}))) = E(\prod_{i=1}^n e^{\frac{tX_i}{\sqrt{n}}})$$

چون متغیرها مستقل هستند می‌توان امید ضرب‌ها را به ضرب امید تبدیل کرد و چون یکسان هستند، می‌توان فقط برای یک متغیر حساب کرد و سپس آن را بتوان n رساند:

$$M_{Z_n}(t) = E(\exp(\frac{tx}{\sqrt{n}}))^n = M_X(\frac{t}{\sqrt{n}})^n$$

که این همان چیزی است که می‌خواستیم.

۳

با استفاده از دو رابطه قبلی داریم:

$$\lim_{n \rightarrow \infty} M_{Z_n}(t) = \lim_{n \rightarrow \infty} (1 + \frac{(\frac{t}{\sqrt{n}})^2}{2})^n = (1 + \frac{t^2}{2n})^n$$

$$\xrightarrow{m=\frac{t^2}{2}} \lim_{n \rightarrow \infty} M_{Z_n}(t) = (1 + \frac{m}{n})^n = e^m = e^{\frac{t^2}{2}}$$

۴

دیدیم که MGF میانگین یک سری متغیر iid با میانگین صفر و واریانس یک با MGF توزیع نرمال استاندارد برابر شد. پس می‌توان گفت که توزیع میانگین n متغیر iid با میانگین صفر و واریانس یک یک توزیع نرمال است.

در حالاتی که میانگین برابر صفر نیست یا واریانس برابر یک نیست، می‌توان Z Score کرد. به بیان دیگر:

$$Y_i = \frac{X_i - \mu}{\sigma} \Rightarrow E(Y) = 0, Var(Y) = 1 \Rightarrow \bar{Y}_n \sim Normal(0, 1)$$

$$\Rightarrow \frac{\bar{X}_n - \mu}{\sigma} \sim Normal(0, 1) \Rightarrow \bar{X}_n \sim Normal(\mu, \sigma)$$

که در این فرمول  $\mu$  و  $\sigma$  میانگین و انحراف معیار Sample mean هستند که رابطه آن را با میانگین و انحراف معیار جمعیت داریم:

$$\mu_{\bar{X}_n} = \mu_{population}, \sigma_{\bar{X}_n} = \frac{\sigma_{population}}{\sqrt{n}}$$

پس به طور کلی برای هر توزیعی می‌توان گفت که توزیع میانگین نمونه‌ها برابر است با

$$\bar{X}_n \sim Normal(\mu, \frac{\sigma}{\sqrt{n}})$$

اگر  $n$  به سمت بینهایت برود. در عمل به ازای  $n$  های بزرگتر از 30 می‌توان با دقت خوبی از این رابطه استفاده کرد.

## B: The Cauchy Anomaly (When CLT Breaks)


۱

خیر. زیرا براساس ویژگی بیان شده، میانگین  $n$  متغیر تصادفی با توزیع کوشی برابر با فقط یک متغیر است، پس عملاً  $n$  تاثیری ندارد، از طرفی خود توزیع کوشی هم میانگین ندارد پس با میل کردن  $n$  به بینهایت، میانگین به یک عدد میل نمی‌کند.

۲

خیر کار نمی‌کند زیرا واریانس معین نیست و عملاً مقدار ضرب را نمی‌توان بدست آورد. در درجه دوم حتی اگر واریانس معین بود، این بازه با استفاده از LLN بدست آمده که می‌گوید توزیع میانگین به شکل نرمال است ولی در توزیع کوشی چون واریانس معین نیست، از CLT پیروی نمی‌کند و نمی‌توان بازه اطمینان را به شکل توزیع نرمال استاندارد تبدیل کرد.

۳



شکل ۶: نمودار sample mean برای توزیع نرمال و کوشی

در شکل ۶ می‌توان دید که توزیع نرمال مطابق انتظار به مقدار میانگین جامعه (صفر) متمایل می‌شود ولی توزیع کوشی در مقادیر بالا نیز (مثلاً ۸۰۰) نوسان دارد و به جایی متمایل نشده است.

۴

قضیه CLT برای هر توزیعی که واریانس محدود داشته باشد صدق می‌کند. اگر توزیع واریانس محدود و معین نداشته باشد نمی‌توان درباره CLT یا محاسبه بازه اطمینان با استفاده از توزیع نرمال استاندارد حرفی زد. علاوه بر این اگر توزیع واریانس بالایی داشته باشد، دیرتر Converge می‌کند و نیاز به  $n$  بالایی است (البته معمولاً به ازای  $n$  برابر 30 توزیع را نرمال می‌گیرند).

## A: Conceptual Understanding

۱

\* توزیع نمونه توزیع اعدادی است که در یک نمونه بدست آمده‌اند. برای مثال اعدادی که در نمونه مشاهده می‌شوند. با نمونه‌گیری می‌توان میانگین و واریانس و دیگر آماره‌های توزیع نمونه را بدست آورد.

\* توزیع نمونه‌گیری برابر توزیعی است که در نمونه‌گیری‌های مختلف بدست می‌آید. برای مثال وقتی در Confidence interval گفته می‌شود این بازه به احتمال ۹۵ درصد شامل میانگین جامعه می‌باشد، بازه‌ها از روی نمونه‌گیری‌های مختلف ساخته می‌شوند. با یک نمونه‌گیری نمی‌توان آماره‌های این توزیع مثل میانگین و ... را بدست آورد. (با آماره‌های جامعه می‌توان) بلکه می‌توان احتمالات مختلف آن را توضیح داد.

۲

\* آزمایش اول توزیع نمونه را نشان می‌دهد. (برای یک نمونه خاص)

\* آزمایش دوم توزیع نمونه‌گیری را نشان می‌دهد.

\* آزمایش دوم. توزیع آزمایش اول به نوع توزیع بستگی دارد.

۳

\* اشتباه. توزیع نمونه به توزیع جامعه بستگی دارد. CLT درباره توزیع نمونه‌گیری می‌باشد.

\* درست است. طبق CLT این گزاره درست است.

\* اشتباه. با زیاد شدن  $n$  واریانس نمونه به واریانس جامعه نزدیک و نزدیک‌تر می‌شود.

\* درست است. (البته به شرط محدود بودن واریانس جامعه) با زیاد شدن  $n$  نمونه‌گیری‌های مختلف به هم نزدیک خواهند شد و واریانس کمتری خواهد داشت.

## B: Detailed Example

۱

داریم:

$$\mu = E(X) = 0.3 + 0.4 + 1.5 = 2.2$$

$$\sigma = E((X - \mu)^2) = 0.3 * 1.2^2 + 0.2 * 0.2^2 + 0.5 * 0.8^2 = 0.3 * 1.44 + 0.2 * 0.04 + 0.5 * 0.64 = 0.76$$

۲

$$\left\{ \begin{array}{l} A = (1, 1) \Rightarrow P(A) = 0.09 \\ A = (1, 2) \Rightarrow P(A) = 0.06 \\ A = (1, 3) \Rightarrow P(A) = 0.15 \\ A = (2, 1) \Rightarrow P(A) = 0.06 \\ A = (2, 2) \Rightarrow P(A) = 0.04 \\ A = (2, 3) \Rightarrow P(A) = 0.1 \\ A = (3, 1) \Rightarrow P(A) = 0.15 \\ A = (3, 2) \Rightarrow P(A) = 0.1 \\ A = (3, 3) \Rightarrow P(A) = 0.25 \end{array} \right.$$

۳

$$\left\{ \begin{array}{l} A = (1, 1) \Rightarrow \mu_{sample} = 1 \\ A = (1, 2) \Rightarrow \mu_{sample} = 1.5 \\ A = (1, 3) \Rightarrow \mu_{sample} = 2 \\ A = (2, 1) \Rightarrow \mu_{sample} = 1.5 \\ A = (2, 2) \Rightarrow \mu_{sample} = 2 \\ A = (2, 3) \Rightarrow \mu_{sample} = 2.5 \\ A = (3, 1) \Rightarrow \mu_{sample} = 2 \\ A = (3, 2) \Rightarrow \mu_{sample} = 2.5 \\ A = (3, 3) \Rightarrow \mu_{sample} = 3 \end{array} \right.$$

۴

عملا باید معکوس بخش ۳ باتوجه به احتمالات حساب شده در بخش ۲ حساب شود:

$$P(\bar{x} = 1) = 0.09$$

$$P(\bar{x} = 1.5) = 0.12$$

$$P(\bar{x} = 2) = 0.34$$

$$P(\bar{x} = 2.5) = 0.2$$

$$P(\bar{x} = 3) = 0.25$$

۵

باتوجه به توزیع  $\bar{X}$  داریم:

$$E(\bar{X}_2) = 0.09 + 0.18 + 0.68 + 0.5 + 0.75 = 2.2 =$$

$$E(\bar{X}_2 - \mu) = 0.09 * 1.2^2 + 0.12 * 0.7^2 + 0.34 * 0.2^2 + 0.2 * 0.3^2 + 0.25 * 0.8^2 = 0.09 * 1.44 + 0.12 * 0.49 + 0.34 * 0.04 + 0.2 * 0.09 + 0.25 * 0.64 = 0.38$$

پس می‌توان دید که :

$$E(\bar{X}_2) = \mu_{population}, Var(\bar{X}_2) = \frac{\sigma_{population}}{2}$$

## C: CLT Connection


۱

\* توزیع مقادیر بیشتری را شامل می‌شود و طبق قضیه حد مرکزی به توزیع نرمال نزدیک می‌شود.

\* تغییری نمی‌کند (به عنوان یک شهود، می‌توان دید که علیرغم این‌که توزیع مقادیر بیشتری را شامل می‌شود ولی حول میانگین بصورت متقارن تغییر می‌کند). برای اثبات نیز طبق فرمول می‌توان دید که میانگین Sample mean ارتباطی با n ندارد و برابر میانگین جامعه می‌باشد.

\* کم می‌شود (باز به عنوان شهود می‌توان این‌طور دید که با شامل شدن مقادیر بیشتر، فاصله بین نقاط تمرکز در توزیع اصلی پر می‌شود و واریانس کم می‌شود). برای اثبات نیز طبق فرمول میانگین Sample mean می‌توان دید که واریانس این توزیع برابر است با:

$$\frac{\sigma_{population}}{\sqrt{n}}$$



شکل ۷: نمودار واریانس و میانگین Sample Mean به ازای n

۲

از آن جا که عملگرهای خطی روی انتگرال (و بالطبع امید) تاثیر ندارند می توان عبارت را در مخرج ضرب کرد و با میانگین جمع کرد. پس باتوجه به فرمول های میانگین و واریانس توزیع داریم:

$$\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1) \Rightarrow \bar{X} \sim \frac{\sigma}{\sqrt{n}}N(0, 1) + \mu \Rightarrow \bar{X} \sim N(\mu, \frac{\sigma}{\sqrt{n}})$$

با توجه به قضیه حد مرکزی، توزیع  $\bar{X}_n$  از نوع نرمال می باشد.


۳

با زیاد شدن سائز نمونه، همچنان در حال مشاهده یک نمونه برداری از یک توزیع خاص هستیم، پس با یک نمونه بزرگ، شکل توزیع نمونه شبیه به توزیع جامعه می شود و به سمت نرمال می رود و CLT صدق نمی کند.

CLT درباره توزیع نمونه برداری صحبت می کند. توزیع میانگین نمونه ها. با این که خود میانگین نمونه باتوجه به توزیع بدست می آید (برای مثال در بخش های قبل به ازای  $n = 2$  حساب شد). اما توزیع این میانگین ها به شکل نرمال خواهد بود.

سوال ۱۱

**A: CLT Visual Demonstration**



شکل ۸: نمودار هیستوگرام Sample mean

\* به ازای  $n = 30$  توزیع شبیه به نرمال به نظر می‌رسد. به‌ازای  $n$  های کمتر، توزیع شبیه به نرمال است ولی متقارن نیست ولی در  $n = 30$  توزیع تقریباً متقارن است.

\* به‌ازای  $n$  های بزرگتر، دامنه توزیع (مجموعه مقادیری که در نمونه مشاهده می‌شوند) بیشتر می‌شود ولی واریانس توزیع کم می‌شود (این را می‌توان از فاصله بین دوخط عمودی دید).

\* خیر. با زیاد شدن  $n$  میانگین همچنان (مطابق انتظار) روی میانگین جامعه می‌ماند.

\* می‌توان دید که توزیع  $X_n$  به سمت یک توزیع نمایی با میانگین جامعه و انحراف معیار  $\frac{\sigma}{\sqrt{n}}$  می‌رود. که CLT هم همین را بیان می‌کند.

## B: Confidence Interval Coverage

\* از آنجایی که CLT در بینهایت به صورت کامل صدق می‌کند، در  $n = 30$  تقریباً می‌توان گفت که توزیع نرمال است ولی خطاهایی وجود دارد. همچنین خطای نمونه‌گیری نیز وجود دارد (با احتمال کم).

\* چون CLT بیشتر به حد بینهایت خود نزدیک می‌شود انتظار می‌رود که Coverage اندکی بهتر شود. البته چون CLT در  $n = 30$  نیز با دقت خوبی اعمال می‌شود، انتظار می‌رود تا روند بهبود بسیار کم باشد.


\* زیرا برای اطمینان بیشتر، بازه بزرگتری در نظر گرفته می‌شود و میانگین جامعه، دفعات بیشتری در بازه می‌افتد.



جدول ۹: تعداد داده مورد نیاز به ازای پارامترهای مختلف بازه اطمینان

| $\sigma$ | Margin of Error | 90% CI | 95% CI | 99% CI |
|----------|-----------------|--------|--------|--------|
| 0.1      | 0.01            | 271    | 385    | 664    |
| 0.1      | 0.02            | 68     | 97     | 166    |
| 0.2      | 0.01            | 1083   | 1537   | 2659   |
| 0.2      | 0.02            | 271    | 385    | 664    |

## C: Sample Size Calculator



شکل ۹: میزان تعداد داده مورد نیاز برحسب حاشیه خطا

\* طبق فرمول بدست آمده در تابع، برای سایز داده برحسب حاشیه خطا داریم:

$$n = \left( \frac{Z_{0.5+\frac{\alpha}{2}} * \sigma}{ME} \right)^2 = \left( \frac{constant}{ME} \right)^2 = \frac{constant}{ME^2}$$

این رابطه  $\left(\frac{1}{x^2}\right)$  به وضوح خطی نیست و به همین علت نمودار نیز خطی نیست.

\* با میل کردن  $ME$  به سمت صفر،  $n$  به سمت بینهایت می‌رود، برای همین برای حاشیه خطای کمتر نیاز به داده بیشتری داریم. شهود احتمالی نیز مطابق این است زیرا برای اینکه بتوان با احتمال یکسان بازه را کوچک‌تر کرد، باید داده بیشتری داشت که واریانس نمونه‌گیری کاهش یابد.

\* برای نظرسنجی اول باید بزرگ‌ترین بازه قابل قبول را انتخاب کرد و سپس بر اساس آن اقدام به نظرسنجی کرد. اگر نیاز به حاشیه خطای در حد ۰.۳۰ داشت می‌توان با نمونه برداری با سایز تنها ۹۶ یک بازه اطمینان با حاشیه خطای ۰.۰۳ ارائه داد. اما اگر با همین شرایط نیاز باشد حاشیه خطا ۰.۰۱ باشد، به نمونه‌ای با سایز ۸۶۵ نیازمندیم. زیرا یک رشد معکوس با توان ۲ دارد. پس منطقی است که اول بزرگ‌ترین میزان قابل قبول حاشیه خطا را بیابیم و سپس به میزان مورد نیاز (یا برای اطمینان کمی بیشتر) نمونه برداری صورت بگیرد.

