



زمستان ۱۴۰۴

استنباط آماری

پروپوزال پروژه

مرتضی ملکی نژاد شوشتری - ۸۱۰۱۰۴۲۵۶

1 Data Provenance and Structure

مجموعه داده انتخاب شده [1]، شامل درخواست افراد برای وام است و label آن این است که با درخواست وام موافقت شده است یا خیر. در نسخه‌ای که دانلود شده است، داده بین سال‌های ۲۰۰۷ تا ۲۰۱۸ جمع‌آوری شده است. این داده توسط خود سایت Lending Club از تهیه شده است و سپس در Kaggle توسط یکی از کاربران سرهم شده است. داده به اینصورت جمع‌آوری شده است که ابتدا Lending Club داده مشتریان خود را جمع‌آوری کرده است و سپس با استفاده از داده‌های دیگری مربوط به اعتبار افراد، مجموعه داده غنی‌تر شده است.

2 Suitability for Statistical Inference

این مجموعه داده بزرگ است و حدود ۲۹۹۰۹۴۴۲ سطر دارد. ستون‌های آن انواع مختلفی دارند. نمایی از این تنوع در جدول ۱ آمده است.

۱.۲ نمونه‌برداری و توزیع نمونه

به دلیل حجم زیاد این مجموعه داده و این موضوع که داده‌های این مجموعه داده تعریف مشخصی دارند و حد و حدود آن‌ها مشخص است، احتمالاً فرض‌هایی مثل محدود بودن واریانس در آن صدق کند و قضایایی مثل قضیه اعداد بزرگ و حد مرکزی در آن صدق کند.

۲.۲ ویژگی‌ها

تعداد ستون‌های این مجموعه داده نیز زیاد است و یحتمل فرض‌هایی مثل مستقل خطی بودن در آن صدق نکند. اگر برای ستون‌های عددی آن ماتریس Correlation حساب شود و سپس توزیع مقادیر Correlation را ببینیم می‌توان دید مقادیر قدر مطلق Correlation تقریباً همه بازه بین صفر تا یک را پوشش می‌دهند و هم ویژگی‌هایی داریم که به هم وابسته هستند و هم ویژگی‌هایی که هیچ ارتباطی به یکدیگر ندارند.

۳.۲ توزیع ویژگی‌ها

اکثر ویژگی‌های عددی، توزیعی شبیه به توزیع نرمال دارند ولی چولگی به سمت راست دارند که باید این موضوع در آن‌ها برطرف شود. همچنین بازه ویژگی‌ها یکی نیست که می‌تواند مشکل ساز شود و بهتر است که اول توزیع‌ها را نرمال استاندارد کرد.

3 Scope of Analysis

چون این مجموعه داده سطرهای زیادی دارد و هم ویژگی‌های عددی پیوسته و هم ویژگی‌های categorical دارد، می‌توان کارهای متعددی روی آن انجام داد.

3.1 Hypothesis Testing

می‌توان چک کرد که (verification_status) بر روی (int_rate) تاثیر دارد یا خیر. فرض صفر این است که تاثیری ندارد. با آزمون فرضیه اگر فرض صفر رد شود، یعنی احتمالاً وضعیتی که از کاربر بدست می‌آید روی نرخ سود او تاثیر می‌گذارد، ولی اگر فرض صفر رد نشد، نمی‌توان حرفی درباره رابطه بین وضعیت تایید کاربر و نرخ سود او گفت.

3.2 ANOVA

با استفاده از ANOVA می‌توان مقایسه کرد که حالت‌های متفاوت (home_ownership) چه تاثیری روی میانگین (Debt_to_Income) دارد. زیرا مالکیت خانه، یک ویژگی رده‌ای¹ است و با استفاده از ANOVA می‌توان دید که روی Debt to Income تاثیر دارد یا خیر.

3.3 Chi Squared

برای این قسمت باید از دو داده که رده‌ای هستند استفاده کرد. برای مثال می‌توان رابطه (home_ownership) با (grade) را بررسی کرد.

3.4 Linear Regression


برای linear regression می‌توان سعی کرد که میزان درآمد سالانه (annual_income) را پیش‌بینی کرد. میزان درآمد یک متغیر پیوسته است و رگرشن برای این کار مناسب است. یکی از بخش‌های این قسمت، انتخاب ویژگی‌های مناسب برای رگرشن است.

3.5 Non parametric test


در اینجا می‌توان رابطه بین (loan_amnt) و (loan_status) را بررسی کرد که آیا مبلغ وام در نرخ نکول آن تاثیر دارد یا خیر. چون مبلغ وام چولگی دارد، اگر به شکل نرمال درنیاید، تست‌های پارامتریک مثل T Test برای آن مناسب نیستند و تست non parametric بهتر است.

¹Categorical

از آنجایی که گفته شده گزارش باید حداکثر دوصفحه باشد، جدول و عکس‌ها در اینجا آورده شده‌اند.



شکل ۱: هیستوگرام مقادیر **correlation**. برای بهتر دیدن این که در هر مقداری تقریباً **correlation** هست هیستوگرام مجذور قدرمطلق آن نیز رسم شده تا مقادیر زیاد صفر کمتر اثر بگذارند.



شکل ۲: توزیع یک‌سری از ویژگی‌ها. واضح است که اکثر ویژگی‌ها چولگی به سمت راست دارند.

جدول ۱: تعدادی از ویژگی‌ها، نوع آن‌ها و تعداد مقادیر یکتای آن در بین یک میلیون داده اول مجموعه داده

Category	Feature Name	Type	Unique Count
Identifier	id	Object	500,001
Numerical	loan_amnt	float64	1,494
	annual_inc	float64	31,259
	dti (Debt-to-Income)	float64	5,886
	revol_bal	float64	65,295
Categorical	home_ownership	String	5
	purpose	String	15
	addr_state	String	51
	disbursement_method	String	3
Ordinal	grade	String	8
	sub_grade	String	36
	emp_length	String	12
Temporal	issue_d	String	16
	earliest_cr_line	String	699
Boolean/Flag	hardship_flag	String	3
	debt_settlement_flag	String	3

۵ مراجع

References

- [1] wordsforthewise. Lending Club Dataset. <https://www.kaggle.com/datasets/wordsforthewise/lending-club>. Accessed: 2026-02-01. Kaggle, 2018.