



زمستان ۱۴۰۴

استنباط آماری

گزارش فاز ۲: تحلیل‌های آماری

مرتضی ملکی‌نژاد شوشتری - ۸۱۰۱۰۴۲۵۶

از مجموعه داده Lending Club [1] فقط وام‌های پذیرفته شده (حدود ۵۰۰۰۰۰ سطر) برای تحلیل استفاده شده است. در فاز ۲، پنج تحلیل آماری مطابق پروپوزال انجام شد: آزمون فرضیه با ANOVA یک‌طرفه، ANOVA برای مقایسه میانگین‌ها، آزمون خی‌دو برای استقلال، رگرسیون خطی برای پیش‌بینی درآمد سالانه، و آزمون ناپارامتریک Man Whitney برای مقایسه مبلغ وام در دو وضعیت وام. در ادامه برای هر تحلیل، روش و تکنیک به کاررفته و سپس نتایج عددی و تفسیر آن‌ها آمده است.

۱ روش‌ها و نتایج

۱.۱ آزمون فرضیه: اثر وضعیت تأیید بر نرخ بهره

روش و تکنیک: سؤال این است که آیا وضعیت تأیید متقاضی (verification_status) بر نرخ بهره (int_rate) تأثیر دارد یا خیر. فرض صفر این است که این متغیر رده‌ای اثری بر میانگین نرخ بهره ندارد. چون یک متغیر رده‌ای (سه سطح: تأیید نشده، تأیید از منبع، تأیید شده) و یک متغیر پیوسته داریم، از تحلیل واریانس یک‌طرفه (One-way ANOVA) استفاده شد. داده‌های دارای مقدار معتبر برای هر دو متغیر استخراج و سه گروه با هم مقایسه شدند.

نتیجه: مقدار آماره F حدود ۱۹۱۱۱ و مقدار p عملاً صفر بود؛ بنابراین تقریباً با هر confidence level ای فرض صفر رد می‌شود. میانگین نرخ بهره در سه گروه «تأیید نشده»، «تأیید از منبع»، و «تأیید شده» به ترتیب حدود ۱۰/۹۷، ۱۲/۶۳ و ۱۴/۱۱ درصد بود. تفسیر: با بالاتر بودن سطح تأیید، نرخ بهره به طور میانگین بیشتر می‌شود؛ که مخالف انتظار است. حدسی که برای این موضوع زده می‌شود این است که افراد احراز هویت شده، وام‌های بزرگ‌تر و بالتبع با سود بیشتری می‌گیرند.

۲.۱ اثر نوع مالکیت مسکن بر نسبت بدهی به درآمد

روش و تکنیک: نسبت بدهی به درآمد (dti) شاخص مهمی برای توان بازپرداخت وام است. فرض صفر این است که نوع مالکیت مسکن (home_ownership) بر میانگین dti اثری ندارد. با مدل رگرسیون خطی با اثر ثابت رده‌ای (OLS) با C(home_ownership) و جدول ANOVA نوع ۲، معناداری اثر بررسی شد. مقادیر فراطرف dti (مثلاً بالای ۱۰۰) که احتمال خطای ورود یا موارد خاص هستند، حذف شدند تا برآوردها پایدار بمانند.

نتیجه: اثر home_ownership از نظر آماری بسیار معنادار بود (مقدار p در حد مرتبه 10^{-78}). در سطح ۵ درصد فرض صفر رد می‌شود؛ یعنی نوع مالکیت مسکن (اجاره، مالکیت، رهن و غیره) با میانگین نسبت بدهی به درآمد ارتباط دارد. این نتیجه با انتظار اقتصادی سازگار است: ساختار مالکیت مسکن می‌تواند با درآمد، پس‌انداز و سطح بدهی افراد همبسته باشد.

۳.۱ وابستگی مالکیت مسکن و گرید وام

روش و تکنیک: برای بررسی ارتباط بین دو متغیر رده‌ای، مالکیت مسکن (home_ownership) و گرید وام (grade)، از آزمون استقلال استفاده شد. فرض صفر این است که این دو متغیر مستقل هستند. جدول توافقی (contingency table) ساخته شد و آزمون χ^2 دو (chi-squared test of independence) روی آن اعمال شد.

نتیجه: مقدار آماره χ^2 دو حدود ۳۱۹۹ با ۱۸ درجه آزادی و مقدار p عملاً صفر بود. در سطح ۵ درصد فرض استقلال رد می‌شود؛ یعنی بین نوع مالکیت مسکن و گرید وام وابستگی معنادار وجود دارد. از جدول توافقی برمی‌آید که در رده‌های MORTGAGE و RENT تعداد وام‌های با گریدهای مختلف با رده OWN متفاوت است؛ مثلاً توزیع گرید در وام‌گیرندگان با رهن یا اجاره با مالکین متفاوت است، که می‌تواند در طراحی محصولات وام و ارزیابی ریسک مفید باشد.

۴.۱ پیش‌بینی درآمد سالانه

روش و تکنیک: هدف پیش‌بینی درآمد سالانه (annual_inc) با استفاده از متغیرهای در دسترس بود. ویژگی‌های ورودی شامل مبلغ وام (loan_amnt)، نسبت بدهی به درآمد (dti)، حد پایین نمره FICO (fico_range_low)، مانده (revol_bal)، تعداد حساب‌های اعتباری باز (open_acc) و طول اشتغال (به صورت عددی از روی emp_length) در نظر گرفته شدند. داده‌های نامعتبر و نقاط فراطرف (درآمد منفی یا بالای ۲ میلیون دلار، dti خارج از بازه معقول مثلاً بالای ۶۰) حذف شدند. داده به نسبت ۸۰٪ به مجموعه آموزش و آزمون تقسیم شد و مدل رگرسیون خطی روی داده آموزش برازش و با ضریب تعیین و RMSE روی داده آزمون ارزیابی شد.

نتیجه: ضریب تعیین (R^2) روی داده آزمون حدود ۰/۳۳ و جذر میانگین مربعات خطا (RMSE) حدود ۴۴۲۵۰ دلار بود. در بین ضرایب برآوردشده، dti اثر منفی بر درآمد پیش‌بینی شده داشت و مبلغ وام، fico، تعداد حساب‌های باز و طول اشتغال اثر مثبت داشتند. مدل حدود یک‌سوم از واریانس درآمد را توضیح می‌دهد؛ با توجه به میانگین خطای پیش‌بینی هنوز قابل توجه است، که می‌تواند به دلیل نبود متغیرهای مهم (مثلاً تحصیلات، شغل، منطقه) یا ناهمگنی زیاد درآمدها باشد. با این حال جهت اثر ضرایب از نظر اقتصادی قابل تفسیر است.

۵.۱ آزمون ناپارامتریک: مبلغ وام در وام‌های جاری در مقابل نکول شده

روش و تکنیک: مبلغ وام (loan_amnt) در این داده‌ها چولگی دارد و توزیع آن لزوماً نرمال نیست؛ بنابراین استفاده از آزمون‌های پارامتریک مثل t برای مقایسه میانگین دو گروه مناسب نیست. از آزمون ناپارامتریک U Mann-Whitney (Mann-Whitney U) برای مقایسه توزیع مبلغ وام بین دو گروه «جاری» (Current) و «نکول شده» (Charged Off) استفاده شد. فرض صفر این است که توزیع مبلغ وام در دو گروه یکسان است (دو طرفه).

نتیجه: مقدار p عملاً صفر بود؛ بنابراین در سطح ۵ درصد فرض صفر رد می‌شود. میانه مبلغ وام در وام‌های جاری ۱۶۰۰۰ دلار و در وام‌های نکول شده ۱۵۰۰۰ دلار بود. یعنی تفاوت توزیع مبلغ وام بین دو وضعیت از نظر آماری معنادار است؛ اگرچه اختلاف میانه‌ها به نسبت کم است، حجم نمونه بزرگ باعث شده که این تفاوت به عنوان معنادار تشخیص داده شود. این نتیجه نشان می‌دهد که نمی‌توان مبلغ وام را در دو گروه یکسان فرض کرد و در مدل‌سازی احتمال نکول یا در تحلیل سیاست وام‌دهی می‌توان مبلغ وام را به عنوان یکی از متغیرهای مرتبط در نظر گرفت.

References

- [1] wordsforthewise. *Lending Club Dataset*. <https://www.kaggle.com/datasets/wordsforthewise/lending-club>. Accessed: 2026-02-01. Kaggle, 2018.