

دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی برق و کامپیوتر



یادگیری ماشین

تمرین شماره ۲

نام و نام خانوادگی
مرتضی ملکی نژاد شوشتری

شماره دانشجویی
۸۱۰۱۰۴۲۵۶

۲۶ آذر ۱۴۰۴

فهرست مطالب

۱	چکیده	۱
۲	Window Parzen	۱
۲		۱.۱
۳		۲.۱
۳		۳.۱
۴		۴.۱
۵	Spectrum Eigenvalue the of Shift	۲
۵		۱.۲
۵		۲.۲
۷	Kernel a Optimizing	۳
۷		۱.۳
۷		۲.۳
۷	Dimensionality of Curse the and KNN	۴
۸	Metrics Choosing	۵
۹	Regression Ridge Kernel	۶
۱۰	Regression Linear Deriving	۷
۱۱	Lasso of Interpretation Bayesian A	۸
۱۲	Kernel Gaussian with Classification Window Parzen	۹

۱	نمودار $\hat{p}$ به ازای مقادیر مختلف h	۳
۲	مقدار $\hat{p}$ به ازای $a = 1, h = \frac{1}{1.98}$ در بازه $[0, 0.04]$	۴
۳	نمودار پراکندگی نقاط	۱۳
۴	میزان likelihood به ازای مقادیر مختلف میانگین و واریانس. مقادیر محاسبه شده به صورت تئوری به صورت خط به نمایش در آمده‌اند.	۱۴

فهرست جداول

۱	احتمال تخمین زده شده برای هر نقطه با $h = 1$	۱۲
۲	احتمال تخمین زده شده برای هر نقطه با $h = 0.1$	۱۲

این تمرین برای تسلط روی Hypothesis Testing ، KNN ، Parzen و توزیع χ^2 و توزیع های مشتق از آن و استفاده های آن (مثلا توزیع واریانس) ارائه شده است.

Parzen Window

۱.۱

فرمول پارزن برابر است با:

$$\hat{P}(X) = \frac{1}{N} \sum_{i=1}^N \frac{1}{h^d} \phi\left(\frac{x - x_i}{h}\right)$$

که در این جا d برابر یک است زیرا فقط یک بعد داریم. چون هدف بدست آوردن میانگین $\hat{P}(X)$ می باشد، باید امید را به شیوه ای حساب کرد که در آن داده متغیر تصادفی باشد. (که در فرمول نهایی x موجود باشد). چون داده ها نیز از توزیع جامعه هستند، می توان احتمال را جایگذاری کرد. همچنین چون در فرمول parzen داریم میانگین n متغیر تصادفی را حساب می کنیم و می دانیم که امید یک متغیر iid با امید میانگین همه برابر است می توان صرفاً برای یک متغیر تصادفی حساب کرد. پس داریم:

$$E(\hat{P}(Y)) = \int_0^a \frac{1}{h^d} \phi\left(\frac{x-y}{h}\right) \frac{1}{a} dy = \frac{1}{ha} \int_0^a \phi\left(\frac{x-y}{h}\right) dy$$

اگر x از y کمتر باشد مقدار ϕ صفر می شود. پس اگر x از صفر کمتر باشد، مقدار داخل انتگرال همواره صفر است و خروجی صفر می شود. اگر x بین صفر و a باشد داریم:


$$\begin{aligned} E(\hat{P}(Y)|0 < x \leq a) &= \frac{1}{ha} \int_0^x \phi\left(\frac{x-y}{h}\right) dy = \frac{1}{ha} \int_0^x e^{-\frac{y-x}{h}} dy \\ &= \frac{1}{ha} [he^{-\frac{y-x}{h}}]_0^x = \frac{1}{a} (1 - e^{-\frac{x}{h}}) \end{aligned}$$

اگر x از a بزرگ تر باشد داریم:

$$E(\hat{P}(Y)|0 < x \leq a) = \frac{1}{ha} \int_0^a \phi\left(\frac{x-y}{h}\right) dy = \frac{1}{ha} \int_0^a e^{\frac{y-x}{h}} dy$$

$$= \frac{1}{ha} \left[h e^{\frac{y-x}{h}} \right]_0^a = \frac{1}{a} \left(e^{\frac{a-x}{h}} - e^{\frac{-x}{h}} \right) = \frac{1}{a} (e^{\frac{a}{h}-1}) e^{\frac{-x}{h}}$$

۲.۱



شکل ۱: نمودار $\hat{p}$ به ازای مقادیر مختلف h

۳.۱

داریم:

$$\int_0^a (\hat{p}(x) - p(x)) dx = \int_0^a \frac{1}{a} \left(e^{\frac{-x}{h}} - e^{\frac{-a}{h}} \right) dx = \frac{1}{a} \left[-h e^{\frac{-x}{h}} \right]_0^a = \frac{-h}{a} \left[e^{\frac{-a}{h}} - 1 \right] =$$

$$\frac{h}{a} \left(1 - e^{\frac{-a}{h}} \right)$$

با جایگذاری متغیر $t = \frac{-a}{h}$ داریم:

$$\frac{1 - e^t}{-t} \leq 0.01 \Rightarrow \frac{e^t - 1}{t} \leq 0.01$$


اگر بسط تیلور $e^t = 1 + t + \frac{t^2}{2}$ را بنویسیم داریم:

$$1 + 0.5t \leq 0.01 \Rightarrow 0.5t \leq 0.99 \Rightarrow t \leq 1.98 \Rightarrow \frac{a}{h} \geq 1.98 \Rightarrow h \leq \frac{a}{1.98}$$

یعنی برای بایاس کمتر از یک درصد، h باید کمتر از حدودا نصف a باشد.

۴.۱

$$a = 1 \Rightarrow h = \frac{1}{1.98} \approx 0.5$$



شکل ۲: مقدار $\hat{p}$ به ازای $a = 1, h = \frac{1}{1.98}$ در بازه $[0, 0.04]$

Shift of the Eigenvalue Spectrum

$$\xi A = \lambda_A I, \xi B = \lambda_B I \Rightarrow \xi(A + B) = (\lambda_A + \lambda_B)I$$

یعنی ξ بردار ویژه $A + B$ است و مقدار ویژه آن برابر با جمع دو مقدار ویژه می باشد.

۱.۲

حالت تکین وقتی پیش می آید که دترمینان صفر باشد یا به عبارت دیگر، یکی از مقادیر ویژه ماتریس $X^T X$ صفر باشد. واضح است که با جمع کردن ماتریس با λI مقدار ویژه های ماتریس با λ جمع می شود

$$U = x^T X \quad \xi U = \gamma I \Rightarrow \xi(U + \lambda I) = \xi U + \xi \lambda = \gamma \xi + \lambda \xi = (\gamma + \lambda) \xi \Rightarrow \xi(U + \lambda I) = (\gamma + \lambda) \xi$$

که یعنی با جمع λI مقادیر ویژه بردار U با λ جمع می شوند. از آنجایی که $U = X^T X$ یک ماتریس semi positive definite است، مقادیر ویژه آن همه نامنفی هستند. پس اگر λ یک مقدار مثبت باشد، نتیجه یک ماتریس positive definite است که دترمینان آن مثبت است و جواب دارد.

۲.۲

$$\text{linear} \Rightarrow \hat{\beta} = \operatorname{argmin}(y - \beta X)^2 = (X^T X)^{-1} X^T y$$

$$\text{Ridge} \Rightarrow \hat{\beta} = \operatorname{argmin}(y - \beta X)^2 + (\lambda \beta)^2 = (X^T X + \lambda I)^{-1} X^T y$$

واضح است که در ridge مقدار bias بیشتر است زیرا بعد از فیت شدن نیز به علت وجود λ مدل روی داده کامل فیت نمی شود. در مقابل در linear regression چون هدف فیت شدن کامل روی داده است بایاسی اضافه نمی شود و بایاس موجود ناشی از داده است.

در ridge چون یکی از اهداف کم بودن مقدار β می باشد، احتمال بیش برآزش کمتر است.

برای مثال ممکن است مدل به دو ویژگی در مقابل هم، امتیازهای قرینه ولی بزرگی بدهد که روی داده آموزش به طور کامل خنثی شوند ولی موقع تست چون ممکن است مقدار این ویژگی ها اندکی باهم تفاوت داشته باشد، منجر به خطای بالایی خواهد شد. ولی در ridge با جلوگیری از زیاد شدن β جلوی این مورد گرفته می شود.

برای جمع بندی، ridge کمی bias بیشتری دارد ولی variance کمتری دارد. این tradeoff را می توان با مقدار λ کنترل کرد.

Optimizing a Kernel

۱.۳

$$L(x_i) = \sum_i (y_i^2 + \hat{y}_i^2 - 2y_i\hat{y}_i) = (y_i - (\frac{\sum_j K(x_i, x_j)y_j}{\sum_j K(x_i, x_j)}))^2$$

اگر برای $L(x_i)$ مقدار خود $x_j = x_i$ نیز در نظر گرفته شود، احتمال بیش‌برازش وجود دارد پس بهتر است که خود متغیر در نظر گرفته نشود پس داریم:

$$\begin{aligned} L &= \sum_i (y_i^2 + \hat{y}_i^2 - 2y_i\hat{y}_i) = \sum_i (y_i - (\frac{\sum_{j \neq i} K(x_i, x_j)y_j}{\sum_{j \neq i} K(x_i, x_j)}))^2 \\ &= \sum_i (y_i - (\frac{\sum_{j \neq i} e^{-(x_i - x_j)W(x_j - xI)^T} y_j}{\sum_{j \neq i} e^{-(x_i - x_j)W(x_j - xI)^T}}))^2 \end{aligned}$$

۲.۳

KNN and the Curse of Dimensionality

a

اگر بازه $[a, b]$ انتخاب شود باید مقدار $P(a \leq x \leq b)$ حساب شود. در توزیع یکنواخت این عبارت برابر است با طول بازه تقسیم بر طول کل که در این حالت خاص برابر با 0.1 می باشد.

b

باتوجه به اینکه دو ویژگی از هم مستقل هستند احتمال آنها در هم ضرب می شود یعنی برابر است با 0.01

c

مشابه قسمت قبل با ضرب احتمال ها داریم:

$$P = 0.1^p = 0.1^{100}$$

d

اگر تعداد داده نسبت به ابعاد بصورت نمایی رشد نکند، برای تخمین هر نقطه داده کمی موجود است و نمی توان با دقت خوبی پیش بینی کرد.

در روش parzen این مشکل به این صورت رخ پیدا می کند که جاهای زیادی در pdf estimate صفر می باشد (زیرا داده ای یافت نشده است). در روش KNN این مشکل به اینصورت رخ می دهد که پنجره بزرگ و بزرگ تر می شود و احتمالا از داده های دور استفاده شود که نتیجتا تخمین خوبی نمی دهد.

Metrics Choosing

a

استفاده از cosine بهتر است زیرا در مقادیری که ذکر شد، نسبت کافئین به شکر (یا برعکس) جداکننده بهتری نسبت به شکر یا کافئین به تنهایی است.

b

در اینجا چون بردار صفر وارد می شود نسبت کافی نیست (اگر صفر هم نبود احتمال اشتباه گرفتن آب با انرژی را وجود داشت زیرا نسبت تقریباً یکسانی دارند). در اینجا استفاده از فاصله اقلیدسی منطقی است زیرا مقدار عددی ویژگی ها اهمیت دارد.

c

چون مقدار ها عددی نیستند فاصله همینگ بهتر است.

d

گزینه ۳. در درخت تصمیم، میزان تاثیر ویژگی ها سنجیده می شود ولی در سنجش فاصله این عدد سنجیده نمی شود.

Kernel Ridge Regression

a

با استفاده از vector notation داریم:

$$J = \frac{1}{2} \sum (X\theta - Y)^2 + \frac{\lambda}{2} |\theta|^2 = \frac{1}{2} (X\theta - Y)^T (X\theta - Y) + \frac{\lambda}{2} \theta^T \theta$$

$$= \frac{1}{2}(\theta^T X^T X \theta - \theta^T X^T Y - Y^T X \theta + Y^T Y + \lambda \theta^T \theta)$$

این عبارات عدد هستند پس ترانهاد آنها باهم برابر است. دو عبارت وسط ترانهاد همدیگر هستند و باهم برابر هستند پس داریم:

$$J = \frac{1}{2}(\theta^T X^T X \theta - 2\theta^T X^T Y + Y^T Y + \lambda \theta^T \theta)$$

با مشتق گرفتن نسبت به θ و صفر گذاشتن داریم:

$$\frac{1}{2}(2X^T X \theta - 2X^T Y + 2\lambda \theta) = 0 \Rightarrow (X^T X + \lambda I)\theta = X^T Y$$

$$\Rightarrow \theta = ((X^T X + \lambda I)^{-1} X^T Y)$$

b

حل نشده است.

Deriving Linear Regression

a

داریم:

$$E(yx) = w^T x^2 + \epsilon x = w^T E(x^2) + E(\epsilon)E(x) = w^T \Sigma_x$$

b

می دانیم بهترین تخمینگر میانگین جامعه، میانگین نمونه است. پس داریم:

$$E(yx|D) = \frac{1}{n} \sum_{i=1}^n (x_i y_i)$$

c

داریم:

$$L = E((w^T x - y)^2) \xrightarrow{\text{minimize loss} \rightarrow \text{derivative from } w} E(2(w^T x - y)x) = 0 \Rightarrow$$

$$E(w^T x^2) = E(yx) \Rightarrow w^T \Sigma_x \Rightarrow \hat{w} = \left(\frac{E(yx)}{\Sigma_X} \right)^T = \left(\frac{\Sigma_{xy}}{\Sigma_x} \right)^T$$

d

روی صورت اتفاقی نمی افتد زیرا مقدار آن از روی نمونه حساب شد. ولی در مخرج، درواقع $E(X^2)$ بود. پس یعنی باید با مربع میانگین جمع شود پس داریم:

$$\hat{w} = \frac{\Sigma_{xy}}{\Sigma_x + \mu_x^2}$$

e

بله. درجایی از محاسبات از نرمال بودن استفاده نشد. صرفا اگر نرمال باشد می توان چیزهایی مثل بازه اطمینان و غیره را حساب کرد.

A Bayesian Interpretation of Lasso

a

داریم:

$$f(w|(y|x)) = \frac{f(y|x, w)f(w)}{f(y|x)}$$

چون مقدار w در مخرج نقشی ندارد و برای همه w ها یکسان است می توان از آن صرفنظر کرد. پس یعنی باید w ای پیدا کرد که مقدار $f(w)f(y|x, w)$ در آن بیشینه باشد. پس داریم:

$$f(w|(y|x)) \propto f(w)f(y|x, w) = \frac{1}{2b} e^{-\frac{|w|}{b}} * \prod \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(y - w.x)^2}{2\sigma^2}}$$

با حذف مقادیری که w در آن‌ها نقشی ندارد داریم:

$$f(w|(y|x)) \propto e^{-\left(\frac{|w|}{b} + \sum \frac{(y - w.x)^2}{2\sigma^2}\right)}$$

b

با گرفتن لگاریتم از حاصل قسمت قبل داریم :

$$l = -\left(\frac{|w|}{b} + \sum \frac{(y - w.x)^2}{2\sigma^2}\right)$$

از آنجایی که لگاریتم صعودی است کافیت مقدار 1 بیشینه شود تا maximum likelihood

بدست آید. همچنین می‌توان یک عدد ثابت را ضرب کرد پس داریم:

$$\hat{w} = \operatorname{argmax} \frac{1}{2b\sigma^2} |w| + \sum (y - w.x)^2$$

که این همان چیزی است که در سوال آمده و مقدار λ برابر است با:

$$\frac{1}{2b\sigma^2}$$

Parzen Window Classification with Gaussian Kernel


موارد در نوتبوک 10.ipynb حل شده‌اند. در هر دو مورد کلاس ۱ انتخاب شد.

جدول ۱: احتمال تخمین زده شده برای هر نقطه با $h = 1$

Coordinates	$P(\omega_1)$	$P(\omega_2)$	$P(\omega_3)$
(0.5, 1.0, 0.0)	0.1259	0.4711	0.3775
(0.31, 1.51, -0.5)	0.1534	0.4828	0.2050
(-0.3, 0.44, -0.1)	0.1399	0.3783	0.1771

جدول ۲: احتمال تخمین زده شده برای هر نقطه با $h = 0.1$

Coordinates	$P(\omega_1)$	$P(\omega_2)$	$P(\omega_3)$
(0.5, 1.0, 0.0)	8.77×10^{-20}	6.77×10^{-5}	8.00×10^{-17}
(0.31, 1.51, -0.5)	2.87×10^{-20}	1.20×10^{-5}	2.16×10^{-25}
(-0.3, 0.44, -0.1)	3.64×10^{-12}	3.78×10^{-4}	1.06×10^{-39}



شکل ۳: نمودار پراکندگی نقاط

Maximum likelihood estimation

a,b

$$f(x|\mu, \sigma) \propto \frac{1}{\sigma} e^{-\frac{(x - \mu)^2}{2\sigma^2}}$$

برای تخمین mle باید این عبارت را براساس μ و σ بیشینه کرد. برای میانگین واضح است که کمترین مقدار داخل پرانتز (و در نتیجه بیشترین مقدار توان) وقتی است که مقدار $\sum (x - \mu)^2$ کمینه باشد. با باز کردن این عبارت داریم:

$$\mu = \operatorname{argmin} \sum x^2 + \mu^2 - 2x\mu = \operatorname{argmin} (n\mu^2 - 2n\bar{x}\mu) = \mu^2 - 2\mu\bar{x} \Rightarrow \mu = \bar{x}$$

برای واریانس داریم:

$$l = \sum \left(-\ln(\sigma) - \frac{(x - \mu)^2}{2\sigma^2} \right)$$

با مشتق گیری بر حسب σ داریم:

$$-\left(\frac{n}{\sigma} + \sum \frac{(x - \mu)^2}{2} \left(-\frac{2}{\sigma^3}\right)\right) = \frac{-1}{\sigma} \left(n - \sum \frac{(x - \mu)^2}{\sigma^2}\right) = 0 \Rightarrow \sigma^2 = \sum \frac{(x - \mu)^2}{n}$$

که با محاسبه با اعداد بدست می‌آید:



$$\mu_{theory} = 100.48049999999999$$

$$\sigma_{theory} = 14.707769026946268$$

مقدار عددی نیز چیزی در همین حدود شد:

$$\mu_{numeric} = 100.48050398080368$$

$$\sigma_{numeric} = 14.707763577982128$$



شکل ۴: میزان likelihood به ازای مقادیر مختلف میانگین و واریانس. مقادیر محاسبه شده به صورت تئوری به صورت خط به نمایش درآمده‌اند.

c,d

سوال درواقع fisher information را می‌خواهد:

$$I^{-1} = \begin{bmatrix} \frac{\sigma^2}{n} & 0 \\ 0 & \frac{2\sigma^4}{n} \end{bmatrix} \approx \begin{bmatrix} 1.081 & 0 \\ 0 & 467.93 \end{bmatrix}$$

هم در حالت عددی و هم در حالت تئوری این مقدار تقریباً برابر است.

e

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2$$

با استفاده از این فرمول بازه با استفاده از کد در نوتبوک محاسبه شد. بازه اطمینان 95 درصد

انحراف معیار برابر است با:

[13.4274, 16.3507]

f

- برای Z test چون سائز نمونه از 30 بزرگ تر است می توان از خود Z استفاده کرد. چون راجع به Alternative Hypothesis حرفی زده نشده، تست two sided در نظر گرفته می شود. طبق فرمول داریم:

$$z = \frac{100.48 - 103}{\frac{14.7}{\sqrt{200}}} \approx -2.42 \Rightarrow p_value = 2 * (1 - Z_{-2.42}) \approx 0.01$$

پس یعنی فرض صفر رد می شود.