



پاییز ۱۴۰۴

استنباط آماری

تمرین سوم

مرتضی ملکی نژاد شوشتری - ۸۱۰۱۰۴۲۵۶

پاکسازی داده و استخراج ویژگی

داده‌های اولیه

مجموعه داده شامل ۷۲۰ فایل صوتی است که به صورت زیر توزیع شده‌اند:

◇ زبان آلمانی: ۱۸۰ نمونه

◇ زبان ایتالیایی: ۱۸۰ نمونه

◇ زبان کره‌ای: ۱۸۰ نمونه

◇ زبان اسپانیایی: ۱۸۰ نمونه

همه فایل‌های صوتی با نرخ نمونه‌برداری ۱۶ کیلوهرتز بارگذاری شده‌اند.

استخراج ویژگی‌ها

برای استخراج ویژگی‌های مناسب از فایل‌های صوتی، از دو روش اصلی استفاده شده است:

ویژگی‌های MFCC

MFCC (Mel-Frequency Cepstral Coefficients) یکی از ویژگی‌های رایج در پردازش سیگنال‌های صوتی است که اطلاعات مهمی در مورد طیف فرکانسی سیگنال ارائه می‌دهد. در این پروژه، ۱۳ ضریب MFCC برای هر فایل صوتی استخراج شده است.

ویژگی‌های Mel Spectrogram

Mel Spectrogram نمایشی از انرژی سیگنال در مقیاس Mel است که به درک انسان از فرکانس نزدیک‌تر است. در این پروژه، ۱۲۸ ویژگی Mel Spectrogram برای هر فایل صوتی استخراج شده است.

چون طول صوت‌ها برابر نیست، بعد دوم این ویژگی‌ها متفاوت است. و اکثر الگوریتم‌هایی که در ادامه استفاده می‌شوند نیاز دارند تا ابعاد ویژگی‌ها ثابت باشد. به همین منظور از این ویژگی‌ها در بعد دوم میانگین گرفته شد.

ترکیب ویژگی‌ها

در نهایت، با ترکیب این دو مجموعه ویژگی، یک بردار ویژگی 141 بعدی برای هر نمونه ایجاد شده است:

$$X_{combined} = [X_{MFCC}, X_{Mel}] \quad (1)$$


که در آن $X_{MFCC} \in \mathbb{R}^{13}$ و $X_{Mel} \in \mathbb{R}^{128}$ هستند.

نرمال‌سازی

برای بهبود عملکرد الگوریتم‌های یادگیری ماشین، تمام ویژگی‌ها با استفاده از StandardScaler نرمال‌سازی شده‌اند تا میانگین صفر و واریانس واحد داشته باشند.

تجسم داده‌ها

برای تجسم بهتر داده‌ها، از تحلیل مؤلفه‌های اصلی (PCA) استفاده شده و داده‌ها در فضای دو بعدی نمایش داده شده‌اند. شکل ۱ نمایش PCA ویژگی‌های MFCC و Mel Spectrogram را نشان می‌دهد.



شکل ۱: نمایش PCA ویژگی‌های MFCC و Mel Spectrogram

خوشه‌بندی

تعیین تعداد خوشه‌های بهینه

برای تعیین تعداد خوشه‌های بهینه، از دو روش استفاده شده است:


◇ روش Elbow: بررسی تغییرات Within Cluster نسبت به تعداد خوشه‌ها

◇ روش Silhouette Score: محاسبه نمره Silhouette برای تعداد خوشه‌های مختلف

نتایج حاصل از این دو روش در جدول ۱ و شکل ۲ نمایش داده شده‌اند.

جدول ۱: نتایج تعیین تعداد خوشه‌های بهینه

Silhouette Score	within cluster sum	تعداد خوشه‌ها
68106.60	0.3052	۲
52850.66	0.2814	۳
46053.22	0.2558	۴
41255.80	0.2550	۵
36803.24	0.2570	۶
32713.95	0.2805	۷
30534.69	0.2937	۸
28647.57	0.2966	۹
26826.33	0.2971	۱۰



شکل ۲: تعیین تعداد خوشه‌های بهینه با استفاده از روش Elbow و Silhouette Score

بر اساس نتایج، تعداد خوشه‌های بهینه برابر با ۴ انتخاب شده است که با تعداد کلاس‌های موجود (چهار زبان) مطابقت دارد.

الگوریتم‌های خوشه‌بندی

K-Means

الگوریتم K-Means یکی از ساده‌ترین و پرکاربردترین الگوریتم‌های خوشه‌بندی است. نتایج حاصل از اجرای این الگوریتم با ۴ خوشه در جدول ۲ نمایش داده شده است.

جدول ۲: نتایج خوشه‌بندی K-Means

مقدار	معیار
0.2558	Silhouette Score
46053.22	Inertia
۲۵۳	تعداد نمونه‌ها در خوشه ۰
۱۵۲	تعداد نمونه‌ها در خوشه ۱
۹۲	تعداد نمونه‌ها در خوشه ۲
۲۲۳	تعداد نمونه‌ها در خوشه ۳

Agglomerative Clustering (Single Link)

الگوریتم خوشه‌بندی سلسله‌مراتبی با استفاده از پیوند Single Link اجرا شده است. نتایج در جدول ۳ نمایش داده شده است.

جدول ۳: نتایج خوشه‌بندی سلسله‌مراتبی

مقدار	معیار
0.2103	Silhouette Score
۶۹۶	تعداد نمونه‌ها در خوشه ۰
۳	تعداد نمونه‌ها در خوشه ۱
۱۰	تعداد نمونه‌ها در خوشه ۲
۱۱	تعداد نمونه‌ها در خوشه ۳

همانطور که مشاهده می‌شود، این الگوریتم یک خوشه بزرگ با 696 نمونه و سه خوشه کوچک ایجاد کرده است که نشان‌دهنده مشکل الگوریتم Single Link در تشخیص خوشه‌های با اندازه‌های مختلف است.

Gaussian Mixture Model (GMM)

الگوریتم GMM با استفاده از مدل مخلوط گاوسی اجرا شده است. نتایج در جدول ۴ نمایش داده شده است.

جدول ۴: نتایج خوشه‌بندی GMM

مقدار	معیار
0.2808	Silhouette Score
193744.81	Log Likelihood
۲۶۹	تعداد نمونه‌ها در خوشه ۰
۲۷۸	تعداد نمونه‌ها در خوشه ۱
۸۸	تعداد نمونه‌ها در خوشه ۲
۸۵	تعداد نمونه‌ها در خوشه ۳


مقایسه الگوریتم‌های خوشه‌بندی

جدول ۵: مقایسه کلی الگوریتم‌های خوشه‌بندی را نشان می‌دهد.

جدول ۵: مقایسه الگوریتم‌های خوشه‌بندی

الگوریتم	Silhouette Score	توزیع خوشه‌ها
K-Means	0.2558	
Hierarchical (Single Link)	0.2103	
GMM	0.2808	

شکل ۳: نمایش بصری نتایج خوشه‌بندی را با استفاده از PCA نشان می‌دهد.



شکل ۳: نمایش بصری نتایج خوشه‌بندی با استفاده از PCA

طبقه‌بندی

تقسیم داده‌ها

داده‌ها به صورت تصادفی به دو مجموعه آموزش و آزمون تقسیم شده‌اند:

◇ مجموعه آموزش: 576 نمونه (80%)

◇ مجموعه آزمون: 144 نمونه (20%)

توزیع کلاس‌ها در هر دو مجموعه به صورت یکنواخت حفظ شده است.

الگوریتم‌های طبقه‌بندی

K-Nearest Neighbors (KNN)

الگوریتم KNN با استفاده از همسایگان نزدیک برای طبقه‌بندی استفاده شده است.

Support Vector Machine (SVM)

الگوریتم SVM با استفاده از کرنل مناسب برای طبقه‌بندی چندکلاسه استفاده شده است.

Random Forest

الگوریتم Random Forest با استفاده از مجموعه‌ای از درخت‌های تصمیم‌گیری اجرا شده است.

Neural Network (MLP)

شبکه عصبی چندلایه (MLP) با استفاده از MLPClassifier اجرا شده است.

نتایج طبقه‌بندی

نتایج حاصل از اجرای الگوریتم‌های مختلف در جدول ۶ نمایش داده شده است.

جدول ۶: نتایج کلی طبقه‌بندی


الگوریتم	دقت (Accuracy)
KNN	0.9722
SVM	0.9861
Random Forest	0.9861
Neural Network	0.9722

جدول ۷ معیارهای تفصیلی شامل Precision، Recall و F1-Score را برای هر الگوریتم نشان می‌دهد.

جدول ۷: معیارهای تفصیلی طبقه‌بندی

الگوریتم	دقت	Macro Precision	Macro Recall	Macro F1	Weighted Precision	Weighted Recall	Weighted F1
KNN	0.9722	0.9737	0.9722	0.9722	0.9737	0.9722	0.9722
SVM	0.9861	0.9865	0.9861	0.9861	0.9865	0.9861	0.9861
Random Forest	0.9861	0.9865	0.9861	0.9860	0.9865	0.9861	0.9860
Neural Network	0.9722	0.9737	0.9722	0.9722	0.9737	0.9722	0.9722


شکل ۴: نمایش بصری معیارهای مختلف را برای الگوریتم‌های مختلف نشان می‌دهد.



شکل ۴: مقایسه معیارهای مختلف طبقه‌بندی

ماتریس درهم‌ریختگی

ماتریس‌های درهم‌ریختگی برای هر الگوریتم در شکل ۵ نمایش داده شده‌اند.



شکل ۵: ماتریس‌های درهم‌ریختگی برای الگوریتم‌های مختلف

بحث و نتیجه‌گیری

نتایج خوشه‌بندی

از بین الگوریتم‌های خوشه‌بندی مورد استفاده، K-Means بهترین عملکرد را با Silhouette Score برابر با 0.2558 داشته است. این الگوریتم توزیع متعادلی از نمونه‌ها در خوشه‌های مختلف ایجاد کرده است. الگوریتم Hierarchical با Single Link عملکرد ضعیف‌تری داشته و یک خوشه بزرگ با اکثریت نمونه‌ها ایجاد کرده است.

نتایج طبقه‌بندی

همه الگوریتم‌های طبقه‌بندی عملکرد بسیار خوبی داشته‌اند و دقت بالای 97% را نشان داده‌اند. SVM و Random Forest با دقت 98.61% بهترین عملکرد را داشته‌اند. KNN و Neural Network نیز با دقت 97.22% عملکرد بسیار خوبی داشته‌اند. تفاوت‌های جزئی در معیارهای Precision، Recall و F1-Score نشان می‌دهد که همه الگوریتم‌ها به خوبی قادر به تشخیص و تمایز بین زبان‌های مختلف هستند.

نتیجه‌گیری نهایی

نتایج نشان می‌دهد که ویژگی‌های استخراج شده (MFCC و Mel Spectrogram) برای تشخیص زبان مناسب هستند و الگوریتم‌های یادگیری ماشین قادر به استفاده مؤثر از این ویژگی‌ها هستند. در بین الگوریتم‌های طبقه‌بندی، SVM و Random Forest بهترین عملکرد را داشته‌اند و می‌توانند برای کاربردهای عملی استفاده شوند. برای افزایش دقت می‌توان تعداد ویژگی‌ها را بیشتر کرد و از مدل‌هایی که از این نکته بهره می‌برند، مثل شبکه عصبی استفاده کرد تا دقت بالاتری گرفت.

خوشه‌بندی حتی در بهترین حالت هم نمی‌تواند به عنوان معیار خوبی برای تشخیص زبان‌ها باشد. ولی می‌توان از آن برای سنجش شباهت زبان‌ها به هم استفاده کرد.

چون حساب کردن متریک‌ها به داده خروجی نیاز دارد، در همان نوتبوک‌های classification و clustering متریک‌ها حساب شدند.