

دانشگاه تهران
پردیس دانشکده‌های فنی

دانشکده مهندسی برق و کامپیوتر

تمرین شماره: ۲
یادگیری عمیق با کاربرد در تصویر و صوت

نام و نام خانوادگی: مرتضی ملکی‌نژاد شوشتری
شماره دانشجویی: ۸۱۰۱۰۴۲۵۶

نیم‌سال دوم سال تحصیلی ۴۰۴-۴۰۵

فهرست مطالب

۴	۱ آشنایی با محاسبات انجام شده در فرآیند آموزش
۴	۱.۱ انجام یک مرحله آموزش کامل
۴	۱.۱.۱ مقادیر اولیه
۵	۲.۱.۱ انتشار رو به جلو
۶	۳.۱.۱ انتشار رو به عقب
۸	۲.۱ مقایسه انواع pooling
۸	۳.۱ تغییر تعداد کانال
۹	۲ طبقه بندی با کمک شبکه های مدرن پیچشی
۹	۱.۲ ساخت دیتالودر به صورت دستی
۱۰	۲.۲ جایگذاری بلوک A
۱۲	۳.۲ جایگذاری بلوک B
۱۳	۴.۲ جایگذاری بلوک C
۱۵	۵.۲ نتایج
۱۷	۶.۲ نمایش خروجی فیلترهای کانولوشنی
۱۷	۷.۲ انتقال دانش

فهرست تصاویر

۱۰.۱	معماری مدل	۵
۱۰.۲	شاخص‌های مختلف مدل A هنگام آموزش	۱۱
۲.۲	شاخص‌های مختلف مدل B هنگام آموزش	۱۲
۳.۲	شاخص‌های مختلف مدل B هنگام آموزش	۱۴
۴.۲	نمودار خطا و دقت هر سه مدل در کنار هم	۱۵
۵.۲	یک عکس ورودی و خروجی فیلترهای لایه اول مدل برای آن	۱۷
۶.۲	خروجی و دقت روی مجموعه داده‌های آموزش و صحت‌سنجی برای fashion mnist	۱۸
۷.۲	ماتریس درهم‌ریختگی برای مدل با بلوک A (بهترین مدل) روی مجموعه داده fashion mnist	۱۹
۸.۲	نمونه اعضای کلاس‌های مجموعه داده Fashion mnist	۲۰
۹.۲	ماتریس درهم‌ریختگی بدون منجمد کردن لایه استخراج ویژگی	۲۱

فهرست جداول

۱۱	شاخص‌های مختلف مدل A هنگام آموزش	۱.۲
۱۳	شاخص‌های مختلف مدل B هنگام آموزش	۲.۲
۱۴	شاخص‌های مختلف مدل C هنگام آموزش	۳.۲
۱۵	نتیجه نهایی مدل‌ها	۴.۲
۱۸	دقت مدل روی مجموعه داده آزمون fashion mnist	۵.۲

سوال ۱

آشنایی با محاسبات انجام شده در فرآیند آموزش

این سوال به روابط ریاضی مورد استفاده در یک شبکه عصبی پیچشی می‌پردازد.


۱.۱ انجام یک مرحله آموزش کامل

۱.۱.۱ مقادیر اولیه

با استفاده از کد داده شده، اطلاعات شبکه مطابق زیر است:

$$X_1 = \begin{bmatrix} -2 & 0 & -1 \\ -2 & -2 & 0 \\ 0 & -2 & -1 \end{bmatrix} \quad X_2 = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 2 \\ 0 & 0 & 0 \end{bmatrix}$$

$$W_{conv1} = \begin{bmatrix} -1 & 0 \\ 1 & 2 \end{bmatrix} \quad W_{conv2} = \begin{bmatrix} 1 & 1 \\ 0 & 2 \end{bmatrix} \quad W_{linear} = \begin{bmatrix} 2 & -2 & -4 & 3 \end{bmatrix}$$
$$bias_{conv} = -1 \quad bias_{linear} = 1$$



شکل ۱.۱: معماری مدل

۲.۱.۱ انتشار رو به جلو

برای بخش padding داریم:

$$X_{padded_1} = \begin{bmatrix} -2 & -2 & -2 & 0 & -2 \\ 0 & -2 & 0 & -1 & 0 \\ -2 & -2 & -2 & 0 & -2 \\ -2 & 0 & -2 & -1 & -2 \\ -2 & -2 & -2 & 0 & -2 \end{bmatrix} \quad X_{padded_2} = \begin{bmatrix} 0 & 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 2 & 0 \end{bmatrix}$$

سپس برای convolution داریم:

$$z_1 = X_{padded_1} * W_1 = \begin{bmatrix} -2 & 0 & 0 & -1 \\ -6 & -4 & -2 & -3 \\ 0 & -2 & -2 & -5 \\ -4 & -6 & 0 & -3 \end{bmatrix} \quad z_2 = \begin{bmatrix} 0 & 0 & 2 & 2 \\ 0 & 0 & 4 & 0 \\ 0 & 0 & 2 & 2 \\ 0 & 0 & 4 & 0 \end{bmatrix}$$

$$\Rightarrow z = z_1 + z_2 + bias = \begin{bmatrix} -3 & -1 & 1 & 0 \\ -7 & -5 & 1 & -4 \\ -1 & -3 & -1 & -4 \\ -5 & -7 & 3 & -4 \end{bmatrix}$$

بعد از این مرحله باید max pooling انجام شود:

$$z_{pooled} = \begin{bmatrix} -1 & 1 \\ -1 & 3 \end{bmatrix}$$

سپس اعمال تابع leaky ReLU با شیب 0.1

و سپس flat کردن را داریم:

$$a_1 = \begin{bmatrix} -0.1 & 1 \\ -0.1 & 3 \end{bmatrix} \Rightarrow a_{1_{flat}} = \begin{bmatrix} -0.1 \\ 1 \\ -0.1 \\ 3 \end{bmatrix}$$

حال باید لایه خطی نهایی را اعمال کرد و مقدار بایاس را به آن اضافه نمود:

$$z_2 = \begin{bmatrix} 2 & -2 & -4 & 3 \end{bmatrix} * \begin{bmatrix} -0.1 \\ 1 \\ -0.1 \\ 3 \end{bmatrix} = 7.2 \quad a_2 = z_2 + bias = 8.2$$

پس یعنی خروجی شبکه برای این ورودی مقدار 8.2 است.

۳.۱.۱ انتشار رو به عقب

اول باید مقدار خطا حساب شود. با توجه به اینکه در سوال آمده است برای خطا از میانگین مجذور استفاده شود، مقدار برچسب برابر 1- و ضریب یادگیری برابر 0.1 است، داریم:

$$error_{mse} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = 9.2^2 = 84.64$$

حال باید با استفاده از قاعده زنجیری، مقدار گرادیان خطا نسبت به هر پارامتر را یافت. (درموقع محاسبه مشتق و گذر از لایه pooling یک وضعیت تساوی پیش آمد. با مشورت با هوش مصنوعی، مقدار گرادیان فقط به اولین بیشینه اختصاص داده شد.) (برای کانولوشن از نماد * استفاده شده است.)

$$\begin{aligned}
 \frac{\partial E}{\partial a_2} &= 2(8.2 - (-1)) = 18.4 \frac{\partial E}{\partial bias_{linear}} = \frac{\partial E}{\partial a_2} * \frac{\partial a_2}{\partial bias_{linear}} = 18.4 \\
 \frac{\partial E}{\partial W_{linear}} &= \frac{\partial E}{\partial a_2} * \frac{\partial a_2}{\partial W_{linear}} = 18.4 * a_{1_{flat}}^T = \begin{bmatrix} -1.84 & 18.4 & -1.84 & 55.2 \end{bmatrix} \\
 \frac{\partial E}{\partial a_{1_{flat}}} &= \frac{\partial E}{\partial a_2} * \frac{\partial a_2}{\partial z_2} * \frac{\partial z_2}{\partial a_{1_{flat}}} = 18.4 * 1 * W_{linear}^T = \begin{bmatrix} 36.8 \\ -36.8 \\ -73.6 \\ 55.2 \end{bmatrix} \Rightarrow \frac{\partial E}{\partial a} = \\
 \begin{bmatrix} 36.8 & -36.8 \\ -73.6 & 55.2 \end{bmatrix} \\
 \Rightarrow \frac{\partial E}{\partial z_{pooled}} &= \begin{bmatrix} 3.68 & -36.8 \\ -7.36 & 55.2 \end{bmatrix} \\
 \frac{\partial E}{\partial z} &= \frac{\partial E}{\partial z_{pooled}} * \frac{\partial z_{pooled}}{\partial z} = \begin{bmatrix} 0 & 3.68 & -36.8 & 0 \\ 0 & 0 & 0 & 0 \\ -7.36 & 0 & 0 & 0 \\ 0 & 0 & 55.2 & 0 \end{bmatrix} \\
 \frac{\partial E}{\partial bias_{conv}} &= \frac{\partial E}{\partial z} * \frac{\partial z}{\partial bias_{conv}} = sum \begin{bmatrix} 0 & 3.68 & -36.8 & 0 \\ 0 & 0 & 0 & 0 \\ -7.36 & 0 & 0 & 0 \\ 0 & 0 & 55.2 & 0 \end{bmatrix} = 14.72 \\
 \frac{\partial E}{\partial z_1} &= \frac{\partial E}{\partial z} * \frac{\partial z}{\partial z_1} = \frac{\partial z}{\partial z_1} \Rightarrow \frac{\partial E}{\partial z_1} = \frac{\partial E}{\partial z_2} = \frac{\partial E}{\partial z} = \begin{bmatrix} 0 & 3.68 & -36.8 & 0 \\ 0 & 0 & 0 & 0 \\ -7.36 & 0 & 0 & 0 \\ 0 & 0 & 55.2 & 0 \end{bmatrix} \\
 \frac{\partial E}{\partial W_{conv1}} &= \frac{\partial E}{\partial z_1} * \frac{\partial z_1}{\partial W_{conv1}} = \frac{\partial E}{\partial z_1} * X_{padded_1} = \begin{bmatrix} -29.44 & -47.84 \\ -103.04 & 36.8 \end{bmatrix} \\
 \frac{\partial E}{\partial W_{conv2}} &= \frac{\partial E}{\partial z_2} * \frac{\partial z_2}{\partial W_{conv2}} = \frac{\partial E}{\partial z_2} * X_{padded_2} = \begin{bmatrix} 0 & -73.6 \\ 0 & 110.4 \end{bmatrix}
 \end{aligned}$$

حال با توجه به اینکه ضریب یادگیری برابر 0.1 است، باید مقدار گرادیان‌ها را در 0.1 ضرب کرد و با

مقدار قبلی پارامتر جمع کرد تا به مقدار جدید رسید. پس داریم:

$$\begin{aligned} bias_{linear} &= 1 - 0.1 * 18.4 = 1 - 1.84 = -0.84 \\ W_{linear} &= \begin{bmatrix} 2 & -2 & -4 & 3 \end{bmatrix} - 0.1 \begin{bmatrix} -1.84 & 18.4 & -1.84 & 55.2 \end{bmatrix} = \begin{bmatrix} 2.184 & -3.84 & -3.816 & -2.52 \end{bmatrix} \\ bias_{conv} &= -1 - 0.1 * 14.72 = -2.472 \\ W_{conv1} &= \begin{bmatrix} -1 & 0 \\ 1 & 2 \end{bmatrix} - 0.1 \begin{bmatrix} -29.44 & -47.84 \\ -103.04 & 36.8 \end{bmatrix} = \begin{bmatrix} 1.944 & 4.784 \\ 11.304 & -1.68 \end{bmatrix} \\ W_{conv2} &= \begin{bmatrix} 1 & 1 \\ 0 & 2 \end{bmatrix} - 0.1 \begin{bmatrix} 0 & -73.6 \\ 0 & 110.4 \end{bmatrix} = \begin{bmatrix} 1 & 8.36 \\ 0 & -9.04 \end{bmatrix} \end{aligned}$$

۲.۱ مقایسه انواع pooling

اگر از average pooling استفاده می‌شود، در انتشار رو به جلو، هنگام بدست آوردن z_{pooled} از روی z به جای اینکه بیشینه در نظر گرفته شود، میانگین حساب می‌شود و در انتشار رو به عقب، به جای این که یک ماسک بولین^۱ در نظر گرفته شود که مقادیر بیشینه در یک مربع دو در دو در آن یک هستند، مقدار گرادیان بر تعداد درایه‌های پنجره (در اینجا ۴) تقسیم شده و مشتق z بدست می‌آید.

۳.۱ تغییر تعداد کانال

در اینجا در لایه کانولوشن عملاً فقط یک ویژگی حساب می‌شود و لایه فقط یک هسته^۲ دارد. برای تعداد کانال خروجی بیشتر، یعنی لایه کانولوشن باید ویژگی‌های بیشتری را بیابد، پس باید چندین هسته داشته باشد. هر هسته به اندازه کانال‌های ورودی * ابعاد فیلتر باید پارامتر داشته باشد.

برای مثال، اگر بخواهیم خروجی لایه کانولوشن دو کاناله باشد، باید $2 * 2 * 2$ پارامتر جدید برای پارامترهای کانولوشن و ۱ پارامتر جدید برای بایاس هسته جدید معرفی کرد. هر هسته بین پارامترهای خود و کانال‌های ورودی عمل کانولوشن را انجام می‌دهد و سپس خروجی کانال‌های مختلف ورودی و مقدار bias را باهم جمع می‌کند. چون دو هسته موجود است، خروجی لایه یک خروجی دو کاناله با ابعاد ۴ در ۴ است.

^۱boolean

^۲kernel

سوال ۲

طبقه بندی با کمک شبکه های مدرن پیچشی

۱.۲ ساخت دیتالودر به صورت دستی

اول برای مجموعه داده، ابعاد آن به ۲۸ در ۲۸ تغییر داده شد تا لایه های پیچشی دو بعدی^۱ بتوانند کار کنند. برای افزودن داده، سه تغییر چرخش، انتقال و نویز نمک فلفلی^۲ صرفاً روی مجموعه داده آموزش با ضریب احتمال 0.2 اضافه شدند. از آنجایی که حجم مجموعه داده بزرگ است، برای این که زمان آموزش خیلی زیاد نشود، بخش افزودن داده تصویر جدیدی درست نمی کند و صرفاً تصویر قبلی را تغییر می دهد. همچنین بر روی همه مجموعه ها (آموزش، صحت سنجی و آزمون) چک می شود که اگر مقدار شدت رنگ بصورت ۰ تا ۲۵۵ داده شده، به صفر تا یک مقیاس^۳ شود. در بخش دیتالودر^۴ مقدار ۳۲ برای سایز دسته^۵ در نظر گرفته شد و تعیین شد تا داده ها بصورت تصادفی جابجا شوند.^۶

¹2d convolutional

²Salt and pepper noise

³Scale

⁴DataLoader

⁵Batch size

⁶Shuffle


۲.۲ جایگذاری بلوک A

در این بخش از بلوک A استفاده شد. نکته خاص بلوک A این است که با اضافه کردن یک اتصال باقی‌مانده^۷ باعث می‌شود تا بلوک ویژگی‌های ورودی را از دست ندهد و هم ویژگی‌های ورودی و هم ویژگی‌های استخراجی در خروجی آن نقش دارد.

تفاوت دو نوع معماری داده شده در این است که یکی از آن‌ها در ارتباط مستقیم ورودی، یک لایه پیچش یک در یک دارد. این باعث می‌شود تا این بلوک مجبور نباشد تا تعداد کانال‌های ورودی و خروجی آن برابر باشد، زیرا اگر این لایه نبود، هنگام جمع ورودی و خروجی بلوک، ابعاد متفاوت می‌شد ولی با وجود این بلوک، ارتباط مستقیم از یک لایه کانولوشن عبور می‌کند که کانال‌های ورودی آن برابر با کانال‌های ورودی بلوک و کانال‌های خروجی آن برابر با کانال‌های خروجی بلوک است.

این لایه یک در یک علاوه بر تطبیق ابعاد، این امکان را نیز به مدل می‌دهد تا عمق بیشتری (کانال‌های بیشتری) از تصویر را پردازش کند و سپس این ویژگی‌ها را باهم ترکیب کند.

⁷Residual connection




شکل ۱.۲: شاخص‌های مختلف مدل A هنگام آموزش

جدول ۱.۲: شاخص‌های مختلف مدل A هنگام آموزش

Epoch	train_loss	train_acc	val_loss	val_acc
0	0.155060	95.310000	0.058931	98.360000
1	0.055143	98.426000	0.025974	99.240000
2	0.046224	98.662000	0.023006	99.380000
3	0.039257	98.890000	0.020706	99.430000
4	0.035947	98.968000	0.026350	99.200000

۳.۲ جایگذاری بلوک B

ایده بلوک B که از مدل اینسپشن^۸ الهام گرفته شده است، این است که در شبکه‌های پیچش، یکی از چالش‌ها تعیین اندازه هسته پیچش^۹ است که می‌تواند باعث شود ویژگی‌های خوبی استخراج نشود و یا آموزش مدل طولانی شود. این بلوک، هسته‌های مختلفی را امتحان کرده و در نهایت همه آن‌ها باهم خروجی را تشکیل می‌دهند.



شکل ۲.۲: شاخص‌های مختلف مدل B هنگام آموزش

^۸Inception

^۹Convolution Kernel

جدول ۲.۲: شاخص‌های مختلف مدل B هنگام آموزش


Epoch	train_loss	train_acc	val_loss	val_acc
0	0.426373	85.952000	0.157498	95.360000
1	0.130969	96.054000	0.078504	97.440000
2	0.103298	96.940000	0.061154	98.210000
3	0.092428	97.144000	0.046544	98.730000
4	0.086451	97.344000	0.045756	98.740000

۴.۲ جایگذاری بلوک C

بلوک C عملاً ترکیب دو بلوک قبل است. به این صورت که اتصال باقی‌مانده که در بلوک A بود را دارد و همچنین شبکه‌های پیچشی متعدد که در بلوک B موجود بود را نیز دارد.

پارامتر g عملاً تعداد گروه‌های پیچشی را نشان می‌دهد (که برای مثال در بلوک B دو لایه پیچشی سه در سه وجود دارد).

هرچقدر این گروه‌ها بیشتر باشند، اطلاعات متنوع‌تری (و نه لزوماً عمیق‌تر) از داده‌ها یافت می‌شود ولی مدل سنگین‌تر می‌شود.




شکل ۳.۲: شاخص‌های مختلف مدل B هنگام آموزش

جدول ۳.۲: شاخص‌های مختلف مدل C هنگام آموزش

Epoch	train_loss	train_acc	val_loss	val_acc
0	0.486524	83.976000	0.182243	94.850000
1	0.162272	95.110000	0.062752	98.140000
2	0.123943	96.212000	0.063555	98.000000
3	0.103672	96.802000	0.075380	97.740000
4	0.095231	97.052000	0.098605	97.420000

۵.۲ نتایج



شکل ۴.۲: نمودار خطا و دقت هر سه مدل در کنار هم

جدول ۴.۲: نتیجه نهایی مدل‌ها

مدل	آموزش	صحت‌سنجی	آزمون
تمرین اول	99.124	97.5	97.43
بلوک A	99.27	99.2	98.068
بلوک B	98.72	98.74	96.512
بلوک C	97.07	97.42	97.042

همانطور که در نمودار ۴.۲ می‌توان دید، بعد از پنج دور آموزش، همچنان خطای آموزش نزولی هست ولی خطای صحت‌سنجی دیگر نزولی نیست و مدل اشباع شده است. برای جلوگیری از بیش‌برازش از افزودن نویز به تصویر در بخش افزودگی داده و اضافه کردن لایه دراپ‌اوت^{۱۰} استفاده شد و خطای صحت‌سنجی به آموزش

¹⁰Dropout

نزدیک شد ولی همچنان جای کار دارد.

با دیدن جدول ۴.۲ می‌توان دید که به غیر از مدل A بقیه مدل‌ها از مدل تمرین اول عملکرد ضعیف‌تری دارند. این موضوع به این دلیل است که مجموعه داده MNIST مجموعه داده به نسبت ساده‌ای است و یک مدل عصبی ساده ولی با بهینه‌سازی‌های جانبی (برای مثال استفاده از منظم‌سازی و تنظیم دقیق تعداد نوروں و لایه) می‌تواند به خوبی آن را فرا بگیرد. ولی مدل‌های پیچیده‌تری مثل مدل‌های این سوال چون قدرت بیشتری دارند، احتمال دچار شدن به بیش‌برازش نیز در آن‌ها بیشتر است. با افزایش تعداد دوره‌های یادگیری به ۵۰ (تعداد دوره آموزشی در تمرین اول) می‌توان با اطمینان خوبی حدس زد که خطای آموزش در این مدل‌ها بسیار کمتر باشد ولی خطای صحت‌سنجی بهبودی نیابد و یا حتی بدتر شود.


تنها مدلی که از مدل تمرین قبل بهتر عمل کرد مدل با بلوک A است. زیرا با استفاده از اتصال باقی‌مانده، این مدل هم ویژگی‌های ساده (ویژگی‌های ورودی) و هم ویژگی‌های مکانی پیچیده‌تری که با لایه پیچشی یاد گرفته است را حفظ می‌کند و در نتیجه در این تسک ساده، داده‌ای را از دست نمی‌دهد و اطلاعات بیشتری را برای لایه‌های تماماً متصل^{۱۱} فراهم می‌کند. البته حتی این موضوع هم بعد از افزودن نویز و لایه دراپ‌اوت ممکن شد.

به عنوان مثال. بلوک C که به عنوان ترکیب دو بلوک دیگر است از هردوی آن‌ها ضعیف‌تر عمل کرده است. روند مشهود در آموزش به این صورت است که هرچقدر مدل‌ها پیچیده‌تر شدند دقت کمتر شده است. پس عملاً در اینجا کم‌برازش^{۱۲} رخ نداده است و اصلاً از اول نیز نیازی به استفاده از مدل‌های پیچیده نبوده.

¹¹Fully connected

¹²Underfitting

۶.۲ نمایش خروجی فیلترهای کانولوشنی



شکل ۵.۲: یک عکس ورودی و خروجی فیلترهای لایه اول مدل برای آن

با توجه به عکس ۵.۲ می‌توان دید که فیلترها در اینجا کارهایی مثل لبه‌یابی عمودی (مثلاً کانال ۶)، لبه‌یابی افقی (کانال ۹) و یا وارونه کردن رنگ‌های تصویر (کانال ۲) را انجام داده‌اند. فیلترهای ساده‌ای که در بینایی ماشین کلاسیک بصورت دستی تهیه و به مدل‌ها داده می‌شد.

۷.۲ انتقال دانش


با انجام این کار آموزش بسیار سریع‌تر شد. البته فریز کردن لایه در این‌جا خیلی منطقی نیست زیرا از مجموعه داده جدید نیز حجم خوبی موجود است. نتایج این آموزش در جدول ۵.۲ آمده است.

در بررسی‌هایی که انجام شد، فریز نکردن لایه‌ها باعث شد تا مطابق انتظار فرآیند آموزش طول بکشد ولی


بعد از ۲۰ دوره، دقتی حدود ۷۰ درصد را نتیجه داد که از نتیجه‌های بدست آمده بهتر است.

جدول ۵.۲: دقت مدل روی مجموعه داده آزمون fashion mnist

مدل	دقت
بلوک A	62.86
بلوک B	50.0
بلوک C	48.43




شکل ۶.۲: خروجی و دقت روی مجموعه داده‌های آموزش و صحت‌سنجی برای fashion mnist



شکل ۷.۲: ماتریس درهم‌ریختگی برای مدل با بلوک A (بهترین مدل) روی مجموعه داده fashion mnist


همانطور که در تصویر ۷.۲ می‌توان دید، مدل خیلی خوب عمل نکرده است و بخش خوبی از تصاویر را در کلاس‌های صفر و چهار طبقه‌بندی کرده است (البته این موضوع ثابت نیست و در یک اجرای دیگر کلاس‌های شش و نه بیشترین عضو را داشتند). دلیلی که برای این اشتباه می‌تواند باشد این است که ویژگی‌هایی که برای تشخیص اعداد بکار می‌رود عموماً از جنس انحنای اعداد است ولی ویژگی‌هایی که برای طبقه‌بندی در مجموعه داده fashion mnist استفاده می‌شوند از جنس بافت لباس هستند. و برخلاف اعداد، لباس‌ها ممکن است انحنای یکسانی داشته باشند (برای مثال گروه صفر، دو، چهار و شش) و تنها تفاوت آن‌ها در جنس لباس باشد.



شکل ۸.۲: نمونه اعضای کلاس‌های مجموعه‌داده Fashion mnist

اگر لایه استخراج ویژگی منجمد نشود، ماتریس درهم‌ریختگی ۹.۲ حاصل می‌شود که در آن دیگر مدل بایاس^{۱۳} روی گروه خاصی ندارد و خطا به نسبت پراکندگی دارد. گروه‌هایی که شباهت ظاهری دارند (برای مثال گروه ۲ و گروه ۴) باهم اشتباه گرفته می‌شوند.

¹³Bias



شکل ۹.۲: ماتریس درهم‌ریختگی بدون منجمد کردن لایه استخراج ویژگی