

به نام خدا



دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده برق و کامپیوتر



یادگیری عمیق با کاربرد در تصویر و صوت

دکتر رشاد حسینی

تمرین شماره ۴

طرح تمرین:

پرهام سازدار

خرداد ۱۴۰۵

فهرست مطالب

3	 فهرست شکلها
4	 فهرست جدولها
5	 جدول اصطلاحات تخصصی
6	 سؤال اول – برچسب گذاری دنباله (۵۰ نمره)
6	 هدف تمرین
6	 بخش اول (برسی پایگاه داده) (۱.۱)
7	 بخش دوم (برسی collate_fn) (۲.۱)
7	 بخش سوم (آموزش شبکه) (۳.۱)
9	 سؤال دوم – VIT (۶۰ نمره)
9	 هدف تمرین
10	 بخش اول (آموزش شبکه Vit) (۱.۲)
11	 سوال دوم (برسی حالت های دیگر) (۲.۲)
13	 مراجع
14	 پیاده سازی
15	 گزارش
15	 بارگذاری
16	 ارتباط با ما

فهرست شکل‌ها

شکل ۱- معماری مدل مبدل تصویر ۱۰

شکل ۲- نقشه توجه ۱۲

فهرست جدول‌ها

جدول ۱ اصطلاحات تخصصی	۵
جدول ۲ پارامترهای آموزش شبکه	۱۱

جدول اصطلاحات تخصصی

جدول ۱ اصطلاحات تخصصی

اصطلاح	مخفف	معادل فارسی
MultiLayer Perceptron	MLP	پرسپترون چندلایه
Stochastic Gradient Descent	SGD	کاهش گرادیان تصادفی
Activation Function	-	تابع فعال ساز
Loss Function	-	تابع هزینه
Mean Squared Error	MSE	میانگین مربعات خطا
Learning rate	-	نرخ یادگیری
Cross-Entropy	CE	آنترپی متقابل
Accuracy	-	صحت
Epoch	-	دوره
Batch size	-	اندازه بسته
Confusion Matrix	-	ماتریس درهم ریختگی
Precision	-	دقت
Recall	-	یادآوری

سؤال اول – برچسب گذاری دنباله (۵۰ نمره)

هدف تمرین

در این تمرین به کمک شبکه ی LSTM به پیش بینی لیبل های (NER (Name Entity Recognition میپردازید ، در این سوال تنها الزام است از معماری Encoder استفاده کنید .این تسک، اعمال تسکی مهم و در عین حال ساده از منظر پردازش زبان طبیعی سنتی تا پیش از معرفی ترنسفورمر می باشد، در این بخش به خوبی خواهید دانست که قوت مدل ها تا پیش از معماری جدید ترنسفورمر چه بود. دیتاست مورد استفاده در این سوال، دیتاست [conll/eriktks](#) می باشد.

بخش اول (برسی پایگاه داده) (۱.۱)

الف) ابتدا dataset را load کرده و به بررسی آن بپردازید، این دیتاست شامل چه ستون هایی (features) است؟ (۳ نمره)

ب) میبیند که در این دیتاست به جز tag های ner ، دو tag دیگر نیز وجود دارد، هر کدام چه چیزی را نمایش میدهد؟ درباره آن ها توضیح دهید. (۴ نمره)

ج) از بخش train دیتاست برای ساخت کلاس vocab استفاده کنید، کلاس vocab شما باید دارای توابع زیر باشد: (۱۰ نمره)

- تابع ساخت vocab
- تابع تبدیل توکن به id
- تابع تبدیل id به توکن
- تابع که اندازه vocab را نمایش دهد

به نکات زیر دقت کنید

- این دیتاست tokenize شده است و نیازی نیست که مجددا جمله ها را tokenize کنید .
- توکن های '</s>', '<s>', '<unk>', '<pad>' به وکب خود اضافه کنید.
- از یک متغیر cutoff در ساخت vocab استفاده کنید تا توکن های با تکرار کمتر از cutoff را به وکب اضافه نکند، مقدار cutoff را برابر ۵ قرار دهید.

د) بعد از نوشتن کلاس vocab و ساختن واژگان : (۳ نمره)

- سائز واژگان را نمایش دهید.
- مشخص کنید که $id = 0$ چه توکنی است.
- توکن "quick" دارای چه id می باشد.

بخش دوم (برسی `collate_fn`) (۲.۱)

در این بخش به آماده سازی dataset و data loader بپردازید، همچنین دقت کنید که به دلیل تفاوت در طول جملات و استفاده از batch در آموزش شبکه، باید طول تمامی جملات هم اندازه باشند. در نتیجه می بایست طول جملات کوتاه تر با استفاده از توکن `<pad>` افزایش یابند تا هم اندازه شوند، برای این کار شما لازم است از متغیر `collate_fn` در ساخت data loader استفاده کنید. (۷ نمره)

الف) توضیح دهید که استفاده از `collate_fn` چه برتری نسبت به پد کردن تمام جملات به اندازه بزرگترین جمله دیتاست دارد؟ (۱ نمره)

ب) بعد از ساختن دیتالودر، ابعاد (shape) اولین batch دیتالودر در مجموعه train و validation را نمایش دهید. (۲ نمره)

بخش سوم (آموزش شبکه) (۳.۱)

الف) شبکه Encoder با ویژگی های زیر تعریف کنید: (۵ نمره)

- شامل لایه Embedding
- شامل یک لایه RNN دو طرفه (bidirection)
- شامل یک لایه Linear

بعد از آموزش شبکه برای ۱۰ اپاک موارد زیر را نمایش دهید:

- نمودارهای های تابع هزینه و دقت روی دیتای train و validation را رسم کنید.
- با استفاده از `classification_report` از کتابخانه sklearn دقت بدست آمده روی هر لیبل را نمایش دهید.

نکته مهم: دقت کنید که لیبل هایی که برای pad کردن استفاده کردید باید حین آموزش شبکه mask شوند (یعنی در محاسبه loss و دقت مورد استفاده قرار نگیرند) تا دقت بدست آمده واقعی باشد.

پارامترهای شبکه:

- `embedding_size = 64`
- `hidden_size = 64`
- `batch_size = 32`
- `num_epochs = 10`
- `learning_rate = 1e-3`

ب) بخش الف را تکرار کنید، اما این بار از biLSTM برای شبکه استفاده کنید و نمودارها و classification report را نمایش دهید. (۵ نمره)

ج) بخش ب را تکرار کنید، اما این بار از biGRU برای شبکه استفاده کنید و نمودارها و classification report را نمایش دهید. (۵ نمره)

چ) تفاوت نتایج بخش الف و ب و ج را تحلیل کنید؟ آیا تفاوتی که میبینید قابل توجه است؟ تحلیل خود را ذکر کنید. (۵ نمره)

هدف تمرین

در سال ۲۰۱۵، جرقه‌های اولیه‌ی توجه در شبکه‌های عصبی با ارائه نشان‌ده، توجه‌کن و بگو [۳] زده شد، جایی که مدل پیشنهادی یاد گرفت چگونه با تمرکز بر بخش‌های خاصی از تصویر، توضیحاتی را به ازای آن بخش‌ها تولید کند. این ایده در مقاله‌ی توجه همه چیز است که نیاز دارید [۴] به اوج خود رسید و مدل مبدل معرفی شد که تماماً بر پایه‌ی مکانیسم‌های توجه عمل می‌کرد و به شکل چشمگیری عرصه‌ی متن را دگرگون ساخت. سپس در سال ۲۰۲۰، با انتشار یک تصویر به اندازه‌ی ۱۶×۱۶ کلمه ارزش دارد [۵]، استفاده از شبکه‌های مبدل در کاربردهای تصویری مورد بررسی قرار گرفت و توانست نشان دهد که این شبکه عملکردی رقابتی با مدل‌های کانولوشنی دارد.

مدل‌های مبدل تصویری با توانایی توجه به رابطه‌های دور و نزدیک، سادگی مقیاس‌پذیری و هم‌سانی ساختاری با مدل‌های مبدل متنی، برتری خود را نسبت به شبکه‌های کانولوشنی رایج نشان دادند. از سوی دیگر بایاس استقرایی تصویری ضعیف‌تر، نیاز به دادگان و بار محاسباتی بیشتر و ساختار پیچیده و غیرشهودی‌تر از نقطه ضعف‌های این شبکه‌ها می‌باشد.


در ارائه [5] ViT، تلاش شد تا با یافتن راه حلی برای تبدیل تصویر ورودی به دنباله‌ای از نهفته‌سازی‌ها تا جای ممکن ساختار مدل مبدل حفظ شود (شکل ۶-۱). برای انجام این کار ابتدا تصویر ورودی با یک اندازه قطعه مشخص، قطعه‌بندی می‌گردد.

در گام بعدی هر یک از قطعه‌های دو بعدی را مسطح کرده و با اعمال تبدیل خطی، نهفته‌سازی هر قطعه بدست می‌آید. برای کاربرد کالس بندی، یک نهفته‌سازی افزوده همانند آنچه در شکل ۶-۱ نشان داده شده است (در مکان صفر) به دنباله نهفته‌سازیها پیوست می‌گردد. این بردار قابل یادگیری می‌باشد و در طی آموزش، نهفته‌سازیهای میانی متناظر آن با گذر از الیه‌های مبدل تالش می‌کنند یک بازنمایی سراسری از تصویر ورودی یاد بگیرند.

پس از تولید دنباله نهفته‌سازی قطعه‌ها، نهفته‌سازیهای مکانی به بردار متناظر هر قطعه افزوده می‌گردد. از آن جا که در کاربرد تصویر مفهوم مکان دو بعدی می‌باشد، از بردارهای مکانی تک بعدی و ثابت به کار رفته در مدل اصلی مبدل استفاده نشده و بر خالف آن قابل یادگیری می‌باشند. ادامه روند پردازش نهفته‌سازیها همانند مدل اصلی مبدل می‌باشد. در نهایت و در انتهای مدل همانند مدل BERT، بر روی

خروجی متناظر با توکن کالس، یک دسته بند خطی اعمال می شود تا احتمال کالس های مختلف به دست آورده شود.

با در نظر داشتن این پیش درآمد، در این سوال هدف پیاده سازی مدل ViT و آشنایی با بخشهای مختلف معماری و اهمیت هر یک، شیوه آموزش و درک بهتر چگونگی عملکرد آن می باشد. به این منظور اجازه استفاده از کتابخانه و کد های آماده وجود ندارد.



شکل ۱ معماری مدل مبذل تصویر

بخش اول (آموزش شبکه Vit) (۱.۲)

پس از پیاده سازی مدل خود به صورت پارامتری، مطابق با جدول ۳ آن را آموزش دهید و نمودار خطا و دقت بر روی دادگان آموزشی و اعتبارسنجی در حین آموزش را گزارش کنید. همچنین این مقادیر را به ازای دادگان آزمایشی نیز اعلام کنید. (۳۰ نمره)

مقدار	پارامتر
CIFAR-10	مجموعه داده
آنتروپی متقابل	تابع هزینه
۴	لایه‌های مبدل
۸	هدهای توجه
۱۲۸	اندازه نهفته‌سازی
۴×۴	اندازه قطعه‌بندی تصویر
۱۲۸	پهنای لایه خطی درون لایه مبدل

جدول ۲ پارامترهای آموزش مدل پایه


توجه داشته باشید که انتخاب هر یک از ابرپارامترهای آموزشی دیگر مانند بهینه‌ساز، نرخ یادگیری و غیره، به عهده خودتان می‌باشد. انتظار می‌رود در پایان آموزش دقت مدل بر روی دادگان آزمایشی دستکم به ۶۰ درصد رسیده باشد. همچنین می‌توانید با اعمال افزونگی داده‌های مختلف عملکرد مدل را تقویت کنید.

سوال دوم (بررسی حالت های دیگر) (۲.۲)

الف) آموزش مدل را به ازای هر یک از موارد زیر تکرار کرده (گزارش نتایج همانند بخش ۱) و نتیجه را با مقایسه از دید محاسبات، عملکرد و بیش‌برازش با مدل پایه گزارش کنید (۱۰ نمره)

- اندازه نهفته‌سازی‌های ۶۴ و ۲۵۶
- تعداد لایه‌های مبدل ۲ و ۸
- اندازه قطعه‌بندی ۲×۲ و ۸×۸
- تصویر ورودی بزرگ شده با اندازه ۶۴×۶۴

ب) نقشه توجه (ماتریس شباهت بردارهای K و Q) در ردیف مربوط به CLS را در انتهای لایه‌های ۱، ۲ و ۴ به ازای ۱ هد دلخواه و نیز میانگین هدهای توجه در آن لایه و ۲ تصویر دادگان آزمایشی رسم و آن را تحلیل کنید (همانند شکل زیر). (۱۰ نمره)



شکل ۲ یک نمونه از نمودار توجه نهفته سازی CLS برای هر یک از قطعه های دیگر تصویر در لایه های مختلف

ج) (امتیازی) بخش ب را به ازای مدل پیش‌آموزش‌دیده vit-b-16 موجود در کتابخانه torchvision نیز انجام دهید و نتیجه را مقایسه کنید (لایه‌های ۴، ۸ و ۱۲ را انتخاب کنید). (۱۰ نمره)

مراجع

- [1] B. Zhang and R. Sennrich, "Root Mean Square Layer Normalization," *arXiv preprint arXiv:1910.07467*, 2019.
- [2] J. Ainslie, J. Lee-Thorp, M. de Jong, Y. Zemlyanskiy, F. Lebrón, and S. K. Sanghai, "GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints," *arXiv preprint arXiv:2305.13245*, 2023.
- [3] K. Xu, J. Ba, R. Kiros, K. Cho, A. C. Courville, R. Salakhutdinov, R. S. Zemel, and Y. Bengio, "Show, Attend and Tell: Neural Image Caption Generation with Visual Attention," in *International Conference on Machine Learning (ICML)*, 2015.
- [4] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention Is All You Need," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [5] A. Dosovitskiy *et al.*, "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale," in *International Conference on Learning Representations (ICLR)*, 2021.
- [6] H. Touvron, M. Cord, M. Douze, F. Massa, A. Sablayrolles, and H. Jégou, "Training data-efficient image transformers & distillation through attention," in *International Conference on Machine Learning (ICML)*, 2021.

پیاده‌سازی

- به منظور مدیریت و نگهداری منبع کد پیاده‌سازی، ساختاربندی آن باید به صورت درختواره زیر باشد؛ توضیح مربوط به کارکرد هر فایل و پوشه آورده شده است.

```
homework_code/
├── data/                                # Data-related files
│   ├── data_loader.py                 # Data loading and preprocessing
│   └── dataset/                       # Raw data (if applicable)
├── models/                            # Model-related files
│   ├── model.py                      # Define your neural network architecture
│   └── saved_models/                 # Save trained models
├── notebooks/                         # Jupyter notebooks (optional)
│   └── exploratory.ipynb             # Initial data exploration
├── scripts/                           # Python scripts
│   ├── main.py                      # Main script to run the entire pipeline
│   ├── train.py                     # Training loop
│   └── evaluate.py                   # Model evaluation
├── config/                           # configurations
│   ├── config.yaml                  # Store hyperparameters
│   └── logging.yaml                 # Logging, Checkpoints (optional)
├── utils/                             # Utility functions or helper modules
│   ├── visualization.py             # Plotting functions
│   └── metrics.py                   # Custom evaluation metrics
├── README.md                         # Project documentation (optional)
└── .gitignore                       # Git ignore file (optional)
```

- کد شما باید قابلیت اجرا بر روی بخش کوچکی از داده‌ها را داشته باشد تا دستیار آموزشی بتواند در مدت زمان کوتاهی پیاده‌سازی شما را ارزیابی کند.
- از آدرس‌دهی مطلق در کدهای خود استفاده نکنید و به جای آن از آدرس‌دهی نسبی استفاده نمایید.
- توابع و کلاس‌ها باید توضیح داشته باشند. 😊 😊
- در صورت مشاهده‌ی موارد همانندی بین دو یا چند فرد در گزارش کار و یا کد به طرفین تقلب **نمره صفر** داده خواهد شد. به کپی برداری از کدهای آماده اینترنت، تصویر صفحه^۱ یا کد دیگران نمره‌ای تعلق نخواهد گرفت.

¹ Screen Shot

- اگر برای بخشی از پیاده‌سازی، از کدهای آماده اینترنتی استفاده می‌کنید که جزء قسمتهای اصلی تمرین نمی‌باشد، حتما باید لینک آن در گزارش و کد ارجاع داده شود. در غیر اینصورت تقلب محسوب شده و کل نمره تمرین را از دست می‌دهید ولی محدودیتی در استفاده از منابع اینترنتی ندارید.

گزارش

- گزارش شما در فرایند تصحیح از اهمیت ویژه‌ای برخوردار خواهد بود. لذا تمامی نکات و فرض‌هایی که برای محاسبات و پیاده‌سازی خود در نظر می‌گیرید را در گزارش ذکر کنید. دقت داشته باشید که ۵۰ درصد از نمره تمرین شما مربوط به گزارش است.
- الزامی به ارائه توضیح جزئیات کد در گزارش نمی‌باشد. اما باید نتایج بدست آمده را به‌صورت کامل گزارش و تحلیل کنید.
- گزارش حتما به فارسی نوشته و از برابر فارسی لغات استفاده شود.^۱ در صورت تمایل می‌توانید از قالب لیتک^۲ نیز برای نوشتن گزارش استفاده نمایید.
- در گزارش خود برای تصاویر زیرنویس و برای جداول بالانویس اضافه نمایید و به آن‌ها ارجاع دهید. این توضیحات باید به‌طور مستقل منظور از شکل یا جدول را برسانند.
- از تصویر صفحه برای گزارش نتیجه یا روابط ریاضی استفاده نشود و نتیجه باید به‌صورت عددی یا جدول آورده شده و روابط ریاضی نیز نوشته شود.
- اگر شکل از منبعی گرفته شده باید ارجاع داده شود و ارجاع‌ها را در یک قالب استاندارد آورده شوند.

بارگذاری

- به زمان تحویل تمرین‌ها دقت کافی داشته باشید، برای هر تمرین از زمان ارسال دو هفته فرصت پاسخگویی خواهید داشت.
- انجام این تمرین به‌صورت تک نفره است.
- مهلت این تمرین تا یک هفته قبل از اعمال نمرات است.

^۱ برای نمونه به جای Epoch، اپاک یا دوره را به کار برده و در صورت نیاز برابر انگلیسی پانویس شود. فرهنگ لغت دکتر کسایی

^۲ Latex

- شما قادر نیستید هیچ تمرینی را با بیش از ۷ روز تاخیر بازگذاری کنید. (دقیقا ۷ روز پس از مهلت بارگذاری، سامانه بسته خواهد شد).
- لطفا برای هر تمرین گزارش، فایل کدها و سایر ضمائم مورد نیاز را با فرمت زیر در صفحه درس در سامانه eLearn بارگذاری نمائید.

HW#_[Lastname]_[StudentNumber].zip

ارتباط با ما

- در صورت وجود هر گونه ابهام یا مشکل می‌توانید از طریق آیدی تلگرام زیر با دستیاران آموزشی در ارتباط باشید.

@Parham_sz21