

دانشگاه تهران
پردیس دانشکده‌های فنی

دانشکده مهندسی برق و کامپیوتر

تمرین شماره: ۲
یادگیری عمیق با کاربرد در تصویر و صوت

نام و نام خانوادگی: مرتضی ملکی‌نژاد شوشتری
شماره دانشجویی: ۸۱۰۱۰۴۲۵۶

نیم‌سال دوم سال تحصیلی ۴۰۴-۴۰۵

فهرست مطالب

۴	۱	برچسب‌گذاری دنباله
۴	۱.۱	بررسی پایگاه داده
۵	۲.۱	بررسی collate fn
۶	۳.۱	آموزش شبکه
۸	۱.۳.۱	مقایسه مدل‌ها
۹	۲	VIT
۹	۱.۲	آموزش شبکه
۱۰	۲.۲	بررسی حالت‌های دیگر

فهرست تصاویر

۱۰.۱	نمودارهای خطا و دقت مدل RNN همراه با گزارش دسته‌بندی	۶
۲۰.۱	نمودارهای خطا و دقت مدل LSTM همراه با گزارش دسته‌بندی	۷
۳۰.۱	نمودارهای خطا و دقت مدل GRU همراه با گزارش دسته‌بندی	۷
۴۰.۱	نمودارهای خطا و دقت مدل‌ها در کنار هم	۸
۱۰.۲	نمودار خطا و دقت مدل	۱۰
۲۰.۲	نمودار خطا و دقت مدل با بُعد embedding برابر ۶۴	۱۱
۳۰.۲	نمودار خطا و دقت مدل با بُعد embedding برابر ۲۵۶	۱۱
۴۰.۲	نمودار خطا و دقت مدل با ۲ لایه‌ی Transformer	۱۱
۵۰.۲	نمودار خطا و دقت مدل با ۸ لایه‌ی Transformer	۱۲
۶۰.۲	نمودار خطا و دقت مدل با اندازه‌ی patch برابر ۲×۲	۱۲
۷۰.۲	نمودار خطا و دقت مدل با اندازه‌ی patch برابر ۸×۸	۱۲
۸۰.۲	نمودار خطا و دقت مدل با اندازه‌ی تصویر ۶۴×۶۴	۱۳
۹۰.۲	نقشه توجه برای شکل اول	۱۴
۱۰۰.۲	نقشه توجه برای شکل دوم	۱۵
۱۱۰.۲	نقشه توجه برای شکل اول با مدل vitb16	۱۶
۱۲۰.۲	نقشه توجه برای شکل دوم با مدل vitb16	۱۷

فهرست جداول

۵		۱.۱	سطر اول مجموعه داده آموزش
۱۰		۱.۲	خطا و دقت مدل روی مجموعه داده های مختلف
۱۳		۲.۲	خطا، دقت و میزان زمان آموزش مدل های مختلف

سوال ۱

برچسب‌گذاری دنباله

۱.۱ بررسی پایگاه داده

(آ) یکی از سطرهای مجموعه داده^۱ در جدول ۱.۱ آمده است. می‌توان دید علاوه بر NER Tag مجموعه داده دو ستون دیگر به اسم‌های pos tag و chunk tag نیز دارد.

(ب) pos tag عملاً نقش گرامری هر توکن را مشخص می‌کند. برای مثال NNP یک اسم مشخصه^۲ است. اهمیت این برچسب در NER از این رو است که ما به دنبال تشخیص کلاس اسامی (و به طور خاص اسامی مشخصه) هستیم. پس می‌توان افعال را در نظر نگرفت و اگر یک کلمه فعل بود از آن صرف‌نظر کرد.

chunk tag عملاً تعمیم pos tag است. یعنی سعی می‌کند جمله را بجای در سطح توکن در سطح عبارت^۳ بسنجد. و توکن‌ها را باهم دسته می‌کند.

¹Dataset

²Proper noun

³phrase

جدول ۱.۱: سطر اول مجموعه داده آموزش

Token	EU	rejects	German	call	to	boycott	British	lamb	.
Pos Tag	NNP	VBZ	JJ	NN	TO	VB	JJ	NN	.
Chunk Tag	B-NP	B-VP	B-NP	I-NP	B-VP	I-VP	B-NP	I-NP	O
NER Tag	B-ORG	O	B-MISC	O	O	O	B-MISC	O	O

(ج) کد مربوط به vocab پیاده‌سازی شد. این کد به ترتیب توکن‌ها را بررسی می‌کند و تعداد تکرار هرکدام که به مقدار cutoff رسید، آن را به لیست vocab اضافه می‌کند.

(د)

```
۱ vocab = Vocab(ds_train)
۲ print(f"{len(vocab) = }")
۳ print(f"Token 0 is '{vocab.id_to_token(0)}'")
۴ print("'quick' token id is ", vocab.token_to_id("quick"))
```

نمونه کد ۱: موارد خواسته‌شده بخش «د»

```
len(vocab) = 4913
Token 0 is 'to'
'quick' token id is 4813
```

۲.۱ بررسی collate fn

(آ) هرچقدر بیشتر یک جمله پد شود، باعث می‌شود احتمال توجه مدل به توکن‌های معنی‌دار آن کم‌تر شود. زیرا نسبت توکن‌های معنی‌دار به طول جمله کم می‌شود. ولی پد کردن برای محاسبه اجتناب‌ناپذیر است. حال اگر در یک دسته^۴ این کار انجام شود، هم محاسبه امکان‌پذیر است و هم پد کردن به میزان کم‌تری اتفاق می‌افتد.

(ب)

^۴batch

```

۱ dataloader = get_dataloader(ds_train)
۲ first_batch = next(iter(dataloader))
۳ tokens = [item[0] for item in first_batch]
۴ tokens = np.array(tokens)
۵ print(tokens.shape)


```

نمونه کد ۲: شکل بیج اول توکن‌ها

(32, 47)

۳.۱ آموزش شبکه


(آ) مدل RNN:



شکل ۱.۱: نمودارهای خطا و دقت مدل RNN همراه با گزارش دسته‌بندی


(ب) مدل LSTM:

۳.۱. آموزش شبکه



شکل ۲.۱: نمودارهای خطا و دقت مدل LSTM همراه با گزارش دسته‌بندی

ج) مدل GRU:




شکل ۳.۱: نمودارهای خطا و دقت مدل GRU همراه با گزارش دسته‌بندی

۱.۳.۱ مقایسه مدل‌ها

در تصویر ۴.۱ می‌توان دقت و خطای مدل‌ها را در کنار هم دید. روی داده آموزش، دقت مدل RNN از دو مورد دیگر بدتر است و این به دلیل این است که در مدل RNN روابط بلندمدت کلمات حفظ نمی‌شوند. اما دقت مدل‌های GRU و LSTM به هم نزدیک است که این مطابق انتظار است. مهم‌ترین آورده GRU نسبت به LSTM در سادگی محاسبات است نه در دقت.

روی داده صحت‌سنجی، می‌توان دید در دوره‌های اول نیز، مدل RNN کندتر همگرا می‌شود. اما دوره‌های آخر، دیگر دقت افزایش پیدا نمی‌کند و هر سه مدل به نوعی اشباع شده‌اند.



شکل ۴.۱: نمودارهای خطا و دقت مدل‌ها در کنار هم

سوال ۲

VIT

۱.۲ آموزش شبکه

مطابق خواسته سوال، شبکه vit پیاده‌سازی شد. شبکه چند بلوک دارد. ابتدا یک بلوک برای patching embedding پیاده‌سازی شد. وظیفه این بلوک این است که تصویر را به patch تقسیم کند (هر patch مشابه یک کلمه در جمله است). و بعد این patch ها را از یک لایه خطی عبور دهد. یک لایه کانولوشن^۱ که در آن سائز با گام stride برابر است، عملاً همین کار را می‌کند.

ماژول بعدی مربوط به مکانیزم Attention است. برای هر توکن (Patch) باید مقدار توجه آن را با استفاده از ماتریس‌های q ، k و v درآورد. این ماتریس‌ها در ابتدا جدا حساب می‌شدند، ولی پس از کمک گرفتن از هوش مصنوعی، برای بهبود سرعت، هر سه این ماتریس‌ها باهم در یک لایه خطی بزرگ حساب می‌شوند و سپس جدا می‌شوند. خروجی این بلوک، حاصل ضرب مقدار توجه^۲ در مقدار^۳ است که از یک لایه خطی نیز گذر داده می‌شود.

سپس یک بلوک MLP پیاده‌سازی شده که توضیح خاصی نیاز ندارد. تنها نکته آن این است که در مقاله ViT استفاده از تابع فعال‌ساز GELU پیشنهاد شده و تنها بین دو لایه خطی، فعال‌ساز وجود دارد و پس از

¹Convolution


²Attention

³value

لایه خطی دوم، تابع فعال‌سازی وجود ندارد.

در نهایت بلوک‌های قبل در یک ماژول Transformer سرهم می‌شوند. این بلوک Transformer فقط برای رمزگذار^۴ است.

شبکه ViT در عمل، پس از انجام Patch Embedding و اضافه کردن CLS embedding و Pos embedding خروجی را به لایه‌های transformer می‌دهد و در نهایت روی بخش CLS یک لایه خطی اجرا می‌کند تا نتیجه طبقه‌بندی را خروجی دهد.



شکل ۱.۲: نمودار خطا و دقت مدل

جدول ۱.۲: خطا و دقت مدل روی مجموعه داده‌های مختلف


Dataset	Acc	Loss
Train	64.90%	0.9815
Val	65.22%	0.9931
Test	62.53%	1.0353

۲.۲ بررسی حالت‌های دیگر


(آ) خواسته‌های سوال در نوتبوک model_eval پیاده‌سازی شده‌اند.

در گزارش، نمودارهای مدل‌های مختلف آمده است که به دلیل اینکه سوال مقایسه آن‌ها را نخواست، و دقت نهایی در جدول ۲.۲ آمده است، صرفاً نتایج جدول مقایسه می‌شوند.


⁴Encoder




شکل ۲.۲: نمودار خطا و دقت مدل با بُعد embedding برابر ۶۴




شکل ۳.۲: نمودار خطا و دقت مدل با بُعد embedding برابر ۲۵۶




شکل ۴.۲: نمودار خطا و دقت مدل با ۲ لایه‌ی Transformer




شکل ۵.۲: نمودار خطا و دقت مدل با ۸ لایه‌ی Transformer



شکل ۶.۲: نمودار خطا و دقت مدل با اندازه‌ی patch برابر ۲×۲



شکل ۷.۲: نمودار خطا و دقت مدل با اندازه‌ی patch برابر ۸×۸



شکل ۸.۲: نمودار خطا و دقت مدل با اندازه‌ی تصویر ۶۴×۶۴

همانطور که در جدول ۲.۲ می‌توان دید، بیش‌برازش زیادی در هیچ کدام از مدل‌ها رخ نداده است. مدلی که با تصاویر بزرگ‌شده و یا patch کوچک‌تر آموزش دیده شده، دقت بهتری دارد ولی زمان آموزش آن‌ها نیز به شدت بیشتر است. بطوری که اگر مدل‌های دیگر را با دوره‌های بیشتر آموزش داد احتمالاً بتوان با همان زمان به دقت بهتری رسید. البته باید توجه داشت که احتمالاً دوره‌های بیشتر منجر به بیش‌برازش شود و باید برای این مسئله راه‌حلی پیدا کرد.


جدول ۲.۲: خطا، دقت و میزان زمان آموزش مدل‌های مختلف

Experiment	Train Acc	Train Loss	Val Acc	Val Loss	Test Acc	Test Loss	Duration (s)
baseline	64.90%	0.9815	65.22%	0.9931	62.53%	1.0353	85.8
embedding=64	62.04%	1.0554	62.72%	1.0513	60.84%	1.0794	59.6
embedding=256	61.72%	1.0513	62.40%	1.0557	62.10%	1.0545	147.8
layers=2	62.68%	1.0315	63.60%	1.0180	62.37%	1.0428	43.2
layers=8	64.12%	0.9974	63.98%	1.0041	62.78%	1.0407	156.6
patch=2x2	65.39%	0.9706	65.26%	0.9817	64.20%	0.9915	860.4
patch=8x8	58.10%	1.1596	57.00%	1.1791	56.48%	1.2031	20.5
image=64x64	65.52%	0.9606	64.76%	0.9783	63.99%	0.9892	702.3


(ب) خواسته‌های سوال در نوت‌بوک plot_attention پیاده‌سازی شده‌اند.

با دیدن تصاویر ۹.۲ و ۱۰.۲ می‌توان دید که head اول فقط روی یک بخش خاص از تصویر (مثلاً یک لبه یا یک بخش کشتی) تمرکز کرده است. ولی با میانگین گرفتن از همه head ها، می‌توان دید مدل به بخش‌های مختلف شکل توجه کرده است. البته همچنان در جاهایی بجای شکل روی پس‌زمینه تمرکز کرده است که این مورد خوب نیست.

(ج) نقشه توجه مدل vitb16 در تصاویر ۱۱.۲ و ۱۲.۲ آمده است. اگر این تصاویر را با تصاویر ۹.۲ و ۱۰.۲ مقایسه کنیم، می‌بینیم در لایه‌های اول، نقشه توجه به نسبت پراکنده است و مدل روی بخش‌های




شکل ۹.۲: نقشه توجه برای شکل اول




شکل ۱۰.۲: نقشه توجه برای شکل دوم

مختلفی از تصویر تمرکز کرده است. در مقابل مدل ما از اول روی بخش‌های اصلی تصویر تمرکز کرده است. این موضوع می‌تواند به این علت باشد که مدل vitb16 را روی داده cifar آموزش ندیده است و finetune نشده است و در مراحل اول سعی در بررسی بخش‌های مختلف تصویر دارد.

با عمیق‌تر شدن لایه‌ها می‌توان دید که مدل به مرور، اثر بخش‌های مختلف را خنثی می‌کند و روی نقاط محدودی از تصویر تمرکز می‌کند. اگر مجدد لایه‌های آخر را باهم مقایسه کنیم، می‌توان دید که مدل finetune شده، روی بخش‌های مختلفی از تصویر اصلی دقت می‌کند. پس احتمالاً مدل مقاوم‌تری است.



شکل ۱۱.۲: نقشه توجه برای شکل اول با مدل vitb16



شکل ۱۲.۲: نقشه توجه برای شکل دوم با مدل vitb16