

به نام خدا



دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده برق و کامپیوتر



یادگیری عمیق با کاربرد در تصویر و صوت

دکتر رشاد حسینی

تمرین شماره 5

طرح تمرین:

پرهام سازدار

تیر ۱۴۰۵

فهرست مطالب

فهرست شکل ها	۴
فهرست جدول ها	۵
جدول اصطلاحات تخصصی	۶
سؤال اول - تشخیص احساسات از گفتار	۷
مقدمه	۷
آماده سازی داده (۱۲ نمره)	۷
معرفی مجموعه داده	۷
ساختار دیتالودر	۸
استخراج ویژگی (۹ نمره)	۸
۱. استخراج ویژگی سنتی	۹
۲. استخراج ویژگی مبتنی بر یادگیری	۹
طبقه بندی (۱۲ نمره)	۱۰
آموزش و ارزیابی مدل (۱۲ نمره)	۱۱
تحلیل کیفی نتایج (۹ نمره)	۱۲
مقایسه و جمع بندی (۶ نمره)	۱۲
سؤال امتیازی (۹ نمره)	۱۳
سؤال دوم - بهینه سازی	۱۴
مقدمه	۱۴
بخش اول (پیاده سازی تابع هدف و گرادیان)	۱۴
بخش دوم (پیاده سازی بهینه سازها)	۱۴
پیاده سازی	۱۷

گزارش ۱۸

بارگذاری ۱۸

ارتباط با ما ۱۹

فهرست شکل‌ها

شکل ۱. مسیر پیموده شده توسط الگوریتم ۱۵

فهرست جدول‌ها

جدول ۱- تنظیمات پیشنهادی ۱۱

جدول اصطلاحات تخصصی

اصطلاح	مخفف	معادل فارسی
Speech Emotion Recognition	SER	تشخیص احساس از گفتار
Hidden-Unit BERT	HuBERT	-
mel spectrogram	-	مل اسپکتروگرام
self-supervised	-	خود نظارتی
Multi Layer Perceptron	MLP	-
accuracy	-	صحت
loss	-	زیان
Confusion Matrix	-	ماتریس درهم ریختگی
Sampling rate	-	نرخ نمونه برداری
Batch size	-	اندازه دسته
Epoch	-	دوره
Learning rate	-	نرخ یادگیری
Optimizer	-	بهینه ساز
Loss function	-	تابع هزینه

سؤال اول – تشخیص احساسات از گفتار

مقدمه

در تعاملات انسانی، احساسات نقش مهمی در درک و تفسیر گفتار دارند. انسان‌ها به راحتی می‌توانند احساس گوینده را از **لحن و شدت صدا، کشش کلمات و زیروبمی صدا** تشخیص دهند، حتی اگر معنای واژگان را ندانند. توانایی درک احساس از روی صدا برای ماشین‌ها نیز به سرعت در حال تبدیل شدن به یک قابلیت حیاتی است، به‌ویژه در کاربردهایی مانند:

- تعامل انسان-ماشین (مانند دستیار صوتی هوشمند)
- تحلیل تماس‌های مرکز خدمات مشتریان
- پایش وضعیت روحی در محیط‌های درمانی

در این تمرین، هدف، طراحی یک سیستم تشخیص احساس از گفتار (SER^1) است که بتواند احساس اصلی موجود در کلیپ صوتی را بین چند حالت مشخص تشخیص دهد. برای این کار ابتدا با ویژگی‌های سنتی مانند **log-Mel spectrogram** کار خواهید کرد، سپس از مدل‌های پیش آموزش دیده مدرن برای استخراج ویژگی استفاده می‌کنید.

آماده‌سازی داده (۱۲ نمره)

معرفی مجموعه داده

برای انجام این تمرین، از مجموعه داده‌ی **CREMA-D²** (Crowd-sourced Emotional Multimodal Actors Dataset) استفاده شده است. این مجموعه داده یکی از منابع عمومی و استاندارد برای تحلیل احساس از گفتار است که بر پایه‌ی اجراهای بازیگران حرفه‌ای ساخته شده و شامل تنوع احساسی و صوتی مناسبی است.

¹ Speech Emotion Recognition

² <https://www.kaggle.com/datasets/cjlok1/cremad>

مجموعه داده CREMA-D شامل بیش از ۷۴۰۰ فایل صوتی (فرمت wav) است که توسط ۹۱ گوینده (۴۸ مرد و ۴۳ زن) با لهجه‌های مختلف آمریکایی ضبط شده‌اند. هر گوینده ۱۲ جمله‌ی از پیش تعیین شده را در حالت‌های احساسی مختلف بیان کرده است. این احساسات شامل موارد زیر هستند:

- Neutral (خنثی)
- Happy (شاد)
- Sad (غمگین)
- Angry (عصبانی)
- Fearful (ترسیده)
- Disgust (منزجر)

ساختار دیتالودر

موارد مربوط به دو قسمت زیر باید به صورت پارامتری و در `config/config.yaml` مقداری شوند.

برای کاهش بار محاسباتی و زمان موردنیاز:

- فقط از چهار احساس `happy`، `angry`، `sad` و `neutral` استفاده کنید.
- فقط از داده‌های مربوط به ۲۰ نفر از گویندگان استفاده کنید.

در ادامه پس از بارگذاری فایل صوتی که می‌توانید با `torchaudio.load()` یا `librosa.load()` انجام دهید، موارد زیر را اعمال کنید:

۱. تنظیم نرخ نمونه‌برداری؛
۲. یکسان‌سازی طول صوت‌ها؛
۳. اعمال تابع استخراج ویژگی.

استخراج ویژگی (۹ نمره)

یکی از اهداف اصلی این سؤال، مقایسه ویژگی‌های استخراج شده به روش سنتی و روش‌های مبتنی بر یادگیری است. در تدریس مبحث صوت، با روند استخراج ویژگی سنتی، به خوبی آشنا شده‌اید. در ابتدا

طبق همین روند پیش رفته و از این ویژگی‌ها برای دسته‌بندی داده‌ها استفاده می‌شود. در بخش بعد، از روش مدرن‌تر، یعنی مدل ³ Hubert برای استخراج ویژگی استفاده خواهد شد.

در این قسمت انتظار می‌رود در مسیر `homework_code/utlis/features.py` این دو نوع استخراج ویژگی را به صورت مجزا پیاده‌سازی کنید. این توابع برحسب نیاز (مشخص شده در `config.py`) به عنوان ورودی به دیتالودر ارسال خواهند شد.

۱. استخراج ویژگی سنتی

در مرحله اول، از ویژگی‌های مل اسپکتروگرام^۴ استفاده خواهد شد. مل اسپکتروگرام یک نمایش تصویری از صدای دیجیتال است که شدت انرژی فرکانس‌ها را در طول زمان نشان می‌دهد، با این تفاوت که مقیاس فرکانسی آن مطابق با درک شنوایی انسان (مقیاس مل) تغییر یافته است. با انجام مراحل زیر، به این ویژگی‌ها دست خواهید یافت.

۱. تبدیل به mel spectrogram

۲. تبدیل به log-scale

۲. استخراج ویژگی مبتنی بر یادگیری

در این قسمت از مدل پیش آموزش داده **HuBERT** برای استخراج ویژگی استفاده خواهد شد که یک مدل خود نظارتی^۵ برای یادگیری بازنمایی‌های صوتی است. HuBERT با استفاده از روش‌های ماسک‌گذاری بخش‌هایی از ورودی، سعی می‌کند اطلاعات گم‌شده را حدس بزند و همین باعث می‌شود ویژگی‌های غنی و مفیدی از صدا استخراج کند که برای کارهایی مثل تشخیص گفتار، شناسایی گوینده یا بازشناسی احساسات بسیار مفید هستند. ورودی این مدل، داده صوتی خام و خروجی آن، بازنمایی‌هایی است که در نسخه پایه این مدل، ابعاد آن ۷۶۸ است.

مراحل:

³ Hidden-Unit BERT

⁴ mel spectrogram

⁵ Self-Supervised

۱. از آنجاکه HubertModel انتظار دارد ورودی‌اش به صورت یک tensor از feature vectors باشد، نمی‌توان سیگنال صوتی خام را مستقیماً به آن داد؛ بنابراین، پیش از عبور دادن سیگنال به مدل، باید آن را با استفاده از ابزاری مانند Wav2Vec2FeatureExtractor پردازش کنید.
۲. مدل `hubert-base-ls960`^۶ از HuggingFace یا torchaudio را بارگذاری کنید.
۳. برای هر کلیپ صوتی، یک بردار ویژگی (embedding) از مدل استخراج کنید (`last_hidden_state`).

طبقه‌بندی (۱۲ نمره)

- در این قسمت یک طبقه‌بند ساده پیاده‌سازی می‌کنید که ورودی آن، ویژگی‌های استخراج شده در مرحله قبل است و خروجی آن احساس تشخیص داده‌شده برای این ورودی است.
- باتوجه به ماهیت تصویری که ویژگی مل دارد، می‌توانید از یک مدل کانولوشنی ساده برای این ویژگی‌ها استفاده کنید.
 - در مورد ویژگی‌های استخراج شده توسط مدل Hubert نیز، می‌توانید از یک مدل `MLP`^۷ ساده استفاده کنید.

^۶ <https://huggingface.co/facebook/hubert-base-ls960>

^۷ Multi Layer Perceptron

آموزش و ارزیابی مدل (۱۲ نمره)

۱. ابتدا داده‌ها را به سه دسته آموزش (۸۰ درصد)، اعتبارسنجی و آزمون تقسیم کنید (طوری که توزیع احساسات در مجموعه داده‌ها تقریباً یکنواخت باشد).
۲. مدل را با هایپرپارامترهای مناسب آموزش دهید.
۳. نمودارهای مربوط به تغییرات صحت^۸ و زیان^۹ روی داده آموزش و اعتبارسنجی را رسم کنید.
۴. ماتریس درهم‌ریختگی^{۱۰} و صحت نهایی را روی داده آزمون گزارش کنید.
۵. باتوجه به نتایج، این دو نوع استخراج ویژگی را مقایسه کنید.

تنظیمات پیشنهادی برای این سؤال در جدول ۱ ارائه شده است. بدیهی است در صورت نیاز، می‌توانید هر یک از این تنظیمات را با ذکر دلیلی مختصر، مطابق نظر خود تغییر دهید.

جدول ۱- تنظیمات پیشنهادی

پارامتر	مقدار
نرخ نمونه‌برداری ^{۱۱}	۱۶۰۰۰ هرتز
یکسان‌سازی طول زمانی	۳ ثانیه
احساسات	خنثی، شاد، غمگین، عصبانی
گوینده‌ها	۱۰۰۱ تا ۱۰۲۱
اندازه دسته ^{۱۲}	۱۲۸
دوره ^{۱۳}	۵ تا ۲۰
نرخ یادگیری ^{۱۴}	۰.۰۱
بهینه‌ساز ^{۱۵}	Adam
تابع هزینه ^{۱۶}	CrossEntropy
تعداد لایه کانولوشنی (mel)	۳
تعداد لایه MLP (hubert)	۱

⁸ Accuracy

⁹ Loss

¹⁰ Confusion Matrix

¹¹ Sampling rate

¹² Batch size

¹³ Epoch

¹⁴ Learning rate

¹⁵ Optimizer

¹⁶ Loss function

تحلیل کیفی نتایج (۹ نمره)

عملکرد هر یک از روش‌ها را از نظر کیفی به صورت زیر، تحلیل کنید:

- دقت مدل برای هر احساس چقدر بوده؟ تحلیل کنید.
- بیشترین اشتباه مدل در تشخیص کدام احساسات بوده؟ چرا؟
- کدام احساسات بیشتر با یکدیگر اشتباه گرفته شده‌اند؟ چرا؟

مقایسه و جمع‌بندی (۶ نمره)

در این بخش از شما انتظار می‌رود یک مقایسه کلی و مختصر بین این دو روش انتخاب ویژگی، انجام دهید. مواردی مانند میزان پیچیدگی مدل‌هایی که روی ویژگی‌های استخراج‌شده اعمال شده‌اند، تعداد دوره‌های لازم برای آموزش هر یک از این دو مدل و نتایج به‌دست‌آمده را بررسی کنید.

سؤال امتیازی (۹ نمره)

مقاله [SpeechT5](#) یکی از مقالات مهم در حوزه مدل‌های encoder-decoder چندوجهی برای گفتار است که توسط Microsoft معرفی شده. این مدل تلاش می‌کند با یک چارچوب واحد، چندین تسک گفتاری مختلف (مانند ASR، TTS، Speaker ID و...) را پوشش دهد. پس از مطالعه این مقاله، به سؤالات زیر پاسخ دهید.

سؤال ۱: معماری مدل SpeechT5 را شرح دهید.

سؤال ۲: مدل SpeechT5 چگونه با داده‌های گفتاری بدون برچسب پیش‌آموزش داده می‌شود؟ pretext task آن چیست؟

سؤال ۳: چه تسک‌هایی با SpeechT5 انجام شده‌اند؟ برای هر تسک، ساختار ورودی و خروجی را خلاصه توضیح دهید.

سؤال دوم – بهینه سازی

مقدمه

در این تمرین، با اجرای عملی سه بهینه‌ساز پرکاربرد SGD, ADAM, RMSPROB روی تابع غیرمحدب Rosenbrock، تفاوت آن‌ها را از نظر سرعت همگرایی، پایداری در برابر نویز و حساسیت به نرخ یادگیری بررسی می‌کنیم. هدف این است که دانشجو به‌جای اتکا به توضیحات تئوری، با مشاهده مسیر حرکت و نمودار خطا، درکی شهودی و مقایسه‌ای از نقاط قوت و ضعف هر الگوریتم به دست آورد تا در پروژه‌های یادگیری عمیق بتواند بهینه‌ساز مناسب را آگاهانه انتخاب کند.

بخش اول (پیاده‌سازی تابع هدف و گرادیان)

۱. تابع $\text{rosenbrock}(x, y)$ را بنویسید تا مقدار

$$f(x, y) = 100(y - x^2)^2 + (1 - x)^2$$

برگرداند.

۲. توابع گرادیان $\text{grad}_x(x, y)$ و $\text{grad}_y(x, y)$ را پیاده کنید.


۳. نمودار سه بعدی این تابع را در بازه $[-1, 1]$ رسم کنید.

بخش دوم (پیاده‌سازی بهینه‌سازها)

۱. هر یک از روش‌های SGD، RMSProp و ADAM را با استفاده از قابلیت‌های پایه پای‌تورچ

پیاده‌سازی کنید. دقت کنید که هر یک به صورت کلاس پیاده‌سازی شوند و از `torch.optim.optimizer` ارث‌بری کنند.

۲. الگوریتم بهینه‌سازی را تا زمانی که گرادیان تابع شما از یک عدد ثابت (به عنوان مثال ۰.۰۰۱) کمتر نشده است ادامه دهید تا همگرا شوید. (با نرخ یادگیری ۰.۱ برای هر سه روش استفاده کنید). سپس مسیر پیموده شده در اجرای الگوریتم‌ها را نمایش دهید و نتایج سه روش را با هم مقایسه کنید. دیگر پارامترها را در صورت وجود، ثابت خود تنظیم و نیز از زمان‌بندی استفاده نکنید.



شکل ۱. مسیر پیموده شده توسط الگوریتم

۳. نمودار مقدار تابع در هر دوره بر حسب شماره دوره و هم چنین فاصله اقلیدوسی تا مقدار بهینه در هر دوره بر حسب شماره دوره را رسم کنید و با یکدیگر مقایسه کنید.
۴. حال به ازای نرخ یادگیری ۰.۰۱ و ۱ نیز گام پیشین را انجام دهید. نتایج را تحلیل و عملکرد روش‌های مختلف را با هم مقایسه کنید.
۵. حال هر ۳ الگوریتم را از ۳ نقطه شروع متفاوت اجرا کنید و هر ۳ الگوریتم را از نظر سرعت همگرایی و تعداد دوره که می‌پیمایند مقایسه کنید.
۶. حال در هر مرحله به گرادینان محاسبه شده یک نویز گوسی با واریانس بسیار کم اضافه کنید و هر سه الگوریتم را مجدد اجرا کنید و نتایج را با قسمت‌های قبلی مقایسه کنید.

پیاده‌سازی

- به منظور مدیریت و نگهداری منبع کد پیاده‌سازی، ساختاربندی آن باید به صورت درختواره زیر باشد؛ توضیح مربوط به کارکرد هر فایل و پوشه آورده شده است.

```
homework_code/
├── data/                                # Data-related files
│   ├── data_loader.py                 # Data loading and preprocessing
│   └── dataset/                       # Raw data (if applicable)
├── models/                            # Model-related files
│   ├── model.py                      # Define your neural network architecture
│   └── saved_models/                 # Save trained models
├── notebooks/                         # Jupyter notebooks (optional)
│   └── exploratory.ipynb             # Initial data exploration
├── scripts/                           # Python scripts
│   ├── main.py                      # Main script to run the entire pipeline
│   ├── train.py                     # Training loop
│   └── evaluate.py                   # Model evaluation
├── config/                            # configurations
│   ├── config.yaml                  # Store hyperparameters
│   └── logging.yaml                 # Logging, Checkpoints (optional)
├── utils/                             # Utility functions or helper modules
│   ├── visualization.py             # Plotting functions
│   └── metrics.py                   # Custom evaluation metrics
├── README.md                          # Project documentation (optional)
└── .gitignore                        # Git ignore file (optional)
```

- کد شما باید قابلیت اجرا بر روی بخش کوچکی از داده‌ها را داشته باشد تا دستیار آموزشی بتواند در مدت زمان کوتاهی پیاده‌سازی شما را ارزیابی کند.
- از آدرس‌دهی مطلق در کدهای خود استفاده نکنید و به جای آن از آدرس‌دهی نسبی استفاده نمایید.
- توابع و کلاس‌ها باید توضیح داشته باشند. 😊 😊
- در صورت مشاهده‌ی موارد همانندی بین دو یا چند فرد در گزارش کار و یا کد به طرفین تقلب **نمره صفر** داده خواهد شد. به کپی برداری از کدهای آماده اینترنت، تصویر صفحه^{۱۷} یا کد دیگران نمره‌ای تعلق نخواهد گرفت.

¹⁷ Screen Shot

- اگر برای بخشی از پیاده‌سازی، از کدهای آماده اینترنتی استفاده می‌کنید که جزء قسمتهای اصلی تمرین نمی‌باشد، حتما باید لینک آن در گزارش و کد ارجاع داده شود. در غیر اینصورت تقلب محسوب شده و کل نمره تمرین را از دست می‌دهید ولی محدودیتی در استفاده از منابع اینترنتی ندارید.

گزارش

- گزارش شما در فرایند تصحیح از اهمیت ویژه‌ای برخوردار خواهد بود. لذا تمامی نکات و فرض‌هایی که برای محاسبات و پیاده‌سازی خود در نظر می‌گیرید را در گزارش ذکر کنید. دقت داشته باشید که ۵۰ درصد از نمره تمرین شما مربوط به گزارش است.
- الزامی به ارائه توضیح جزئیات کد در گزارش نمی‌باشد. اما باید نتایج بدست آمده را به‌صورت کامل گزارش و تحلیل کنید.
- گزارش حتما به فارسی نوشته و از برابر فارسی لغات استفاده شود^{۱۸}. در صورت تمایل می‌توانید از قالب لیتک^{۱۹} نیز برای نوشتن گزارش استفاده نمایید.
- در گزارش خود برای تصاویر زیرنویس و برای جداول بالانویس اضافه نمایید و به آن‌ها ارجاع دهید. این توضیحات باید به‌طور مستقل منظور از شکل یا جدول را برسانند.
- از تصویر صفحه برای گزارش نتیجه یا روابط ریاضی استفاده نشود و نتیجه باید به‌صورت عددی یا جدول آورده شده و روابط ریاضی نیز نوشته شود.
- اگر شکل از منبعی گرفته شده باید ارجاع داده شود و ارجاع‌ها را در یک قالب استاندارد آورده شوند.

بارگذاری

- به زمان تحویل تمرین‌ها دقت کافی داشته باشید، برای هر تمرین از زمان ارسال دو هفته فرصت پاسخگویی خواهید داشت.
- انجام این تمرین به‌صورت تک نفره است.
- مهلت این تمرین تا یک هفته قبل از اعمال نمرات است.

^{۱۸} برای نمونه به جای Epoch، اپاک یا دوره را به کار برده و در صورت نیاز برابر انگلیسی پانویس شود. فرهنگ لغت دکتر کسایی

^{۱۹} Latex

- شما قادر نیستید هیچ تمرینی را با بیش از ۷ روز تاخیر بازگذاری کنید. (دقیقا ۷ روز پس از مهلت بارگذاری، سامانه بسته خواهد شد).
- لطفا برای هر تمرین گزارش، فایل کدها و سایر ضمائم مورد نیاز را با فرمت زیر در صفحه درس در سامانه eLearn بارگذاری نمائید.

HW#_[Lastname]_[StudentNumber].zip

ارتباط با ما

- در صورت وجود هر گونه ابهام یا مشکل می‌توانید از طریق تلگرام زیر با دستیار آموزشی در ارتباط باشید.

❖ [@https://t.me/Parham_sz21](https://t.me/Parham_sz21)