

دانشگاه تهران
پردیس دانشکده‌های فنی

دانشکده مهندسی برق و کامپیوتر

تمرین شماره: ۵
یادگیری عمیق با کاربرد در تصویر و صوت

نام و نام خانوادگی: مرتضی ملکی‌نژاد شوشتری
شماره دانشجویی: ۸۱۰۱۰۴۲۵۶

نیم‌سال دوم سال تحصیلی ۴۰۴-۴۰۵

فهرست مطالب

۴	۱ تشخیص احساسات از گفتار
۴	۱.۱ مجموعه داده
۵	۲.۱ ویژگی‌ها
۵	۳.۱ طبقه‌بندی
۶	۴.۱ آموزش و ارزیابی مدل
۷	۵.۱ سوال امتیازی
۷	۱.۵.۱ معماری مدل Speech T5
۹	۲.۵.۱ Pretext task داده‌های گفتاری مدل
۹	۳.۵.۱ تسک‌های انجام‌شده با SpeechT5
۱۰	۲ بهینه‌سازی
۱۰	۱.۲ پیاده‌سازی تابع هدف و گرادینان
۱۱	۲.۲ پیاده‌سازی بهینه‌سازها

فهرست تصاویر

۴	توزیع احساسات در بین مجموعه داده‌های مختلف	۱.۱
۵	افراد موجود در هر بخش داده	۲.۱
۶	نمودار خطا و دقت مدل روی داده‌های آموزش و صحت‌سنجی با hubert	۳.۱
۶	نمودار خطا و دقت مدل روی داده‌های آموزش و صحت‌سنجی با mel spectro	۴.۱
۷	ماتریس درهم ریختگی	۵.۱
۸	معماری مدل که در مقاله آمده است	۶.۱
۱۰	نمودار تابع rosenbrock بین یک تا منفی یک	۱.۲
۱۱	نمودار تابع rosenbrock بین یک تا منفی یک	۲.۲
۱۲	نمودار فاصله برای ضریب یادگیری یک صدم	۳.۲
۱۲	نمودار فاصله برای ضریب یادگیری یک دهم	۴.۲
۱۳	نمودار فاصله برای ضریب یادگیری یک	۵.۲
۱۳	نمودار مقدار تابع برای ضریب یادگیری یک صدم	۶.۲
۱۴	نمودار مقدار تابع برای ضریب یادگیری یک دهم	۷.۲
۱۴	نمودار مقدار تابع برای ضریب یادگیری یک	۸.۲

فهرست جداول

۵	۱.۱	تعداد کانال‌های هر لایه مدل پیچشی
۵	۲.۱	تعداد کانال‌های هر لایه پیچشی
۹	۳.۱	خلاصه تسک‌های انجام‌شده با SpeechT5 و ساختار ورودی/خروجی آن‌ها


سوال ۱

تشخیص احساسات از گفتار


۱.۱ مجموعه داده

مجموعه داده از سایت kaggle دانلود شد و بارگذاری شد. برای دیتالودر تنها اطلاعات گوینده و برچسب هر داده ذخیره شد زیرا خود جمله در اینجا اهمیتی ندارد. اهمیت گوینده نیز در فیلتر کردن مجموعه داده مطابق خواست سوال است. پس از فیلتر کردن داده‌ها کلاس Dataset هنگامی که یک داده درخواست می‌شود، فایل مربوط به داده را می‌خواند، طول آن را مطابق کانفیگ تغییر می‌دهد و ویژگی‌های آن را استخراج می‌کند و سپس ویژگی‌ها و برچسب را خروجی می‌دهد.

بررسی شد که در بین داده‌ها پس از فیلتر کردن، ناهماهنگی خاصی در بین احساسات نباشد.



شکل ۱.۱: توزیع احساسات در بین مجموعه داده‌های مختلف



شکل ۲.۱: افراد موجود در هر بخش داده

۲.۱ ویژگی‌ها

برای استخراج ویژگی Mel Spectrogram از تابع آماده موجود در torch و برای بارگذاری مدل Hubert از کتابخانه transformers استفاده شد.

برای Mel پس از استخراج ویژگی‌های Mel باید از آن‌ها لگاریتم بگیریم تا برای انسان معنی دار تر باشند. برای این کار از تبدیل Amplitude to decibel استفاده شد.

مدل hubert نیز پیچیدگی خاصی ندارد. هر ورودی را ابتدا به Wav2Vec2 می‌دهیم و سپس خروجی آن را به مدل Hubert می‌دهیم و خروجی لایه پنهان آخر را به عنوان نمایش صوت خروجی می‌دهیم.

۳.۱ طبقه‌بندی

مشابه خواسته سوال از یک مدل پیچشی برای mel و از یک مدل MLP برای Hubert استفاده می‌کنیم. تعداد کانال‌های مدل پیچشی در جدول ۱.۱ آمده است.

جدول ۱.۱: تعداد کانال‌های هر لایه مدل پیچشی


شماره لایه	تعداد کانال
۱	۱۶
۲	۳۲
۳	۶۴

جدول ۲.۱: تعداد کانال‌های هر لایه پیچشی


برای مدل تماماً متصل نیز از یک مدل با یک لایه پنهان استفاده شد.

۴.۱ آموزش و ارزیابی مدل


آموزش مدل با همان پارامترهای پیشنهادی انجام شد. تنها برای تعداد دور از مقدار ۲۰ استفاده شد. زیرا با استفاده از ۵ دور، به طور واضحی مدل هنوز اشباع نشده بود.



شکل ۳.۱: نمودار خطا و دقت مدل روی داده‌های آموزش و صحت‌سنجی با hubert



شکل ۴.۱: نمودار خطا و دقت مدل روی داده‌های آموزش و صحت‌سنجی با mel spectro



شکل ۵.۱: ماتریس درهم ریختگی


روی بهترین مدل توانست به دقت ۷۷ درصد روی داده‌های آزمون برسد.

با مقایسه نمودارهای ۳.۱ و ۴.۱ می‌توان دید که مدل hubert هم در عدم بیش‌برازش و هم در دقت به مراتب بهتر از مدل mel spectrogram بوده است. مدل mel هم اختلاف زیادی بین دقت روی آزمون و آزمایش دارد و هم نتوانسته در دقت به مدل hubert برسد. همچنین بعد از دوره‌های کمی اشباع می‌شود در حالی که مدل hubert حتی پس از ۲۰ دور نیز اشباع نشده است.

۵.۱ سوال امتیازی

۱.۵.۱ معماری مدل Speech T5

مدل در اینجا شامل یک مدل کدگذار کدگشای اصلی همراه با شش بلوک مجزا است. این بلوک‌های مجزا پیچیدگی‌های modality ها را هندل می‌کنند و شبکه کدگذار کدگشا نیز اصل پردازش را انجام می‌دهد.



شکل ۶.۱: معماری مدل که در مقاله آمده است

همانطور که در شکل ۶.۱ می‌توان دید، ابتدا متن و گفتار هر کدام به یک شبکه مجزا داده می‌شوند سپس خروجی این دو به مدل کدگذار کدگشا داده می‌شود. هنگام انتقال اطلاعات از کدگذار به کدگشا، خروجی دو بلوک دیگر که یکی برای متن و یکی برای گفتار است نیز به این اطلاعات اضافه می‌شود. پس از پردازش اطلاعات در کدگشا، خروجی به یک بلوک پس پردازش متن و یک بلوک پس پردازش گفتار داده می‌شود. در ادامه وظیفه هر کدام از این بلوک‌ها توضیح داده شده است.

• Speech Encoder Pre-Net

تبدیل صوت به بردارهای representation با استفاده از ۷ بلوک convolutional برای ورود به رمزگذار.

• Text Encoder Pre-Net

تبدیل توکن‌های متن به بردارهای embedding برای ورود به رمزگذار.

• Speech Decoder Pre-Net

تبدیل صوت به فضای یکپارچه برای ورود به رمزگشا.

• Text Decoder Pre-Net

تبدیل توکن‌های متن هدف به بردارهای embedding مشترک برای ورود به رمزگشا.

• Speech Decoder Post-Net

تبدیل خروجی رمزگشا به صوت برای تولید گفتار

• Text Decoder Post-Net

تبدیل خروجی رمزگشا به توزیع احتمالی روی توکن‌های متن با استفاده از یک لایه خطی به همراه تابع Softmax برای تولید متن.

۲.۵.۱ Pretext task داده‌های گفتاری مدل

مدل SpeechT5 با استفاده از دو pretext task بر روی داده‌های گفتاری بدون برچسب آموزش داده می‌شود. شیوه آموزش مدل تقریباً شبیه به bert است یعنی بخش‌هایی از ورودی ماسک می‌شود و مدل باید آن‌ها را حدس بزند.

در تسک اول مدل باید صرفاً واحد صوتی ماسک شده را پیدا کند. یعنی به نوعی شبیه به پیش‌بینی توکن در فضای متنی. در اینجا صرفاً بخش کدگذار و سمت ورودی مدل آموزش داده می‌شود.

در تسک دوم مدل باید سعی کند صوت را بازسازی کند یعنی هم بخش ورودی و کدگذار آموزش داده می‌شود و هم بخش خروجی و کدگشا برای تولید صوت.

۳.۵.۱ تسک‌های انجام‌شده با SpeechT5

مدل SpeechT5 بر روی شش تسک مختلف ارزیابی شده است.

تسک	ورودی	خروجی
تشخیص خودکار گفتار	صوت گفتار	دنباله کاراکترهای متن
تبدیل متن به گفتار	متن	ویژگی‌های Mel-Log Filterbank
ترجمه گفتار	صوت به زبان انگلیسی	متن به زبان آلمانی یا فرانسوی
تبدیل صدا	صوت گوینده مبدا	صوت گوینده هدف
بهبود گفتار	صوت نویزی	صوت تمیز
تشخیص گوینده	صوت یک گوینده	برچسب گوینده


جدول ۳.۱: خلاصه تسک‌های انجام‌شده با SpeechT5 و ساختار ورودی/خروجی آن‌ها

سوال ۲

بهینه‌سازی

۱.۲ پیاده‌سازی تابع هدف و گرادیان


مطابق خواسته سوال تابع هدف و گرادیان پیاده‌سازی شد. نمودار این تابع در شکل ۱.۲ آمده است.



شکل ۱.۲: نمودار تابع rosenbrock بین یک تا منفی یک


۲.۲ پیاده‌سازی بهینه‌سازها

مطابق خواست سوال برای توابع بهینه‌سازی هر سه تابع بهینه‌ساز پیاده شدند و مسیرهای آن‌ها در شکل ۲.۲ آمده است.




شکل ۲.۲: نمودار تابع rosenbrock بین یک تا منفی یک


همچنین نمودارهای فاصله و خطا برای مقادیر خواسته شده حساب شد. جهت اینکه مقادیر قابل مشاهده باشند از آن‌ها لگاریتم گرفته شده است.




شکل ۳.۲: نمودار فاصله برای ضریب یادگیری یک صدم.




شکل ۴.۲: نمودار فاصله برای ضریب یادگیری یک دهم.




شکل ۵.۲: نمودار فاصله برای ضریب یادگیری یک .



شکل ۶.۲: نمودار مقدار تابع برای ضریب یادگیری یک صدم.



شکل ۷.۲: نمودار مقدار تابع برای ضریب یادگیری یک دهم.



شکل ۸.۲: نمودار مقدار تابع برای ضریب یادگیری یک.

همانطور که در شکل ۸.۲ و ۵.۲ می‌توان دید، هنگامی که نرخ یادگیری زیاد می‌شود، مدل converge نمی‌کند.

همچنین در همه مدل‌ها SGD عملکرد خیلی بدی دارد زیرا تابع محدب نیست.