

دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی برق و کامپیوتر

بازپیاذه‌سازی شبکه ساده ترنسفورمرگونه برای ابرتفکیک‌پذیری سبک تصویر

یادگیری عمیق با کاربرد در تصویر و صوت

نام و نام خانوادگی: آریا کورشی حضرت

شماره دانشجویی: ۸۱۰۱۰۴۰۳۹

نام و نام خانوادگی: مرتضی ملک‌نژاد

شماره دانشجویی: ۸۱۰۱۰۴۲۵۶

پروژه نهایی درس

فهرست مطالب

۶	چکیده
۷	۱ مقدمه و صورت مسئله
۷	۱.۱ تعریف مسئله
۷	۲.۱ هدف و دامنه پروژه
۷	۳.۱ جمع‌بندی مقاله مبنا
۹	۲ روش پیشنهادی مقاله
۹	۱.۲ پیمانه‌سازی کانولوشنی
۱۰	۲.۲ بلوک پیمانه‌سازی ترنسفورمرگونه
۱۰	۳.۲ گروه پیمانه‌سازی و توجه فضایی
۱۰	۴.۲ چارچوب کامل STSN
۱۲	۳ جزئیات پیاده‌سازی
۱۲	۱.۳ ساختار منبع کد
۱۳	۲.۳ استنتاج جزئیات نامشخص معماری
۱۳	۳.۳ آماده‌سازی داده
۱۴	۴.۳ آموزش و ذخیره مدل
۱۴	۵.۳ سنجه‌های ارزیابی
۱۶	۴ آزمایش‌ها و نتایج
۱۶	۱.۴ تنظیمات گزارش‌شده در مقاله
۱۶	۲.۴ آزمایش حذف مؤلفه مقاله
۱۷	۳.۴ تنظیمات اجرای نهایی ما
۱۸	۴.۴ روند همگرایی
۱۹	۵.۴ نتایج نهایی روی پنج مجموعه معیار

۲۱		تحلیل مجموعه به مجموعه	۱.۵.۴
۲۳		زمان استنتاج و بررسی کیفی	۶.۴
۲۳		نمونه های کیفی در حالت های مختلف	۱.۶.۴
۲۶		نسخه مسابقه NTIRE ۲۰۲۳	۷.۴

۵ تحلیل، محدودیت ها و بازتولیدپذیری

۲۷		چرا تطبیق پارامتر برای ما مهم بود؟	۱.۵
۲۷		محدودیت های مقایسه	۲.۵
۲۷		روش اجرای پروژه	۳.۵
۲۸		منابع کد و داده بیرونی	۴.۵

۶ نتیجه گیری

فهرست تصاویر

۱.۲	مسیر داده در پیاده‌سازی STSN؛ چهار گروه میانی هرکدام شامل چهار بلوک پیمانه‌سازی هستند.	۱۱
	بازترسیم توسط ما بر اساس روابط مقاله.	
۱.۴	روند آموزش مدل مقیاس دو روی همه ۸۰۰ تصویر DIV2K؛ سمت راست مرحله ۱۰۰ دوره‌ای از صفر	۱۸
	و سمت چپ مرحله ۱۰۰ دوره‌ای شروع گرم است. محور و مقادیر مستقیماً به وسیله برنامه تولید شده‌اند.	
۲.۴	روند کامل آموزش مقیاس سه؛ سمت راست آموزش ۱۰۰ دوره‌ای از صفر و سمت چپ آموزش ۱۰۰ دوره‌ای	۱۸
	شروع گرم است. هر دو نمودار از تاریخچه ذخیره‌شده اجرای کگل رسم شده‌اند.	
۳.۴	روند کامل آموزش مقیاس چهار؛ سمت راست آموزش ۱۰۰ دوره‌ای از صفر و سمت چپ آموزش	۱۹
	۱۰۰ دوره‌ای شروع گرم است. نوسان PSNR پایشی در این مقیاس علت گزارش کردن وزن آخرین دوره	
	به جای انتخاب بهترین وزن را روشن می‌کند.	
۴.۴	مقایسه زیان آموزش در دو مرحله ۱۰۰ دوره‌ای برای هر سه مقیاس. منحنی‌ها مستقیماً از تاریخچه‌های	۱۹
	ذخیره‌شده اجرای نهایی رسم شده‌اند.	
۵.۴	مقایسه PSNR خروجی نهایی STSN پس از شروع گرم با خط پایه دومکعبی روی پنج مجموعه معیار.	۲۱
	هر پنل یک ضریب بزرگ‌نمایی را نشان می‌دهد.	
۶.۴	افزایش PSNR بر اثر مرحله ۱۰۰ دوره‌ای شروع گرم نسبت به پایان مرحله نخست، برای هر مجموعه	۲۲
	و مقیاس.	
۷.۴	نمونه baby از Set5 در مقیاس دو پس از شروع گرم؛ از راست به چپ: مرجع پروضوح، STSN،	۲۴
	دومکعبی و ورودی کم‌وضوح.	
۸.۴	نمونه barbara از Set14 در مقیاس دو؛ بافت پارچه و خطوط ریز میز، تفاوت بازسازی ساختاری	۲۴
	را آشکار می‌کنند. ترتیب پنل‌ها از راست: مرجع، STSN، دومکعبی و ورودی است.	
۹.۴	مقایسه کیفی یک تصویر Urban100 در مقیاس دو پس از شروع گرم؛ از راست به چپ: مرجع	۲۴
	پروضوح، خروجی STSN، درون‌یابی دومکعبی و ورودی کم‌وضوح. شکل خروجی مستقیم برنامه است.	
۱۰.۴	نمونه 101085 از B100 در مقیاس سه؛ از راست به چپ: مرجع، STSN، دومکعبی و ورودی	۲۵
	کم‌وضوح. این نمونه رفتار مدل روی بافت طبیعی نامنظم را نشان می‌دهد.	
۱۱.۴	نمونه ARMS از Manga109 در مقیاس سه؛ خروجی STSN خطوط ترسیمی و نوشته‌های ریز را	۲۵
	نسبت به دومکعبی واضح‌تر نگه می‌دارد.	

- ۱۲.۴ نمونه bird از Set5 در بزرگ‌نمایی چهاربرابری؛ این حالت اثر کاهش شدید اطلاعات ورودی بر مرزهای طبیعی را نشان می‌دهد. ترتیب پنل‌ها از راست: مرجع، STSN، دوکعبی و ورودی است. ۲۵
- ۱۳.۴ نمونه img_002 از Urban100 در مقیاس چهار؛ خطوط مورب و قوس‌های تکراری سازه برای مقایسه بازسازی هندسی مناسب‌اند. ۲۶

فهرست جداول

۱۳	تطبیق شمار پارامترهای پیاده‌سازی با مقادیر جدول‌های حذف مؤلفه مقاله در مقیاس دو	۱.۳
۱۶	نتایج STSN گزارش شده در مقاله؛ هر خانه به‌ترتیب PSNR برحسب دسی‌بل و SSIM را نشان می‌دهد	۱.۴
۱۷	بخشی از نتایج کیفی حذف مؤلفه مقاله پیش از شروع گرم در مقیاس دو	۲.۴
۱۷	زمان و شمار پارامتر اجرای نهایی؛ زمان‌ها از تاریخچه ذخیره‌شده خود برنامه استخراج شده‌اند	۳.۴
۱۸	تغییر میانگین زیان L_1 روی داده کامل DIV2K	۴.۴
۲۰	همه نتایج پایان مرحله نخست ۱۰۰ دوره‌ای پیش از شروع گرم؛ هر خانه به‌ترتیب PSNR برحسب دسی‌بل و SSIM را نشان می‌دهد	۵.۴
۲۰	همه نتایج پایان مرحله شروع گرم در مقایسه با درونیابی دومکعبی و STSN گزارش شده در مقاله؛ هر جفت ستون شامل PSNR برحسب دسی‌بل و SSIM است	۶.۴
۲۲	اختلاف PSNR خروجی نهایی برحسب دسی‌بل؛ «مرحله اول» خروجی ۱۰۰ دوره‌ای پیش از شروع گرم است	۷.۴
۲۳	میانگین زمان استنتاج هر تصویر روی کارت Tesla T4، برحسب میلی‌ثانیه	۸.۴
۲۳	سنجه‌های عددی نمونه‌های کیفی نمایش داده‌شده؛ اعداد از ردیف همان تصویر در فایل‌های CSV گرفته شده‌اند	۹.۴

چکیده

در این پروژه مقاله «یک شبکه ساده ترنسفورمرگونه برای ابرتفکیک پذیری سبک تصویر» را از ابتدا بررسی و بازپاده سازی کردیم. مسئله این است که از یک تصویر کم وضوح، تصویری با ابعاد بزرگ تر و جزئیات نزدیک به نمونه مرجع ساخته شود؛ در عین حال مدل باید برای کاربردهای کم تاخیر سبک بماند. ایده اصلی مقاله جایگزینی خودتوجهی پرهزینه با «پیمانه سازی کانولوشنی» است. در این عملگر، دو شاخه کانولوشنی ساخته می شود، خروجی آن ها عضویه عضو ضرب می شود و در پایان یک کانولوشن 3×3 ویژگی محلی را استخراج می کند. این عملگر در ساختاری شبیه بلوک ترنسفورمر، همراه با نرمال سازی لایه ای، پرسپترون چندلایه و اتصال مانده قرار می گیرد.

پیاده سازی ما شامل آماده سازی زوج های کم وضوح و پر وضوح، افزایش داده، مدل کامل، آموزش با زیان L_1 ، ارزیابی روی کانال روشنایی، ذخیره نقاط واریسی، شروع گرم، رسم نمودار و آزمایش های حذف مؤلفه است. جزئیاتی که در مقاله صریح نبودند با تطبیق شمار پارامترها استنتاج شدند؛ مدل مقیاس دو دقیقاً 881,912 پارامتر دارد و شمار پارامتر همه نسخه های حذف مؤلفه نیز با جدول مقاله برابر شد. هر سه مدل روی همه ۸۰۰ تصویر آموزشی DIV2K اجرا شدند. برای هر مقیاس، ۱۰۰ دوره آموزش از صفر و سپس ۱۰۰ دوره آموزش با شروع گرم انجام دادیم و خروجی پایان مرحله دوم را روی همه تصاویر پنج مجموعه معیار سنجیدیم. در مقیاس دو، نتیجه Set5 برابر ۳۷/۱۶۳ دسی بل و ۰/۹۵۷۵ و نتیجه Urban ۱۰۰ برابر ۳۰/۳۴۳ دسی بل و ۰/۹۰۹۳ شد. شروع گرم در همه ۱۵ حالت، PSNR را نسبت به مرحله نخست افزایش داد و فاصله مدل با درون یابی دو مکعبی نیز در همه مجموعه ها مثبت بود. باقی ماندن فاصله با اعداد مقاله با بودجه ۲۰۰ دوره ای ما در برابر آموزش ۱۰۰۰ دوره ای و بازآموزی مقاله سازگار است.

واژه های کلیدی: ابرتفکیک پذیری تک تصویری، شبکه سبک، پیمانه سازی کانولوشنی، توجه فضایی، بازآرایی زیرپیکسلی.

فصل ۱

مقدمه و صورت مسئله

۱.۱ تعریف مسئله

در ابرتفکیک‌پذیری تک‌تصویری، ورودی یک تصویر کم‌وضوح $x \in \mathbb{R}^{H \times W \times 3}$ است و هدف یادگیری نگاشتی مانند f_θ برای تولید تصویر $\hat{y} = f_\theta(x) \in \mathbb{R}^{sH \times sW \times 3}$ است؛ s ضریب بزرگ‌نمایی و θ پارامترهای مدل است. چون در فرایند کاهش وضوح بخشی از بسامدهای بالا از بین می‌روند، پاسخ مسئله یکتا نیست. شبکه باید با استفاده از آمار داده آموزشی، لبه، بافت و ساختار محتمل را بازسازی کند.

روش‌های مبتنی بر شبکه کانولوشنی در این مسئله موفق بوده‌اند، ولی وابستگی‌های دوربرد را به‌صورت غیرمستقیم و با افزایش عمق یا میدان دید می‌آموزند. ترنسفورمرها این محدودیت را با خودتوجهی کاهش می‌دهند، اما ماتریس توجه برای $N = HW$ نشانه، هزینه‌ای تقریباً متناسب با N^2 دارد. این هزینه روی تصویرهای بزرگ، مخصوصاً در مرحله استنتاج، مشکل اصلی است. مقاله مبنا برای حفظ سبک ترنسفورمر و حذف ماتریس توجه، از پیمان‌سازی کانولوشنی استفاده می‌کند [۲، ۱].

۲.۱ هدف و دامنه پروژه

هدف ما فقط نوشتن لایه مدل نبود. کل مسیر آزمایش را در نظر گرفتیم: ساخت داده کم‌وضوح با کاهش دومکعبی، برش هم‌تراز وصله‌ها، افزایش داده، آموزش، ارزیابی، ذخیره مدل، تولید شکل و اجرای نسخه‌های حذف مؤلفه. سه ضریب مقیاس ۲، ۳ و ۴ در مدل پشتیبانی می‌شوند. پیکربندی پیش‌فرض مطابق آزمایش مقیاس دو مقاله است و حالت quick-همان مدل کامل را روی داده‌ای کوچک اجرا می‌کند تا دستیار آموزشی بدون تغییر کد، در زمان کوتاه همه مسیر را بررسی کند.

۳.۱ جمع‌بندی مقاله مبنا

مقاله سه ادعای اصلی دارد. نخست، بلوک پیشنهادی به‌جای محاسبه شباهت همه مکان‌های تصویر، با کانولوشن و ضرب هادامارد کار می‌کند و نسبت به تعداد پیکسل‌ها رشد خطی دارد. دوم، قرار دادن این عملگر در ساختار پیش‌نرمال‌سازی‌شده و مانده، مزیت سازمان‌دهی بلوک ترنسفورمر را نگه می‌دارد. سوم، ترکیب چهار گروه از این بلوک‌ها با توجه فضایی تقویت‌شده و بازسازی زیرپیکسلی، نسبت مناسبی میان کیفیت، تعداد پارامتر و زمان اجرا ایجاد می‌کند. نویسندگان گزارش کرده‌اند

که مدل آن‌ها نسبت به LWSwinIR حدود 5.6 برابر سریع‌تر است، در حالی که تعداد پارامتر و کیفیت دو مدل نزدیک‌اند [۱].

فصل ۲

روش پیشنهادی مقاله

۱.۲ پیمانه سازی کانولوشنی

ورودی نرمال شده را با $F \in \mathbb{R}^{B \times C \times H \times W}$ نشان می دهیم. عملگر پیمانه سازی دو شاخه دارد. شاخه اول زمینه مکانی را با یک کانولوشن نقطه ای و سپس کانولوشن عمقی بزرگ استخراج می کند:

$$F_d = \text{DWConv}_{k \times k}(\text{Conv}_{1 \times 1}(F)). \quad (1.2)$$

شاخه دوم مقدار ویژگی را می سازد:

$$F_v = \text{Conv}_{1 \times 1}(F). \quad (2.2)$$

دو خروجی عضویه عضو ضرب و سپس فرافکنی می شوند:

$$\text{CM}(F) = \text{Conv}_{3 \times 3}(F_d \odot F_v). \quad (3.2)$$

تفاوت مهم نسخه ابرتفکیک پذیری با عملگر اصلی Conv2Former در کانولوشن آخر است. نسخه اصلی از کانولوشن 1×1 استفاده می کرد، ولی مقاله آن را با 3×3 جایگزین کرده تا پیش از بازسازی، ویژگی های محلی بهتر حفظ شوند. نتیجه حذف مؤلفه نیز این انتخاب را پشتیبانی می کند: در PSNR، Urban100، مدل کامل 32.58 و نسخه فرافکنی 1×1 برابر 32.48 دسی بل گزارش شده است.

اگر هزینه کانولوشن های نقطه ای را هم لحاظ کنیم، مرتبه محاسباتی رابطه ۳.۲ تقریباً برابر است با

$$\mathcal{O}(HWC^2 + HWk^2C), \quad (4.2)$$

در حالی که خودتوجهی سراسری جمله‌ای از مرتبه $O((HW)^2C)$ دارد. بنابراین با ثابت ماندن تعداد کانال و اندازه کرنل، هزینه پیمانه‌سازی نسبت به تعداد پیکسل‌ها خطی است.

۲.۲ بلوک پیمانه‌سازی ترنسفورمرگونه

هر بلوک از دو زیرلایه تشکیل می‌شود. ابتدا نرمال‌سازی لایه‌ای روی کانال‌ها انجام می‌شود، سپس پیمانه‌سازی کانولوشنی و اتصال مانده اعمال می‌شوند:

$$Z = F_{i-1} + \gamma_1 \odot \text{CM}(\text{LN}(F_{i-1})), \quad (5.2)$$

$$F_i = Z + \gamma_2 \odot \text{MLP}(\text{LN}(Z)). \quad (6.2)$$

γ_1 و γ_2 بردارهای مقیاس یادگرفتنی هستند. پرسپترون چندلایه ابتدا کانال‌ها را دو برابر می‌کند، یک کانولوشن عمقی 3×3 برای اختلاط مکانی دارد و سپس تعداد کانال‌ها را به مقدار اول برمی‌گرداند. تابع فعال‌سازی در این بخش GELU است. وجود مسیرهای مانده باعث می‌شود گرادیان در شبکه عمیق‌تر پایدارتر منتقل شود.

۳.۲ گروه پیمانه‌سازی و توجه فضایی

هر گروه از چهار بلوک رابطه ۶.۲، یک کانولوشن 3×3 و یک واحد توجه فضایی تقویت‌شده تشکیل شده است:

$$F_i = \text{C2FB}_i(F_{i-1}), \quad i = 1, \dots, n, \quad (7.2)$$

$$F_c = \text{Conv}_{3 \times 3}(F_n), \quad (8.2)$$

$$F_{\text{group}} = \text{ESA}(F_c). \quad (9.2)$$

در واحد توجه فضایی، تعداد کانال‌ها از ۵۰ به ۱۲ کاهش می‌یابد. یک مسیر کم‌وضوح با کانولوشن گام‌دار و بیشینه‌گیری، میدان دید را بزرگ می‌کند و یک مسیر کوتاه اطلاعات محلی را نگه می‌دارد. پس از درون‌یابی مسیر کم‌وضوح و جمع دو مسیر، یک نگاشت سیگموئیدی به‌عنوان ماسک توجه روی ورودی ضرب می‌شود. این واحد از ایده توجه فضایی تقویت‌شده در شبکه تجمیع ویژگی مانده استفاده می‌کند [۳].

۴.۲ چارچوب کامل STSN

مدل کامل سه بخش دارد. در بخش اول، یک کانولوشن 3×3 ویژگی کم‌عمق را استخراج می‌کند:

$$F_0 = \text{Conv}_{3 \times 3}(x). \quad (10.2)$$


در بخش دوم، چهار گروه به صورت زنجیره‌ای اجرا می‌شوند:

$$F_g = \text{Group}_g(F_{g-1}), \quad g = 1, \dots, 4. \quad (11.2)$$

خروجی کم‌عمق و خروجی همه گروه‌ها روی بعد کانال به هم چسبانده می‌شوند. یک کانولوشن 1×1 تعداد کانال‌ها را کاهش می‌دهد و کانولوشن 3×3 بعدی ویژگی‌ها را هموار و مخلوط می‌کند:

$$F_{\text{comb}} = \text{Conv}_{3 \times 3}(\text{Conv}_{1 \times 1}([F_0, F_1, F_2, F_3, F_4])). \quad (12.2)$$

در پایان، F_{comb} با F_0 جمع می‌شود. کانولوشن بازسازی $3s^2$ کانال تولید می‌کند و بازآرایی زیرپیکسلی آن‌ها را به تصویر RGB با ابعاد $sH \times sW$ تبدیل می‌کند [۸]. شکل ۱.۲ مسیر داده پیاده‌سازی ما را نشان می‌دهد. این شکل بازترسیم مستقل معماری است و تصویر صفحه یا کپی شکل مقاله نیست.



شکل ۱.۲: مسیر داده در پیاده‌سازی STSN؛ چهار گروه میانی هرکدام شامل چهار بلوک پیمانه‌سازی هستند. بازترسیم توسط ما بر اساس روابط مقاله.

فصل ۳

جزئیات پیاده‌سازی

۱.۳ ساختار منبع کد

کد در پوشه `homework_code` قرار دارد و ساختار درختی خواسته شده رعایت شده است. فایل‌های اضافی `ablation.py`، `download_set5.py` و پوشه آزمون‌ها برای بازتولیدپذیری افزوده شده‌اند.

```
homework_code/
|-- data/
|   |-- data_loader.py
|   |-- download_set5.py
|   `-- dataset/
|-- models/
|   |-- model.py
|   `-- saved_models/
|-- scripts/
|   |-- main.py
|   |-- train.py
|   |-- evaluate.py
|   `-- ablation.py
|-- config/
|   |-- config.yaml
|   `-- logging.yaml
|-- utils/
|   |-- config.py
|   |-- visualization.py
|   `-- metrics.py
|-- tests/test_pipeline.py
|-- README.md
```

```
-- requirements.txt
```

همه مسیرهای موجود در فایل پیکربندی نسبت به ریشه پروژه تفسیر می‌شوند. تنها مسیر مطلق که در زمان اجرا دیده می‌شود با `Path(__file__).resolve()` از محل خود فایل ساخته می‌شود و هیچ نام کاربری، حرف درایو یا مسیر وابسته به رایانه در کد نوشته نشده است.

۲.۳ استنتاج جزئیات نامشخص معماری

متن مقاله نسبت گسترش پرسپترون، اندازه کرنل عمقی و تعداد کانال میانی توجه فضایی را صریح ذکر نکرده است. به جای انتخاب دلخواه، از جدول‌های حذف مؤلفه به عنوان قید استفاده کردیم. منطق این بازسازی به صورت زیر بود:

- تفاوت مدل کامل و مدل بدون پرسپترون 180,800 پارامتر است. با ۱۶ بلوک، سهم هر پرسپترون همراه با نرمال‌سازی و مقیاس لایه 11,300 می‌شود؛ این عدد دقیقاً با نسبت گسترش ۲ و کانولوشن عمقی 3×3 سازگار است.

- تفاوت مدل کامل و مدل بدون پیمانه‌سازی 542,400 پارامتر است. سهم 33,900 پارامتری هر بلوک، با کرنل عمقی 11×11 ، دو کانولوشن نقطه‌ای، فرافکنی 3×3 ، نرمال‌سازی و مقیاس لایه دقیقاً به دست می‌آید.

- حذف توجه فضایی 26,600 پارامتر کم می‌کند. تقسیم این مقدار میان چهار گروه، 6,650 پارامتر برای هر واحد می‌دهد که با ۱۲ کانال میانی، یعنی $\lfloor 50/4 \rfloor$ ، برابر است.

این بررسی یک آزمون خودکار شده است؛ بنابراین تغییر ناخواسته معماری باعث شکست آزمون می‌شود. جدول ۱.۳ نتیجه را نشان می‌دهد.

جدول ۱.۳: تطبیق شمار پارامترهای پیاده‌سازی با مقادیر جدول‌های حذف مؤلفه مقاله در مقیاس دو

گونه مدل	مقاله (هزار)	پیاده‌سازی (دقیق)	اختلاف
مدل کامل	۸۸۱/۹	۸۸۱,۹۱۲	•
فرافکنی 1×1	۵۶۱/۹	۵۶۱,۹۱۲	•
بدون دروازه توجه	۷۰۲/۷	۷۰۲,۷۱۲	•
بدون پیمانه‌سازی	۳۳۹/۵	۳۳۹,۵۱۲	•
بدون پرسپترون	۷۰۱/۱	۷۰۱,۱۱۲	•
بدون توجه فضایی	۸۵۵/۳	۸۵۵,۳۱۲	•
بدون کانولوشن گروه	۷۹۱/۷	۷۹۱,۷۱۲	•

منظور از اختلاف صفر در جدول، برابری با مقدار دقیق استنتاج‌شده پیش از گرد کردن به هزار پارامتر است؛ خود مقاله اعداد ستون دوم را با یک رقم اعشار گزارش کرده است.

۳.۳ آماده‌سازی داده

کلاس مجموعه داده دو حالت دارد. اگر جفت LR موجود باشد، نام فایل‌های دو پوشه تطبیق داده و ابعاد آن‌ها هم‌تراز می‌شود. در غیر این صورت، تصویر HR ابتدا طوری برش می‌خورد که ابعادش مضرب s باشد و سپس کاهش دومکعبی

روی آن اجرا می‌شود. در حالت آموزش یک وصله تصادفی HR انتخاب و مختصات LR متناظر از مضرب دقیق آن برداشته می‌شود؛ در نتیجه خطای نیم‌پیکسل یا جابه‌جایی میان هدف و ورودی ایجاد نمی‌شود.

افزایش داده شامل بازتاب افقی تصادفی و چرخش تصادفی صفر، ۹۰، ۱۸۰ یا ۲۷۰ درجه است. این تنظیم دقیقاً با توضیح مقاله سازگار است. داده‌ها به تنسور RGB در بازه صفر تا یک تبدیل می‌شوند. برای اجرای آفلاین، تابعی نوشته‌ایم که تصاویرهای ساختگی دارای گرادیان، بافت تناوبی، لبه، دایره و مستطیل تولید می‌کند. این تصاویر از منبع خارجی گرفته نشده‌اند.

در اجرای نهایی، هر ۸۰۰ تصویر آموزشی DIV2K و جفت‌های کم‌وضوح رسمی دومکعبی برای هر سه مقیاس استفاده شدند [۴]. ارزیابی نیز روی تمام تصاویر پنج مجموعه Set5، Set14، B100، Urban100 و Manga109 انجام شد. برای جلوگیری از اختلاف میان پیاده‌سازی‌های بازنمونه‌برداری، جفت‌های آماده Set5 و Set14 مستقیماً به‌کار رفتند و برای سه مجموعه دیگر، تصاویر کم‌وضوح با تابع imresize متلب و گزینه دومکعبی پادهمپوشانی ساخته شدند. تعداد تصاویر پیش از شروع آموزش و ارزیابی به‌صورت برنامه‌ای کنترل شد.

۴.۳ آموزش و ذخیره مدل

تابع هدف میانگین قدرمطلق خطای پیکسل‌ها است:

$$\mathcal{L}_1(\theta) = \frac{1}{3sHsW} \sum_{c=1}^3 \sum_{u=1}^{sH} \sum_{v=1}^{sW} |f_{\theta}(x)_{cuv} - y_{cuv}|. \quad (۱.۳)$$

بهینه‌ساز آدم با $\beta_1 = 0.9$ ، $\beta_2 = 0.99$ و $\epsilon = 10^{-8}$ استفاده شده است [۷]. نرخ یادگیری اولیه 5×10^{-4} است و هر ۲۰۰ دوره نصف می‌شود. مقاله اندازه دسته ۳۲، آموزش ۱۰۰۰ دوره‌ای و سپس بازآموزی با راهبرد شروع گرم را گزارش کرده است. مطابق تصمیم پروژه، ما همان اندازه دسته و همه ۸۰۰ تصویر را حفظ کردیم، اما بودجه هر مرحله را به ۱۰۰ دوره کاهش دادیم: مرحله نخست از وزن تصادفی و مرحله دوم از وزن پایان مرحله نخست آغاز می‌شود. در هر مرحله بهینه‌ساز و زمان‌بند از نو ساخته می‌شوند؛ از این‌رو نرخ یادگیری در بازه ۱۰۰ دوره‌ای هنوز به نخستین پله کاهش دوره ۲۰۰ نرسیده و ثابت می‌ماند. نقاط واریسی آخرین دوره و بهترین PSNR پایشی ذخیره می‌شوند، ولی اعداد اصلی از نقطه واریسی پایان دوره ۱۰۰ مرحله شروع گرم و اعداد «پیش از شروع گرم» از پایان مرحله نخست گرفته می‌شوند؛ بنابراین Set5 در انتخاب وزن گزارش‌شده دخالت ندارد.

۵.۳ سنجه‌های ارزیابی

مطابق مقاله، ارزیابی روی کانال روشنایی انجام می‌شود. تبدیل RGB به Y با قرارداد رایج MATLAB به‌شکل زیر است:

$$Y = \frac{65.481R + 128.553G + 24.966B + 16}{255}, \quad (۲.۳)$$

که در آن R ، G و B در بازهٔ صفر تا یک‌اند. سپس حاشیه‌ای به عرض s پیکسل حذف می‌شود. نسبت بیشینهٔ سیگنال به نویز از خطای میانگین مربعات محاسبه می‌شود:

$$\text{PSNR} = 10 \log_{10} \left(\frac{1}{\text{MSE}} \right). \quad (3.3)$$

شاخص شباهت ساختاری با پنجرهٔ گاوسی ۱۱ پیکسلی، انحراف معیار 1.5 و بازهٔ دادهٔ یک محاسبه می‌شود [۶]. برای مقایسهٔ منصفانه، همین تبدیل رنگ و حذف حاشیه هم برای STSN و هم برای خط پایهٔ دومکعبی استفاده شده است.

فصل ۴

آزمایش‌ها و نتایج

۱.۴ تنظیمات گزارش‌شده در مقاله

نویسندگان برای ضرایب ۲، ۳ و ۴ به‌ترتیب اندازه‌ی وصله‌ی ۹۶، ۱۴۴ و ۱۹۲ را به‌کار برده‌اند. چهار گروه، چهار بلوک در هر گروه و ۵۰ کانال ویژگی ثابت مانده‌اند. آموزش روی DIV2K و ارزیابی روی Set5، Set14، B100، Urban100 و Manga109 انجام شده است. جدول ۱.۴ فقط ردیف STSN جدول اصلی مقاله را بازنویسی می‌کند تا مرجع عددی روش روشن باشد؛ این اعداد خروجی اجرای ما نیستند.

جدول ۱.۴: نتایج STSN گزارش‌شده در مقاله؛ هر خانه به‌ترتیب PSNR برحسب دسی‌بل و SSIM را نشان می‌دهد

مقیاس	پارامتر (هزار)	Set5	Set14	B100	Urban100	Manga109
×2	۸۸۱/۹	۰/۹۶۱۱ / ۳۸/۱۹	۰/۹۱۹۹ / ۳۳/۷۸	۰/۹۰۱۳ / ۳۲/۳۰	۰/۹۳۳۶ / ۳۲/۶۸	۰/۹۷۷۸ / ۳۹/۱۳
×3	۸۸۸/۷	۰/۹۲۹۲ / ۳۴/۶۲	۰/۸۴۶۶ / ۳۰/۵۴	۰/۸۰۹۰ / ۲۹/۲۲	۰/۸۶۲۱ / ۲۸/۵۹	۰/۹۴۸۰ / ۳۴/۱۱
×4	۸۹۸/۲	۰/۸۹۸۲ / ۳۲/۴۶	۰/۷۸۶۰ / ۲۸/۷۶	۰/۷۴۰۵ / ۲۷/۶۸	۰/۷۹۷۱ / ۲۶/۳۹	۰/۹۱۴۲ / ۳۰/۹۳

زمان گزارش‌شده برای مقیاس‌های ۲، ۳ و ۴ به‌ترتیب ۶۴۰، ۲۹۸ و ۱۶۸ میلی‌ثانیه و تعداد ضرب‌جمع‌ها به‌ترتیب ۱۹۷/۷، ۹۹/۹ و ۵۰/۳ میلیارد است. کاهش هزینه با افزایش ضریب مقیاس در نگاه اول عجیب به نظر می‌رسد، ولی ابعاد ورودی LR برای خروجی ثابت کوچک‌تر می‌شود. در مقیاس دو، زمان ۶۴۰ میلی‌ثانیه در برابر ۳۵۹۰ میلی‌ثانیه LWSwinIR همان نسبت سرعت حدود 5.6 برابر را می‌سازد.

۲.۴ آزمایش حذف مؤلفه مقاله

مهم‌ترین نتیجه حذف مؤلفه روی مجموعه‌های دارای ساختار زیاد دیده می‌شود. جدول ۲.۴ تغییر PSNR دو مجموعه را نشان می‌دهد. حذف کامل پیمانه‌سازی در Urban100 حدود 0.52 دسی‌بل و در Manga109 حدود 0.36 دسی‌بل افت ایجاد کرده است. حذف پرسپترون نیز افت قابل‌توجه دارد. توجه فضایی و کانولوشن محلی گروه پارامتر بسیار کمتری نسبت به بدنه دارند، ولی هر دو روی تصاویر شهری اثر محسوسی گذاشته‌اند.

جدول ۲۰۴: بخشی از نتایج کیفی حذف مؤلفه مقاله پیش از شروع گرم در مقیاس دو

گونه مدل	PSNR در Urban100	PSNR در Manga109
مدل کامل	۳۲/۵۸	۳۹/۰۶
فراکنی 1×1	۳۲/۴۸	۳۹/۰۱
بدون دروازه توجه	۳۲/۲۰	۳۸/۸۵
بدون پیمانه‌سازی	۳۲/۰۶	۳۸/۷۰
بدون پرسپترون	۳۲/۳۰	۳۸/۸۶
بدون توجه فضایی	۳۲/۴۳	۳۹/۰۰
بدون کانولوشن گروه	۳۲/۴۴	۳۹/۰۰

شروع گرم بدون افزودن پارامتر، PSNR را روی Urban100 از ۳۲/۵۸ به ۳۲/۶۸ و روی Manga109 از ۳۹/۰۶ به ۳۹/۱۳ رسانده است. به همین دلیل کد ما مسیر شروع گرم را جدا از ادامه عادی آموزش پیاده می‌کند.

۳.۴ تنظیمات اجرای نهایی ما

اجرای نهایی روی کارت گرافیکی NVIDIA Tesla T4 در محیط کگل، پایتون ۳/۱۲/۱۳، PyTorch 2.10.0+cu128، و کودا ۱۲/۸ انجام شد. برای هر سه مقیاس، همه ۸۰۰ تصویر آموزشی DIV2K و جفت‌های رسمی کم‌وضوح دومکعبی به‌کار رفتند. اندازه وصله پروجو برای مقیاس‌های ۲، ۳ و ۴ به ترتیب ۹۶، ۱۴۴ و ۱۹۲ و اندازه وصله کم‌وضوح در هر سه حالت ۴۸ بود. اندازه دسته ۳۲، تعداد کارگر بارگذاری داده ۲، بذر تصادفی ۸۱۰۱۰۴۰۳۹ و زیان همان L_1 مقاله بود.

برای هر مقیاس دو مرحله اجرا کردیم: مرحله نخست ۱۰۰ دوره از وزن تصادفی و مرحله دوم ۱۰۰ دوره با شروع از وزن پایان مرحله نخست. هر مرحله ۲۵۰۰ به‌روزرسانی و کل آموزش هر مقیاس ۵۰۰۰ به‌روزرسانی داشت. مقاله برای آموزش نخست ۱۰۰۰ دوره را مشخص کرده، اما تعداد دوره بازآموزی مدل اصلی را صریح ننوشته است؛ بنابراین فرض مستند ما این بود که بودجه ۱۰۰ دوره‌ای انتخاب‌شده برای پروژه، به هر یک از دو مرحله اختصاص یابد. برای جلوگیری از انتخاب نتیجه بر پایه مجموعه آزمون، تمام اعداد اصلی از نقطه واری آخرین دوره گرفته شدند، نه بهترین نقطه واری بر اساس Set5.

جدول ۳۰۴: زمان واقعی آموزش را نشان می‌دهد. مجموع زمان پردازش کارت گرافیکی شش اجرا حدود ۹/۴۱ ساعت بود. اجراهای سه مقیاس مستقل از یکدیگرند و به همین علت امکان اجرای هم‌زمان آن‌ها وجود داشت.

جدول ۳۰۴: زمان و شمار پارامتر اجرای نهایی؛ زمان‌ها از تاریخچه ذخیره‌شده خود برنامه استخراج شده‌اند

مقیاس	شمار پارامتر	مرحله نخست (دقیقه)	شروع گرم (دقیقه)	مجموع (دقیقه)
۲	۸۸۱,۹۱۲	۹۵/۱	۹۴/۴	۱۸۹/۵
۳	۸۸۸,۶۷۷	۸۷/۸	۹۶/۸	۱۸۴/۶
۴	۸۹۸,۱۴۸	۹۰/۷	۹۹/۶	۱۹۰/۳


۴.۴ روند همگرایی

جدول ۴.۴ زیان نخستین و آخرین دوره هر مرحله را مقایسه می‌کند. در هر سه مقیاس، زیان پایان مرحله شروع گرم از پایان آموزش نخست کمتر شد. بزرگ‌تر بودن زیان دوره نخست شروع گرم نسبت به آخرین دوره مرحله نخست تناقض نیست، زیرا ترتیب وصله‌های تصادفی، بهینه‌ساز و حالت‌های مومنتوم در ابتدای مرحله دوم از نو ساخته شدند.


جدول ۴.۴: تغییر میانگین زیان L_1 روی داده کامل DIV2K

مقیاس	نخستین دوره مرحله اول	پایان مرحله اول	نخستین دوره شروع گرم	پایان شروع گرم
۲	۰/۱۵۷۳۳	۰/۱۵۴۲	۰/۲۰۹۷	۰/۱۴۵۳
۳	۰/۱۹۹۴۳	۰/۲۳۳۰	۰/۲۹۶۰	۰/۲۲۶۵
۴	۰/۱۶۳۵۸	۰/۲۸۶۲	۰/۳۵۳۶	۰/۲۷۰۰


شکل‌های ۱.۴ تا ۳.۴ هر شش نمودار آموزش را نمایش می‌دهند؛ برای هر مقیاس، نمودار مرحله نخست و شروع گرم جداگانه آمده است. هر نقطه آبی میانگین زیان تمام ۲۵ دسته آن دوره و نقاط قرمز PSNR پایشی روی Set5 هستند. افت ناگهانی یا پله نرخ یادگیری دیده نمی‌شود، زیرا نخستین نصف‌شدن نرخ یادگیری در دوره ۲۰۰ تعریف شده و هر مرحله ما در دوره ۱۰۰ پایان می‌یابد.



شکل ۱.۴: روند آموزش مدل مقیاس دو روی همه ۸۰۰ تصویر DIV2K؛ سمت راست مرحله ۱۰۰ دوره‌ای از صفر و سمت چپ مرحله ۱۰۰ دوره‌ای شروع گرم است. محور و مقادیر مستقیماً به وسیله برنامه تولید شده‌اند.



شکل ۲.۴: روند کامل آموزش مقیاس سه؛ سمت راست آموزش ۱۰۰ دوره‌ای از صفر و سمت چپ آموزش ۱۰۰ دوره‌ای شروع گرم است. هر دو نمودار از تاریخچه ذخیره‌شده اجرای کگل رسم شده‌اند.




شکل ۳.۴: روند کامل آموزش مقیاس چهار؛ سمت راست آموزش ۱۰۰ دوره‌ای از صفر و سمت چپ آموزش ۱۰۰ دوره‌ای شروع گرم است. نوسان PSNR پایشی در این مقیاس علت گزارش کردن وزن آخرین دوره به جای انتخاب بهترین وزن را روشن می‌کند.

در مقیاس دو، زیان شروع گرم در پایان به 0.1453 رسید و بیشترین PSNR پایشی نیز در همان انتهای مرحله به دست آمد. مقیاس سه روندی مشابه داشت و زیان نهایی آن 0.2265 شد. در مقیاس چهار، زیان تا 0.2700 کاهش یافت، اما PSNR پایشی به علت حساسیت بیشتر بازسازی چهاربرابری نوسان داشت؛ بهترین مقدار پایشی 30.967 و مقدار آخرین دوره 30.779 دسی بل بود. ما مقدار دوم را در تمام جدول‌های اصلی به کار بردیم تا قاعده انتخاب وزن برای هر سه مقیاس یکسان بماند.

شکل ۴.۴ همین روند را به صورت فشرده نمایش می‌دهد. در هر سه مقیاس، منحنی مرحله شروع گرم از مقدار زیان پایین‌تری آغاز می‌شود و در پایان نیز از مرحله نخست کمتر است.

Training curves for the two fixed-budget stages



شکل ۴.۴: مقایسه زیان آموزش در دو مرحله ۱۰۰ دوره‌ای برای هر سه مقیاس. منحنی‌ها مستقیماً از تاریخچه‌های ذخیره شده اجرای نهایی رسم شده‌اند.

۵.۴ نتایج نهایی روی پنج مجموعه معیار

برای اینکه اثر هر مرحله مستقل دیده شود، جدول ۵.۴ همه نتایج پایان آموزش نخست را گزارش می‌کند. سپس جدول ۶.۴ نتیجه پایان دوره ۱۰۰ شروع گرم را برای همان ۱۵ ترکیب مقیاس و مجموعه می‌آورد. سنج‌ها روی کانال روشنایی و پس از حذف حاشیه‌ای به عرض ضریب مقیاس محاسبه شده‌اند. هر مقدار میانگین همه تصاویر آن مجموعه است، نه نتیجه یک نمونه منتخب: ۵ تصویر Set5، ۱۴ تصویر Set14، ۱۰۰ تصویر B100، ۱۰۰ تصویر Urban100 و ۱۰۹ تصویر Manga109؛ در مجموع ۳۲۸ تصویر در هر اجرا. نتیجه تصویر به تصویر شش اجرا نیز در ۳۰ فایل CSV داخل پوشه‌های outputs تحویل داده شده است. این ۱۹۶۸ ردیف خام مبنای میانگین‌های گزارش‌اند، اما برای خوانایی به صورت کامل داخل متن چاپ نشده‌اند.

جدول ۵.۴: همه نتایج پایان مرحله نخست ۱۰۰ دوره‌ای پیش از شروع گرم؛ هر خانه به ترتیب PSNR برحسب دسی‌بل و SSIM را نشان می‌دهد


مقیاس	Set5	Set14	B100	Urban100	Manga109
۲	۰/۹۵۴۳ / ۳۶/۷۵۹	۰/۹۰۶۶ / ۳۲/۴۸۲	۰/۸۸۸۰ / ۳۱/۳۸۷	۰/۸۹۷۳ / ۲۹/۶۶۸	۰/۹۶۵۳ / ۳۶/۰۷۵
۳	۰/۹۰۲۳ / ۳۲/۴۶۷	۰/۸۱۶۵ / ۲۹/۱۱۴	۰/۷۸۲۹ / ۲۸/۲۶۰	۰/۷۹۱۷ / ۲۵/۹۳۹	۰/۸۹۹۰ / ۲۹/۸۶۱
۴	۰/۸۵۷۳ / ۳۰/۲۵۴	۰/۷۵۰۸ / ۲۷/۳۵۰	۰/۷۱۱۰ / ۲۶/۷۹۳	۰/۷۱۸۴ / ۲۴/۳۲۳	۰/۸۴۳۵ / ۲۷/۰۷۶

مرحله نخست در همه مجموعه‌ها از دومکعبی بهتر شد، ولی فاصله آن با خروجی شروع گرم روی مجموعه‌های بافت‌دار بیشتر است. برای نمونه، شروع گرم PSNR مقیاس سه را روی Manga109 از ۲۹/۸۶۱ به ۳۱/۲۶۹ رساند؛ یعنی افزایش ۱/۴۰۸ دسی‌بل بدون تغییر معماری یا شمار پارامتر.

جدول ۶.۴: همه نتایج پایان مرحله شروع گرم در مقایسه با درونیایی دومکعبی و STSN گزارش شده در مقاله؛ هر جفت ستون شامل PSNR برحسب دسی‌بل و SSIM است

مقیاس	مجموعه	مدل ما		دومکعبی		مقاله	
		SSIM	PSNR	SSIM	PSNR	SSIM	PSNR
۲	Set5	۰/۹۵۷۵	۳۷/۱۶۳	۰/۹۳۳۶	۳۳/۹۶۰	۰/۹۶۱۱	۳۸/۱۹
۲	Set14	۰/۹۱۱۵	۳۲/۸۲۶	۰/۸۷۵۳	۳۰/۵۴۴	۰/۹۱۹۹	۳۳/۷۸
۲	B100	۰/۸۹۳۶	۳۱/۶۸۵	۰/۸۴۹۷	۲۹/۷۴۳	۰/۹۰۱۳	۳۲/۳۰
۲	Urban100	۰/۹۰۹۳	۳۰/۳۴۳	۰/۸۴۵۸	۲۷/۰۷۳	۰/۹۳۳۶	۳۲/۶۸
۲	Manga109	۰/۹۷۲۰	۳۶/۸۶۷	۰/۹۳۸۶	۳۱/۲۵۲	۰/۹۷۷۸	۳۹/۱۳
۳	Set5	۰/۹۱۶۶	۳۳/۱۷۹	۰/۸۷۲۱	۳۰/۶۱۳	۰/۹۲۹۲	۳۴/۶۲
۳	Set14	۰/۸۲۷۷	۲۹/۴۶۶	۰/۷۸۱۲	۲۷/۷۸۷	۰/۸۴۶۶	۳۰/۵۴
۳	B100	۰/۷۹۳۲	۲۸/۵۷۰	۰/۷۴۴۳	۲۷/۳۱۹	۰/۸۰۹۰	۲۹/۲۲
۳	Urban100	۰/۸۱۶۴	۲۶/۶۵۵	۰/۷۳۹۸	۲۴/۵۸۲	۰/۸۶۲۱	۲۸/۵۹
۳	Manga109	۰/۹۲۳۶	۳۱/۲۶۹	۰/۸۶۰۳	۲۷/۱۹۸	۰/۹۴۸۰	۳۴/۱۱
۴	Set5	۰/۸۷۲۲	۳۰/۷۷۹	۰/۸۱۴۲	۲۸/۶۰۱	۰/۸۹۸۲	۳۲/۴۶
۴	Set14	۰/۷۶۲۴	۲۷/۷۲۳	۰/۷۰۹۰	۲۶/۲۱۰	۰/۷۸۶۰	۲۸/۷۶
۴	B100	۰/۷۱۹۷	۲۷/۰۵۸	۰/۶۷۲۲	۲۶/۰۵۱	۰/۷۴۰۵	۲۷/۶۸
۴	Urban100	۰/۷۳۹۳	۲۴/۷۸۱	۰/۶۶۱۶	۲۳/۲۴۰	۰/۷۹۷۱	۲۶/۳۹
۴	Manga109	۰/۸۶۹۷	۲۸/۱۶۸	۰/۷۹۰۶	۲۵/۰۷۲	۰/۹۱۴۲	۳۰/۹۳

شکل ۵.۴: مقایسه جدول را به صورت بصری خلاصه می‌کند. در همه مجموعه‌ها و هر سه مقیاس، خروجی نهایی STSN از درونیایی دومکعبی PSNR بالاتری دارد.



شکل ۵.۴: مقایسه PSNR خروجی نهایی STSN پس از شروع گرم با خط پایه دومکعبی روی پنج مجموعه معیار. هر پنل یک ضریب بزرگ‌نمایی را نشان می‌دهد.

در همه ۱۵ حالت، مدل آموزش دیده از درون‌یابی دومکعبی بهتر است. بیشترین بهبود در Manga109 رخ داد: ۵/۶۱۵، ۴/۰۷۱ و ۳/۰۹۶ دسی‌بل برای مقیاس‌های ۲، ۳ و ۴. این رفتار با ماهیت این مجموعه سازگار است، زیرا خطوط و بافت‌های تکراری تصویرهای کمیک از یادگیری ساختاری بیش از هموارسازی ثابت سود می‌برند. کمترین بهبود مربوط به B100 بود، ولی حتی آن‌جا نیز برای هر سه مقیاس بیش از یک دسی‌بل افزایش به دست آمد.

۱.۵.۴ تحلیل مجموعه به مجموعه

در Set5 که کوچک‌ترین و معمولاً ساده‌ترین معیار است، خروجی نهایی به ترتیب ۳۷/۱۶۳، ۳۳/۱۷۹ و ۳۰/۷۷۹ دسی‌بل شد. SSIM نیز از ۰/۹۵۷۵ در مقیاس دو به ۰/۸۷۲۲ در مقیاس چهار کاهش یافت. این افت با افزایش ضریب بزرگ‌نمایی طبیعی است، زیرا در مقیاس چهار تعداد بیشتری از جزئیات باید از ورودی کوچک‌تر تخمین زده شوند.

در Set14 تنوع محتوایی بیشتر است و نتیجه سه مقیاس به ۳۲/۸۲۶، ۲۹/۴۶۶ و ۲۷/۷۲۳ دسی‌بل رسید. بهبود نسبت به دومکعبی بین ۱/۵۱۳ تا ۲/۲۸۳ دسی‌بل بود؛ بنابراین شبکه فقط روی مجموعه کوچک Set5 بهتر نشده و روی تصاویر متنوع‌تر نیز مزیت پایدار دارد.

در B100 کمترین افزایش PSNR نسبت به دومکعبی، یعنی ۱/۹۴۲، ۱/۲۵۱ و ۱/۰۰۷ دسی‌بل، دیده شد. این مجموعه بیشتر شامل تصاویر طبیعی است و بافت‌های نامنظم آن نسبت به خطوط تکراری شهری و کمیک، سود کمتری از بازسازی ساختاری شبکه می‌برند. در عوض فاصله ما با مقاله در همین مجموعه از همه کمتر بود: ۰/۶۱۵، ۰/۶۵۰ و ۰/۶۲۲ دسی‌بل.

در Urban100 شروع گرم نقش مهم‌تری داشت و برای مقیاس‌های ۲، ۳ و ۴ به ترتیب ۰/۶۷۵، ۰/۷۱۶ و ۰/۴۵۸ دسی‌بل افزود. خروجی نهایی ۳۰/۳۴۳، ۲۶/۶۵۵ و ۲۴/۷۸۱ دسی‌بل بود. خطوط نما، پنجره‌ها و الگوهای تکراری ساختمان‌ها با میدان دید ۱۱ در ۱۱ پیمانه‌سازی و توجه فضایی معماری سازگارند، ولی فاصله باقی‌مانده با مقاله نشان می‌دهد یادگیری همین جزئیات به آموزش طولانی‌تر حساس است.

در Manga109 هم PSNR و هم SSIM بیشترین سود را از مدل گرفتند. خروجی نهایی به ۳۶/۸۶۷/۰/۹۷۲۰، ۳۱/۲۶۹/۰/۹۲۳۶ و ۲۸/۱۶۸/۰/۸۶۹۷ رسید. افزایش شروع گرم در مقیاس‌های سه و چهار به ترتیب ۱/۴۰۸ و ۱/۰۹۲ دسی‌بل بود؛ این دو مقدار بزرگ‌ترین اثر شروع گرم در کل جدول‌اند. در نتیجه، آموزش دوم بیش از همه برای بازسازی خطوط باریک و بافت‌های منظم کمیک مؤثر بوده است.


جدول ۷.۴ دو مقایسه مهم را جدا می‌کند. ستون نخست نشان می‌دهد شروع گرم در همه حالت‌ها مفید بوده است.

ستون دوم فاصله خروجی نهایی با خط پایه را نشان می‌دهد. ستون سوم اختلاف با مقاله است؛ منفی بودن آن یعنی اجرای ۲۰۰ دوره‌ای ما هنوز به آموزش طولانی مقاله نرسیده است.

جدول ۷.۴: اختلاف PSNR خروجی نهایی بر حسب دسی‌بل؛ «مرحله اول» خروجی ۱۰۰ دوره‌ای پیش از شروع گرم است

مقیاس	مجموعه	نسبت به مرحله اول	نسبت به دومکعبی	نسبت به مقاله
۲	Set5	۰/۴۰۴+	۳/۲۰۳+	۱/۰۲۷-
۲	Set14	۰/۳۴۵+	۲/۲۸۳+	۰/۹۵۴-
۲	B100	۰/۲۹۸+	۱/۹۴۲+	۰/۶۱۵-
۲	Urban100	۰/۶۷۵+	۳/۲۷۱+	۲/۳۳۷-
۲	Manga109	۰/۷۹۲+	۵/۶۱۵+	۲/۲۶۳-
۳	Set5	۰/۷۱۳+	۲/۵۶۶+	۱/۴۴۱-
۳	Set14	۰/۳۵۱+	۱/۶۷۹+	۱/۰۷۴-
۳	B100	۰/۳۱۰+	۱/۲۵۱+	۰/۶۵۰-
۳	Urban100	۰/۷۱۶+	۲/۰۷۳+	۱/۹۳۵-
۳	Manga109	۱/۴۰۸+	۴/۰۷۱+	۲/۸۴۱-
۴	Set5	۰/۵۲۵+	۲/۱۷۷+	۱/۶۸۱-
۴	Set14	۰/۳۷۳+	۱/۵۱۳+	۱/۰۳۷-
۴	B100	۰/۲۶۵+	۱/۰۰۷+	۰/۶۲۲-
۴	Urban100	۰/۴۵۸+	۱/۵۴۰+	۱/۶۰۹-
۴	Manga109	۱/۰۹۲+	۳/۰۹۶+	۲/۷۶۲-

شکل ۶.۴: افزایش PSNR مرحله شروع گرم نسبت به مرحله نخست را برای همه ۱۵ حالت نشان می‌دهد. همه میله‌ها مثبت‌اند؛ بیشترین افزایش مربوط به Manga109 در مقیاس سه است.



شکل ۶.۴: افزایش PSNR بر اثر مرحله ۱۰۰ دوره‌ای شروع گرم نسبت به پایان مرحله نخست، برای هر مجموعه و مقیاس.

فاصله با مقاله روی B100 کمتر و روی مجموعه‌های ساختاری Urban100 و Manga109 بیشتر است. برداشت ما این است که بافت‌ها و وابستگی‌های پیچیده‌تر برای استفاده کامل از میدان دید بزرگ شبکه به تعداد به‌روزرسانی بیشتری

نیاز دارند. این یک استنباط از الگوی جدول است، نه آزمایش حذف مستقل. همچنین در مقیاس چهار، بهترین نقطه واریسی پایشی Set5 به $30/967$ دسی‌بل رسید، اما برای رعایت قاعده یکسان و پرهیز از انتخاب روی آزمون، مقدار پایان دوره یعنی $30/779$ گزارش شد.

۶.۴ زمان استنتاج و بررسی کیفی

جدول ۸.۴ میانگین زمان اجرای یک تصویر را روی همان کارت T4 نشان می‌دهد. زمان به اندازه و مقیاس تصویر وابسته است؛ از این رو مقایسه مستقیم اعداد مجموعه‌های متفاوت یا مقایسه با سخت‌افزار مقاله منصفانه نیست. الگوی کلی درست است: با بزرگ‌تر شدن ورودی کم‌وضوح، زمان افزایش می‌یابد و Manga109 و Urban100 سنگین‌ترین مجموعه‌ها هستند.

جدول ۸.۴: میانگین زمان استنتاج هر تصویر روی کارت Tesla T4، برحسب میلی‌ثانیه

مقیاس	Set5	Set14	B100	Urban100	Manga109
۲	۶۰/۵	۱۱۴/۶	۷۳/۰	۴۰۱/۴	۵۱۶/۷
۳	۳۰/۸	۶۰/۶	۳۹/۸	۱۸۲/۲	۲۲۷/۵
۴	۲۰/۶	۴۷/۰	۲۸/۵	۹۸/۰	۱۲۸/۴


۱.۶.۴ نمونه‌های کیفی در حالت‌های مختلف

برای اینکه بررسی بصری به یک تصویر شهری محدود نماند، هفت نمونه از پنج مجموعه و هر سه ضریب بزرگ‌نمایی در شکل‌های ۷.۴ تا ۱۳.۴ آورده‌ایم. هر چهار پنل مستقیماً از آرایه‌های ورودی، درونیایی، خروجی شبکه و مرجع ساخته شده‌اند و تصویر صفحه نیستند. این نمونه‌ها برای پوشش دادن چهره و بافت پارچه، بافت طبیعی، خطوط معماری، تصویر کمیک و بزرگ‌نمایی دشوار چهاربرابری انتخاب شده‌اند. همه تصاویر مقایسه‌ای تولیدشده، از جمله نمونه‌های دیگری که در متن جا نشده‌اند، در پوشه benchmarks اجرا موجودند.

جدول ۹.۴: سنج‌های عددی نمونه‌های کیفی نمایش داده‌شده؛ اعداد از ردیف همان تصویر در فایل‌های CSV گرفته شده‌اند

مقیاس	مجموعه	تصویر	PSNR مدل	SSIM مدل	PSNR دومکعبی	SSIM دومکعبی
۲	Set5	baby	۳۸/۶۷۵	۰/۹۶۶۴	۳۷/۲۳۶	۰/۹۵۴۹
۲	Set14	barbara	۲۸/۳۴۲	۰/۸۷۶۵	۲۸/۱۰۷	۰/۸۴۶۷
۲	Urban100	img_001	۳۱/۷۲۹	۰/۸۹۴۹	۲۸/۳۰۶	۰/۸۲۶۱
۳	B100	101085	۲۴/۷۹۳	۰/۶۵۲۳	۲۴/۰۴۱	۰/۵۹۰۷
۳	Manga109	ARMS	۲۹/۵۱۸	۰/۸۵۲۸	۲۷/۰۷۶	۰/۷۷۵۴
۴	Set5	bird	۳۳/۰۷۹	۰/۹۲۱۶	۳۰/۴۴۰	۰/۸۷۷۶
۴	Urban100	img_002	۲۵/۶۱۰	۰/۷۷۰۹	۲۴/۲۷۷	۰/۶۸۲۸

در نمونه baby، مدل بافت کلاه، مرز چشم‌ها و خطوط ظریف صورت را بدون ایجاد لبه شدید حفظ کرده و $1/439$ دسی‌بل از دومکعبی بهتر است. این تصویر نمونه‌ای از ناحیه‌های نرم همراه با چند بافت ریز است.




شکل ۷.۴: نمونه baby از Set5 در مقیاس دو پس از شروع گرم؛ از راست به چپ: مرجع پروضوح، STSN، دومکعبی و ورودی کم‌وضوح.

نمونه barbara به‌خاطر پارچه‌های راه‌راه و بافت‌های بسامد بالا دشوار است. افزایش PSNR فقط ۰/۲۳۴ دسی‌بل است، اما SSIM از ۰/۸۴۶۷ به ۰/۸۷۶۵ رسیده؛ یعنی بهبود ساختار محلی از کاهش خطای پیکسلی مشهودتر بوده است.



شکل ۸.۴: نمونه barbara از Set14 در مقیاس دو؛ بافت پارچه و خطوط ریز میز، تفاوت بازسازی ساختاری را آشکار می‌کنند. ترتیب پل‌ها از راست: مرجع، STSN، دومکعبی و ورودی است.

در شکل ۹.۴، تکرار پنجره‌ها و لبه‌های ساختمان نسبت به دومکعبی منظم‌تر شده و افزایش ۳/۴۲۳ دسی‌بلی با این تفاوت بصری سازگار است. با این حال، در جزئیات بسیار ریز هنوز اختلاف با مرجع دیده می‌شود.



شکل ۹.۴: مقایسه کیفی یک تصویر Urban100 در مقیاس دو پس از شروع گرم؛ از راست به چپ: مرجع پروضوح، خروجی STSN، درون‌یابی دومکعبی و ورودی کم‌وضوح. شکل خروجی مستقیم برنامه است.

نمونه 101085 از B100 بافت طبیعی و نامنظم دارد. در این‌جا افزایش PSNR برابر ۰/۷۵۲ دسی‌بل است، ولی SSIM حدود ۰/۰۶۲ افزایش یافته است. مدل مرز پیکره‌ها را واضح‌تر می‌کند، اما نبود الگوی تکراری منظم باعث می‌شود سود آن از نمونه‌های شهری و کمیک کمتر باشد.



شکل ۱۰.۴: نمونه 101085 از B100 در مقیاس سه؛ از راست به چپ: مرجع، STSN، دومکعبی و ورودی کم‌وضوح. این نمونه رفتار مدل روی بافت طبیعی نامنظم را نشان می‌دهد.

در تصویر ARMS خطوط باریک نقشه، نوشته‌ها و مرزهای ترسیمی فراوان‌اند. STSN نسبت به دومکعبی $2/442$ دسی‌بل و حدود $0/077$ SSIM بهتر است. این نتیجه با بهبود بالای میانگین Manga109 هم‌جهت است و نشان می‌دهد مدل در بازسازی ساختارهای خطی و تکرارشونده موفق‌تر است.




شکل ۱۱.۴: نمونه ARMS از Manga109 در مقیاس سه؛ خروجی STSN خطوط ترسیمی و نوشته‌های ریز را نسبت به دومکعبی واضح‌تر نگه می‌دارد.

برای نمایش دشواری مقیاس چهار، دو محتوای متفاوت انتخاب شد. در تصویر bird، مرز منقار و چشم و شاخه‌های باریک واضح‌تر شده‌اند و افزایش PSNR به $2/639$ دسی‌بل می‌رسد؛ با این حال، فاصله با مرجع هنوز بیشتر از نمونه‌های مقیاس دو است.



شکل ۱۲.۴: نمونه bird از Set5 در بزرگ‌نمایی چهاربرابری؛ این حالت اثر کاهش شدید اطلاعات ورودی بر مرزهای طبیعی را نشان می‌دهد. ترتیب پل‌ها از راست: مرجع، STSN، دومکعبی و ورودی است.

نمونه شهری مقیاس چهار شامل خط‌های مورب و منحنی‌های تکرارشونده سازه است. مدل $1/333$ دسی‌بل و حدود $SSIM \ 0.88$ بهتر از دو مکعبی عمل می‌کند و پیوستگی تیرها را بهتر نگه می‌دارد، ولی در بخش‌های بسیار متراکم بخشی از خطوط ظریف همچنان نرم می‌شوند.



شکل ۱۳.۴: نمونه img_002 از Urban100 در مقیاس چهار؛ خطوط مورب و قوس‌های تکراری سازه برای مقایسه بازسازی هندسی مناسب‌اند.

۷.۴ نسخه مسابقه NTIRE ۲۰۲۳

مقاله در بخش پایانی نسخه بزرگ‌تری را برای مسابقه NTIRE 2023 توضیح می‌دهد. در آن نسخه تعداد گروه‌ها ۵، تعداد بلوک هر گروه ۴، تعداد کانال ویژگی ۱۵۰ و کانال میانی توجه فضایی ۳۲ است. بازه RGB نیز به جای یک، ۲۵۵ در نظر گرفته شده است. آموزش اولیه با DIV2K و LSDIR، وصله ۱۹۲، دسته ۱۶ و ۷۰ دوره انجام شده؛ سپس شروع گرم ۴۵۰ دوره‌ای و در مرحله آخر آموزش ۲۰۰ دوره‌ای با DIV2K و Flickr2K و نرخ یادگیری 5×10^{-5} اجرا شده است. این تیم با PSNR برابر 30.78 و $SSIM$ برابر 0.8582 رتبه نهم جدول مقاله را به دست آورده است. کلاس مدل ما همین تغییر تعداد گروه، کانال و کانال توجه را می‌پذیرد، ولی وزن نسخه مسابقه به علت نبود مجموعه‌های آموزشی افزوده در محدوده این پروژه آموزش داده نشده است.

فصل ۵

تحلیل، محدودیت‌ها و بازتولیدپذیری

۱.۵ چرا تطبیق پارامتر برای ما مهم بود؟

فقط برابر بودن شکل خروجی برای اثبات بازپیاپی‌سازی معماری کافی نیست. برای مثال، تغییر کرنل عمقی از ۱۱ به ۷ همچنان خروجی با ابعاد درست می‌دهد ولی رفتار و ظرفیت مدل متفاوت می‌شود. تطبیق هفت عدد مستقل در جدول ۱.۳ قید قوی‌تری ایجاد می‌کند: سهم هر پیمانه‌سازی، پرسپترون، توجه فضایی، کانولوشن گروه و فرافکنی به‌طور جداگانه سنجیده شده است. به همین دلیل اطمینان داریم پیاده‌سازی از نظر ساختار پارامتری با مدل مقاله سازگار است.

۲.۵ محدودیت‌های مقایسه

سه محدودیت باید روشن باشد. نخست، مقاله وزن‌های آموزش‌دیده را منتشر نکرده و برخی جزئیات معماری در متن صریح نیستند؛ ما آن‌ها را از شمار پارامترها استنتاج و فرض‌ها را مستند کرده‌ایم. دوم، روش دقیق کاهش دوماکعبی در کتابخانه‌های مختلف اندکی تفاوت دارد. برای آموزش از جفت‌های رسمی DIV₂K و برای ارزیابی از جفت‌های آماده و بازنمونه‌برداری دوماکعبی متلب استفاده کردیم تا این اختلاف کم شود. سوم، کامل بودن داده به معنای برابر بودن بودجه بهینه‌سازی نیست: مقاله ۱۰۰۰ دوره و سپس بازآموزی را گزارش می‌کند، در حالی که مطابق محدودیت پروژه هر مرحله ما ۱۰۰ دوره بود. بنابراین اختلاف ستون آخر جدول ۷.۴ را به‌عنوان نتیجه بازپیاپی‌سازی ۲۰۰ دوره‌ای گزارش می‌کنیم، نه بازتولید کامل بودجه محاسباتی مقاله.

۳.۵ روش اجرای پروژه

پس از نصب وابستگی‌های فایل requirements.txt، دستور زیر مسیر کوچک و سریع را برای کنترل سلامت پیاده‌سازی انجام می‌دهد:

```
python scripts/main.py --quick
```

برای بررسی عددی معماری می‌توان نوشت:


```
python scripts/ablation.py
python -m unittest discover -s tests -v
```

برای تکرار آزمایش گزارش شده روی هر سه مقیاس، پس از قرار دادن جفت‌های DIV₂K و مجموعه‌های معیار در مسیرهای نسبی پیکربندی، دستور زیر هر دو مرحله ۱۰۰ دوره‌ای را اجرا می‌کند:

```
python scripts/run_full_experiment.py --epochs 100
```

خروجی‌ها شامل بهترین و آخرین نقطه واریسی هر مرحله، تاریخچه JSON، جدول CSV هر تصویر، نمودار آموزش، مقایسه کیفی و جدول تجمیعی پنج مجموعه هستند. بذر تصادفی پیش‌فرض ۸۱۰۱۰۴۰۳۹ است. آزمون‌های خودکار سه مورد را بررسی کردند: برابری پارامترهای هفت گونه مدل، شکل خروجی همه ضرایب مقیاس و هم‌ترازی وصله‌های LR/HR؛ هر سه آزمون موفق بودند. اسکریپت collect_kaggle_results.py نیز کامل بودن شش اجرا را کنترل و جدول‌های گزارش را از فایل‌های خام تولید می‌کند.

۴.۵ منابع کد و داده بیرونی

بخش اصلی مدل، حلقه آموزش، سنج‌ها و شکل‌ها در این پروژه نوشته شده‌اند و کد آماده‌ای از اینترنت در آن‌ها کپی نشده است. برای فهم عملکرد مبنا، مقاله و مخزن رسمی Conv₂Former بررسی شدند [۲، ۹]. تصاویر DIV₂K از نسخه‌های آینه‌ای داده رسمی در کگل و مجموعه‌های آزمون از منابع معرفی شده در کد دریافت شدند؛ فایل‌های کم‌وضوح سه مجموعه نیز با اسکریپت متلب همراه پروژه ساخته شدند. نشانی دریافت Set5 داخل download_set5.py و در منبع [۱۰] آمده است. همه تصاویر گزارش خروجی مستقیم کد یا نمودار ترسیم‌شده از تاریخچه عددی‌اند و هیچ تصویر صفحه‌ای در گزارش استفاده نشده است.

فصل ۶

نتیجه‌گیری

در این پروژه کل روش STSN را از مرحله داده تا گزارش نتیجه بازپیاپی‌سازی کردیم. ایده مهم روش این است که می‌توان ساختار مانده و پیش‌نرمال‌سازی ترنسفورمر را نگه داشت، ولی خودتوجهی درجه دوم را با پیمانه‌سازی کانولوشنی خطی جایگزین کرد. کانولوشن 3×3 پایانی ویژگی محلی، کرنل عمقی ۱۱ میدان دید، پرسپترون اختلاط کانال و توجه فضایی انتخاب مکان‌های مهم را بر عهده دارند.

قوی‌ترین راستی‌آزمایی ساختاری ما برابری دقیق شمار پارامتر مدل کامل و همه گونه‌های حذف مؤلفه با مقاله بود. راستی‌آزمایی تجربی نیز روی کل ۸۰۰ تصویر، DIV2K، سه مقیاس و همه تصاویر پنج مجموعه معیار انجام شد. مدل نهایی در هر ۱۵ حالت از دومکعبی بهتر بود و شروع گرم نیز در هر ۱۵ حالت نسبت به مرحله نخست PSNR را افزایش داد. بهترین بهبود نسبت به دومکعبی ۵/۶۱۵ دسی‌بل روی Manga109 در مقیاس دو بود. با وجود این، نتیجه هنوز در همه حالت‌ها پایین‌تر از مقاله است؛ اختلاف ۰/۶۱۵ تا ۲/۸۴۱ دسی‌بل با کاهش بودجه از آموزش ۱۰۰۰ دوره‌ای و بازآموزی مقاله به دو مرحله ۱۰۰ دوره‌ای ما سازگار است. کد و داده ذخیره‌شده امکان ادامه تا بودجه مقاله را بدون تغییر معماری فراهم می‌کنند.

- [1] G. Gendy, N. Sabor, J. Hou, and G. He, “A Simple Transformer-Style Network for Lightweight Image Super-Resolution,” in *CVPR Workshops*, pp. 1484–1494, 2023.
- [2] Q. Hou, C.-Z. Lu, M.-M. Cheng, and J. Feng, “Conv2Former: A Simple Transformer-Style ConvNet for Visual Recognition,” arXiv:2211.11943, 2022.
- [3] J. Liu, W. Zhang, Y. Tang, J. Tang, and G. Wu, “Residual Feature Aggregation Network for Image Super-Resolution,” in *CVPR*, pp. 2359–2368, 2020.
- [4] E. Agustsson and R. Timofte, “NTIRE 2017 Challenge on Single Image Super-Resolution: Dataset and Study,” in *CVPR Workshops*, pp. 126–135, 2017.
- [5] M. Bevilacqua, A. Roumy, C. Guillemot, and M.-L. Alberi-Morel, “Low-Complexity Single-Image Super-Resolution Based on Nonnegative Neighbor Embedding,” in *BMVC*, 2012.
- [6] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, “Image Quality Assessment: From Error Visibility to Structural Similarity,” *IEEE Transactions on Image Processing*, vol. 13, no. 4, pp. 600–612, 2004.
- [7] D. P. Kingma and J. Ba, “Adam: A Method for Stochastic Optimization,” arXiv:1412.6980, 2014.
- [8] W. Shi et al., “Real-Time Single Image and Video Super-Resolution Using an Efficient Sub-Pixel Convolutional Neural Network,” in *CVPR*, pp. 1874–1883, 2016.
- [9] HVision-NKU, “Official PyTorch Implementation of Conv2Former,” <https://github.com/HVision-NKU/Conv2Former>, accessed August 2026.
- [10] E. Siow, “Set5 Dataset Card and Image Archives,” <https://huggingface.co/datasets/eugenesiow/Set5>, accessed August 2026.