



بهار ۱۴۰۵

پردازش زبان‌های طبیعی

میانترم

مرتضی ملکی‌نژاد شوشتری - ۸۱۰۱۰۴۲۵۶

۱ سوالات اسلایدها

۱.۱ Tokenization

سوال ۱

دو روش tokenization نام ببرید که در یکی از آن‌ها تعداد توکن‌ها کم باشد و در دیگری زیاد باشد. هرکدام از این موارد چه مزایا و معایبی دارند؟

سوال ۲

استفاده از tokenization در سطح زیرکلمه چه فایده‌ای دارد؟ چالش‌های آن چیست و یکی از ایده‌های کلی برای حل این چالش را مختصر توضیح دهید.

۲.۱ Text Classification and Naive Bayes

سوال ۳

در چه صورتی Naive Bayes Bag of Words classification برابر با Bayes classifier بهینه می‌شود؟

سوال ۴

استفاده از laplace smoothing چه فایده‌ای دارد؟ آیا در دقت مدل تأثیر می‌گذارد؟

۳.۱ Sentiment Analysis

سوال ۵

پردازش زبان طبیعی چالش‌های مخصوصی مثل ابهام و یا درگیر زمینه (Context) بودن را دارد. در تسک تحلیل احساسات کدام موارد نقش پررنگ‌تری بازی می‌کنند؟

سوال ۶

تفاوت Binarized Multinomial Naive Bayes و Multivariate Bernoulli Naive Bayes در چیست؟

۴.۱ Logistic Regression

سوال ۷

تفاوت مدل‌های Discriminative و Generative در چیست؟ چرا گفته می‌شود Naive Bayes یک مدل Generative است ولی Logistic Regression یک مدل Discriminative است؟

سوال ۸

چرا گفته می‌شود Logistic Regression یک مدل تفسیرپذیر است؟ این تفسیرپذیری چه اهمیتی دارد؟

۵.۱ Word Embedding

سوال ۹

چگونه با تصویرسازی^۱ یک embedding می‌توان سوگیری‌های^۲ جامعه را یافت؟

سوال ۱۰

با افزایش طول پنجره در Word2vec چه تغییری در همسایه‌های یافت‌شده پیدا می‌شود؟

۶.۱ Neural Networks

سوال ۱۱

چرا عمق بیشتر یک شبکه عصبی، معمولاً تأثیر مشهودتری دارد تا اضافه کردن تعداد نوروں به یک لایه؟

سوال ۱۲

توضیح دهید CNN و RNN هرکدام به چه صورت سعی در بهبود شبکه عصبی دارند؟

۷.۱ Language Model

سوال ۱۳

توضیح دهید فرض مارکوف در مدل N-Gram چه کمکی به حل مسئله می‌کند؟

سوال ۱۴

چرا تفاوت دقت هنگام استفاده از bigram نسبت به unigram بیشتر از وقتی است که به جای trigram از bigram استفاده می‌کنیم؟ آیا افزایش طول پنجره همواره موجب بهبود دقت می‌شود؟

۸.۱ Large Language Model

سوال ۱۵

برای هرکدام از معماری‌های مدل‌های زبانی بزرگ یک مثال کاربردی بزنید و توضیح دهید که چرا در این تسک، این معماری مناسب‌تر است؟

^۱ Visualize

^۲ Bias

سوال ۱۶

توضیح دهید که چرا موقع نمونه‌برداری برای توکن خروجی همواره بهترین نتیجه انتخاب نمی‌شود؟ و trade-off این قضیه به چه صورت است؟

۲ سوالات ترکیبی

سوال ۱۷

به نظر شما هریک از معماری‌های مدل‌های زبانی بزرگ از مدل‌های Generative هستند یا Discriminative؟ توضیح دهید.

سوال ۱۸

اگر در tokenization از روشی استفاده شود که منجر به این شود که هر توکن لزوماً یک بخش معنادار نباشد (مثلاً استفاده از character tokenization)، در لایه embedding چه مسئله‌ای پیش می‌آید؟ آیا ممکن است یک لایه embedding مناسب بتواند این مسئله را حل کند؟

سوال ۱۹

به نظر شما اگر یک مدل N-Gram و یک مدل Multivariate Naive Bayes داشته باشیم، در تسک پردازش احساسات کدام یک نتیجه بهتری می‌دهند؟ (نکته مهم استدلال شماست نه لزوماً انتخاب مدل.)

سوال ۲۰

اگر در یک مدل زبانی بزرگ، temperature را کاهش دهیم، برای perplexity چه اتفاقی می‌افتد؟ توضیح دهید.

۳ پاسخ و بارم‌بندی سوالات

سوال ۱

راه‌حل

برای یک tokenization با تعداد توکن کم می‌توان به character tokenization و برای یک tokenization با تعداد توکن زیاد می‌توان به word tokenization اشاره کرد. اگر تعداد type های توکن کم باشد، منجر به این می‌شود که احتمالاً توکن‌های پایه‌تری موجود است و توکن ناشناس پیدا نمی‌شود؛ ولی باعث می‌شود که خروجی فرآیند tokenization تعداد زیادی توکن باشد که فرآیند آموزش و استنتاج مدل را کند می‌کند. از طرف دیگر اگر تعداد type ها زیاد باشد، احتمال دیدن توکن ناشناس بیشتر است؛ برای مثال اگر مدل کلمات drive, driver, teach را دیده باشد ولی کلمه teacher را ندیده باشد، نمی‌تواند توکن مناسب برای کلمه teacher را بیابد.

بارم‌بندی

جدول ۱: بارم‌بندی سوال ۱

درصد نمره	نام بخش
۳۰	بیان نمونه روش‌های tokenization با تعداد توکن کم و زیاد
۲۵	بیان مشکلات تعداد type توکن کم
۱۰	بیان مزایای تعداد type توکن کم
۲۵	بیان مشکلات تعداد type توکن زیاد
۱۰	بیان مزایای تعداد type توکن زیاد

علت

به‌نظرم، این سوال چکیده بخش اول را شامل می‌شود. تعداد توکن چه تاثیری دارد؟ و چه نیازی بود که به سمت tokenization در سطح زیر کلمه برویم؟ هم من باب معنا و تاثیر tokenization در دقت مدل؛ هم من باب پایدار بودن و کارکرد^۳ مدل.

سوال ۳

راه‌حل

در طبقه‌بند Bag of Words Naive Bayes دو فرض اساسی موجود است که اگر این دو فرض درست باشند، این طبقه‌بند همان طبقه‌بند بهینه Bayes می‌شود.

فرض اول در Bag of Words است که بیان می‌کند ترتیب کلمات اثری روی کلاس آن ندارد.

فرض دوم در قسمت Naive Bayes است که بیان می‌کند پدیدار شدن یک کلمه روی پدیدار شدن سایر کلمات اثری نخواهد داشت.

در عمل این دو فرض تقریباً هیچ‌وقت محقق نمی‌شوند. به عنوان شهود می‌توان دید که استفاده از bigram در مدل‌های N-gram بهبود خیلی زیادی نسبت به مدل unigram دارد؛ پس فرض استقلال کلمات فرض دقیقی نیست.

^۳performance

جدول ۲: بarmبندی سوال ۳

نام بخش	درصد نمره
بیان فرض عدم اهمیت ترتیب	۴۵
بیان فرض استقلال کلمات	۴۵
توضیح عملی بودن فرضها	۱۰

علت

این سوال ضعفهای اساسی مدل را بررسی می کند که چرا علیرغم وجود یک مدل به این سادگی، از مدل های زبانی بزرگ مبتنی بر شبکه عصبی استفاده می شود که بسیار پیچیده تر هستند. همچنان استفاده از مدل Naive Bayes می تواند توجیه خود را داشته باشد ولی باید حواسمان به این دو فرض باشد.

سوال ۴

راه حل

استفاده از Laplace smoothing تأثیر چندانی در دقت مدل ندارد؛ زیرا باعث نمی شود ترتیب احتمال کلاس ها تغییر کند. مزیت اصلی استفاده از Laplace smoothing پایدارتر شدن مدل است تا وقتی یک N-gram را نمی تواند پیدا کند، همچنان بتواند خروجی تولید کند. اما اکثر اوقات استفاده از روش های دیگری مثل backoff و یا ترکیب سایر N-gram ها با context کوچک تر نتیجه بهتری می دهد.

بارمبندی

جدول ۳: بarmبندی سوال ۴

نام بخش	درصد نمره
بیان تأثیر Laplace smoothing در دقت مدل	۵۰
بیان فایده Laplace smoothing	۵۰

علت

یکی از سوال هایی که موقع تدریس این بخش برای من پیش آمده بود، این بود که Laplace smoothing تقریباً هیچ تأثیری در دقت ندارد. و چرا این کار را انجام می دهیم (به جای مثلاً یک error handling ساده موقع یافتن n gram ها). ولی با نگاه دقیق تر می توان دید که این یک راه ساده برای وقتی است که ما از دقت مدل راضی هستیم و فقط می خواهیم پایداری داشته باشیم.

سوال ۵

راه حل

تسک پردازش احساسات در ظاهر یک طبقه بندی متن معمولی است، اما برخی چالش ها در آن برجسته تر هستند:

- ◇ **کنایه:** یکی از چالش‌ها، کنایه و ابهام است. در تحلیل احساسات (مثلاً در کامنت‌های فیلم)، افراد ممکن است با تضاد نظر خود را بیان کنند (مثلاً: «این هم یکی از آن فیلم‌های شاهکاری بود که بعدش می‌خواهید پولتان را پس بگیرید!»).
- ◇ **ابهام تسک:** در بسیاری از موارد خودِ نظر فرد متناقض است و واضح نیست که برآیند نهایی مثبت است یا منفی.
- ◇ **زمینه (Context):** در نظرات احساسی گاهی زمینه‌های بلندتری موجود است که استفاده از روش‌هایی با پنجره کوتاه مثل 5-gram را بی‌اثر می‌سازد.

علت

به نظرم مهم‌ترین بخش این اسلاید، راه‌های ارائه شده برای تسک طبقه‌بندی احساسات نیستند (چرا که احتمالاً یک مدل زبانی مبتنی بر هوش مصنوعی از راه‌های ارائه شده دقت بالاتری بدهد). بلکه توضیح تسک و نمونه جملاتی هستند که در اسلاید آمده است. برای بررسی تسک، بهترین راه نیز بررسی ورودی و خروجی است که برای مثال Negation چه چالش جدیدی بیان می‌کند؟ و مهم دسته‌بندی این چالش‌ها است (نسبت به حفظ راه ارائه شده)

سوال ۶

راه‌حل

در طبقه‌بند Bernoulli عملاً دو مقدار p و $1 - p$ برای حضور یا عدم حضور هر متغیر بررسی می‌شود. ولی در Multinomial تعداد تکرار متغیرها اهمیت دارد (در حالت Binarized تکرار با عدد یک سقف‌گذاری می‌شود). این تفاوت بیشتر مفهومی است و در عمل نتایج طبقه‌بندی بسیار نزدیک است.

علت

این عبارت که این دو طبقه‌بند یکی نیستند و باهم تفاوت دارند برای من سوال شد و جستجو کردم تا به جواب برسم. این که علیرغم شباهت ریاضیاتی، مفهوم این دو توزیع متفاوت است به نظرم نکته مهمی آمد. که حتی در Binary Multivariate normal علیرغم clip کردن، همچنان دید ما به متغیر مفهوم «تکرار» است نه «شکست» و یا «موفقیت».

سوال ۷

راه‌حل

در مدل‌های Generative مدل به دنبال یادگیری توزیع احتمال مشترک $P(x, y)$ است و موقع استنتاج likelihood را حساب می‌کند. مانند Naive Bayes که توزیع هر کلاس را تخمین زده و با MLE پیش‌بینی می‌کند. در مدل‌های Discriminative مدل مستقیماً به دنبال یادگیری مرزهای تصمیم یا $P(y|x)$ است. مانند Logistic Regression که پارامترهای خط جداکننده را یاد می‌گیرد.

علت

این سوال درواقع ذات مدل‌ها را بررسی می‌کند. که مزیت و عیب هر کدام از روش‌ها چیست. برای من برای اولین بار در ذهنم این سوگیری وجود داشت که مدل‌های قوی توزیع را یاد می‌گیرند و generative هستند و مدل‌های ضعیف‌تر discriminative. ولی می‌بینیم که یک مدل خیلی ساده مثل naive bayes نیز می‌تواند generative باشد و اصل تفاوت در رویکرد است نه پیچیدگی.

سوال ۸

راه حل

چون در Logistic Regression خروجی حاصل یک ترکیب خطی از ویژگی‌هاست، وزن اختصاص داده شده به هر ویژگی نشان‌دهنده میزان اهمیت و تأثیر آن در کلاسیک است. این موضوع به ما اجازه می‌دهد سوگیری‌های مدل (مثلاً نسبت به جنسیت یا نژاد) را شناسایی و رفع کنیم.

علت

مفهوم logistic regression را در سایر درس‌ها مثل ML داشتیم. لذا به ذهنم آمد به جای یک سوال تکراری از شیوه کار Logistic regression یک سوال کمی مفهومی‌تر از مزایای آن نسبت به یک مدل پیچیده‌تر بپرسم.

سوال ۹

راه حل

چون embedding یک تصویرسازی از کلمات به ما می‌دهد، می‌توان روابط را بررسی کرد. مثلاً نسبت بین دکتر و مرد را به نسبت پرستار تطبیق داد و دید به «زن» می‌رسیم یا نه.

بارم‌بندی

توضیح نمره کامل را دارد.

علت

این بخش از محدود جاهایی است که embedding به خودی خود خروجی می‌دهد و به عنوان بخشی از یک مدل بزرگ‌تر در نظر گرفته نمی‌شود. و این موضوع برای من جالب بود.

سوال ۱۸

راه حل

ایده کلی Embedding این است که توکن‌هایی با بافت مشابه، بردارهای مشابهی بگیرند. اگر در tokenization واحدهای معنادار جدا نشوند (مثلاً در سطح کاراکتر)، رابطه معنادار بین توکن‌ها ضعیف شده و لایه embedding رفتاری نزدیک به تصادفی پیدا می‌کند. اگرچه لایه embedding با پنجره بزرگ‌تر می‌تواند برخی ترکیبات (مانند morpheme‌هایی مثل er) را یاد بگیرد، اما این کار نسبت به انجام آن در سطح توکن‌ساز پرهزینه‌تر و کم‌بازده‌تر است.

علت

هنگامی که من برای اولین بار با مفاهیم tokenization و embedding آشنا می‌شدم، تفاوت اصلی این دو لایه را متوجه نمی‌شدم. از نظر من وظیفه هر دو این لایه‌ها تبدیل ورودی به یک‌سری از اعداد بود. ولی با دید یکم عمیق‌تر، وظیفه tokenizer شکستن کلمه است و وظیفه embedder پیوند دادن کلمه به زمینه اطراف آن. پس این که آیا embedding که یک لایه به نسبت پیچیده‌تر است می‌تواند با tokenization بد به کار خود ادامه دهد سوال جالبی به ذهنم آمد.

سوال ۲۰

راه حل

کاهش temperature باعث می شود مدل به گزینه های با احتمال بالا وزن بیشتری بدهد، که منجر به افزایش قطعیت و کاهش weighted branching factor می شود. از آنجا که perplexity معادل با همان weighted branching factor است، کاهش temperature باعث کاهش مقدار perplexity می شود.

بارم بندی

جدول ۴: بarm بندی سوال ۲۰

درصد نمره	نام بخش
۳۰	توضیح رابطه temperature با قطعیت مدل و Logistic Regression branching factor
۳۰	توضیح نسبت perplexity با branching factor
۴۰	جمع بندی

علت

این که مفهوم perplexity که در بخش n gram مطرح شد و از شاخص های بررسی دقت مدل است می تواند از یک هایپر پارامتر temperature که بیشتر جنبه خوشایند کردن محصول را دارد تا بالا آوردن دقت تاثیر بپذیرد برایم جالب به نظر آمد.

۴ سوال های باز

سوال ۱

در دنیای امروز، تقریباً بزرگ ترین مدل ها مدل های decoder ای هستند. به طوری که حتی در وظایفی که انتظار می رفت مدلی بر پایه encoder decoder باشد، مثل ترجمه نیز مدل های decoder با استفاده از پرامپت مناسب می توانند دقت مناسبی بدهند که این امر بخاطر داده زیاد آموزش آنها و این واقعیت است که این مدل ها بصورت self supervised آموزش می بینند.

ولی در حجم داده کمتر، مدل های encoder decoder عملکرد بهتری برای ترجمه دارند. آیا می توان حجم عظیمی از داده (در اردر حجم داده آموزش decoder ها به سایر معماری ها داد؟ آیا اصلاً این کار فایده ای خواهد داشت یا در نهایت به همان دقت مدل های decoder می رسید؟)

سوال ۲

آیا برای افزایش توضیح پذیری مدل های زبانی بزرگ، می توان چند مدل متفاوت که هر کدام روی یک داده تخصصی آموزش دیده اند را در نظر گرفت و سپس با استفاده از یک لایه logistic regression جواب مناسب را در نظر گرفت؟ (این کار به احتمال انجام شده است.)

در ادامه با ورودی دادن متن ابتدا به یک مدل encoder و سپس به این لایه logistic نمی توان پنجره ای به نحوه کار مدل یافت؟ در واقع فقط می تواند مدل های متخصص نباشد. حتی یک مدل باشد که با system prompt های متفاوتی بالا آمده است.