

دانشگاه تهران
پردیس دانشکده‌های فنی

دانشکده مهندسی برق و کامپیوتر

تمرین شماره: ۱
هوش مصنوعی قابل اعتماد

نام و نام خانوادگی: مرتضی ملکی‌نژاد شوشتری
شماره دانشجویی: ۸۱۰۱۰۴۲۵۶

نیم‌سال دوم سال تحصیلی ۴۰۴-۴۰۵

فهرست مطالب

۵	۱ تعمیم پذیری
۵	۱.۱ سوالات توضیحی
۵	۱.۱.۱ مفهوم همبستگی کاذب و شکست ERM
۵	۲.۱.۱ فرموله سازی خطای بدترین گروه و گروه های داده
۶	۳.۱.۱ نقش تابع زیان GCE
۷	۴.۱.۱ بررسی فرض اول مقاله
۷	۵.۱.۱ ایده الگوریتم JTT
۸	۲.۱ سوالات پیاده سازی
۸	۱.۲.۱ آماده سازی داده و مصور سازی
۸	۲.۲.۱ آموزش مدل پایه با ERM
۸	۳.۲.۱ استخراج مجموعه خطا (ERROR SET)
۹	۴.۲.۱ ساخت دیتاست وزن دار UPSAMPLING
۹	۵.۲.۱ آموزش مجدد مدل
۱۰	۶.۲.۱ پیاده سازی تابع زیان GCE
۱۲	۲ حملات خصمانه
۱۲	۱.۲ مرور مفاهیم
۱۲	۱.۱.۲ دسته بندی روش های حمله متخاصم
۱۲	۲.۱.۲ اهمیت حملات جعبه سیاه
۱۳	۳.۱.۲ حملات هدف دار و غیر هدف دار
۱۳	۲.۲ حمله جعبه سیاه

۱۳	آسیب‌پذیری نسبت به حمله جعبه سفید	۱.۲.۲
۱۳	روش حمله SimBA	۲.۲.۲
۱۴	تفاوت SimBA و SimBA-DCT	۳.۲.۲
۱۴	حملات امتیازمحور و حملات مبتنی بر پرچسب	۴.۲.۲
۱۴	معیارهای ارزیابی	۵.۲.۲
۱۵	حملات جعبه سفید	۳.۲
۱۵	مدل و مجموعه داده	۱.۳.۲
۱۵	FGSM	۲.۳.۲
۱۶	PGD	۳.۳.۲

فهرست تصاویر

۸	۱.۱ نمونه داده‌ها پس از تغییرات گفته شده
۸	۲.۱ نمودار خطا و دقت برای مجموعه‌های آموزش و آزمون روی مدل پایه
۹	۳.۱ نمونه موارد خطای مدل پایه روی داده آموزش
۹	۴.۱ نمودارهای خطا و آموزش هنگام آموزش مجدد مدل روی داده‌های upsample شده
۱۰	۵.۱ نمودارهای خطا و آموزش هنگام آموزش مدل پایه با استفاده از تابع ضرر GCE
۱۰	۶.۱ نمودارهای خطا و آموزش هنگام آموزش مدل upsample شده با استفاده از تابع ضرر GCE
	۱.۲ نمایش ۴ مورد از نمونه عکس اصلی، عکس دستکاری شده و نمایش بردار δ در FGSM.
	مقادیر دلتا از -0.03 تا 0.03 بوده و برای آنکه خروجی قابل تفسیری بدهد به صفر تا
۱۶	یک مقیاس شده است.
	۲.۲ نمایش ۴ مورد از نمونه عکس اصلی، عکس دستکاری شده و نمایش بردار δ در PGD.
	مقادیر دلتا از -0.03 تا 0.03 بوده و برای آنکه خروجی قابل تفسیری بدهد به صفر تا
۱۷	یک مقیاس شده است.

فهرست جداول

۱۱	۱.۱	مقایسه خطا و دقت نهایی مدل‌ها
۱۸	۱.۲	میانگین فاصله l_2 در عکس‌های تولیدی

سوال ۱

تعمیم پذیری

۱.۱ سوالات توضیحی

۱.۱.۱ مفهوم همبستگی کاذب و شکست ERM

در بسیاری از الگوریتم‌های مرسوم یادگیری ماشین، تلاش برای کمینه کردن ریسک تجربی^۱ است. از آنجایی که صرف ریسک تجربی مطرح است، ممکن است مدل شروع به یادگیری ویژگی‌های کاذب بکند. این ویژگی‌ها که در داده آموزشی موجود هستند باعث می‌شود تا دقت مدل روی آن‌ها بهبود یابد، ولی از آنجایی که در داده‌های واقعی این ویژگی‌های کاذب وجود ندارند باعث می‌شود تا دقت مدل کاهش یابد.

به عبارت دیگر مدل با یادگیری این ویژگی‌های کاذب دچار بیش‌برازش می‌شود و دیگر به سراغ یادگیری ویژگی‌های اصلی نمی‌رود.

۲.۱.۱ فرموله سازی خطای بدترین گروه و گروه های داده

پژوهش‌هایی که برای کاهش سوگیری انجام شده‌اند را می‌توان به دو دسته کلی تقسیم کرد. در دسته اول، ویژگی‌ای که سوگیری را اضافه می‌کند معلوم است. (برای مثال، نمونه عکسی که دسته‌بندی حیوانات را با توجه به پس‌زمینه انجام می‌داد و در مقاله آمده است.) و در دسته دوم این ویژگی‌ها نامعلوم است.

¹Empirical risk

اگر این ویژگی‌ها معلوم نباشند، باید به داده‌ها مراجعه کرد. ویژگی‌های کاذب در بعضی نمونه‌های ورودی بیشتر است. نمونه‌هایی که ویژگی‌های کاذب در آن‌ها بیشتر است، نمونه‌های هم‌راستا با بایاس^۲ و نمونه‌هایی که ویژگی‌های کاذب ندارند یا در آن‌ها کمتر است را نمونه‌های در تضاد^۳ با بایاس نامیده می‌شوند.

هدفی که برای مدل تعیین می‌شود این است که مدل روی هر دو این گروه‌ها عملکرد خوبی داشته باشد. مدل‌هایی که دچار سوگیری می‌شوند عملکرد خیلی خوبی روی گروه‌های هم‌راستا با بایاس دارند ولی در گروه‌های در تضاد با بایاس عملکرد ضعیفی خواهند داشت. به همین منظور، هدفی که تعیین می‌شود به این صورت است که مدل باید به شیوه‌ای تنظیم شود که بیشینه خطا در بین گروه‌ها کمینه شود. یعنی اگر مدلی بسیار دچار سوگیری شود، خطای مدل روی گروه‌های در تضاد با بایاس حساب می‌شود.

$$\min_{\theta} \max_{b \in \mathcal{B}} \left\{ \hat{\mathcal{L}}_b := \frac{1}{n_b} \sum_{(x,y) \in G_b} \ell(f_{\theta}(x), y) \right\}, \quad (1.1)$$

۳.۱.۱ نقش تابع زیان GCE

در روش پیشنهادی مقاله، در ابتدا برای اینکه نمونه‌های هم‌راستا با بایاس و در تضاد با بایاس شناسایی شوند، ابتدا یک مدل با سوگیری باید آموزش داده شود تا از عملکرد آن روی داده‌ها بتوان تشخیص داد کدام نمونه‌ها دارای ویژگی‌های کاذب هستند.

هرچقدر این مدل دارای سوگیری بیشتری باشد، ویژگی‌های کاذب بیشتری شناسایی می‌شوند. پس برای تقویت این موضوع، می‌توان میزان مشتق را برای نمونه‌هایی که مدل درست پیش‌بینی می‌کند بیشتر در نظر گرفت. به این صورت، مدل سعی می‌کند بیشتر بر روی ویژگی‌های کاذب تکیه کند. زیرا وقتی مقدار مشتق کم باشد، در مرحله بهینه‌سازی، وزن‌ها به مقدار کمی تغییر می‌کنند و با اجرای یک دور آموزش روی همه نمونه‌ها میزان یادگیری مدل برآیندی از ویژگی‌های همه نمونه‌ها خواهد بود ولی در این‌جا مدل بر روی ویژگی‌های خاصی که در بعضی نمونه‌ها وجود دارد تکیه می‌کند.

برای این‌که مشتق پیش‌بینی‌های درست بیشتر شود از خطای GCE استفاده می‌شود که فرمول آن در (۲.۱) آمده است. پارامتر q مقداری بین صفر تا یک دارد. هرچقدر به یک نزدیک‌تر باشد، تشدید کمتری رخ می‌دهد و هرچقدر مقدار کمتری داشته باشد، باعث می‌شود تا تاثیر نمونه‌هایی که درست دسته‌بندی شده‌اند

^۲Bias-aligned groups

^۳Bias-conflicting groups

بیشتر شود.

$$\ell = \frac{1 - p(y|x)^q}{q} \quad (2.1)$$

۴.۱.۱ بررسی فرض اول مقاله

این فرض بیان می‌کند که مدل دارای سوگیری، دقت بهتری روی نمونه‌های هم‌راستا با بایاس دارد. این فرض از چند جهت مهم است. در مرحله اول با استفاده از این فرض می‌توان فرمول کمینه بیشینه (۱.۱) را به این صورت ساده کرد که فقط خطا را روی نمونه‌های در تضاد با بایاس حساب نمود. یعنی عملاً نیازی به گرفتن بیشینه نیست. (زیرا از قبل می‌دانیم که بیشترین خطا روی نمونه‌های در تضاد با بایاس است.) استفاده دیگری که از این فرض می‌شود، هنگام تشخیص نمونه‌های هم‌راستا با بایاس و در تضاد با بایاس است. از آنجایی که فرض می‌شود خطای مدل روی نمونه‌های در تضاد با بایاس بیشتر است، می‌توان از عکس این فرض استفاده نمود. یعنی نمونه‌هایی که مدل دارای سوگیری روی آن‌ها دقت کمتری دارد، نمونه‌های در تضاد با بایاس هستند.


۵.۱.۱ ایده الگوریتم JTT

در این الگوریتم، ابتدا مدل به صورت معمولی آموزش دیده می‌شود. سپس نمونه‌هایی که مدل دقت کمتری روی آن‌ها داشته است (احتمالاً نمونه‌های در تضاد با بایاس) وزن بیشتری می‌گیرند و مدل دوباره آموزش می‌بیند.

این رویکرد به نوعی شبیه به آموزش مدل دارای سوگیری در مقاله قبل است ولی در جهت مخالف. در آن جا با تشدید وزن‌ها سعی می‌شد تا مدل روی نمونه‌های هم‌راستا با سوگیری دقت بهتری داشته باشد و سوگیری بیشتر شود ولی در اینجا با تشدید وزن، سعی می‌شود تا مدل روی نمونه‌های در تضاد با بایاس عملکرد بهتری داشته باشد.


۲.۱ سوالات پیاده‌سازی

۱.۲.۱ آماده‌سازی داده و مصورسازی



شکل ۱.۱: نمونه داده‌ها پس از تغییرات گفته شده


۲.۲.۱ آموزش مدل پایه با ERM



شکل ۲.۱: نمودار خطا و دقت برای مجموعه‌های آموزش و آزمون روی مدل پایه

۳.۲.۱ استخراج مجموعه خطا (ERROR SET)

با مقایسه مقادیر پیش‌بینی شده با مقادیر واقعی، در ۱۰۳۷ مورد، پیش‌بینی با مقدار واقعی یک نیست. در شکل ۳.۱ نمونه مواردی که غلط دسته‌بندی شده‌اند آمده است.



شکل ۳.۱: نمونه موارد خطای مدل پایه روی داده آموزش


۴.۲.۱ ساخت دیتاست وزن‌دار UPSAMPLING

بعد از این کار یک مجموعه داده با ۱۱۰۸۱۳ عضو ساخته شد. که این مقدار با محاسبات منطبق است.

$$60000 + 1037 * 49 = 110813$$

۵.۲.۱ آموزش مجدد مدل

همانطور که در نمودار ۴.۱ می‌توان دید، بعد از استفاده از JTT مدل توانست به دقت بهتری روی داده‌های آموزش برسد. البته مدل اشباع نشده ولی به دلیل محدودیت تعداد دور آموزش تعیین شده در سوال، از آموزش بیشتر آن صرف‌نظر شد.




شکل ۴.۱: نمودارهای خطا و آموزش هنگام آموزش مجدد مدل روی داده‌های upsample شده


۶.۲.۱ پیاده‌سازی تابع زیان GCE

استفاده از تابع زیان GCE تاثیر مشهودی دارد. استفاده از این تابع ضرر باعث می‌شود تا مدل سوگیری بیشتری داشته باشد و حجم errorset بیشتر شود. همچنین می‌توان دید که با استفاده از این تابع ضرر، از آنجایی که مدل بیشتر دچار سوگیری می‌شود، دقت روی مجموعه داده آزمون بسیار کاهش می‌یابد. با آموزش مدل با استفاده از GCE حجم errorset برابر با ۲۵۴۶ شد که با توجه به سوگیری بیشتر مدل قابل توجهی است.

با upsample کردن این داده‌ها و آموزش مجدد مدل می‌توان به دقتی بهتر از اجرای JTT، با تابع ضرر cross entropy رسید که نتایج آن در جدول ۱.۱ آمده است.



شکل ۵.۱: نمودارهای خطا و آموزش هنگام آموزش مدل پایه با استفاده از تابع ضرر GCE



شکل ۶.۱: نمودارهای خطا و آموزش هنگام آموزش مدل upsample شده با استفاده از تابع ضرر GCE

جدول ۱.۱: مقایسه خطا و دقت نهایی مدل‌ها

مدل	داده‌های آموزش		داده‌های آزمون	
	خطا	دقت (%)	خطا	دقت (%)
مدل پایه	0.0825	97.86	0.9778	78.15
مدل با JTT	0.0181	99.49	0.7798	84.51
مدل با تابع ضرر GCE	0.0614	95.69	1.2067	15.35
مدل jtt با استفاده از خطاهای GCE	0.0112	99.66	0.7501	88.21

سوال ۲

حملات خصمانه

۱.۲ مرور مفاهیم

۱.۱.۲ دسته‌بندی روش‌های حمله متخاصم

- **جعبه سیاه:** در حمله جعبه سیاه، مهاجم اطلاعات خاصی از مدل ندارد و فقط می‌تواند به مدل ورودی بدهد و برچسب و یا احتمال کلاس‌ها بگیرد.
- **جعبه سفید:** در حمله جعبه سفید مهاجم اطلاعات مدل را دارد (معماری، وزن‌ها و غیره) و می‌تواند با استفاده از این اطلاعات سعی کند مدل را به اشتباه بیاندازد.

یک دسته‌بندی که به نوعی میان این دو است حمله خاکستری است که در آن مهاجم اطلاعات محدودی از مدل را دارد. برای مثال معماری مدل را می‌داند ولی وزن‌های آن را خیر.

۲.۱.۲ اهمیت حملات جعبه سیاه

در حملات جعبه سیاه، مهاجم نیاز به هیچ اطلاعاتی از مدل ندارد و در نتیجه در هر حالتی قابل انجام است. اگر یک مدل نسبت به حملات جعبه سفید آسیب‌پذیر باشد، ممکن است با بسته کردن مدل و حفاظت از اطلاعات مربوط به آن، برای مدل مشکلی پیش نیاید. ولی اگر مدلی نسبت به حمله جعبه سیاه آسیب‌پذیر باشد، صرف اینکه مهاجم بتواند به مدل ورودی بدهد می‌تواند منجر به بروز مشکل شود.

۳.۱.۲ حملات هدف‌دار و غیرهدف‌دار

- غیرهدف‌دار: در این نوع حملات، تمرکز مهاجم صرفاً بر این است که ورودی‌ای بدهد که مدل را به اشتباه بیاندازد.
- هدف دار: در این حملات، تمرکز مهاجم بر این است که ورودی‌ای بدهد که مدل را به تولید خروجی مشخص و مورد نظر مهاجم وادار کند.

۲.۲ حمله جعبه سیاه

۱.۲.۲ آسیب‌پذیری نسبت به حمله جعبه سفید

در این مقاله بیان می‌شود که طبق مقاله [۱] تقریباً همه مدل‌های دسته‌بندی تصویر نسبت به حملات جعبه سفید آسیب‌پذیرند. و تفسیر نویسنده مقاله این است که تصاویر طبیعی به مرزهای تصمیم مدل‌ها نزدیک هستند و این آسیب‌پذیری در ابعاد بالا تقریباً اجتناب‌ناپذیر است.

۲.۲.۲ روش حمله SimBA

همانطور که در بخش قبل بیان شد، تصاویر طبیعی به مرزهای تصمیم نزدیک هستند. همچنین اگر در نظر بگیریم که یک نمونه وجود دارد که با تغییراتی که برای انسان قابل تشخیص نیست، باعث شود کلاس یک عکس عوض شود، مسئله حمله به مدل عملاً یک مسئله جستجو است.

روشی که در مقاله بیان می‌شود به این صورت است که با توجه به این‌که عکس‌ها با مرز تصمیم فاصله کمی دارند، فرض می‌گیرد که جهت حرکت اهمیت کمتری داشته باشد و نیاز نیست بر روی این جهت خیلی تمرکز کرد. پس یک سری بردار جهت (Q) انتخاب شده و در هر گام یکی از این بردارها $q \in Q$ انتخاب شده و مقدار $\delta + q\epsilon$ به عکس اضافه می‌شود و بررسی می‌شود تا آیا امتیاز کلاس کاهش می‌یابد یا خیر. اگر امتیاز کاهش یافت مقدار δ با $q\epsilon$ جمع زده می‌شود و اگر امتیاز کاهش نیافت عکس با بردار $q\epsilon - \delta$ جمع زده می‌شود و مجدد چک می‌شود و در صورت کاهش امتیاز مقدار δ به روزرسانی می‌شود

برای این‌که تعداد کوثری‌ها کاهش یابد بهتر است از بردارهای متعامد استفاده شود تا همدیگر را خنثی نکنند. اگر بردارها متعامد نباشند، همچنان این حمله ممکن است ولی به تعداد کوثری‌های بیشتری نیاز خواهد داشت.

۳.۲.۲ تفاوت SimBA و SimBA-DCT

در روش SimBA برای بردارهای کاندید، از مختصات دکارتی استفاده می‌شود. یعنی در هر دور آموزش رنگ یکی از پیکسل‌ها کم یا زیاد می‌شود. ولی در روش SimBA-DCT بردارها بجای تعریف روی فضای دکارتی روی فضای فرکانس تعریف می‌شوند. این عمل به این خاطر است که تحقیقات نشان داده که نویزها در فرکانس‌های پایین‌تر حالت خصمانه^۱ بیشتری دارند. به این معنی که برای انسان قابلیت تشخیص کمتری دارند ولی بیشتر در خروجی مدل تاثیر دارند. پس یعنی با تغییر عکس در این حوزه می‌توان با فاصله کمتر، میزان امتیاز مدل را بیشتر کم کرد.

۴.۲.۲ حملات امتیاز محور و حملات مبتنی بر برچسب

در حملات مبتنی بر برچسب، مدل برای خروجی تنها گروهی که عکس در آن دسته‌بندی شده است را می‌دهد. ولی در حملات امتیاز محور، مدل احتمال تعلق عکس به هر دسته را می‌دهد. در حملات امتیاز محور از آنجایی که معیار پیوسته‌ای برای سنجش عملکرد حمله وجود دارد، تعداد کوئری‌ها کمتر است. مدل SimBA که در مقاله معرفی شده است یک مدل امتیاز محور است زیرا بر اساس این‌که با تغییر داده شده، امتیاز کلاس کم شده یا نه بردار خود را به‌روز می‌کند.

۵.۲.۲ معیارهای ارزیابی

در مقاله از سه معیار برای ارزیابی روش‌ها استفاده می‌شود:

- **نرخ موفقیت:** نرخ موفقیت بیان می‌کند در چند درصد مواقع حمله موفق شده که مدل را به اشتباه بیاورد (یا در حالت حمله هدف‌دار، باعث شود تا مدل خروجی مطلوب را تولید کند). هرچقدر این مقدار بیشتر باشد بهتر است زیرا حمله توانسته در موارد بیشتری مدل را به اشتباه بیاورد.
- **میانگین کوئری:** این مورد بیان می‌کند برای هر حمله، به طور میانگین چند کوئری استفاده شده است. منطقاً هرچقدر این مقدار کمتر باشد بهتر است زیرا زمان و هزینه کمتری صرف می‌شود.
- **میانگین L_2 :** این مورد بیان می‌کند که عکس نهایی که باعث به اشتباه انداختن مدل می‌شود با عکس اولیه چقدر فاصله دارد. هرچقدر این عدد کمتر باشد یعنی مدل ضعیف‌تر بوده و حمله قوی‌تر بوده است.

¹adversarial

۳.۲ حملات جعبه سفید


۱.۳.۲ مدل و مجموعه داده

مدل و تصاویر با موفقیت بارگذاری شدند و همانطور که در سوال آمده، دقت مدل روی داده‌های نمونه برابر با ۱۰۰ بود.

۲.۳.۲ FGSM

در روش FGSM ابتدا مقدار خطا برای ورودی و برجسب حساب می‌شود و سپس گرادیان خطا نسبت به ورودی حساب می‌شود سپس از این مقدار گرادیان فقط علامت آن در نظر گرفته می‌شود و در یک ϵ ضرب می‌شود و با عکس جمع می‌شود. اگر حمله هدف‌دار باشد، موقع محاسبه خطا، برجسب خروجی مدنظر داده می‌شود و موقع به روزرسانی عکس، در راستای نزول گرادیان حرکت می‌کنیم بجای صعود آن.

با انجام حمله FGSM روی نمونه‌ها، از ۲۵ عکس ورودی، تنها در ۲ مورد مدل همچنان دسته درست را پیش‌بینی می‌کرد و دقت مدل از ۱۰۰ به ۸ درصد افت کرد.




شکل ۱.۲: نمایش ۴ مورد از نمونه عکس اصلی، عکس دستکاری شده و نمایش بردار δ در FGSM. مقادیر دلتا از -0.03 تا 0.03 بوده و برای آن‌که خروجی قابل تفسیری بدهد به صفر تا یک مقیاس شده است.

۳.۳.۲ PGD

الگوریتم PGD به نوعی، نسخه iterative الگوریتم FGSM است. به این صورت که در هر مرحله، مشابه FGSM مقدار گرادیان خروجی نسبت به ورودی حساب می‌شود. ولی بجای این‌که $\epsilon * \text{sign}(\text{gradient})$ با عکس جمع شود و عکس نهایی خروجی داده شود، بلکه یک بردار اولیه δ با مقادیر صفر در نظر گرفته می‌شود و مقدار $\alpha * \text{gradient}$ به آن اضافه می‌شود. سپس چک می‌شود که این مقدار δ باعث می‌شود تا عکس دستکاری شده از همسایگی عکس اولیه خارج شود یا خیر و اگر خارج می‌شد δ کلیپ می‌شود و تا وقتی که مدل کلاس اشتباهی را انتخاب کند و یا تعداد دورها از ابر پارامتر بیشینه تعداد دور بیشتر شود، این کار تکرار می‌یابد.

با استفاده از این روش مدل تنها یک عکس را توانست درست پیش‌بینی کند و دقت آن به 0.04 کاهش یافت. علیرغم این‌که این شیوه حمله از FGSM قدرتمندتر است و توانست دقت را کمتر کند ولی حمله کندتری است و همانطور که از مقایسه شکل ۱.۲ و ۲.۲ می‌توان یافت، بردار δ های یافت شده در دو الگوریتم بسیار شبیه به هم هستند. ولی برخلاف روش FGSM که در آن مقادیر هر کانال پیکسل‌ها باینری است (که در ϵ ضرب شده) در PGD این مقادیر می‌توانند مقادیری میانی بگیرند.



شکل ۲.۲: نمایش ۴ مورد از نمونه عکس اصلی، عکس دستکاری شده و نمایش بردار δ در PGD. مقادیر دلتا از -0.03 تا 0.03 بوده و برای آن‌که خروجی قابل تفسیری بدهد به صفر تا یک مقیاس شده است.

برای مقایسه بهتر دو حمله، میانگین فاصله l_2 در حملات نیز در جدول ۱.۲ آمده است.

جدول ۱.۲: میانگین فاصله l_2 در عکس‌های تولیدی

مدل	میانگین فاصله l_2
FGSM	1.6628
PGD	0.928

منابع

- [۱] A. Athalye, N. Carlini, and D. Wagner, “Obfuscated gradients give a false sense of security: Circumventing defenses to adversarial examples,” *Proceedings of the 32th International Conference on Machine Learning (ICML)*, 2018. DOI: [10.48550/arXiv.1802.00420](https://doi.org/10.48550/arXiv.1802.00420). arXiv: [1802.00420](https://arxiv.org/abs/1802.00420) [cs.LG]. [Online]. Available: <https://arxiv.org/abs/1802.00420>.