

دانشگاه تهران
پردیس دانشکده‌های فنی

دانشکده مهندسی برق و کامپیوتر

تمرین شماره: ۴
هوش مصنوعی قابل اعتماد

نام و نام خانوادگی: مرتضی ملکی‌نژاد شوشتری
شماره دانشجویی: ۸۱۰۱۰۴۲۵۶

نیم‌سال دوم سال تحصیلی ۴۰۴-۴۰۵

فهرست مطالب

۵	۱ مبانی و نظریه
۵	بخش اول
۵	پرسش ۱
۹	پرسش ۲
۱۰	پرسش سوم. انصاف علی و خلاف واقع
۱۲	بخش دوم. پرسش‌های مفهومی و کاربردی
۱۲	پرسش ۴: مسئله جانشین/برچسب در سلامت
۱۳	پرسش ۵. انتخاب معیار، تحت قید عدم امکان (اعطای وام)
۱۴	پرسش ۶. داوری مناقشه COMPASS
۱۵	پرسش ۷. فراتر از انصاف حاشیه‌ای - زیرگروه‌ها و زمان‌ها
۱۶	بخش سوم. پیاده‌سازی و تحلیل تجربی
۱۶	بررسی اولیه داده‌ها
۱۸	مدل پایه
۱۹	تحلیل عملکرد مدل بر حسب نژاد
۲۰	روش‌های کاهش سوگیری
۲۱	بده‌بستان میان دقت و انصاف
۲۳	بررسی اتحاد Chouldechova
۲۳	تحلیل تقاطعی
۲۴	۲ سوال دوم - حریم خصوصی در یادگیری ماشین و یادگیری فدرال
۲۴	بخش اول

۲۴	زیربخش اول - حساسیت و مکانیزم لاپلاس
۲۵	زیربخش دوم - انتشار خصوصی داده‌ها
۲۶	زیربخش سوم - تخصیص بودجه حریم خصوصی و ترکیب مکانیزم‌ها
۲۸	بخش دوم - سوالات مفهومی
۲۸	زیربخش اول - حریم خصوصی، استحکام و یادگیری فدرال
۲۹	زیربخش دوم - حملات حریم خصوصی و مسموم سازی در یادگیری فدرال
۳۰	زیربخش سوم
۳۱	بخش سوم - سوالات پیاده‌سازی
۳۱	زیربخش اول: آماده‌سازی داده‌ها
۳۶	زیربخش دوم: آموزش مدل

فهرست تصاویر

۱۷	توزیع امتیاز خطر COMPAS بر حسب نژاد	۱.۱
۱۸	مهم‌ترین ویژگی‌های جانشین برای پیش‌بینی نژاد	۲.۱
۱۹	منحنی ROC مدل پایه	۳.۱
۲۰	منحنی ROC به تفکیک گروه‌های نژادی	۴.۱
۲۲	بدهیستان میان دقت و انصاف	۵.۱
۳۲	نمونه تصاویر دیتاست FEMNIST به همراه برچسب واقعی	۱.۲
۳۲	توزیع تعداد نمونه‌ها به ازای هر نویسنده	۲.۲
۳۴	سهم هر سازمان از کل داده‌های آموزشی	۳.۲
۳۵	توزیع تعداد سازمان‌هایی که هر Subject در آن حضور دارد	۴.۲
۳۵	درصد‌های Subject حاضر در یک سازمان در مقابل چند سازمان	۵.۲
۳۷	دقت و تابع هزینه مدل در طول دوره‌های آموزش فدرال	۶.۲

فهرست جداول

۱۶	نتایج طبقه‌بندی مدل دارای سوگیری	۱.۱
۱۸	گزارش عملکرد مدل برای پیش‌بینی ویژگی نژاد از روی سایر ویژگی‌ها	۲.۱
۱۹	اختلاف معیارهای انصاف میان گروه‌های نژادی	۳.۱
۲۱	مقادیر سنجه‌های انصاف برای حذف‌کننده تأثیر نامتناسب	۴.۱
۲۱	مقادیر سنجه‌های انصاف برای روش گرادیان نمایی	۵.۱
۲۱	دقت مدل‌های مختلف	۶.۱
۲۳	سنجه‌های انصاف برای گروه‌های حساس مختلف در تحلیل تقاطعی	۷.۱
۲۷	تقسیم ϵ بین مکانیزم‌ها	۱.۲
۳۱	آمار دیتاست FEMNIST	۲.۲
۳۳	تعداد نویسندگان و تصاویر در مجموعه‌های Member و Non-Member	۳.۲
۳۳	توزیع داده‌ها بین سازمان‌ها	۴.۲
۳۷	اظهارنامه استفاده از هوش مصنوعی	۵.۲

سوال ۱

مبانی و نظریه

بخش اول

پرسش ۱

الف

۱. استقلال: این شرط بیان می‌کند که باید مقدار پیش‌بینی‌شده نسبت به متغیر تصادفی زیرگروه‌ها مستقل باشد. یعنی اگر در نظر بگیریم A متغیر تصادفی زیرگروه و R متغیر تصادفی مربوط به مقدار پیش‌بینی‌شده باشد، داریم:

$$A \perp R \Rightarrow P(R|A) = P(R) \Rightarrow P(R|A = a) = P(R|A = b) = P(R)$$

یکی از محدودیت‌های این معیار این است که حتی اگر زیرگروه A تاثیر بدون سوگیری روی نتیجه داشته باشد، ما آن تاثیر را نیز در نظر نمی‌گیریم. مثلاً جنسیت می‌تواند روی سابقه‌کار و سابقه‌کار روی درصد پذیرش رزومه تاثیر داشته باشد، ولی اگر معیار هدف استقلال باشد، این اطلاعات به کلی نادیده گرفته می‌شود. **جداسازی:** این شرط بیان می‌کند که مقدار پیش‌بینی‌شده باید با توجه به مقدار واقعی برچسب، نسبت به زیرگروه‌ها مستقل باشد. به عبارت دیگر، اگر A متغیر تصادفی زیرگروه، Y برچسب

واقعی و R مقدار پیش‌بینی‌شده باشد، خواهیم داشت:

$$R \perp A \mid Y \Rightarrow P(R \mid A, Y) = P(R \mid Y)$$

$$P(R \mid A = a, Y = y) = P(R \mid A = b, Y = y)$$

این معیار به نوعی تا حدی مشکل معیار قبل را سعی می‌کند حل کند تا اطلاعات تاثیرگذار روی خروجی از دست نروند. برای همین مقدار برجسب را در شرط قرار می‌دهد.

این معیار تضمین می‌کند که برای افرادی که برجسب واقعی یکسانی دارند، توزیع خروجی مدل در تمامی زیرگروه‌ها یکسان باشد. بنابراین مدل نباید برای افراد با وضعیت واقعی یکسان، صرفاً به دلیل تعلق به یک زیرگروه خاص، رفتار متفاوتی داشته باشد.

یک شیوه نگاه به این معیار این است که نرخ خطا در زیرگروه‌های مختلف باید یکی باشد. اگر مدلی که احتمال وقوع جرم را پیش‌بینی می‌کند، روی افراد سیاه‌پوست نرخ خطای بیشتری دارد می‌توان گفت مدل دچار سوگیری است.

این معیار اجازه می‌دهد توزیع کلی پیش‌بینی‌ها میان زیرگروه‌ها متفاوت باشد، به شرط آنکه این تفاوت ناشی از اختلاف در برجسب‌های واقعی باشد.

بستگی: این شرط بیان می‌کند که برجسب واقعی باید با توجه به مقدار پیش‌بینی‌شده، نسبت به زیرگروه‌ها مستقل باشد. اگر A متغیر تصادفی زیرگروه، Y برجسب واقعی و R مقدار پیش‌بینی‌شده باشد، خواهیم داشت:

$$Y \perp A \mid R \Rightarrow P(Y \mid A, R) = P(Y \mid R)$$

$$P(Y \mid A = a, R = r) = P(Y \mid A = b, R = r)$$

این معیار بیان می‌کند که مقدار پیش‌بینی‌شده باید در تمامی زیرگروه‌ها تفسیر یکسانی داشته باشد. به عبارت دیگر، اگر دو فرد از دو زیرگروه مختلف امتیاز یا احتمال پیش‌بینی یکسانی دریافت کنند، احتمال واقعی تعلق آن‌ها به کلاس مثبت نیز باید یکسان باشد. یعنی پیش‌بینی مدل اطلاعاتی راجع به

زیرگروه ندهد.

ب

برای هر یک از سه معیار آماری، یک معیار انصاف متناظر برای تصمیم‌گیری دودویی به صورت زیر تعریف می‌شود:

۱. استقلال: برابری جمعیتی

این معیار بیان می‌کند که نرخ پذیرش باید در تمام زیرگروه‌ها یکسان باشد. بنابراین

$$P(\hat{Y} = 1 \mid A = a) = P(\hat{Y} = 1 \mid A = b)$$

به عبارت دیگر، احتمال دریافت تصمیم مثبت نباید به عضویت در زیرگروه وابسته باشد.

۲. جداسازی: برابری شانس‌ها

این معیار بیان می‌کند که برای افراد با برجسب واقعی یکسان، خروجی مدل نباید به زیرگروه وابسته باشد. بنابراین

$$P(\hat{Y} = 1 \mid Y = y, A = a) = P(\hat{Y} = 1 \mid Y = y, A = b), \quad y \in \{0, 1\}$$

که معادل برابر بودن نرخ مثبت واقعی^۱ و نرخ مثبت کاذب^۲ در تمام زیرگروه‌ها است.

۳. بسندگی: برابری پیش‌بینی

این معیار بیان می‌کند که اگر مدل تصمیم مثبت بگیرد، احتمال درست بودن این تصمیم باید در همه زیرگروه‌ها یکسان باشد. بنابراین

¹True positive rate

²False positive rate

$$P(Y = 1 \mid \hat{Y} = 1, A = a) = P(Y = 1 \mid \hat{Y} = 1, A = b)$$

در حالت پیش‌بینی احتمالاتی، این معیار معادل کالیبراسیون است.

ج

۱. استقلال

مثلاً می‌توان نرخ قبولی رزومه را بررسی کرد. هدف این معیار آن است که نرخ دعوت به مصاحبه میان زنان و مردان یکسان باشد تا جنسیت به طور مستقیم بر تصمیم اثر نگذارد.

۲. جداسازی

مثلاً در یک سیستم پیش‌بینی تکرار جرم مهم است که نرخ خطا برای تمام گروه‌های نژادی یکسان باشد تا یک گروه بیش از گروه دیگر به اشتباه پرخطر تشخیص داده نشود.

۳. بسندگی

مثلاً در یک سیستم که صلاحیت افراد برای دریافت وام را بررسی می‌کند، اگر دو متقاضی از دو گروه مختلف امتیاز اعتباری ۸۰ درصد دریافت کنند، بانک باید بتواند این امتیاز را برای هر دو به یک معنا تفسیر کند؛ در غیر این صورت امتیاز مدل قابل اعتماد نیست.

د

فرض کنید نرخ پایه در دو زیرگروه متفاوت باشد، یعنی

$$P(Y = 1 \mid A = 0) \neq P(Y = 1 \mid A = 1).$$

همچنین فرض کنید مدل غیر بدیهی باشد؛ یعنی پیش‌بینی آن نه کاملاً صحیح باشد و نه مستقل از برجسب واقعی. اگر مقدار $P(Y|A)$ را با استفاده از قانون احتمال کل برای متغیر R بنویسیم داریم:

$$P(Y|A) = \sum_r P(Y|A, R)P(R|A) \xrightarrow{P(R|A)=P(R)} P(Y|A) = \sum_r P(Y|A, R)P(R) \xrightarrow{P(Y|A, R)=P(Y|R)}$$

$$P(Y|A) = \sum_r P(Y|R)P(R)$$

می‌توان دید سمت راست تساوی هیچ اثری از A وجود ندارد پس $P(Y|A) = P(Y)$ ولی این با فرض اولیه که در نظر گرفته بودیم $P(Y|A=a) \neq P(Y|A=b)$ در تناقض است. پس در حالتی که نرخ‌های پایه باهم تفاوت دارند نمی‌توان این دو معیار را باهم داشت.

پرسش ۲

الف

$$\begin{aligned} PPV &= P(Y=1|\hat{Y}=1) = \frac{TP}{TP+FP} \Rightarrow 1-PPV = \frac{FP}{TP+FP} \\ \Rightarrow \frac{1-PPV}{PPV} &= \frac{FP}{TP} \xrightarrow{1-FNR=\frac{FP}{TP+FN}} \frac{1-PPV}{PPV} \cdot (1-FNR) = \frac{FP}{TP} \cdot \frac{TP}{TP+FN} = \\ &\xrightarrow{p=\frac{TP+FN}{TP+TN+FP+FN}} \frac{FP}{TP+FN} \cdot \frac{p}{1-p} \cdot \frac{1-PPV}{PPV} \cdot (1-FNR) = \frac{TP+FN}{TN+FP} \cdot \frac{FP}{TP+FN} = \\ &\frac{FP}{TN+FP} = FPR \end{aligned}$$

ب

با استفاده از الف و فرض ثابت بودن PPV داریم:

$$\frac{FPR}{1-FNR} = \frac{p}{1-p} * constant$$

حال اگر مقدار FPR و FNR یکی باشد پس سمت چپ تساوی برای هر دو گروه یکی می‌شود پس مقدار p نیز باید برای هر دو گروه یکی شود که در تناقض با فرض است.

حالاتی که می‌توان این مقادیر یکی شود وقتی است که در اتحاد ضرب یا تقسیم در صفر داشته باشیم. یعنی مقدار PPV برابر صفر یا یک شود و یا مقدار FNR برابر یک شود.

ج

(برای شناخت مسئله گفته شده در سوال از هوش مصنوعی و همچنین مقاله [۸] استفاده شد.) شرکت سازنده معیار sufficiency را هدف قرار داد. یعنی اگر یک فرد سفیدپوست و یک فرد سیاهپوست ریسک یکسانی بگیرند احتمال تکرار جرم هردوی آنها یکسان است. ولی ProPublica نشان داد که نرخ خطا بین زیرگروهها متفاوت است.

شبهت این موضوع با سوال در این است که اگر معیار sufficiency درست باشد پس انگار مقدار PPV در بین زیرگروهها یکی است. پس مشابه بخش «ب» از آنجایی که نرخ پایه در بین زیرگروهها متفاوت است، پس نرخ خطا نیز متفاوت است.

پس یعنی اگر نرخهای پایه متفاوت باشد نمی توان همزمان هم معیار sufficiency و separation را باهم داشت.

د

اگر نرخهای پایه برابر باشد، تنها حالتی که همزمان با sufficiency بتوان تساوی بخش «الف» را برقرار کرد وقتی است که مقدار FPR و FNR هردو صفر باشد. پس اگر مدل کامل باشد می توان. ولی این حالت تقریباً هیچوقت رخ نمی دهد. زیرا فارغ از حجم داده خود مسئله معمولاً یک نویز غیرقابل پیش بینی نیز دارد. در بهترین حالت می توان گفت هرچقدر مدل کامل تر باشد، از دید separation مدل به سمت fairness حرکت می کند.

پرسش سوم. انصاف علی و خلاف واقع

الف

اگر U متغیرهای Exogenous و V متغیرهای Endogenous باشد و A متغیر حساس باشد و مدل علی ساختاری زیر را داشته باشیم:

$$M = (U, V, F)$$

آنگاه ایده خلاف واقع این است که برای یک نمونه ورودی با استفاده از عملگر do مقدار A آن را تغییر داد و باقی مقادیر U را ثابت نگه داشت و دید خروجی مدل تغییر می کند یا خیر. یعنی:

$$P(\hat{Y}(U) = y | X = x, do(A = a)) = P(\hat{Y}(U) = y | X = x, do(A = a'))$$

ب

در اینجا متغیر X هم می‌تواند تبیین‌کننده باشد و هم پروکسی. اگر فقط مقدار و معنای X را در نظر بگیریم، این یک متغیر تبیین‌کننده است زیرا سال‌های تجربه روی امتیاز استخدام تاثیر دارد و سوگیری خاصی ندارد.

ولی ممکن است از روی سال‌های تجربه بتوان جنسیت را تخمین زد و این موضوع روی امتیاز استخدام اثر بگذارد. در اینصورت پروکسی رخ داده.

مسیر تبیین‌کننده $X -> Y$ و مسیر پروکسی $A -> X -> Y$ است. باید از X اطلاعات صرفاً مربوط به سابقه را استخراج کرد و نه جنسیت.

اگر ما هیچ توضیحی از X و Y نداشته باشیم نمی‌توان فهمید که روابط بین این متغیرهای تصادفی ناشی از سوگیری است و یا رابطه واقعی. برای مثال اگر در گراف سوال مقدار A را برابر سخت‌کوشی در نظر بگیریم همین گراف بدست می‌آید ولی این گراف دیگر سوگیری ندارد چون سخت‌کوشی یک متغیر تبیین‌کننده است. برای همین تشخیص اینکه چه متغیرهایی دچار سوگیری مدل می‌شوند و این که مدل چه معیاری از عدالت را رعایت کند تصمیمی است که از بیرون و براساس هنجار گرفته می‌شود و نه از روی داده.

ج

زیرا همانطور که در بخش قبل ذکر شد اینکه کدام متغیر تاثیر درست دارد و کدام متغیر سوگیری، براساس هنجار است و نه داده. حتی اگر توضیح هر متغیر موجود باشد، ممکن است یک نفر جنسیت را متغیر دارای سوگیری نداند و در نظر بگیرد جنسیت برای استخدام یک متغیر درست و بدون سوگیری است. مثلاً برای موقعیت شغلی مربی مهدکودک معمولاً خانم‌ها قبول می‌شوند.

از این رو اگر یک نفر جنسیت را متغیر دارای اثر بداند یا $\hat{Y} -> A$ را در نظر می‌گیرد. ولی اگر جنسیت را سوگیری در نظر بگیریم این یال نباید در گراف علیت باشد.

بخش دوم. پرسش‌های مفهومی و کاربردی

پرسش ۴: مسئله جانشین/برچسب در سلامت

الف

(برای فهمیدن انواع بایاسی که در سوال ذکر شد از هوش مصنوعی استفاده شد.)

• **تاریخی:** وجود دارد. گروه‌هایی وجود دارد که در گذشته دسترسی نابرابر به خدمات درمانی داشتند و یا هزینه درمان برای آن‌ها متفاوت‌تر است. **بازنمایی و تجمیع و ارزیابی** در اینجا خیلی مسئله نیست ولی درکل احتمالاً وجود دارد. **اندازه‌گیری برچسب:** این مسئله اصلی است. برای اینکه تخمین قابل سنجش‌پذیرتر باشد مدل هزینه درمان را پیش‌بینی می‌کند و فرض کرده‌است بین هزینه و نیاز رابطه واضحی است. ولی هزینه به‌طور کامل نیاز را اندازه‌گیری نمی‌کند. **استقرار:** وجود دارد. مدل برای هدفی متفاوت با آنچه که استفاده می‌شد ساخته شد.

ب

خیر. زیرا در اینجا بیشتر از اینکه مدل روی یک ویژگی دچار سوگیری شده باشد، هدف مدل دارای سوگیری است. یعنی فارغ از هر ویژگی‌ای که مدل با آن آموزش ببیند، این فرض که نیاز از هزینه بدست می‌آید دارای سوگیری است. (هرچند که حتی اگر سوگیری در داده یا گروه بود نیز احتمالاً حذف ویژگی مشکل را حل نمی‌کرد.)

ج

اولاً باید نسبت به متغیر هدف اصلی یعنی نیاز پزشکی سنجید. زیرا سوگیری درون هدف جایگزین یعنی هزینه است. پس اگر نسبت به هزینه حساب کنیم، احتمالاً مشکلی پیدا نکنیم.

در درجه دوم مقاله معیار separation را حساب می‌کند. یعنی بررسی می‌کند در بیماران با سطح بیماری یکسان کدام گروه نرخ خطای بیشتری دارد. (هرچند احتمالاً اگر با روشی متفاوت معیارهای دیگر حساب می‌شد نیز سوگیری در آن معلوم بود.)

د

انگیزه اصلی این که بجای نیاز هزینه پیش‌بینی شد، این است که هزینه قابل سنجش‌تر است. یک راه این است که مستقیم خود نیاز را ارزیابی کرد و از معیارهای عدالت برای سنجش سوگیری مدل استفاده کرد. ولی حتی اگر بخواهیم مدل قابل سنجش‌تری داشته باشیم، اولاً هزینه خود تابع نیاز است و نه بالعکس و فقط اگر هزینه

خام (بدون بیمه و نرمال شده با عوامل محیطی مثل محل و دکتر) را در نظر بگیریم می‌توان بررسی کرد که تا چه اندازه هزینه از روی نیاز می‌تواند تخمین زده شود.

یعنی حتی اگر هزینه را همچنان به عنوان هدف جایگزین در نظر بگیریم باید عوامل دیگری که روی نیاز اثر می‌گذارند را حذف کرد.

پرسش ۵. انتخاب معیار، تحت قید عدم امکان (اعطای وام)

الف

- **بانک:** معیار مهم برای بانک مقدار نرخ مثبت کاذب است. یعنی مدل یکسری وام را تایید کند ولی افراد بازپرداخت نداشته باشند. این مورد باعث ضرر بانک می‌شود. عامل کمتر مهم نرخ منفی کاذب است. این باعث نمی‌شود که بانک ضرر کند ولی باعث می‌شود که سود کمتری کند زیرا می‌توانست با دادن این وام‌ها سود بیشتری بکند.
- **مشتریان:** معیار مهم برای مشتریان مقدار نرخ منفی کاذب است. زیرا باعث می‌شود تا وام نگیرند در حالی که توانایی بازپرداخت وام را داشته‌اند.
- **ناظران:** باتوجه به اینکه این ناظران قاعده ۸۰ درصد را مدنظر قرار داده‌اند، یعنی به نرخ پذیرش در گروه‌های مختلف حساسند. هرچقدر گروه‌های مختلف نرخ قبولی متفاوت‌تری داشته باشند، مسئله بزرگ‌تر است. پس یعنی هم منفی کاذب و هم مثبت کاذب برای این افراد مهم است. (درواقع اصلا این که پیش‌بینی مدل چقدر با واقعیت نزدیک است برای این گروه مهم نیست و فقط برابری گروه‌ها مسئله است.)

ب

باتوجه به اینکه در سوال قاعده ۸۰ درصد ذکر شد پس برابری جمعیتی معیار نزدیک‌تری به نظر می‌رسد. این مورد اطمینان حاصل می‌کند که خروجی مدل از گروه افراد مستقل است. پس نرخ قبولی گروه‌های مختلف تقریباً برابر است و قاعده ۸۰ درصد که بیان می‌کند کمترین گروه باید حداقل ۸۰ درصد بیشترین گروه باشد رعایت می‌شود.

البته این موضوع بدون هزینه نیست. اگر نرخ‌های پایه برابر باشد مسئله‌ای نیست ولی اگر برابر نباشد چون separation نداریم پس یعنی نرخ خطای گروه‌های مختلف برابر نیست. یعنی ممکن است یک گروه مقدار منفی‌های کاذب بیشتری داشته باشد صرفاً به این دلیل که نرخ قبولی آن با بقیه گروه‌ها یکی شود. پس یعنی گروه روی خروجی تاثیر می‌گذارد. ولی حداقل می‌توان گفت که مدل ترکیب جمعیتی را تغییر نمی‌دهد.

پرسش ۶. داوری مناقشه COMPASS

الف

این مسئله به این صورت است که شرکت NorthPointe یک مدل ارائه داد که برای مجرمین احتمال تکرار جرم توسط آن‌ها را پیش‌بینی می‌کرد. این شرکت برای عدالت بیان کرد که اگر دو فرد با دو نژاد مختلف ریسک یکسانی بگیرند احتمال واقعی تکرار جرم آن‌ها مشابه است. یعنی معیار sufficiency را مبنای عدالت قرار داد. اما ProPublica روی نرخ خطا در بین نژادهای مختلف تمرکز کرد و نشان داد که نرخ خطا در بین افراد سفیدپوست و سیاه‌پوست یکی نیست و افراد سیاه‌پوست نرخ خطای بیشتری دارند.

یعنی شرکت می‌گفت که پیش‌بینی دارد بدون سوگیری سعی می‌کند مقدار واقعی را پیش‌بینی کند. ولی ProPublica می‌گفت که اگر مقدار واقعی این‌که جرم تکرار شده یا نه را بدانیم، و مدل را با آن تست کنیم، افراد سیاه‌پوست نرخ خطای بیشتری خواهند داشت.

ب

همانطور که در بخش‌های قبل توضیح داده شد، شرکت عملاً گفته مقدار PPV در بین نژادهای مختلف یکی است. ولی در همان سوال قبل نیز دیدیم که اگر نرخ پایه متفاوت باشد و PPV یکسان باشد، مقدار نرخ خطا نیز متفاوت می‌شود. پس یعنی امکان‌پذیر نیست که در هر دو معیار عدالت داشت.

در حقیقت چون مدل معیار sufficiency را رعایت کرده مجبور است معیار separation را نقض کند. هیچ کدام از طرفین دروغ نمی‌گفتند بلکه هر کدام معیار عدالت را چیز متفاوتی در نظر گرفته بودند.

ج

به طور کلی در سیستم‌های قضائی ترجیح این است که بجای اینکه فردی بصورت اشتباه محاکمه شود، یک فرد گناهکار محاکمه نشود. یعنی اگر متغیر تصادفی Y گناهکار بودن را نشان بدهد، اولویت بر کاهش FP ها است و سپس کاهش FN ها.

در این مسئله اگر هدف این باشد که مدل میزان ریسکی که پیش‌بینی می‌کند واقعا فارغ از نژاد احتمال تکرار جرم را نشان بدهد، معیار separability مهم است. و اگر هدف برابری کامل باشد separation من به نظرم در اینجا علیرغم بحثی که راجع به false positive شد، این که ریسک فارغ از گروه مفهوم یکسانی را بدهد و بتوان به آن اعتماد کرد مهم‌تر است. زیرا تصمیم نهایی را قاضی و یا هیئت منصفه می‌گیرند و این ریسک به نوعی نشان می‌دهد که تا چه میزان دقت نیاز است. پس یعنی حتی اگر مدل ریسکی را به اشتباه

بالا تخمین بزند و مثبت کاذب ایجاد کند، این باعث می‌شود تا سیستم قضائی بیشتر دقت کند ولی اگر مدرک مستدلی یافت نشد فرد تبرئه می‌شود. (البته باید دقت داشت که توزیع جامعه به هم نخورد).

ولی اگر قرار است که خروجی مدل مستقیم منجر به محکومیت و یا تبرئه فرد شود، separation احتمالاً معیار عادلانه‌تری است. همچنین نابرابری‌ای که در سوال‌های قبل بدست آمد در حالت مطلق است. یعنی نمی‌توان تماماً هر دو معیار را داشت ولی می‌توان ترکیبی از هر دو معیار را مدنظر گرفت.

د

خیر. زیرا سوگیری‌های موجود در داده حاصل از نتایج دنیای واقعی هستند. پس یعنی فارغ از مدل این سوگیری‌ها در دنیا وجود دارند. خواه بخاطر محیط باشد یا سطح تمکن افراد و یا ذهنیت افراد. پس اگر مدل را کامل حذف کنیم مسئله کامل حل نمی‌شود. همچنین ذکر شد که از آنجایی که مدل تصمیم نهایی را نمی‌گیرد، این ملاحظه که نباید مثبت کاذب داشته باشیم همچنان رعایت می‌شود. یعنی به نوعی مدل مقدار منفی کاذب را کاهش می‌دهد و بجای این که مثبت کاذب زیاد شود فقط سیستم قضائی هزینه‌های بیشتری متحمل می‌شود (زیرا تحقیقات جامع‌تری انجام داده است).

پرسش ۷. فراتر از انصاف حاشیه‌ای - زیرگروه‌ها و زمان‌ها

الف

مثلاً فرض کنید یک مدل تایید وام داریم که خروجی آن در جدول ۹۹ آمده است. اگر فقط به توزیع‌های حاشیه‌ای نگاه کنیم، نرخ تایید مدل برای هر نژادی برابر ۵۰ درصد و برای هر جنسیتی نیز برابر ۵۰ درصد است که برابر با نرخ تایید کل است و به ظاهر سوگیری‌ای نداریم ولی اگر دقیق‌تر نگاه کنیم می‌بینیم در زیرگروه‌های توام مدل دچار سوگیری شده است.

یک راه می‌تواند این باشد که همه زیرگروه‌ها را امتحان می‌تواند این باشد که مدل را به ازای زیرگروه‌های مختلف امتحان کرد. ولی تعداد زیرگروه‌ها برابر با $3^d - 1$ است زیرا هر ویژگی یا مثبت است یا منفی و یا بی‌تاثیر. پس یعنی حتی با ابعاد کم هم امکان بررسی همه زیرگروه‌ها خیلی ممکن نیست، چه برسد به اینکه ابعاد زیاد شود.

ب

اگر یک مدل تایید وام داشته باشیم، به دلیل fairness ما وام افراد یک گروه که امتیاز پایین گرفته‌اند را به دلیل اینکه نرخ قبولی آن‌ها نیز برابر باقی شود تایید می‌کنیم. منتها این مدل درواقع احتمال بازپرداخت وام

جدول ۱۰.۱: نتایج طبقه‌بندی مدل دارای سوگیری

نژاد	جنسیت	تعداد	خروجی مدل
سیاه پوست	مرد	۱۰۰	۱
سفید پوست	مرد	۱۰۰	۰
سیاه پوست	زن	۱۰۰	۰
سفید پوست	زن	۱۰۰	۱

را حساب می‌کرده. پس افرادی که امتیاز پایین گرفته‌اند احتمال بازپرداخت وام توسط آن‌ها پایین است و با پرداخت نکردن وام، دچار آسیب بیشتری می‌شوند.

بخش سوم. پیاده‌سازی و تحلیل تجربی


(در این سوال، برای تبدیل جداول به جدول latex و بعضاً نوشتن یک سری تابع کمکی برای رسم نمودار و جدول از هوش مصنوعی استفاده شد.)

بررسی اولیه‌ی داده‌ها

نرخ پایه برای هریک از نژادها در جدول ؟؟ آمده است.

race	two_year_recid
African-American	0.523150
Caucasian	0.390870

توزیع متغیر decile_score برای گروه‌های نژادی مختلف در شکل ۱۰.۱ آمده است و نشان می‌دهد که توزیع امتیاز خطر در میان گروه‌های مختلف یکسان نیست و برخی گروه‌ها به‌طور متوسط امتیازهای بالاتری دریافت کرده‌اند. چنین اختلافی نشان‌دهنده‌ی تفاوت در توزیع داده‌ها میان گروه‌های حساس است که می‌تواند منجر به ایجاد سوگیری در مدل‌های پیش‌بینی شود.




شکل ۱.۱: توزیع امتیاز خطر COMPAS بر حسب نژاد

به‌منظور بررسی میزان اطلاعات نژادی موجود در ویژگی‌ها، یک مدل کمکی برای پیش‌بینی نژاد از روی سایر ویژگی‌ها آموزش داده شد. این مدل توانست با دقت حدود 0.67 مقدار نژاد را پیش‌بینی کند.

مهم‌ترین ویژگی‌های مؤثر در این پیش‌بینی در شکل ۲.۱ نمایش داده شده‌اند. مشاهده می‌شود که حتی در صورت حذف مستقیم ویژگی نژاد، برخی ویژگی‌ها همچنان نقش متغیرهای جانشین (Proxy Features) را ایفا می‌کنند. این موضوع یکی از دلایل اصلی باقی ماندن سوگیری پس از حذف ویژگی حساس است.

پس یعنی نمی‌توان گفت که صرفاً با حذف ویژگی نژاد مسئله سوگیری حل می‌شود و با راه‌های نسبتاً پیچیده‌تری باید این مسئله را حل کرد.




شکل ۲.۱: مهم‌ترین ویژگی‌های جانشین برای پیش‌بینی نژاد

جدول ۲.۱: گزارش عملکرد مدل برای پیش‌بینی ویژگی نژاد از روی سایر ویژگی‌ها

Group	Precision	Recall	F1-score	Support
African-American	0.69	0.83	0.75	635
Caucasian	0.62	0.44	0.52	421
Accuracy		0.67		1056
Macro Avg	0.66	0.63	0.63	1056
Weighted Avg	0.66	0.67	0.66	1056

مدل پایه

در ادامه یک مدل Regression Logistic بر روی داده‌های آموزش آموزش داده شد. منحنی ROC مدل در شکل ۳.۱ نمایش داده شده است. مقدار بالای سطح زیر منحنی (AUC) نشان می‌دهد که مدل از قدرت تفکیک مناسبی برخوردار است و می‌تواند افراد دارای احتمال تکرار جرم را از سایر افراد با دقت قابل قبول متمایز کند.



شکل ۳.۱: منحنی ROC مدل پایه


نتایج مربوط به fairness در جدول ۳.۱ آمده است. می‌توان دید که به غیر از demographic parity مدل در سایر زمینه‌ها عملکرد بسیار خوبی دارد. مثلاً هر دو نژاد شانس برابری دارند. به این معنی که نرخ خطا برابر است. پس در ادامه بررسی‌ها هدف بهبود demographic parity است.

جدول ۳.۱: اختلاف معیارهای انصاف میان گروه‌های نژادی

Metric	Between-group Gap
Demographic Parity	0.141
Equal Opportunity	0.000
False Positive Rate Parity Difference (FPR Gap)	0.042
PPV Difference	0.015

تحلیل عملکرد مدل بر حسب نژاد

برای بررسی دقیق‌تر رفتار مدل، منحنی ROC برای هر گروه نژادی به صورت جداگانه رسم شد. نتیجه در شکل ۴.۱ ارائه شده است.



شکل ۴.۱: منحنی ROC به تفکیک گروه‌های نژادی

همان‌گونه که مشاهده می‌شود، منحنی مربوط به افراد سفیدپوست در تمامی نقاط بالاتر از منحنی افراد سیاه‌پوست قرار دارد و در مقادیر نسبتاً کوچک FPR به مقدار تقریباً یک برای TPR می‌رسد. در مقابل، منحنی ROC مربوط به افراد سیاه‌پوست فاصله‌ی بسیار کمتری با خط قطری دارد و در نتیجه توان تفکیک مدل برای این گروه ضعیف‌تر است.

این اختلاف نشان می‌دهد که مدل اطلاعات موجود در داده‌های مربوط به گروه سفیدپوست را بسیار بهتر از گروه سیاه‌پوست یاد گرفته است. از آنجا که Equalized Odds مستلزم برابری همزمان TPR و FPR میان گروه‌ها است، فاصله‌ی زیاد میان منحنی‌های ROC بیانگر آن است که دستیابی به این معیار تنها از طریق تغییر آستانه‌ی تصمیم دشوار خواهد بود و احتمالاً مستلزم کاهش قابل توجهی در دقت مدل است.

روش‌های کاهش سوگیری

به‌منظور مقایسه‌ی سه دسته‌ی روش‌های کاهش سوگیری، سه رویکرد مختلف مورد استفاده قرار گرفت.

در مرحله‌ی پیش‌پردازش از الگوریتم Disparate Impact Remover استفاده شد. این روش با تغییر توزیع برخی ویژگی‌ها تلاش می‌کند وابستگی میان ویژگی‌های ورودی و ویژگی حساس را کاهش دهد، بدون آنکه برجسب‌های داده تغییر کنند.

در مرحله‌ی درون‌پردازش از الگوریتم Exponentiated Gradient همراه با قید Demographic Parity استفاده شد. این روش هنگام آموزش مدل، قید انصاف را مستقیماً وارد مسئله‌ی بهینه‌سازی می‌کند و میان بیشینه‌سازی دقت و رعایت معیار انصاف نوعی مصالحه ایجاد می‌نماید.

در مرحله‌ی پس‌پردازش بهینه‌سازی آستانه چک شد. منتها همانطور که در شکل ۴.۱ آمده است، ROC curve ها از هم واگرا هستند، پس با هر آستانه‌ای باز نمی‌توان به میزان خوبی از fairness رسید، برای همین این موضوع بیش از این بررسی نشد. (زیرا سایر روش‌ها دقت بهتری می‌دهند.)

جدول ۴.۱: مقادیر سنجه‌های انصاف برای حذف‌کننده تأثیر نامتناسب

Metric	Between-group Gap
Demographic Parity	0.123
Equal Opportunity	0.028
False Positive Rate Parity Difference (FPR Gap)	0.035
PPV Difference	0.012

جدول ۵.۱: مقادیر سنجه‌های انصاف برای روش گرادینت نمایشی


Metric	Between-group Gap
Demographic Parity	0.028
Equal Opportunity	0.093
False Positive Rate Parity Difference (FPR Gap)	0.049
PPV Difference	0.098

جدول ۶.۱: دقت مدل‌های مختلف

Model	Accuracy
Baseline Logistic Regression	0.97
Pre-processing (Disparate Impact Remover)	0.96
In-processing (Exponentiated Gradient)	0.88

بده‌بستان میان دقت و انصاف

به‌منظور بررسی اثر تغییر آستانه، مقدار آستانه‌ی تصمیم در ۹ مقدار مختلف بین ۰/۱ تا ۱ تغییر داده شد. برای هر مقدار، Accuracy و اختلاف Demographic Parity و Equal Opportunity محاسبه گردید. نتیجه در شکل ۵.۱ نشان داده شده است.



شکل ۵.۱: بده‌بستان میان دقت و انصاف

نتایج نشان می‌دهد که با افزایش Accuracy اختلاف Parity Demographic نیز افزایش پیدا می‌کند. به بیان دیگر، هرچه مدل از نظر دقت بهتر عمل می‌کند، نرخ پذیرش میان گروه‌های مختلف نیز از یکدیگر فاصله‌ی بیشتری می‌گیرد. این موضوع بیانگر وجود یک بده‌بستان میان پیشینه‌سازی عملکرد مدل و رعایت Parity Demographic است.

در مقابل، هنگام بررسی معیار Opportunity Equal روندی تقریباً معکوس مشاهده شد؛ به گونه‌ای که بهبود این معیار معمولاً با کاهش Accuracy همراه بود. این نتیجه با مباحث نظری مطرح‌شده در بخش دوم همخوانی دارد و نشان می‌دهد که معیارهای مختلف انصاف لزوماً در یک جهت تغییر نمی‌کنند و بهبود یکی از آن‌ها ممکن است موجب بدتر شدن معیار دیگر شود.

پس یعنی ما هرچقدر سعی در بهبود معیار Demographic Parity بکنیم، مقدار Opportunity Equal کاهش می‌یابد. این مسئله در بین مدل‌های مختلف نیز مشهود است. برای مثال در مدل پایه همانطور که در جدول ۳.۱ می‌توان دید، مقدار Opportunity Equal ایده‌آل است. ولی در مدل‌های گرادین نمای، مقدار Demographic Parity خیلی بهتر شده است ولی این به قیمت کمی بدتر شدن Opportunity Equal تمام شده است.

بررسی اتحاد Chouldechova

برای هر یک از آستانه‌های تصمیم، مقادیر FPR ، PPV و FNR برای هر گروه نژادی محاسبه و اتحاد Chouldechova بررسی شد. اختلاف میان مقدار واقعی PPV و مقدار محاسبه‌شده از رابطه‌ی نظری در تمامی آزمایش‌ها در بیشترین حالت حدود $5.56e - 17$ ود. که این اختلاف خیلی ناچیز نیز می‌تواند به علت نویز ذاتی داده و همچنین اختلاف تخمین احتمال از روی داده باشد.

تحلیل تقاطعی

عملکرد مدل گرادبان نمایی برای گروه‌های تقاطعی حاصل از ترکیب نژاد و جنسیت نیز بررسی شد. نتایج مقادیر انصاف در جدول ۷.۱ آمده است. این مقادیر به ازای گروه‌های نژاد، جنسیت و نژاد-جنسیت حساب شده‌اند. همانطور که می‌توان دید، مدل هم در بخش نژاد و هم در بخش جنسیت از لحاظ انصاف خوب است. ولی وقتی به ترکیب دو ویژگی نگاه می‌کنیم مدل عملکرد متوسطی دارد.

جدول ۷.۱: سنجه‌های انصاف برای گروه‌های حساس مختلف در تحلیل تقاطعی

Sensitive Attribute	Metric	Between-group Gap
Race	Demographic Parity	0.046
	Equal Opportunity	0.075
	False Positive Rate Parity Difference (FPR Gap)	0.031
	PPV Difference	0.083
Sex	Demographic Parity	0.031
	Equal Opportunity	0.061
	False Positive Rate Parity Difference (FPR Gap)	0.044
	PPV Difference	0.094
Race-Sex	Demographic Parity	0.066
	Equal Opportunity	0.109
	False Positive Rate Parity Difference (FPR Gap)	0.089
	PPV Difference	0.174

سوال ۲

سوال دوم - حریم خصوصی در یادگیری ماشین و یادگیری فدرال

بخش اول

زیربخش اول - حساسیت و مکانیزم لاپلاس

الف

۱. میانگین مصرف: در اینجا بیشترین تفاوت وقتی است که یک خانوار بدون مصرف با یک خانوار که بیشترین مصرف را دارد جایگزین شود. در اینصورت داریم:

$$\max(q_1(D) - q_1(D')) = \frac{sum + 100}{1000} - \frac{sum}{1000} = 0.1$$

۲. کل مصرف این مشابه بخش میانگین است با این تفاوت که نیازی نیست به تعداد تقسیم کنیم. پس داریم:

$$\max(q_2(D) - q_2(D')) = \text{sum} + 100 - \text{sum} = 100$$

۳. تعداد خانوار در هر الگوی مصرف: در اینجا بیشترین تفاوت وقتی است که الگوی مصرف دو خانواری که باهم تفاوت دارند، هیچ اشتراکی نداشته باشد. پس یعنی بردار تعداد الگوی مصرف در ۴ الگو، اختلاف یک دارد (یا در دو الگو اختلاف ۲) پس یعنی مقدار حساسیت برابر با ۴ است.

ب

برای مکانیزم لاپلاس داشتیم:

$$b = \frac{\Delta}{\epsilon} \xrightarrow{\epsilon=0.2} b = 5\Delta$$

با جایگذاری Δ برای هر مورد داریم:

۱. میانگین مصرف:

$$b = 5\Delta = 0.5$$

۲. کل مصرف

$$b = 5\Delta = 500$$

۳. تعداد خانوار در هر الگوی مصرف:

$$b = 5\Delta = 20$$

زیربخش دوم - انتشار خصوصی داده‌ها

الف

از آنجایی که نویز اعمال شده روی هر کوثری مستقل از سایر کوثری‌ها می‌باشد، این ناسازگاری می‌تواند رخ دهد. در مثال سوال، چون نویز میانگین مستقل از نویز جمع مصرف است، مقدار میانگین گزارش داده شده با جمع گزارش داده شده ناسازگار است.

در اینجا چون می‌دانیم که جمع مصرف هزار برابر میانگین مصرف است، می‌توان این قید را اجبار کرد که پس از اعمال نویز بتوان این قید را ارضا کرد.

ب

$$b = 2.5\Delta = 10$$

ج

در این حالت بجای اینکه Δ برابر با ۴ شود، برابر با یک می‌شود. پس داریم:

$$b = 2.5\Delta = 2.5$$

حال اگر نویزهای داده‌شده را روی داده اعمال کنیم داریم:

$$\begin{aligned} v &= [310 \quad 295 \quad 180 \quad 160 \quad 90 \quad 75] \\ \text{noise} &= [-4 \quad 18 \quad 9 \quad -6 \quad 21 \quad 2] \\ \Rightarrow v + \text{noise} &= [306 \quad 313 \quad 189 \quad 154 \quad 111 \quad 77] \Rightarrow \operatorname{argmax}(v + \text{noise}) = 2 \end{aligned}$$

یعنی در داده‌های اصلی، داده با بیشترین تکرار الگوی مصرف یک بود ولی در داده‌های نویزی الگوی مصرف دو به عنوان بیشینه معلوم شد و خروجی داده می‌شود.

این موضوع به این بده بستان اشاره دارد که هرچقدر بخواهیم بیشتر حریم خصوصی را رعایت کنیم، داده‌ها بیشتر نویزی می‌شوند و در نتیجه اطلاعات و الگوهای داده‌ها بیشتر خراب می‌شود پس دقت مدل (و یا عملکرد سیستم استفاده‌کننده بصورت کلی) افت می‌کند.

زیربخش سوم - تخصیص بودجه حریم خصوصی و ترکیب مکانیزم‌ها

الف

از آنجایی که دقت میانگین مصرف مهم‌تر است پس یعنی بالااجبار حریم خصوصی در آن بیشتر فدا می‌شود پس سهم بیشتری از ϵ باید به میانگین مصرف داده شود. تقسیم‌بندی پیشنهادی من در جدول

جدول ۱.۲: تقسیم ϵ بین مکانیزم‌ها

ϵ	مکانیزم
0.4	میانگین مصرف
0.1	پرتکرار ترین الگوی مصرف
0.1	الگوی مصرف شماره ۶

ب

داریم:

$$b = \frac{\Delta}{\epsilon} = \frac{0.1}{0.4} = 0.25$$

ج

داریم:

$$l_2 = \max(\|f(D) - f(D')\|_2) = \sqrt{1} = 1 \quad \epsilon = 0.1 \quad \delta = 0.1$$

$$\sigma \geq \frac{\sqrt{2 \ln\left(\frac{1.25}{\delta}\right)}}{\epsilon} \xrightarrow{c \approx 2.25} \sigma \geq \frac{2.25}{0.1} \Rightarrow \sigma \geq 22.5$$

د

طبق قانون composition مقدار ϵ ها با هم جمع می‌شود. پس یعنی مقدار privacy loss برابر با $7 * 0.6 = 4.2$ می‌شود. اگر بخواهیم privacy loss کل هفته برابر با 0.6 باقی بماند، باید privacy loss مجموع هر روز را برابر با $\frac{0.6}{7}$ در نظر بگیریم. این موضوع باعث می‌شود تا مقدار نویز خیلی زیاد شود و utility کاهش می‌یابد.

بخش دوم - سوالات مفهومی

زیربخش اول - حریم خصوصی، استحکام و یادگیری فدرال

الف

خیر نمی‌توان. برای مثال در درس حمله‌های مبتنی بر گرادیان را داشتیم که تقریباً ورودی اولیه را بصورت کامل بازسازی می‌کردند.

بهبود عملی حریم خصوصی به معنی الگوریتم‌هایی است که در عمل حریم خصوصی را بهبود می‌دهند ولی اثبات ریاضی برای حد و حدود آن ندارند. در مقابل تضمین رسمی حریم خصوصی به معنی الگوریتم و یا اثبات‌هایی است که کران حریم خصوصی را بطور ریاضی نشان و ثابت می‌کنند (این بخش رو من از تو مقاله پیدا نکردم. با استفاده از ai خوندم که هر کدام از الگوریتم‌ها تو کدام دسته است).

ب

حریم خصوصی به این معنا است که مدل از اطلاعات ورودی خود محافظت کند و مهاجم نتواند راجع به داده آموزشی اطلاعاتی کسب کند. ولی مقاوم بودن به این معنا است که مدل نسبت به حملات مخرب، مثلاً حملات backdoor و یا خصمانه مقاوم باشد.

مثلاً با LDP اگر کلاینتی LDP را اعمال نکند فضای حل بزرگ‌تری خواهد داشت و می‌تواند تاثیر بیشتری بر مدل بگذارد. پس اگر یک مهاجم که قصد حمله backdoor داشته باشد باشیم، می‌تواند راحت تر مدل را آلوده کند. در اینجا حریم خصوصی همچنان حفظ شده ولی این حفظ حریم خصوصی باعث شده است تا مدل کمتر مقاوم باشد.

ج

خیر. زیرا در درس داشتیم که با صعود گرادیان، و معکوس کردن فرآیند Backpropagation می‌توان ورودی را تقریباً کامل بازسازی کرد. هرچند که مدل B باز داده کمتری می‌دهد و همچنین راه را برای حفظ حریم خصوصی بیشتر باز می‌گذارد، ولی فقط همینکه داده نفرستیم و به روزرسانی وزن‌ها فرستاده شود، تقریباً هیچ فایده‌ای در حریم خصوصی نخواهد داشت.

زیربخش دوم - حملات حریم خصوصی و مسموم سازی در یادگیری فدرال

الف

ناقص

ب

همانطور که در مقاله نیز اشاره می‌شود، هرکاری که با مسموم کردن داده قابل انجام است با مسموم کردن مدل نیز قابل انجام است. ولی مسموم کردن مدل انعطاف بیشتری دارد. مثلاً برای مسموم کردن داده اولاً نیاز به داده‌های خراب زیادی است تا بتوان علیرغم سایر کلاینت‌ها همچنان روی مدل تاثیر گذاشت، دوماً سرور مرکزی ممکن است با کارهایی مثل byzantine tolerance داده‌های خراب را تشخیص دهد و سوماً چون حمله مبتنی بر داده است، تعداد و یا توان مهاجمان باید زیاد باشد. چهارماً اگر مکانیزمی مثل LDP داشته باشیم، در مسموم‌سازی داده اثر آن می‌تواند کم رنگ شود ولی در مسموم‌سازی مدل بسادگی می‌توان نویز را نادیده گرفت. ولی در مسموم کردن مدل، چون می‌توان مستقیماً خود مقدار مقادیر به روز رسانی را تغییر داد، می‌توان با اعمال یک norm از پرت بودن مقادیر نسبت به سایر کلاینت‌ها جلوگیری کرد، یا با زیاد کردن ضریب وزن‌ها تاثیر مهاجم را بیشتر کرد و نیازی هم به داده مجزا ندارد.

ج

- ایده کلی حمله مشابه حمله صعود گرادیان است. منتها در حالت کلی، از آنجایی که ممکن است اثر وجود یک عضو در مجموعه داده کلاینت، توسط به روزرسانی‌های سایر کلاینت‌ها کم شود، سرور مرکزی به یک کلاینت خاص (که کلاینت a می‌نامیم) وزن‌های خود کلاینت a را می‌دهد. در نتیجه مدل a فقط روی داده‌های خودش آموزش می‌بیند و تاثیر حضور و یا عدم حضور یک داده در مجموعه داده آن بیشتر است.

در قدم بعدی وقتی سرور مرکزی می‌خواهد ببیند داده x در مجموعه داده کلاینت a بوده یا نه، x را به مدل ورودی می‌دهد و گرادیان را حساب می‌کند و وزن‌ها را در جهت افزایش آن حرکت می‌دهد. اگر مدل قبلاً این ورودی را دیده باشد، تغییر وزن‌ها معنی‌دار می‌شود ولی اگر این داده در مجموعه داده آموزشی نباشد، مقدار تغییر وزن‌ها کوچک است.

- اگر به شمای گرافیکی تابع یادگرفته شده توسط شبکه‌های عصبی نگاه کنیم، عمدتاً به این شکل هست که یک رویه در مکان‌هایی مقدار خروجی پیک زده (به نوعی شبیه ترکیب چند توزیع نرمال) این کار به اینصورت است که وزن‌های اولیه شبکه بسیار کوچک هستند و می‌توان شبکه را به یک لایه نسبتاً هموار

تشبیه کرد. وقتی برای یک ورودی وزن‌ها می‌خواهند به روز رسانی شوند، این رویه دچار قله/دره می‌شود. حال اگر نمونه‌ای که به مدل ورودی داده می‌شود نمونه جدیدی باشد، انگار یک نقطه روی بخش هموار رویه را ورودی داده‌ایم و مقدار آن کم است (شیب در آن ناحیه خیلی زیاد نیست). ولی وقتی یک داده که از قبل دیده شده ورودی داده شود، مدل با تغییر وزن می‌خواهد از یکی از این قله/دره‌ها در بیاید پس تغییر زیاد است.

زیربخش سوم

خطوط پایه

- **Norm Bounding** این روش در هر مرحله به روزرسانی کلاینت‌ها را دریافت می‌کند و در صورتی که نرم یک به روزرسانی از یک حد آستانه بیشتر باشد یا آن را اصلاً اعمال نمی‌کنیم و یا مقادیر آن را کاهش می‌دهیم تا نرم آن در حد آستانه قرار بگیرد.
- **WeakDP** این روش ابتدا Norm Bounding را انجام می‌دهد و سپس یک نویز گاوسی با واریانس ثابت را روی نتیجه اعمال می‌کند. ولی از آنجایی که واریانس از روی ϵ بدست نمی‌آید، مقدار privacy loss در این مکانیزم خیلی زیاد است و عملاً differential privacy خاصی ارائه نمی‌دهد.

CDP و LDP

- **CDP**: در این روش مکانیزم اضافه کردن نویز برای Differential Privacy در سرور مرکزی و روی همه داده‌ها اعمال می‌شود.
- **LDP**: در این روش مکانیزم اضافه کردن نویز برای Differential Privacy در کلاینت‌ها و قبل از ارسال وزن‌ها به سرور مرکزی انجام می‌شود.

تفاوت اصلی در این است که LDP برای دفاع در برابر حمله از سمت سرور مرکزی و CDP برای دفاع در برابر کلاینت‌های مخرب است. مثلاً حمله ویژگی، که از سمت یک کلاینت مخرب است با LDP فایده‌ای ندارد ولی CDP بصورت تئوری می‌تواند در برابر این حمله مقداری دفاع کند. (هرچند که نتیجه خوبی نمی‌دهد).

برای حمله‌هایی که نه از سمت کلاینت و نه از سمت سرور هستند هر دو رویکرد نتیجه خوبی دارند.

ناکارآمدی CDP

در این حملات CDP توانایی دفاع را دارد. ولی چون مقدار ϵ کم است، باعث می‌شود تا نویز شدید شود و utility خیلی کاهش یابد. عملاً دلیل ضعف مدل با CDP و ضعیف بودن weak DP ریشه یکسانی دارد. تقابل utility و privacy

طراحی سیستم پزشکی

اگر چالشی برای کلاینت مخرب نداریم (که با توجه به اینکه ده بیمارستان بزرگ کلاینت‌ها هستند احتمالاً نداشته باشیم) استفاده از CDP بهتر است. CDP هم utility بهتری دارد و هم در برابر حملات، نرخ حمله موفق کمتری دارد.

بخش سوم - سوالات پیاده‌سازی

زیربخش اول: آماده‌سازی داده‌ها

بارگذاری و بررسی اولیه داده


دیتاست FE

جدول ۲.۲: آمار دیتاست FEMNIST


ویژگی	مقدار
تعداد کل نمونه‌ها	۸۱۴,۲۷۷
تعداد کلاس‌ها	۶۲
تعداد نویسندگان	۳,۵۹۷
تعداد نویسندگان عضو	۳,۳۹۷
تعداد نویسندگان غیرعضو	۲۰۰
تعداد نمونه‌های آموزشی	۷۶۹,۶۳۴
تعداد نمونه‌های تست	۴۴,۶۴۳

همان‌طور که در جدول مشخص است، دیتاست شامل تنوع بالایی از نویسندگان و کلاس‌ها است. تصاویر نمونه‌ای از این دیتاست در شکل ۱.۲ نمایش داده شده است که نشان می‌دهد تصاویر شامل اعداد و حروف دست‌نوشته‌ی مختلف با اندازه‌ی ۲۸ در ۲۸ پیکسل هستند. توزیع تعداد نمونه‌ها در بین نویسندگان نیز در شکل ۲.۲ نشان داده شده است که حاکی از توزیع نابرابر است و برخی نویسندگان تعداد نمونه‌های بسیار بیشتری نسبت به دیگران دارند. این با موضوع مقاله که تفاوت حمله‌های record level و subject level در

federated learning است مرتبط است.



شکل ۱.۲: نمونه تصاویر دیتاست FEMNIST به همراه برچسب واقعی



شکل ۲.۲: توزیع تعداد نمونه‌ها به ازای هر نویسنده

تعریف مجموعه‌های Member و Non-Member

دیتاست به صورت تصادفی به دو مجموعه تقسیم شد. ۳,۳۹۷ نویسنده به عنوان Subjects Member و ۲۰۰ نویسنده به عنوان Subjects Non-Member در نظر گرفته شدند. جدول ۳.۲ تعداد نویسندگان و تصاویر مربوط به هر مجموعه را نشان می‌دهد.

جدول ۳.۲: تعداد نویسندگان و تصاویر در مجموعه‌های Member و Non-Member


مجموعه	تعداد نویسندگان	تعداد تصاویر
Subjects Member	۳,۳۹۷	۷۶۹,۶۳۴
Subjects Non-Member	۲۰۰	۴۴,۶۴۳

ایجاد ساختار Cross-Silo

داده‌ها به ۸ گروه مستقل تقسیم شدند. روش توزیع به این گونه انجام شد که برای هر نویسنده از روی یک توزیع شبیه به توزیع نمایی (ولی بصورت گسسته و clip شده بین ۱ تا ۶) معلوم شد که باید داده‌های این نویسنده بین چند سازمان پخش شود و سپس این پخش شدن انجام شد. جدول ۴.۲ و شکل ۳.۲ آمار هر سازمان را نشان می‌دهند.

جدول ۴.۲: توزیع داده‌ها بین سازمان‌ها


سازمان	تعداد تصاویر	درصد از کل داده‌ها	تعداد نویسنده‌ها
۰ Silo	۱۹۱,۰۴۷	۴٪.۱۲	۳,۳۹۷
۱ Silo	۱۹۱,۱۰۱	۴٪.۱۲	۳,۳۹۷
۲ Silo	۱۹۱,۳۱۰	۴٪.۱۲	۳,۳۹۷
۳ Silo	۱۹۱,۲۶۶	۴٪.۱۲	۳,۳۹۷
۴ Silo	۱۹۱,۷۱۴	۵٪.۱۲	۳,۳۹۷
۵ Silo	۱۹۱,۴۶۲	۴٪.۱۲	۳,۳۹۷
۶ Silo	۱۹۱,۲۷۷	۴٪.۱۲	۳,۳۹۷
۷ Silo	۱۹۱,۲۵۸	۴٪.۱۲	۳,۳۹۷




شکل ۳.۲: سهم هر سازمان از کل داده‌های آموزشی

تحلیل آماری و مصورسازی

تحلیل آماری انجام شده بر روی ساختار داده‌ها، نشان‌دهنده ویژگی‌های مهمی است که در شکل‌های ۴.۲ و ۵.۲ قابل مشاهده است.



شکل ۴.۲: توزیع تعداد سازمان‌هایی که هر Subject در آن حضور دارد



شکل ۵.۲: درصد های Subject حاضر در یک سازمان در مقابل چند سازمان

همان‌طور که در شکل ۴.۲ مشاهده می‌شود، تعداد سازمان‌ها به ازای هر نویسنده شبیه به یک توزیع نمایی است. شکل ۵.۲ نشان می‌دهد که حدود ۵۲٪ از نویسنده‌ها در یک سازمان و ۴۸٪ در چند سازمان توزیع

شده‌اند.

زیربخش دوم: آموزش مدل

. یک مدل CNN ساده با معماری زیر برای آموزش طراحی گردید:

- دو لایه کانولوشن با ۱۶ و ۳۲ فیلتر به ترتیب و size kernel برابر با ۳
- لایه‌های ReLU و MaxPooling برای هر لایه کانولوشن
- لایه AdaptiveAvgPool2d برای کاهش ابعاد
- دو لایه Fully Connected با ۱۲۸ و ۶۲ نرون (به تعداد کلاس‌ها)

پارامترهای آموزش به صورت زیر تنظیم شدند:

- تعداد دوره‌های ارتباطی: ۵
- تعداد های Epoch محلی: ۱
- نرخ یادگیری: ۰.۵۰
- تابع هزینه: CrossEntropyLoss
- بهینه‌ساز: SGD با momentum ۰.۹۰


فقط از داده‌های member برای آموزش استفاده شد و از داده‌های non member برای آموزش استفاده‌ای نشد. البته برای evaluation عملکرد مدل روی این داده‌ها حساب شد ولی مدل آموزش داده نشد.

مکانیزم تعامل بین سازمان‌ها و Server به این صورت بود که در هر دور، مدل جهانی به هر سازمان ارسال شده و سازمان‌ها مدل را بر روی داده‌های محلی خود به تعداد های Epoch مشخص آموزش می‌دهند. سپس وزن‌های به‌روزرسانی شده به سرور ارسال شده و سرور با میانگین‌گیری از وزن‌های تمام سازمان‌ها، مدل جهانی جدید را تولید می‌کند.

نتایج آموزش در شکل ۶.۲ نشان داده شده است. دقت مدل بر روی داده‌های آموزشی Member Subjects از

0.0905 در دور اول به 0.8004 در دور پنجم رسید که نشان‌دهنده‌ی همگرایی مناسب مدل است. همچنین دقت مدل بر روی داده‌های تست Subjects Non-Member که در فرآیند آموزش شرکت نداشتند،

از 0.0930 به 0.8042 افزایش یافت.



شکل ۶.۲: دقت و تابع هزینه مدل در طول دوره‌های آموزش فدرال

جدول ۵.۲: اظهارنامه استفاده از هوش مصنوعی

ابزار	برای چه کاری استفاده شد	شرح استفاده
ChatGPT	ریویو و درک مقاله‌ها	برای مرور سریع مقاله‌های مرتبط با In-Membership COMPAS، Privacy Differential و fference، کمک گرفتم تا مفاهیم کلیدی را سریع‌تر درک کنم و به ساختار مقاله مسلط شوم.
ChatGPT	پیاده‌سازی فیلترهای ProPublica	از AI در مورد فیلترهای استاندارد ProPublica برای پالایش دیتاست COMPAS سوال پرسیدم و منطق فیلتر کردن داده‌ها را بررسی کردم.
ChatGPT	تبدیل جدول‌ها به LaTeX	برای تبدیل جدول‌های خروجی pandas به کد LaTeX و فرمت‌دهی مناسب جداول در گزارش از AI کمک گرفتم.
ChatGPT	بهبود ظاهر جداول و نمودارها	برای زیباسازی جداول (افزودن خطوط، تنظیم ستون‌ها) و تنظیم اندازه و کیفیت نمودارها (افزودن برچسب، عنوان، ذخیره با dpi مناسب) از AI کمک گرفتم.
ChatGPT	ریویو و ویرایش نگارشی گزارش	پس از نوشتن پیش‌نویس گزارش، از AI برای ویرایش نگارشی، بهبود روان‌نویسی و یکدست‌سازی لحن متن استفاده کردم.
ChatGPT	کد ریویو	کدهایی که من برای آموزش مدل زدم به مقدار زیادی پیچیده بودن. برای ریویوش از gpt کمک گرفتم

منابع

- [١] Lamdaa. “Compas: Unfair algorithm?” Medium, Accessed: Nov. ٢٢.٢٠٢٣ [On-line]. Available: <https://medium.com/@lamdaa/compas-unfair-algorithm-812702ed6a6a>.