



به نام خدا



دانشگاه تهران

پردیس دانشکده‌های فنی

دانشکده برق و کامپیوتر

درس: هوش مصنوعی قابل اعتماد

مدرس: دکتر مصطفی توسلی پور

تمرین شماره ۴

خرداد ماه ۱۴۰۵

۴	سوال اول: fairness
۶	بخش اول: مبانی و نظریه
۶	پرسش ۱: (سه معیار مشاهده‌ای) (۸ نمره)
۶	پرسش ۲: (استخراج یک نتیجه عدم امکان (اتحاد چولدچوا)) (۱۰ نمره)
۷	پرسش سوم: (انصاف علی و خلاف واقع) (۶ نمره)
۹	بخش دوم: پرسش‌های مفهومی و کاربردی
۹	پرسش ۴: (مسئله جانشین/برچسب در سلامت) (۸ نمره)
۱۰	پرسش ۵: (انتخاب معیار، تحت قید عدم امکان (اعطای وام)) (۶ نمره)
۱۰	پرسش ۶: (داوری مناقشه COMPAS (در پیوند با بخش اول)) (۸ نمره)
۱۱	پرسش ۷: (فراتر از انصاف حاشیه‌ای: زیرگروه‌ها و زمان) (۶ نمره)
۱۲	بخش سوم: پیاده‌سازی و تحلیل تجربی
۱۵	سوال دوم: حریم خصوصی در یادگیری ماشین و یادگیری فدرال
۱۶	بخش اول: سوالات توضیحی
۱۶	زیربخش اول: (حساسیت و مکانیزم لاپلاس) (۲ نمره)
۱۶	زیربخش دوم: (انتشار خصوصی داده‌ها و Report Noisy Max) (۳ نمره)
۱۷	زیربخش سوم: (تخصیص بودجه حریم خصوصی و ترکیب مکانیزم‌ها) (۴ نمره)
۱۹	بخش دوم: سوالات مفهومی
۱۹	زیربخش اول: (حریم خصوصی، استحکام و یادگیری فدرال) (۳ نمره)
۱۹	زیربخش دوم: (حملات حریم خصوصی و مسموم‌سازی در یادگیری فدرال) (۶ نمره)
۲۰	زیربخش سوم: (مکانیزم‌های دفاعی و مبادله حریم خصوصی-استحکام-سودمندی) (۷ نمره)
۲۲	بخش سوم: سوالات پیاده‌سازی
۲۳	زیربخش اول: (آماده‌سازی داده‌ها) (۵ نمره)
۲۴	زیربخش دوم: (آموزش مدل فدرال) (۷ نمره)
۲۵	زیربخش سوم: (ارزیابی حملات Membership Inference) (۸ نمره)
۲۶	زیربخش چهارم: (دفاع مبتنی بر Differential Privacy) (۱۰ نمره)
۲۸	نکات تحویل

منابع مجاز و سیاست استفاده از ابزارهای هوش مصنوعی

این تمرین طوری طراحی شده است که تا جای ممکن آنچه ارزیابی می‌شود، فهم خود شما باشد، نه خروجی ابزارهای مبتنی بر AI. استفاده از دستیارهای هوش مصنوعی و تاجای ممکن برای این کارها مجاز است: جست‌وجوی نحو و رابط برنامه‌نویسی (API) کتابخانه‌ها، اشکال‌زدایی کدی که خودتان نوشته‌اید و نیز ویرایش نگارشی نوشته خودتان.

در پایان، با توجه به گسترش روزافزون به‌کارگیری این ابزارها، دور از انتظار نیست که شما نیز از آن‌ها بیشترین بهره را برده باشید؛ هرچند ما استفاده از آن‌ها را توصیه نمی‌کنیم. با این حال، خود مهارت پرامپت‌نویسی و توسعه با کمک این ابزارها مهارتی ضروری است. به همین دلیل، پر کردن «**اظهارنامه استفاده از هوش مصنوعی**» در انتهای این تمرین الزامی است.

از شما می‌خواهیم در تکمیل این اظهارنامه تا جای ممکن با ما روراست باشید. اگر بیش از حدی که توصیه کرده‌ایم از این ابزارها استفاده کرده و آن را در این اظهارنامه اعلام نکرده باشید و ما از آن آگاه شویم، مشمول کسر نمره و جریمه خواهید شد.

در تکمیل این اظهارنامه دقیق باشید: متن کامل و دقیق هر پرامپت، به همراه ابزاری که از آن بهره گرفته‌اید، و هر جزئیات مهم دیگر را به‌روشنی شرح دهید.

سوال اول: FAIRNESS

یک سیستم یادگیری ماشین می‌تواند دقت‌های بسیار بالایی را به ما بدهد و در عین حال ناعادلانه باشد. این دو ویژگی یکی نیستند، و خلط‌کردن آن‌ها یکی از مهمترین مشکلات بخش بزرگی از نرم‌افزارها و سیستم‌هایی هست که امروز به کار گرفته می‌شوند. به عنوان نمونه‌ای از سیستم‌های نرم‌افزاری می‌توان به مواردی مانند زیر اشاره کرد:

مدل‌هایی که وثیقه تعیین می‌کنند، متقاضیان شغل را رتبه‌بندی می‌کنند، نرخ اعتبار را ارزش‌گذاری می‌کنند، حساب‌های کاربری را به‌عنوان تقلب نشانه‌گذاری می‌کنند، نوبت پیگیری درمان را تخصیص می‌دهند و محتوای کاربران را تایید می‌کنند، اکنون با توابع هدفی آموزش، اعتبارسنجی و عرضه می‌شوند (مانند AUC, Log-Loss، درآمد موردانتظار) که هیچ حرفی درباره این نمی‌زنند که هزینه خطاهای اجتناب‌ناپذیر مدل بر دوش چه کسی می‌افتد. وقتی داده‌های آموزشی جهان را همان‌گونه که بوده (همراه با الگوهایی از محرومیت و همچنین نادیده گرفتن بخشی از داده‌ها) ثبت می‌کنند در نتیجه مدل آموزش دیده با آن‌ها، گرایش دارد همان الگوها را بازتولید کند، و یک قانون تصمیم‌گیری «بهینه» می‌تواند آن‌ها را با دقتی رمزگذاری کند که هیچ بروکراسی انسانی هرگز به آن نرسیده است. در نتیجه این موضوع می‌تواند به ناعدالتی ساختاری و بلند مدت تبدیل شود و حقوق عده زیادی را پایمال کند.

مشکل صرفاً وجود سوگیری نیست؛ مشکل این است که «انصاف^۱» کمیتی یگانه برای بهینه‌سازی نیست. انصاف یک مفهوم مورد مناقشه، چندوجهی و تا اندازه‌ای فلسفی می‌باشد. پژوهش‌های یک دهه اخیر آن را در چندین معیار ریاضی متمایز فرموله کرده‌اند که هر یک شهودی به‌راستی متفاوت را درباره معنای «رفتار برابر» در بر می‌گیرند. نتیجه محوری و تا حدی ناخوشایند این پژوهش‌ها آن است که این معیارها باهم ناسازگارند: به جز موارد منحنی، هیچ قاعده تصمیم‌گیری نمی‌تواند همه آن‌ها را یک‌جا برآورده کند. به بیانی دقیق‌تر، هیچ مدلی نیست که صرفاً «منصفانه» باشد. آنچه در عوض وجود دارد، انتخاب‌های صریح و مناقشه‌پذیر درباره اینکه یک سامانه معین کدام برداشت از انصاف را رعایت خواهد کرد، چه کسی پاسخ‌گوی آن انتخاب است، و این انتخاب به چه بهایی برای دیگر اهداف تمام می‌شود. اکنون ما می‌توانیم در مورد این موارد به بحث و گفتگو بپردازیم و کلیت مباحث موجود در انصاف به این موارد خلاصه می‌شوند.

مناقشه سال ۲۰۱۶ بر سر ابزار سنجش تکرار جرم COMPAS، نمونه بارز این موضوع است. روزنامه‌نگاران ProPublica و شرکت سازنده ابزار (Northpointe که اکنون به نام Equivant تغییر نام داده‌اند)، به نتایجی

^۱ fairness

متضادی درباره اینکه آیا همان سامانه از جنبه نژادی جانبدارانه بوده است یا نه، رسیده‌اند. در این اختلاف نظر، هر دو طرف درست می‌گفتند، چون هر یک در سکوت و پشت پرده، تعریفی متفاوت و قابل دفاع از انصاف را مطرح می‌کردند. این ماجرا داستان یک محصول منحصرا معیوب نیست؛ بلکه داستان یک واقعیت ساختاری است که هر کسی در این حوزه انصاف باید آن را درونی‌سازی کند. همچنین، لازم هست که ما درک خوبی از این مشکلات داشته باشیم تا در آینده که با گسترش سیستم‌های هوشمند، مشکلاتی از این دست بیش از پیش نیز پیش خواهند آمد، برای آن‌ها به خوبی آماده باشیم. در این تمرین نیز قصد داریم تا بیشتر با این دست از مشکلات آشنا شویم تا در حد ابتدایی مسلط به این شکل از این مشکلات باشید و در صورت برخورد با آن‌ها سردرگم نشوید و برای شما آشنا باشند.

این سری تمرین از شما می‌خواهد این واقعیت را در سه سطح مورد توجه قرار دهید. نخست، تعریف‌ها را آن‌قدر دقیق بیان کنید که بتوان با آن‌ها استدلال کرد. دوم، تنش‌های میان تصمیم‌های را آن‌قدر خوب درک کنید که بتوانید به یک تصمیم‌گیرنده واقعی مشورت دهید که کدام را و چرا برگزیند. سوم، ناعدالتی‌ها را در یک طبقه‌بندی واقعی بتواند اندازه‌گیری کنید و بکوشید که آن‌ها را تعدیل کنید، و با بده‌بستان‌ها به‌جای خطابه کردن، به‌شکل واقعی و با استدلال روبه‌رو شوید.

بخش اول: مبانی و نظریه

پرسش ۱: (سه معیار مشاهده‌ای) (۸ نمره)

الف سه معیار استقلال (Independence)، جداسازی (Separation) و بسندگی (Sufficiency) را به صورت صوری و در قالب گزاره‌هایی از استقلال شرطی میان R (یا $\hat{Y}$)، Y و A تعریف کنید.

ب برای هر معیار، دست کم یک استاندارد، به نام معیار انصاف، که آن معیار را برای یک تصمیم دودویی نمونه‌سازی می‌کند، نام ببرید و آن را به صورت تساوی احتمال‌ها بنویسید (مثلاً برابری جمعیتی، فرصت برابر، برابری شانس‌ها، برابری/کالیبراسیون پیش‌بینی، یا برابری پیش‌بینی).

ج برای هر معیار، در یک الی دو جمله شهود هنجاری آن را بیان کنید (اینکه می‌خواهد جلوی چه نوع آسیب یا بی‌انصافی‌ای را بگیرد) و یک کاربرد واقعی مثال بزنید که در آن همین معیار موجه‌ترین انتخاب اصلی باشد؛ سپس این تناسب را توجیه کنید.

د نشان دهید که استقلال و بسندگی در حالت کلی با هم ناسازگارند: وقتی نرخ‌های پایه در گروه‌ها متفاوت‌اند ($P(Y = 1 | A = 0) \neq P(Y = 1 | A = 1)$) و امتیاز غیربدیهی است، این دو نمی‌توانند هم‌زمان برقرار باشند. یک استدلال صوری کوتاه به همراه کمی توضیح و شهود کافی است.

پرسش ۲: (استخراج یک نتیجه عدم امکان (اتحاد چولدچوا)^۲) (۱۰ نمره)

یک گروه را در نظر بگیرید و فرض کنید $p = P(Y = 1)$ نرخ پایه آن باشد. برای یک پیش‌بین دودویی، نرخ مثبت کاذب $FPR = P(\hat{Y} = 1 | Y = 0)$ ، نرخ منفی کاذب $FNR = P(\hat{Y} = 0 | Y = 1)$ و ارزش اخباری مثبت $PPV = P(Y = 1 | \hat{Y} = 1)$ را تعریف می‌کنیم.

الف اتحاد زیر را به دست آورید و همه گام‌های جبری را نشان دهید:

^۲ Chouldechova identity

$$FPR = \frac{p}{1-p} \cdot \frac{1-PPV}{PPV} \cdot (1-FNR)$$

کار را از تعریف PPV برحسب مثبت‌های درست / غلط (TP و FP) شروع کنید.

ب با استفاده از بند (الف) ثابت کنید: اگر $A \in \{0, 1\}$ دو گروه را با نرخ‌های پایه متفاوت $p_0 \neq p_1$ مشخص کند و دسته‌بند در هر دو گروه PPV یکسانی داشته باشد، آنگاه نمی‌تواند FNR و FPR را هم‌زمان در دو گروه برابر کند (مگر در یک حالت تباهیده^۲ یا مرزی). منظورتان از «تباهیده» را دقیق مشخص کنید.

ج توضیح دهید این نتیجه دقیقاً چگونه زیربنای مناقشه COMPAS است: بگویید شرکت سازنده (Northpointe) کدام معیار را به‌عنوان معیار برآورده‌شده برجسته کرد، روزنامه‌نگاران (ProPublica) نقض کدام معیار را نشان دادند، و چرا این اختلاف (با توجه به نابرابری نرخ‌های پایه) به‌جای آنکه خطای مدل‌سازی باشد، از نظر ریاضی اجتناب‌ناپذیر بود.

د یک نفر پیشنهاد می‌کند: «کافی است داده‌های بیشتر و بهتری جمع کنیم تا واسنجی، برابری FPR و برابری FNR هم‌زمان برقرار شوند.» دقیقاً تحت چه شرایطی برقراری هم‌زمان این سه ممکن است؟ و پاسخ شما چه چیزی را روشن می‌کند؟ اینکه این بده‌بستان آماری است (صرفاً مصنوع نمونه متناهی) یا بنیادی؟


پرسش سوم: (انصاف علی و خلاف واقع) (۶ نمره)

الف انصاف خلاف واقع ([Kusner et al., 2017; "Counterfactual Fairness"](#)) را با استفاده از معناشناسی مدل علی ساختاری^۴ (SCM) و نمادگذاری مداخله (do) تعریف کنید. به‌روشنی بگویید چه چیزی ثابت نگه داشته می‌شود و روی چه چیزی مداخله می‌کنیم.

ب مدل علی ساختاری زیر را برای یک امتیاز استخدام در نظر بگیرید که در آن A جنسیت، X سال‌های تجربه و $\hat{Y}$ امتیاز پیش‌بینی‌شده است:

^۴ Structural-causal-model

^۲ Degenerate regime



در این گراف، مسیر پراکسی (proxy) را از مسیر تبیین‌کننده (resolving) (Kilbertus et al., 2017) تفکیک کنید. یک پیش‌بین منصف باید جلوی کدام اثرهای علی A بر $\hat{Y}$ را بگیرد و کدام‌ها را شاید بتوان مشروع دانست؟ و مهم‌تر از آن، توضیح دهید چرا این تشخیص به یک داوری هنجاری یا حقوقی وابسته است؛ داوری‌ای که داده‌ها به‌تنهایی نمی‌توانند آن را فراهم کنند.

(ج) [ارزیابی یک ادعا]. دانشجویی ادعا می‌کند: «انصاف خلاف‌واقع عینی^۵ است؛ تنها پاسخ را مستقیماً از دل ساختار علی داده‌ها بیرون می‌کشد.» توضیح دهید چرا دو تحلیل‌گر با داده یکسان اما گراف‌های علی متفاوت می‌توانند به نتیجه‌های متضادی درباره منصف‌بودن یک سامانه برسند، و بگویید این موضوع درباره «عینی‌بودن^۶» انصاف علی چه چیزی به ما می‌گوید.

^۶ Objectivity

^۵ Counterfactual Fairness

بخش دوم: پرسش‌های مفهومی و کاربردی

برای بیشتر پرسش‌های این بخش، یک پاسخ درست یگانه وجود ندارد. نمره بر اساس دقت، سفت‌گیری منطقی و صداقت استدلال و نیز به‌کارگیری درست ابزار صوری بخش اول داده می‌شود. صرف گفتن اینکه «این یک trade-off است» پاسخ به حساب نمی‌آید؛ در پاسخ‌هایتان موضع بگیرد و از آن با استدلال دفاع کنید.

پرسش ۴: (مسئله جانشین/برچسب در سلامت) (۸ نمره)

سناریو: یک الگوریتم پرکاربرد، بیماران را برای یک برنامه مراقبتی فشرده و پرهزینه شناسایی می‌کند. سازنده ابزار برای رتبه‌بندی «نیاز»، مدل را طوری آموزش می‌دهد که هزینه درمانی آینده هر بیمار را پیش‌بینی کند، با این فرض که بیماران پرهزینه‌تر، بیمارترند. پس از استقرار، یک ممیزی نشان می‌دهد که در سطح بیماری برابر، تعداد بسیار کمتری از بیماران گروهی که از نظر تاریخی به حاشیه رانده شده، در برنامه ثبت‌نام می‌شوند. (برگرفته از مقاله [“Dissecting Racial Bias in an Algorithm Used to Manage the Health of Populations.”](#) (Obermeyer et al., 2019;))

الف نوع یا انواع سوگیری‌های دخیل در این مسئله را از رده‌بندی‌های استاندارد (تاریخی، بازنمایی، اندازه‌گیری/برچسب، تجمیع، ارزیابی، استقرار) نام ببرید و دقیقاً مشخص کنید که انتخاب متغیر هدف کجا آسیب را وارد می‌کند.

ب آیا «انصاف از طریق ناآگاهی» (یعنی حذف ویژگی حساس از مجموعه ویژگی‌ها) جلوی این پیامد را می‌گرفت؟ با دقت استدلال کنید که چرا چنین است یا نه.

ج کدام معیار مشاهده‌ای بخش اول (و سنجیده‌شده در برابر کدام متغیر هدف) این مسئله را آشکار می‌کرد؟ به‌طور مشخص توضیح دهید چرا ممیزی در برابر هدف جانشین (هزینه)، مسئله را پنهان نگه می‌داشت.

د یک راه‌حل ملموس و قابل‌پیاده‌سازی پیشنهاد دهید و محدودیت‌های آن و هر ریسک انصاف تازه‌ای را که ایجاد می‌کند بیان کنید.

پرسش ۵: (انتخاب معیار، تحت قید عدم امکان (اعطای وام)) (۶ نمره)

سناریو: یک بانک برای کنترل تأیید وام از مدلی برای ریسک پیش فرض اعتباری استفاده می‌کند. نهادهای ناظر روی تأثیر نامتناسب (disparate impact؛ قاعده چهارپنجم یا ۸۰٪) حساس‌اند؛ بانک می‌خواهد سود موردانتظارش را بیشینه کند؛ و متقاضیان بیش از هر چیز به این موضوع اهمیت می‌دهند که به اشتباه وامی را که می‌توانستند بازپرداخت کنند، از دست بدهند.

الف آسیب‌های تخصیصی را شناسایی کنید و برای هر یک از سه ذی‌نفع، عدم‌تقارن میان خطای مثبت کاذب و منفی کاذب را مشخص کنید. هزینه هر نوع خطا را چه کسی می‌پردازد؟

ب طبق پرسش ۲ نمی‌توانید برابری جمعیتی، برابری شانس‌ها و واسنجی را هم‌زمان داشته باشید. یک معیار اصلی انتخاب کنید و آن را برای این بافت توجیه کنید. دفاع شما باید اولاً عدم‌تقارن‌های بند (الف) را در نظر بگیرد و ثانیاً به‌صراحت بگوید با این انتخاب چه چیزی را قربانی می‌کنید.

پرسش ۶: (داوری مناقشه COMPAS (در پیوند با بخش اول)) (۸ نمره)

الف به‌طور خلاصه، ادعای اصلی تجربی ProPublica و پاسخ اصلی Northpointe در مورد مناقشه‌ای که در سال ۲۰۱۶ رخ داده و پیش‌تر در این تمرین به آن اشاره کردیم، بیان کنید.

ب با استفاده از همان اتحادی که خودتان در پرسش ۲ به‌دست آوردید، توضیح دهید چرا هر دو طرف در یک معنای دقیق و فنی هم‌زمان حق داشتند. در پاسخ به کمیت‌های مشخص (FPR, PPV, FNR و نرخ‌های پایه) و خود اتحاد ارجاع دهید.

ج **موضع بگیرید.** به‌طور خاص در موضوع بازداشت پیش از محاکمه و عدالت کیفری، کدام معیار انصاف باید در اولویت باشد و چرا؟ استدلال شما باید هزینه اخلاقی یک مثبت اشتباه (FP) را در برابر یک منفی اشتباه (FN) و در همین موضوع را بسنجد (چه کسی و چقدر آسیب می‌بیند) و فراتر از تکرار این نکته برود که «بده‌بستان یا Trade-off ای در کار است».

د آیا موجه‌ترین نتیجه می‌تواند این باشد که «این سامانه اصلاً نباید مستقر شود»؟ استدلال کنید که موافق یا مخالف این گزاره هستید یا خبر و دست‌کم یک ملاحظه بیرون از چارچوب معیارهای انصاف

را هم در نظر بگیرید (مثلاً امکان اعتراض، فرایند دادرسی منصفانه، اعتبارسنجی «تکرار جرم»، یا حلقه بازخورد با پلیس).

پرسش ۷: (فراتر از انصاف حاشیه‌ای: زیرگروه‌ها و زمان) (۶ نمره)

الف دستکاری زیرگروهی انصاف (Kearns et al., 2018; Fairness Gerrymandering). با یک مثال عددی ملموس و ساختگی نشان دهید که چگونه یک طبقه‌بند^۷ می‌تواند معیار انصاف را روی هر ویژگی حساس به تنهایی برآورده کند (مثلاً روی جنسیت، و جداگانه روی نژاد) اما روی یک زیرگروه تقاطعی (یعنی تقاطع دو ویژگی) آن را به شدت نقض کند. توضیح دهید چرا حساب کردن گروه‌های حاشیه‌ای به تنهایی کافی نیست و چرا نمی‌توان به سادگی گفت «همه زیرگروه‌ها را حساب می‌کنیم».

ب اثر تعلل و به تاخیر انداختن (Liu et al., 2018; “Delayed Impact of Fair Machine Learning”). یک سازوکار پویای محتمل را شرح دهید که در آن اعمال برابری جمعیتی در اعطای وام می‌تواند در طول زمان به همان گروهی که قرار بوده به آن کمک کند، آسیب برساند. سازوکار بازخورد را دقیق مشخص کنید و بگویید این موضوع درباره ارزیابی یک مداخله منصفانه، آن هم صرفاً به شکل ایستا و در لحظه اجرا، چه چیزی به ما می‌گوید.

^۷ classifier

بخش سوم: پیاده‌سازی و تحلیل تجربی

مجموعه داده: مجموعه داده COMPAS از ProPublica (تکرار جرم در دو سال؛ پرونده [compas-scores-two-years.csv](#)).

- ویژگی هدف: تکرار جرم در دو سال (two_year_recid).
- ویژگی حساس یا محافظت شده: race (برای مرحله تقاطعی، sex را هم به کار ببرید).
- پالایش استاندارد ProPublica را روی داده‌ها اعمال کنید (مثلاً نگه داشتن رکوردهایی که days_b_screening_arrest آن‌ها در بازه $[-30, 30]$ است).
- این مجموعه داده عمده‌ای است که نتایج تجربی شما مستقیماً به اتحاد پرسش ۲ و داوری پرسش ۶ گره بخورد.
- ابزارها: numpy, pandas, scikit-learn, matplotlib. می‌توانید از Fairlearn یا AIF360 فقط برای الگوریتم‌های تعدیل استفاده کنید. همه سنج‌های انصاف و کالیبراسیون باید توسط خودتان از پایه پیاده‌سازی شوند.
- می‌توانید جهت بررسی درستی پیاده‌سازی انجام شده خود، پیاده‌سازی‌های خود را در برابر یک کتابخانه آماده (مثلاً Fairlearn MetricFrame) با یک رواداری مشخص، اعتبارسنجی کنید. اما توجه کنید که این فراوانی کتابخانه به هیچ عنوان نمی‌تواند که جایگزین پیاده‌سازی شما شود.

مرحله ۰ — بازتولیدپذیری (۲ نمره)

همه مقادیر اولیه تصادفی (seed) را ثابت کنید و نسخه کتابخانه‌ها و پالایش دقیقی را که اعمال کرده‌اید ثبت کنید. از یک تقسیم آموزش/آزمون لایه‌ای (stratified) استفاده کنید و نسبتش را بگویید. یک اسکریپت یا نوت‌بوک قابل اجرا تحویل دهید که همه اعداد و نمودارهای گزارش را بازتولید کند.

مرحله ۱ — ممیزی سوگیری (۶ نمره)

الف نرخ پایه $P(Y = 1)$ را برای هر گروه نژادی جداگانه گزارش کنید.

ب توزیع امتیاز دهکی COMPAS را به تفکیک گروه گزارش کنید (به صورت نمودار).

ج مشخص کنید که race تا چه حد به طور غیرمستقیم در سایر ویژگی‌ها رمزگذاری شده است: یک تحلیل هم‌بستگی^۸ (یا آزمون‌هایی که در آن خود ویژگی حساس را از روی بقیه ویژگی‌ها پیش‌بینی می‌کنید) ارائه دهید تا قوی‌ترین پراکسی‌ها را بیابید؛ و این را به روشنی به پرسش ۳- (ب) ربط دهید.

د در دو بند تفسیر کنید که این ممیزی^۹ برای هر مدلی که در ادامه بر پایه این داده‌ها ساخته می‌شود، چه معنایی دارد.

مرحله ۲ — مدل پایه و سنج‌های دست‌ساز (۸ نمره)

الف یک دسته‌بند پایه (مثلاً رگرسیون لجستیک و/یا گرادین بوستینگ) برای پیش‌بینی تکرار جرم دوساله آموزش دهید و دقت و ROC-AUC کلی را گزارش کنید. توجه کنید که در این مرحله هیچگونه دخالت و تغییری در جهت انصاف نباید اعمال کرده باشید.

ب سنج‌های زیر را خودتان و از پایه (بدون استفاده از کتابخانه انصاف) پیاده‌سازی کنید و هم به تفکیک گروه و هم به صورت شکاف بین گروهی گزارش دهید: اختلاف برابری جمعیتی، اختلاف فرصت برابر (شکاف TPR)، اختلاف برابری نرخ مثبت کاذب (شکاف FPR)، و PPV به تفکیک گروه. کد پیاده‌سازی این سنج‌ها را به طور کامل باید ارائه دهید.

ج یک جدول نتایج تمیز و یکپارچه ارائه دهید (همه سنج‌ها در برابر همه گروه‌ها).

مرحله ۳ — آزمون «انصاف از طریق ناآگاهی» (۴ نمره)

این بار مدل را بدون ویژگی حساس (با حذف آن از مجموعه ویژگی‌ها) دوباره آموزش دهید و کل سنج‌ها را دوباره حساب کنید. آیا اختلاف‌ها از بین می‌روند، کوچک می‌شوند یا باقی می‌مانند؟ رفتاری را که می‌بینید توضیح دهید و آن را به روشنی به استدلال پرسش ۳- (ب) و همان کج‌فهمی‌ای که در بخش‌های اول و دوم مطرح شد، ربط دهید.

مرحله ۴ — تعدیل و مقایسه (۱۰ نمره)

دست‌کم دو روش تعدیل از دو دسته متفاوت به کار ببرید؛ برای نمونه: پیش‌پردازش (بازوزن‌دهی [Kamiran-Calders](#) یا حذف‌کننده تأثیر نامتناسب)؛ پس‌پردازش (برابری شانس‌ها / بهینه‌سازی آستانه،

^۹ audit

^۸ correlation

[Hardt et al.](#)؛ **حین پردازش** (کاهش گرادین نامایی [Agarwal et al.](#) یا حذف سوگیری خصمانه^{۱۰}). برای هر روش، کل سنجها و دقت را دوباره حساب کنید و در یک جدول مقایسه‌ای بیاورید؛ بنویسید کدام اختلاف‌ها بهتر شدند، کدام بدتر شدند و چه هزینه‌ای از نظر دقت پرداختید. به‌صراحت بگویید هر روش کدام مفهوم انصاف را هدف گرفته است.

مرحله ۵ — عدم‌امکان تجربی و مرز بده‌بستان (۶ نمره)

الف با جاروب^{۱۱} آستانه تصمیم و/یا شدت تعدیل، برای دست‌کم یک سنج انصاف یک منحنی **بده‌بستان دقت در برابر انصاف** (مرز پارتو) بسازید و رسم کنید.

ب نتیجه عدم‌امکان را به صورت تجربی بازتولید کنید: نشان دهید که نمی‌توان هم‌زمان شکاف برابری جمعیتی، شکاف فرصت برابر و برابری PPV را صفر کرد. سپس به‌صورت کمی بررسی کنید که مقادیر اندازه‌گیری‌شده PPV، FNR، FPR و نرخ‌های پایه از همان اتحادی که در پرسش ۲ به‌دست آوردید پیروی می‌کنند (باقی‌مانده را گزارش کنید). و بگویید آیا داده‌ها همان‌طور که نظریه پیش‌بینی می‌کند رفتار می‌کنند یا نه.

مرحله ۶ — ممیزی تقاطعی (۴ نمره)

بهترین مدل خود را روی زیرگروه‌های تقاطعی ($\text{race} \times \text{sex}$) دوباره ممیزی کنید. بررسی کنید آیا انصاف حاشیه‌ای برقرار بوده ولی انصاف تقاطعی نقض شده است یا نه (یعنی همان دستکاری زیرگروهی، مطابق پرسش ۷-الف)). جدول زیرگروه‌ها را گزارش و تفسیر کنید.

^{۱۱} sweeping

^{۱۰} Adversarial debiasing

سوال دوم: حریم خصوصی در یادگیری ماشین و یادگیری فدرال

در بسیاری از کاربردهای یادگیری ماشین، داده‌های آموزشی شامل اطلاعات حساس کاربران هستند؛ از سوابق پزشکی و مالی گرفته تا رفتارهای روزمره در سامانه‌های هوشمند. در نگاه اول، ممکن است تصور شود که اگر داده خام مستقیماً منتشر نشود یا در یادگیری فدرال روی دستگاه کاربران باقی بماند، حریم خصوصی افراد حفظ شده است. با این حال، پژوهش‌های متعدد نشان داده‌اند که خود مدل، خروجی‌های آن یا حتی به‌روزرسانی‌های ارسالی در فرآیند آموزش می‌توانند اطلاعاتی درباره داده‌های آموزشی افشا کنند. در این تمرین ابتدا مفاهیم پایه حریم خصوصی را مرور می‌کنیم. سپس با مطالعه مقاله‌ای درباره Differential Privacy در یادگیری فدرال، بررسی می‌کنیم که این رویکرد چگونه میان حفظ حریم خصوصی، مقاومت در برابر حملات و دقت مدل تعادل برقرار می‌کند. در نهایت، یک حمله استنتاج عضویت را به‌صورت ساده‌شده پیاده‌سازی و تحلیل خواهیم کرد.

بخش اول: سوالات توضیحی

یک سامانه مدیریت انرژی شهری را در نظر بگیرید که داده‌های مصرف روزانه برق ۱۰۰۰ خانوار را جمع‌آوری می‌کند. مصرف روزانه هر خانوار پس از پیش‌پردازش در بازه (۰, ۱۰۰) کیلووات‌ساعت قرار دارد. همچنین برای هر خانوار مشخص شده است که در کدام یک از ۶ الگوی مصرف زیر قرار می‌گیرد:

$[A_1, A_2, A_3, A_4, A_5, A_6]$ هر خانوار می‌تواند حداکثر در دو الگوی مصرف ظاهر شود. در این سؤال، دو دیتاست همسایه را دو دیتاستی در نظر بگیرید که فقط در اطلاعات یک خانوار با یکدیگر تفاوت دارند؛ یعنی مقدار مصرف و الگوهای مصرف یک خانوار می‌تواند تغییر کند.

سه درخواست زیر تعریف شده‌اند:

$$[q_1(D) = \text{میانگین مصرف برق خانوارها}]$$

$$[q_2(D) = \text{کل مصرف برق خانوارها}]$$

$$[q_3(D) = \text{بردار تعداد خانوارها در ۶ الگوی مصرف}]$$

زیربخش اول: (حساسیت و مکانیزم لاپلاس) (۲ نمره)

الف) حساسیت (ℓ_1) هر یک از درخواست‌های (q_1), (q_2) و (q_3) را محاسبه کنید.

ب) اگر برای هر سه درخواست به صورت جداگانه از مکانیزم لاپلاس با ($\epsilon = 0.2$) استفاده شود، پارامتر (b) را برای هر درخواست محاسبه کنید.

زیربخش دوم: (انتشار خصوصی داده‌ها و REPORT NOISY MAX) (۳ نمره)

فرض کنید میانگین واقعی مصرف برابر (۳۷.۵) کیلووات‌ساعت و کل مصرف واقعی برابر (37500) کیلووات‌ساعت است. سامانه برای میانگین، نویز (1.8+) و برای کل مصرف، نویز (920-) را از توزیع‌های لاپلاس متناظر با زیربخش قبل نمونه‌برداری کرده است.

الف) چرا ناسازگاری میان خروجی‌های خصوصی می‌تواند در انتشار چند query مرتبط رخ دهد؟ یک راه‌حل مبتنی بر post-processing برای رفع این ناسازگاری پیشنهاد دهید.

اکنون فرض کنید سامانه نمی‌خواهد کل بردار (q_3) را منتشر کند، بلکه فقط می‌خواهد پرتکرارترین الگوی مصرف را اعلام کند. تعداد واقعی خانوارها در شش الگو به صورت زیر است:

$$[310, 295, 180, 160, 90, 75]$$

ب) اگر کل بردار شمارش‌ها با مکانیزم لاپلاس و $(\epsilon = 0.4)$ منتشر شود، مقدار (b) را محاسبه کنید.

ج) اگر به جای انتشار کل بردار، از الگوریتم Report Noisy Max استفاده شود، scale نویز لاپلاس برای هر شمارش چقدر است؟ سپس با فرض نویزهای زیر، خروجی الگوریتم را تعیین کنید:

$[-4, +18, +9, -6, +21, +2]$ آیا الگوی انتخاب‌شده با الگوی واقعاً پرتکرار یکسان است؟ این نتیجه را از دید trade-off میان privacy و utility تحلیل کنید.

زیربخش سوم: (تخصیص بودجه حریم خصوصی و ترکیب مکانیزم‌ها) (۴ نمره)

سامانه تصمیم دارد در پایان هر روز سه خروجی زیر را منتشر کند:

۱. میانگین مصرف برق با مکانیزم لاپلاس؛

۲. نام پرتکرارترین الگوی مصرف با Report Noisy Max؛

۳. بردار شمارش ۶ الگوی مصرف با مکانیزم گاوسی.

بودجه کل روزانه حریم خصوصی برابر $(\epsilon = 0.6)$ است و برای مکانیزم گاوسی مقدار $(\delta = 10^{-5})$ در نظر گرفته می‌شود.

الف) یک تقسیم‌بندی پیشنهادی برای بودجه (ϵ) میان سه خروجی ارائه دهید، به‌طوری‌که دقت میانگین مصرف از دو خروجی دیگر مهم‌تر در نظر گرفته شود. توضیح دهید چرا این تقسیم‌بندی منطقی است.

ب) با استفاده از تقسیم‌بندی پیشنهادی خود، مقدار (b) را برای مکانیزم لاپلاس مربوط به میانگین مصرف محاسبه کنید.

ج) برای بردار شمارش ۶ الگوی مصرف، حساسیت (ℓ_2) را محاسبه کنید. سپس با استفاده از رابطه زیر، مقدار حداقلی (σ) را برای مکانیزم گاوسی به دست آورید:

$$[\sigma \geq \frac{c\Delta_2(f)}{\epsilon}, \quad c^2 > 2 \ln\left(\frac{1.25}{\delta}\right)]$$

د) اگر همین سه گزارش به مدت ۷ روز متوالی منتشر شوند، طبق قانون composition، کران ساده privacy loss کل هفته چقدر می‌شود؟ اگر بخواهیم privacy loss کل هفته همچنان حداکثر (۰.۶) باقی بماند، چه تغییری باید در بودجه روزانه ایجاد شود و این تغییر چه اثری روی utility خواهد داشت؟

بخش دوم : سوالات مفهومی

مقاله [Local and Central Differential Privacy for Robustness](#) را به دقت مطالعه کرده و با توجه به آن به سؤالات زیر پاسخ دهید.

زیربخش اول: (حریم خصوصی، استحکام و یادگیری فدرال) (۳ نمره)

الف) آیا می‌توان یادگیری فدرال^{۱۲} را به‌طور ذاتی و بدون مکانیزم‌های تکمیلی، یک فناوری حفظ حریم خصوصی^{۱۳} کامل دانست؟ با استناد به مقدمه مقاله، تفاوت میان بهبود عملی حریم خصوصی^{۱۴} و تضمین رسمی حریم خصوصی^{۱۵} را در بستر فدرال توضیح دهید.

ب) بر اساس چارچوب مفهومی مقاله، توضیح دهید چرا دستیابی به حریم خصوصی^{۱۶} استحکام/پایداری^{۱۷} دو هدف متمایز هستند که لزوماً یکدیگر را تضمین نمی‌کنند

ج) فرض کنید دو سامانه با دقت نهایی^{۱۸} یکسان داریم:

• سامانه A: آموزش متمرکز با جمع‌آوری داده‌های خام در سرور.

• سامانه B: آموزش فدرال با ارسال به‌روزرسانی‌های مدل به سرور

بدون در نظر گرفتن هیچ مکانیزم دفاعی اضافه مانند Differential Privacy آیا می‌توان ادعا کرد سامانه B/نژاماً حریم خصوصی بیشتری فراهم می‌کند؟

زیربخش دوم: (حملات حریم خصوصی و مسموم‌سازی در یادگیری فدرال) (۶ نمره)

الف) با مطالعه دقیق مقاله و مفاهیم مطرح‌شده در اسلایدهای درس، حملاتی که تا الان یاد گرفته‌اید را بیان کنید. سپس، با استفاده از دانش خود از مباحث کلاس، یک چارچوب دسته‌بندی منطقی برای این حملات ارائه دهید، هر حمله را در دسته مربوطه قرار داده و دلیل انتخاب خود را به‌طور مختصر توجیه کنید. (۲ نمره)

Privacy^{۱۶}
Robustness^{۱۷}
Utility^{۱۸}

Federated Learning^{۱۲}
Privacy-Preserving^{۱۳}
Practical Privacy Improvements^{۱۴}
Formal Privacy Guarantee^{۱۵}

ب) در بستر یادگیری فدرال، مهاجمان معمولاً به داده‌های خام سایر شرکت‌کنندگان دسترسی ندارند. با این وجود، مقاله بین مسموم‌سازی داده¹⁹ و مسموم‌سازی مدل²⁰ تمایز قائل شده و دومی را کانون اصلی ارزیابی خود قرار می‌دهد. با استدلال مفهومی توضیح دهید چرا در این پارادایم توزیع‌شده، مسموم‌سازی مدل نه‌تنها امکان‌پذیر است، بلکه نسبت به مسموم‌سازی داده، تهدیدی عملی‌تر و خطرناک‌تر محسوب می‌شود؟ (۲نمره)

ج) مقاله به حمله Isolating Gradient Ascent به عنوان یکی از قدرتمندترین حملات استنتاج عضویت²¹ فعال²² از سمت سرور²³ اشاره می‌کند (۲نمره)

- مکانیزم دقیق این حمله را شرح دهید: سرور چگونه با دستکاری مدل تجمیع‌شده و ایزوله کردن یک کلاینت هدف، فرآیند بهینه‌سازی محلی آن کلاینت را تحت تأثیر قرار می‌دهد؟
- از دیدگاه ریاضی و رفتار تابع زیان²⁴، توضیح دهید چرا الگوریتم SGD (یا نسخه‌های آن) هنگام مواجهه با یک نمونه عضو در مقایسه با یک نمونه غیرعضو، واکنش گرادیانی متفاوت و قابل تشخیصی از خود نشان می‌دهد که مهاجم می‌تواند آن را رصد کند؟

زیربخش سوم: (مکانیزم‌های دفاعی و مبادله حریم خصوصی) - استحکام -

سودمندی (۷ نمره)

مقاله دو مکانیزم دفاعی را که در ادبیات پیشین مانند کار (Sun et al) برای مقابله با مسموم‌سازی مدل پیشنهاد شده‌اند، به عنوان خط پایه²⁵ معرفی می‌کند هر یک را به‌طور مختصر توضیح دهید. (۲نمره)

مقاله دو رویکرد اصلی دیفرانسیلی را در بستر فدرال پیاده‌سازی و ارزیابی می‌کند:

Local Differential Privacy (LDP) و Central Differential Privacy (CDP) این دو رویکرد را

توضیح دهید (۲نمره)؟

Global Attacker²³
Loss Function²⁴
Baseline²⁵

Data Poisoning¹⁹
Model Poisoning / Backdoor²⁰
Membership Inference Attack²¹
Active²²

تفاوت بنیادین در سطح حفاظت²⁶ این دو مکانیزم چیست؟ (انمره)

چرا مکانیزم CDP که از نظر تئوری می‌تواند در برابر آن دسته از حملات ناکارآمد LDP دفاع کند، در عمل منجر به شکست در همگرایی یا افت شدید دقت وظیفه اصلی²⁷ می‌شود؟ (انمره)

فرض کنید شما معمار سیستم یک کنسرسیوم پزشکی فدرال هستید که تنها شامل $N = 10$ بیمارستان بزرگ است (تعداد شرکت‌کنندگان کم) و داده‌ها به شدت حساس هستند. بر اساس یافته‌های تجربی مقاله در مورد مبادله بین حریم خصوصی، استحکام و سودمندی آیا استفاده از LDP را توصیه می‌کنید یا CDP؟ پاسخ خود را با ذکر دو دلیل مستدل از نتایج مقاله توجیه کنید؟ (انمره)

این تمرین بر اساس مقاله [Subject Membership Inference Attacks in Federated Learning](#) طراحی شده است و هدف آن این است که شما ریسک‌های حریم خصوصی را در محیط‌های یادگیری فدرال میان‌سازمانی^{۲۸} به صورت عملی بررسی کنید.

پیش از آغاز بخش عملی، لازم است مقاله را به دقت مطالعه کنید و مفاهیم کلیدی آن، از جمله Subject Membership، حمله جعبه خاکستری^{۲۹} و نحوه توزیع داده‌ها میان کاربرها را به خوبی درک کنید. در این مرحله، باید متوجه شوید که چگونه ساختار داده‌ها و نحوه مشارکت افراد در فرآیند آموزش فدرال می‌تواند باعث افشای اطلاعات حساس شود..

هدف اصلی این تمرین آن است که شما با مفاهیم یادگیری فدرال، حملات استنتاج عضویت فرد^{۳۰} و سازوکارهای دفاعی مبتنی بر حریم خصوصی تفاضلی به صورت عملی آشنا شوید. ابتدا یک سامانه یادگیری فدرال مبتنی بر الگوریتم میانگین‌گیری فدرال را روی داده‌های FEMNIST پیاده‌سازی می‌کنید. سپس ریسک حریم خصوصی مدل را با اجرای حمله زیان در طول دوره‌های آموزش^{۳۱} در سطح فرد ارزیابی خواهید کرد. در ادامه، اثر دفاع‌های مختلف مبتنی بر حریم خصوصی تفاضلی^{۳۲} را بر موفقیت حمله و دقت مدل بررسی می‌کنید.

در طول تمرین، انتظار می‌رود نتایج به دست آمده را تحلیل کنید و رابطه میان ساختار داده، توزیع افراد، فرآیند آموزش فدرال، سطح حریم خصوصی و کیفیت مدل را بررسی کنید. این تمرین به شما کمک می‌کند تا علاوه بر پیاده‌سازی عملی، مفاهیم بنیادی حریم خصوصی در یادگیری ماشین و موازنه میان حفاظت از داده‌ها و دقت مدل را بهتر درک کنید.

^{۳۱} Loss-Across-Rounds
^{۳۲} Differential Privacy

^{۲۸} Cross-Silo Federated Learning
^{۲۹} Grey-Box Attack
^{۳۰} Subject Membership Inference Attacks

زیربخش اول: (آماده سازی داده ها) (۵ نمره)

در این بخش، هدف ایجاد محیط آزمایش مورد نیاز برای حملات Membership Inference در یادگیری فدرال است.

بارگذاری و بررسی اولیه داده

دیتاست FEMNIST را بارگذاری کرده و ویژگی های اصلی آن را گزارش کنید. حداقل موارد زیر باید ارائه شوند:

- تعداد کل نمونه ها
 - تعداد کلاس ها
 - تعداد نویسندگان (Subjects)
 - تعداد نمونه های متعلق به هر نویسنده
- همچنین چند نمونه تصویر به همراه برچسب واقعی آن ها نمایش دهید و ماهیت داده را به صورت مختصر توضیح دهید.

تعریف مجموعه های Member و Non-Member

در سطح Subject، نویسندگان موجود در دیتاست را به صورت تصادفی به دو مجموعه مجزا تقسیم کنید:

- Member Subjects
- Non-Member Subjects.

در گزارش خود تعداد نویسندگان و تعداد تصاویر موجود در هر مجموعه را ارائه کنید.

پس از تشکیل این دو مجموعه، هیچ داده ای از Subject های Non-Member نباید در فرآیند آموزش فدرال مورد استفاده قرار گیرد.

ایجاد ساختار Cross-Silo

فرض کنید سیستم فدرال شامل ۸ سازمان مستقل^{۳۳} است.

داده های مربوط به نویسندگان عضو مجموعه Member را بین این ۸ سازمان توزیع کنید. نحوه توزیع باید به گونه ای باشد که داده های یک نویسنده بتوانند در یک یا چند سازمان قرار گیرند.

^{۳۳} Silo

در گزارش خود توضیح دهید که روش پارتیشن‌بندی شما چه ویژگی‌هایی ایجاد می‌کند و چرا این ساختار برای مطالعه حملات Membership Inference مناسب است.

تحلیل آماری و مصورسازی

حداقل تحلیل‌های زیر باید ارائه شوند:

- تعداد تصاویر موجود در هر سازمان
 - سهم هر سازمان از کل داده‌های آموزشی
 - توزیع تعداد سازمان‌هایی که هر Subject در آن حضور دارد
 - درصد Subject‌هایی که تنها در یک سازمان حضور دارند
 - درصد Subject‌هایی که داده‌هایشان بین چند سازمان توزیع شده است
- تمام نتایج باید با نمودارهای مناسب نمایش داده شوند.

بحث و نتیجه‌گیری

بر اساس نمودارها و آمارهای استخراج‌شده، درباره موارد زیر بحث کنید:

- آیا توزیع داده‌ها بین سازمان‌ها متوازن است؟
- آیا Subject‌ها عمدتاً در یک Silo حضور دارند یا بین چند سازمان پراکنده شده‌اند؟
- این نوع پارتیشن‌بندی چه تأثیری بر دشواری حملات Membership Inference می‌تواند داشته باشد؟

زیربخش دوم: (آموزش مدل فدرال) (۷ نمره)

بخش ۲: آموزش مدل فدرال

با استفاده از داده‌های آماده‌شده در بخش قبل، یک سیستم یادگیری فدرال مبتنی بر FedAvg پیاده‌سازی کنید و یک مدل جهانی برای طبقه‌بندی داده‌های FEMNIST آموزش دهید. نحوه طراحی مدل، تنظیم ابرپارامترها، تعداد دورهای ارتباطی، تعداد epoch‌های محلی و سایر جزئیات پیاده‌سازی بر عهده شماست و باید در گزارش مستند شوند.

در فرآیند آموزش، تنها داده‌های مربوط به Subject های Member مجاز به مشارکت در یادگیری هستند و داده‌های Non-Member باید کاملاً خارج از فرآیند آموزش باقی بمانند. عملکرد مدل را در طول آموزش پایش کرده و نمودار تغییرات دقت و تابع هزینه را بر حسب تعداد Round ها ارائه کنید. همچنین توضیح دهید آیا مدل به همگرایی رسیده است یا خیر و چه عواملی در کیفیت همگرایی مشاهده شده نقش داشته‌اند. و دقت نهایی مدل جهانی روی مجموعه آزمون را گزارش کنید.

در گزارش خود، مکانیزم تعامل بین Server و سازمان ها را تشریح کنید و توضیح دهید به روزرسانی‌های محلی چگونه در سرور تجمیع می‌شوند. همچنین تحلیل کنید که اگر مرز بین داده‌های Member و Non-Member به درستی رعایت نشود، این موضوع چه اثری بر اعتبار ارزیابی‌های حریم خصوصی در ادامه پروژه خواهد داشت.

زیربخش سوم: (ارزیابی حملات MEMBERSHIP INFERENCE) (۸ نمره)

۳. ارزیابی حملات استنتاج عضویت و تحلیل نتایج

در این بخش، حمله عضویت در سطح Subject معرفی شده در مقاله *Subject Membership Inference* را *Attacks in Federated Learning* پیاده‌سازی و ارزیابی کنید. تنها پیاده‌سازی حمله **Loss-Across-Rounds** مورد نیاز است. انتخاب جزئیات پیاده‌سازی، نحوه تعیین آستانه تصمیم‌گیری و سایر تنظیمات بر عهده شماست و باید در گزارش مستند شوند.

علاوه بر آن، یک حمله پایه در سطح Record طراحی و پیاده‌سازی کنید. برای این بخش می‌توانید با الهام از مفاهیم و روش‌های مطرح شده در مقاله مربوط به Membership Inference در یادگیری فدرال که در تمرین‌های پیشین مطالعه کرده‌اید، یک راهکار مناسب پیشنهاد و پیاده‌سازی نمایید. انتخاب معیار تصمیم‌گیری و تابع تجمیع باید توسط خود شما انجام شود.

برای هر دو حمله:

- معیارهای Accuracy، Precision، Recall و F1-Score را گزارش کنید.
- تغییرات عملکرد حمله در طول Round های آموزش فدرال را بررسی نمایید.
- حداقل یک نمودار از عملکرد حملات در طول فرآیند آموزش ارائه کنید.
- نتایج حمله Subject-Level و Record-Level DP را با یکدیگر مقایسه نمایید.

در گزارش خود تحلیل کنید که:

۱. کدام حمله موفق تر بوده است و چرا؟

۲. نتایج مشاهده شده چه برداشتی درباره ریسک حریم خصوصی در سطح Subject و سطح Record ارائه می کنند؟

زیربخش چهارم: (دفاع مبتنی بر DIFFERENTIAL PRIVACY) (۱۰ نمره)

در این بخش، مکانیزم های دفاعی مبتنی بر Differential Privacy را روی مدل فدرال بخش ۲ اعمال کنید و اثر آن ها را روی حملات بخش ۳ بررسی کنید.

۴.۱. دفاع پایه (DP-SGD / Record-Level DP)

- می توانید از کتابخانه های استاندارد استفاده کنید، اما باید منطق دفاع، سطح حفاظت و نحوه اعمال نویز و clipping را توضیح دهید.
- بودجه هدف $\epsilon \approx 4.0$ ، $\delta = 10^{-5}$
- پس از آموزش، حملات Subject-Level و Record-Level را دوباره اجرا کرده و ϵ ، σ ، clipping norm، دقت مدل و معیارهای F1 را گزارش کنید.

۴.۲. دفاع پیشرفته (Subject-Level DP)

- دفاع پیشرفته ذکر شده در مقاله را پیاده کنید
- بودجه هدف $\epsilon \approx 4.0$ ، $\delta = 10^{-5}$
- حمله بخش ۳ را دوباره اجرا و همان معیارها را گزارش کنید.
- در گزارش توضیح دهید که این دفاع چگونه تفاوت اثر Subject و نمونه های منفرد را مدیریت می کند.

۴.۳. آزمایش حساسیت

سه آزمایش با تغییر یک پارامتر انجام دهید و ϵ نهایی را گزارش کنید:

۱. دو برابر کردن σ

۲. نصف کردن clipping norm

۳. دو برابر کردن تعداد Round ها

تحلیل کنید که تغییرات مشاهده شده با انتظار نظری شما سازگار است و چرا.

۴.۴. مقایسه و تحلیل Trade-off

- نتایج دفاع‌ها را در یک جدول خلاصه کنید: ϵ ، نویز، clipping norm، دقت مدل، و معیارهای موفقیت حملات.
- تحلیل کنید کدام دفاع بهترین تعادل بین حفظ حریم خصوصی Subjects و دقت مدل ایجاد می‌کند و چرا دفاع Subject-Level برای مسئله Subject Membership مناسب‌تر است.

پیوست الف — اظهارنامه استفاده از هوش مصنوعی (تکمیل شده تحویل دهید)

اعلام می‌کنم که اثبات‌ها، استدلال‌های مفهومی، تفسیرها و متن گزارش این تمرین، کار خودم است. از کمک هوش مصنوعی فقط در همان حدی استفاده کرده‌ام که سیاست صفحه نخست اجازه می‌دهد؛ جزئیاتش هم در جدول زیر آمده است. لازم به ذکر هست که این جدول را بسته به نیاز خود و تا جایی که نیاز هست می‌توانید که گسترش دهید.

ابزار	برای چه کاری استفاده شد	پرسش / مرحله و شرح استفاده

نام و نام خانوادگی: _____ امضا / تاریخ: _____

نکات تحویل

- مهلت ارسال این تمرین تا پایان روز "جمعه ۱۹ تیر ماه" خواهد بود. توجه کنید که این تمرین مهلت استفاده از گریس ندارد و تاریخ ذکر شده آخرین فرصت ارسال تمرین خواهد بود.
- این زمان قابل تمدید نیست و در صورت نیاز می‌توانید از گریس استفاده کنید.
- در نظر داشته باشید که حداکثر مهلت آپلود تمرین در سامانه تا ۷ روز پس مهلت تحویل است و پس از آن سامانه بسته خواهد شد.
- در صورت وجود سوال و یا ابهام می‌توانید از طریق ایمیل با موضوع TAI_HW4 با تدریس‌یاران آموزشی در ارتباط باشید. توجه کنید که حتماً ایمیل سرتدریس‌یار نیز CC شود.
- حداکثر تعداد صفحات گزارش برای سوال اول: بدون محدودیت
- حداکثر تعداد صفحات گزارش برای سوال دوم: بدون محدودیت
- لطفاً گزارش، فایل کدها و سایر ضمائم مورد نیاز را با فرمت زیر در سامانه بارگذاری نمائید:
HW4_[Lastname]_[StudentNumber].zip

- تدریس‌یاران تمرین:

۱. پرهام زیلوچیان مقدم

parham_zm@hotmail.com

۱. محمد امین نصرتی

manosratics@gmail.com

- سرتدریس‌یار:

محمد گرجی

gorji.mohammad@ut.ac.ir

با آرزوی سلامتی و موفقیت روزافزون